GBC051 – Computação Científica e Otimização

Prof. Renato Pimentel

2021/1

Sumário

1 Análise de erros **9**
1.1 Introdução . . . 9
1.2 Representação numérica . . . 9
1.3 Sistemas numéricos . . . 11
1.4 Representação de números reais . . . 13
1.5 Erros . . . 15
1.6 Erros nas operações de ponto flutuante . . . 18
1.7 Efeitos numéricos . . . 21
1.8 Exercícios . . . 23

2 Zeros reais de funções reais **25**
2.1 Introdução . . . 25
2.2 Fases da determinação dos zeros . . . 26
2.3 Método da bisseção . . . 31
2.4 Método da falsa posição (*regula falsi*) . . . 35
2.5 Método de Newton-Raphson . . . 40
2.6 Método da secante . . . 43
2.7 Exercícios . . . 47

3 Interpolação polinomial **48**
3.1 Introdução . . . 48
3.2 Fórmula de Lagrange . . . 51
3.3 Forma de Newton . . . 54
3.4 Erro na interpolação . . . 58
3.5 Exercícios . . . 62

4 Teoria da aproximação: método dos mínimos quadrados **64**
4.1 Introdução . . . 64
4.2 Método dos mínimos quadrados (caso discreto) . . . 65
4.3 Caso linear . . . 68
4.4 Caso não linear . . . 69
4.5 Exercícios . . . 73

5 Sistemas lineares **76**
5.1 Introdução . . . 76
5.2 Classificação de sistemas lineares . . . 77
5.3 Método da eliminação de Gauss . . . 82
5.4 Fatoração LU . . . 89
5.5 Erros e refinamento da solução . . . 100
5.6 Métodos iterativos . . . 102
5.7 Método de Gauss-Jacobi . . . 104
5.8 Método de Gauss-Seidel . . . 106
5.9 Exercícios . . . 111

6 Sistemas não lineares **115**
6.1 Introdução . . . 115
6.2 Método de Newton . . . 119
6.3 Método de Newton modificado . . . 122
6.4 Métodos quase-Newton . . . 124
6.5 Exercícios . . . 127

7 Integração numérica **129**
7.1 Introdução . . . 129
7.2 Regra dos trapézios . . . 130
7.3 Regra 1/3 de Simpson . . . 136
7.4 Regra 3/8 de Simpson . . . 139
7.5 Teorema geral do erro . . . 140
7.6 Exercícios . . . 141

8 Resolução numérica de equações diferenciais ordinárias **143**
8.1 Introdução . . . 143
8.2 Problemas de valor inicial . . . 145
8.3 Método de Euler . . . 146
8.4 Métodos de série de Taylor . . . 148
8.5 Métodos de Runge-Kutta . . . 154
8.6 Exercícios . . . 160

9 Resolução numérica de equações diferenciais parciais **162**
9.1 Introdução . . . 162
9.2 Classificação das equações . . . 162
9.3 Diferenças finitas . . . 165
9.4 Equações parabólicas . . . 167
9.5 Exercícios . . . 174

10 Introdução à otimização: programação linear e modelagem **176**
10.1 Definição e Origens da Pesquisa Operacional . . . 176
10.2 Fases de Resolução de Problemas . . . 176
10.3 Principais Áreas da Pesquisa Operacional . . . 179
10.4 Programação linear . . . 180

10.5 Problemas clássicos 184
10.6 Exercícios 188

11 Solução gráfica **191**
11.1 Introdução 191
11.2 Solução ótima, curva de nível e vetor gradiente 193
11.3 Casos especiais 200
11.4 Exercícios 202

12 O método simplex **204**
12.1 Introdução 204
12.2 Forma padrão 205
12.3 Algoritmo simplex 206
12.4 Situações especiais 210
12.5 Exercícios 222

13 Dual e sua relação com o primal **226**
13.1 Regras para construção do dual 228
13.2 Exercícios 232

Apresentação

Objetivos e Ementa

Objetivos

- Explicar os fundamentos dos principais métodos numéricos e empregá-los, com senso critico, à solução de problemas de Computação fazendo uso de uma linguagem científica para programá-los.
- Apresentar uma introdução à otimização, com ênfase em programação linear.

Ementa do curso

- Análise de erros.
- Resolução de equações não-lineares.
- Teoria da aproximação: interpolação e aproximação de curvas.
- Resolução de sistemas lineares.
- Resolução de sistemas não-lineares.
- Integração numérica.
- Resolução de equações diferenciais ordinárias.
- Resolução de equações diferenciais parciais.
- Introdução à otimização.
- Programação linear.
- Métodos baseados no gradiente.

Bibliografia

Bibliografia básica

- CUNHA, F. G. M.; CASTRO, J. K. S. Cálculo Numérico. Fortaleza: UAB/IFCE, 2010. Disponível em https://educapes.capes.gov.br/bitstream/capes/430185/2/Calculo%20Numerico.pdf
- FRANCO, N. B. *Cálculo numérico*. São Paulo: Pearson Prentice Hall, 2006.
- MARINS, Fernando Augusto Silva. *Introdução à pesquisa operacional*. São Paulo: Cultura Acadêmica, 2011. Disponível *gratuitamente* (mediante cadastro) em: http://www.culturaacademica.com.br/catalogo/introducao-a-pesquisa-operacional.
- RUGGIERO, M. A. G.; LOPES, V. L. R. *Cálculo numérico: aspectos teóricos e computacionais*. 2ª. ed. São Paulo: Makron Books. 1996.

Bibliografia complementar

- ASANO, C. H.; COLLI, E. *Cálculo Numérico – Fundamentos e Aplicações*. São Paulo, 2009. Disponível em https://www.ime.usp.br/~asano/LivroNumerico/LivroNumerico.pdf
- GOLDBARG, Marco César; LUNA, Henrique Pacca. *Otimização combinatória e programação linear: Modelos e algoritmos*. Rio de Janeiro: Campus, 2000.
- JACQUES, I.; JUDD, C. *Numerical Analysis*. Dordrecht: Springer, 1987. Disponível em https://link-springer-com.ez34.periodicos.capes.gov.br/book/10.1007%2F978-94-009-3157-2 (acesso Cafe-CAPES)
- JUSTO, A. R. J. et al. *Cálculo Numérico: Um Livro Colaborativo. Versão Python*. [s.l.], 2020. Disponível em https://www.ufrgs.br/reamat/CalculoNumerico/livro-py/livro-py.pdf
- MARTINS, M. V. Vídeo aulas de Pesquisa Operacional. Disponível em: https://www.youtube.com/watch?v=_wJUzN8MoMg&list=PLVWA23fHCKz-XEuEVhTTzc15GiT2-KLTX
- MÜLLGES, G. E.; UHLIG, F. *Numerical Algorithms with C*. Berlin: Springer, 1996. Disponível em https://link-springer-com.ez34.periodicos.capes.gov.br/book/10.1007%2F978-3-642-61074-5 (acesso Cafe-CAPES)
- SOUZA, M. J. F. *Introdução à Otimização: Programação Linear*. Ouro Preto [s. d.] Disponível em http://www.decom.ufop.br/prof/marcone/Disciplinas/Otimizacao/IntroducaoOtimizacao.pdf

Conteúdo previsto

1. Análise de erros em sistemas numéricos
2. Resolução de equações não-lineares:
   - Método bisseção
   - Método falsa posição (regula falsi)
   - Método Newton-Raphson
3. Interpolação e Aproximação Polinomial:
   - Formas de Lagrange e Newton
   - Método dos Mínimos Quadrados
4. Sistemas Lineares:
   - Métodos diretos
   - Método iterativos

5. Sistemas Não-Lineares
6. Integração numérica:
    - Fórmulas de Newton-Cotes
7. Equações diferenciais ordinárias:
    - Euler
    - Runge-Kutta
8. Equações diferenciais parciais:
    - Diferenças finitas
9. Otimização:
    - Resolução gráfica
    - Simplex
    - Métodos baseados no gradiente

Avaliação: aproveitamento e frequência

- 3 provas teóricas:
    - 22/12/2021 ($P1$) – 30 pontos
    - 23/02/2022 ($P2$) – 40 pontos
    - 30/03/2022 ($P3$) – 30 pontos
- Pontos extras individuais (PE): Ao longo das aulas síncronas, professor fará em pontos aleatórios do curso perguntas sobre o conteúdo sendo ministrado. Ganhará 1 ponto extra a primeira pessoa que responder *corretamente* o que se pede.
- Pontos assíncronos (PA): Atividades para entrega, ou eventuais itens de questionários assíncronos de presença valendo pontos (15 pontos no total).
- Nota final (aproveitamento):

$$NF = \min\left(P1 + P2 + P3 + PE + PA,\, 100\right)$$

Importante

Será exigido o uso de webcam/câmera durante a realização das provas, que mostre o aluno e sua folha de resolução ou pelo menos esta última. O aluno que se comprometer a seguir a disciplina fica desde já ciente de que as reuniões das avaliações serão realizadas no Teams e que *o aluno que não cumprir tal exigência terá a nota de sua prova anulada sem direito à avaliação fora de época posterior.*

Frequência

- O aluno que tiver frequência inferior a 75% é reprovado por faltas.
- no caso das reuniões síncronas, o controle será feito pelo MS Teams, que registra detalhadamente os horários de entrada e saída dos alunos das reuniões. Para que o aluno tenha presença nas mesmas será necessária sua presença em pelo menos 50% do tempo de cada uma das duas horas-aula, sendo que no primeiro horário não poderá haver atraso superior a mais de 10 minutos do horário previsto para o início da mesma.
- No caso das aulas assíncronas, será lançado durante o horário de divulgação das mesmas um questionário contendo em geral pelo menos 2 questões, em geral de múltipla escolha (sem pontuação, com exceção dos eventuais pontos assíncronos) sobre o conteúdo gravado, que o aluno deverá responder até o prazo limite coincidente com o início da aula síncrona subsequente (em geral às terças-feiras 08:50). Terão presença nas respectivas datas os alunos que responderem aos questionários correspondentes.
- *Falta em dia de prova*: o aluno somente terá direito a fazer prova em nova data caso apresente justificativa no setor de graduação e/ou coordenação do curso, que encaminhará comunicação por escrito ao professor quando julgá-la plausível.
- É responsabilidade do aluno controlar sua frequência, de modo a evitar reprovação por falta.

Logística

Aulas

- Segunda-feira: 08:50 até 10:30 (assíncrona – vídeoaula YouTube + questionário MS Teams)
- Terça-feira: 08:50 até 10:30 (síncrona – MS Teams)
  Equipe **GBC051 – 2021/1**, código de inscrição *his199y*
- Quarta-feira: 10:40 até 12:20 (síncrona – MS Teams)

Atividades extra-classe

- Listas de exercícios (fixação)
- Questionários assíncronos (MS Teams)

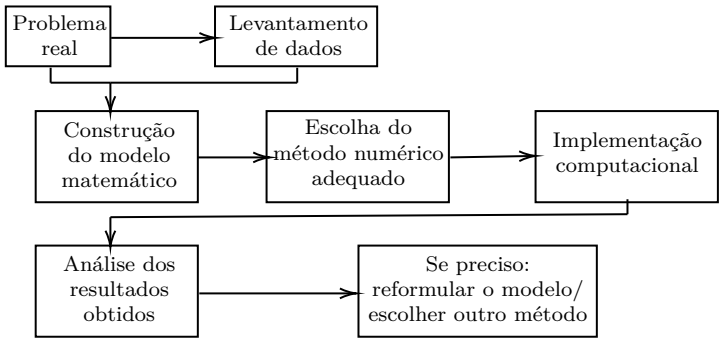
Atendimento e outras informações

- Professor: Renato Pimentel
  - Página: http://www.facom.ufu.br/∼rpimentel
  - E-mail: rpimentel @ ufu . br
  - Sala 1B139
- Atendimento (agendar previamente através de e-mail):
  - Terças-feiras, 19:50 até 20:40, MS Teams
  - Quintas-feiras, 19:00 até 20:40, MS Teams
- Material da disciplina:
  - http://www.facom.ufu.br/∼rpimentel > Ensino > 2021/1 > GBC051 – Computação Científica e Otimização

1 Análise de erros

1.1 Introdução

- Neste curso, estudamos diversos *métodos numéricos* para resolução de problemas;
- Uma das etapas da resolução de problemas é a *análise* dos resultados obtidos.



Método numérico

- Método adotado na resolução de um problema físico, mediante a execução de uma sequência finita de operações aritméticas.
- *Consequência*: Obtenção de um resultado aproximado, cuja diferença do resultado esperado (exato) denomina-se *erro*.

Influenciam nos resultados:

1. a *precisão* dos dados de entrada;
2. a *forma* como estes dados são *representados* em máquina;
3. as *operações numéricas*.

Nosso interesse: itens 2 e 3.
(item 1: imprecisão inerente dos dados de entrada)

1.2 Representação numérica

Exemplo (RUGGIERO; LOPES, 1996): efetuar os dois seguintes somatórios, em uma calculadora e um computador:

$$S = \sum_{i=1}^{30000} x_i, \qquad \text{para } x_i = 0,5 \text{ e } x_i = 0,11$$

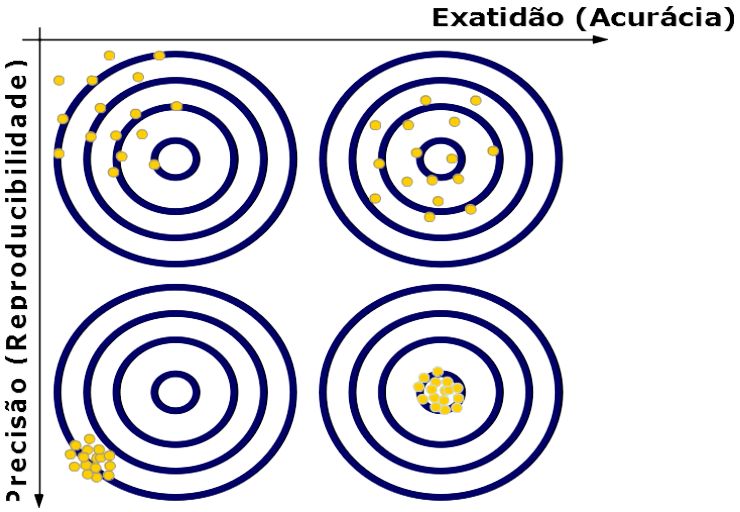
1. Para $x_i = 0,5$:
   - Na calculadora: $S = 15000$
   - No computador: $S = 15000$
2. Para $x_i = 0,11$:
   - Na calculadora: $S = 3300$
   - No computador: $S = 3299,99691$

- A diferença no resultado para $x_i = 0,11$ está relacionada a *representação* dos valores na máquina utilizada.
- Dois fatores:
  1. *Base* escolhida – exs.: sistema decimal (base 10); sistema binário (base 2);
  2. Número máximo de *dígitos* usados.
- Por exemplo, números irracionais (ex.: π) não podem ser representados por um *número finito* de dígitos decimais: 3,14; 3,1415 e 3,141592654 ilustram diferentes aproximações para π. Qual a melhor?
- Um número racional pode ter uma representação finita numa base e não-finita em outras.
- Interação usuário-computador: dados de entrada fornecidos pelo sistema decimal (usuário), e convertida para o sistema binário (máquina).

Acurácia e precisão

Observando a execução dos métodos numéricos, podemos ainda definir os seguintes conceitos:

- *Acurácia* (ou *exatidão*): quão próximo um valor computado/mensurado se encontra do valor real (verdadeiro);
- *Precisão* (ou *reproducibilidade*): Quão próximo um valor computado/ mensurado se encontra de valores previamente computados/mensurados.
- Por outro lado:
  - *Inacurácia* (ou *inexatidão*): desvio sistemático do valor real;
  - *Imprecisão* (ou *incerteza*): magnitude do espalhamento dos valores.



1.3 Sistemas numéricos

- Computador: *sistema binário* (manipula e armazena informação na forma de números binários).
  - Além disso: representação *sempre finita* (memória; tamanho da representação)
- *Sistema decimal*: é o sistema mais importante do ponto de vista prático, sendo usado por nós, seres humanos, em nosso dia a dia.
- Sistema decimal: *Base* (quantidade de algarismos) = 10
  - Algarismos: 0, 1, 2, 3, 4, 5, 6, 7, 8, 9
  - Exemplo:

$$\begin{aligned} 6903 = (6903)_{10} &= 6 \times 10^3 + 9 \times 10^2 + 0 \times 10^1 + 3 \times 10^0 \\ &= 6000 + 900 + 0 + 3 \end{aligned}$$

- Sistema binário: *Base 2*
  - Algarismos: 0, 1
  - Exemplo:

$$\begin{aligned} (101)_2 &= 1 \times 2^2 + 0 \times 2^1 + 1 \times 2^0 \\ &= 4 + 0 + 1 = 5_{10} \end{aligned}$$

(esta é a conversão de binário para decimal!)

- No caso geral, um número inteiro pode ser representado numa base qualquer β sob a forma

$$(a_j\, a_{j-1} \ldots a_2\, a_1\, a_0)_\beta, \quad 0 \leq a_k < \beta\,.$$

  a_k, $k = 0, 1, \ldots, j$, são os algarismos que definem a base.

- A forma vista do lado direito dos exemplos anteriores é a forma *polinomial*:

$$a_j\beta^j + a_{j-1}\beta^{j-1} + \cdots + a_2\beta^2 + a_1\beta + a_0\,.$$

- Conversão de decimal para binário:
  - Divide-se o número pela base binária, 2, obtendo-se um resultado e um resto.
  - Divide-se o resultado por 2, e assim sucessivamente, até que o resultado seja 0.
  - A representação correspondente é dada pelos restos das divisões, de trás para frente.

Conversão de decimal para binário:

- Exemplo: $(19)_{10}$

	$\div 2 =$	Resto	
19	9	1	
9	4	1	↑
4	2	0	
2	1	0	
1	*0*	1	

  Logo, $(19)_{10} = (10011)_2$

Números fracionários

- Parte fracionária (menor que 0):
  - *Multiplica-se* por 2, ao invés de dividir;
  - Multiplica-se a parte fracionária do produto por 2, num processo iterativo, até que esta parte se torne 0;
  - A representação é dada pelos algarismos da parte inteira dos produtos, na sequência em que foram obtidos.

- Exemplo (decimal menor que 1): $(0,625)_{10}$

	$\times 2 =$	Parte inteira
,625	*1*,25	1
,25	*0*,50	0
,50	*1*,*00*	1

↓

Logo, $(0,625)_{10} = (0,101)_2$

- Exemplo (decimal menor que 1): $(0,69)_{10}$

	$\times 2 =$	Parte inteira
,69	*1*,38	1
,38	*0*,76	0
,76	*1*,52	1
,52	*1*,04	1
,04	*0*,08	0
,08	*0*,16	0
⋮	⋮	⋮

↓

Logo, $(0,69)_{10} = (0,101100\ldots)_2$

- Exemplo: $(19,69)_{10}$. Converte-se a parte inteira e a fracionária separadamente!

  $(19,69)_{10} = (10011,101100\ldots)_2$

Exercício

Converta o número $(0,1)_{10}$ para o sistema binário.

1.4 Representação de números reais

- Inteiros: *ponto fixo*: 1o. bit à direita sempre associado à potência 0 da base usada, 2o. à potência 1, etc.
- Números reais: *ponto flutuante*! Parte dos bits é utilizada para representar um *expoente* ⇒ permite maior faixa de resultados.

Aritmética de ponto flutuante

- Um número real num sistema de ponto flutuante de base β é representado sob a forma

$$\pm(.d_1\ d_2\ \ldots\ d_t) \times \beta^e,$$

onde:

- $m \leq e \leq M$ é o *expoente*. Tanto e quanto m e M são valores inteiros.
- t é o número de dígitos da *mantissa* $d_1\ d_2\ \ldots\ d_t$, e $0 \leq d_j < \beta$, para $j = 2, \ldots, t$.
  - $0 < d_1 < \beta$, ou seja, o primeiro dígito d_1 não pode ser nulo (*sistema normalizado*).

Exemplo (RUGGIERO; LOPES, 1996): considere uma máquina que opera no sistema:

$$\beta = 10, \qquad t = 3, \qquad e \in [-5, 5]\,.$$

- Qual o menor e o maior número, em valores absolutos[1], que podem ser representados?
  - Menor número:

$$a = 0,100 \times 10^{-5} = 10^{-6} = 0,000001$$

  - Maior número:

$$b = 0,999 \times 10^{5} = 99900$$

Underflow, overflow

Para um sistema de ponto flutuante cujos menores e maiores valores absolutos representáveis são a e b, respectivamente, podemos definir o conjunto

$$G = \{x \in \mathbb{R};\ a \leq |x| \leq b\}\,.$$

Três situações são possíveis:

1. $|x| \in G$.

   No exemplo visto, $x = 235,89$ pertence a G, pois $x = 0,23589 \times 10^3$ (note que o número pode ser representado no sistema visto, pois $10^{-6} < |x| < 99900$). Uma forma *aproximada* será considerada, entretanto, pois apenas 3 dígitos definem o sistema;

2. $|x| < a$: No exemplo visto, $x = 0,345 \times 10^{-7}$ não pode ser representado pois o expoente é *menor* que -5. (*ocorrência de underflow*);

3. $|x| > b$: No exemplo visto, $x = 0,875 \times 10^{9}$ não pode ser representado pois o expoente é *maior* que -5. (*ocorrência de overflow*).

[1] a menos de sinal

Zero em ponto flutuante

- O *zero* é representado no sistema de ponto flutuante da seguinte forma:
  - mantissa *nula* – todos os t dígitos 0, exceção à regra $d_1 \neq 0$;
  - expoente m (menor possível).
- Considerando-se ainda o sistema decimal exemplificado, onde $t = 3$ e $e \in [-5, 5]$, temos

$$0 = +(,000) \times 10^{-5}$$

- Com a mantissa nula, a escolha do expoente poderia ser arbitrária, mas emprega-se o menor para evitar problemas como ex. adição de zero a outro número.

Por exemplo (RUGGIERO; LOPES, 1996), numa máquina que opera na base 10 com quatro dígitos na mantissa:

$$0,0000 \times 10^0 + 0,3134 \times 10^{-2} = 0,3100 \times 10^{-2}$$

(perda de dois dígitos na precisão do valor).

Subconjunto finito de valores reais

- Ex.: considere um sistema binário – $\beta = 2$ – de aritmética de ponto flutuante com $m = -1$, $M = 2$ e $t = 3$ dígitos para a mantissa.

Quantos números reais podem ser representados *exatamente* neste sistema?

- sinal: + (positivo) ou − (negativo);
- mantissa: $(0,100)$, $0,101$, $0,110$ ou $0,111$;
- expoentes: 2^{-1}, 2^0, 2^1 ou 2^2;
- portanto, 33 números reais podem ser representados neste sistema: 32 não-nulos ($2 \times 4 \times 4$), e o zero.

1.5 Erros

Erros absolutos e relativos

Considere o cálculo da área de uma circunferência de raio 100, adotando-se diferentes aproximações para π:

1. 31400
2. 31416
3. 31415,92654

Qual o resultado obtido com o *menor* erro?

Erro absoluto

O *erro absoluto* é dado pela diferença entre o valor exato de um valor x e seu valor aproximado $\bar{x}$:

$$E_a(x) = x - \bar{x}$$

- Em geral, apenas $\bar{x}$ é conhecido – impossível obter $E_a(x)$.
  - Neste caso, a alternativa é escolher um limitante superior ou estimativa para $|E_a|$.
  - Ex., sabendo que $\pi \in (3,14,\ 3,15)$, qualquer valor de π neste intervalo levará a
    $$|E_a(\pi)| = |\pi - \bar{\pi}| < 0,01\,.$$
- O erro absoluto é limitado em relação à *precisão* dos valores aproximados.

  Considere os exemplos:
  - $\bar{x} = 2112,9$, com $|E_a(x)| < 0,01$ – i.e., $x \in (2112,8,\ 2113)$.
  - $\bar{y} = 5,3$, com $|E_a(y)| < 0,01$ – i.e., $y \in (5,2,\ 5,4)$.
- Os limitantes superiores são iguais: a precisão é a mesma?

É preciso comparar a *ordem de grandeza* de x e y.

Erro relativo

O *erro relativo* entre um valor x e sua aproximação $\bar{x}$ é definido como a razão entre o erro absoluto e esta aproximação:

$$E_r(x) = \frac{E_a(x)}{\bar{x}} = \frac{x - \bar{x}}{\bar{x}}$$

- Do caso visto anteriormente:
  - $|E_r(x)| = \dfrac{|E_a(x)|}{|\bar{x}|} < \dfrac{0,1}{2112,9} \approx 4,7 \times 10^{-5}$
  - $|E_r(y)| = \dfrac{|E_a(y)|}{|\bar{y}|} < \dfrac{0,1}{5,3} \approx 0,02$
- Logo, x é representado com maior precisão que y.

Arredondamento e truncamento

Não se pode representar qualquer número real num sistema de aritmética de ponto flutuante:

- O número t de dígitos significativos é limitado.
- Logo, uma *aproximação* deve ser feita.

– O ideal é que um valor x seja representado no sistema por um valor aproximado $\bar{x}$ tal que $|x - \bar{x}|$ seja o menor possível.

Ex. (FRANCO, 2006): Considere o quociente 15/7. A divisão resulta em $x = 2,142857\cdots = +0,2142857\cdots \times 10^1$

- Se $t = 4$ há 2 alternativas:
  1. $\bar{x}_1 = 0,2142 \times 10^1$
  2. $\bar{x}_2 = 0,2143 \times 10^1$
- Como $|x - \bar{x}_1| = 0,000857$ e $|x - \bar{x}_2| = 0,000143$, $\bar{x}_2$ é a melhor alternativa de aproximação.
- $\bar{x}_1$ é a aproximação por *truncamento* de x:

  no truncamento, representa-se o número com t dígitos, ignorando completamente os restantes.
- $\bar{x}_2$ é a aproximação por *arredondamento* de x: o impacto dos dígitos remanescentes é considerado.

Formalizando

Seja x um número real a ser representado num sistema de t dígitos.
Após a normalização:

$$\begin{aligned} x &= \pm(0, d_1 d_2 \dots d_t d_{t+1} d_{t+2} \dots) \times 10^e \\ &= \pm[\underbrace{(0, d_1 d_2 \dots d_t)}_{f} \times 10^e + \underbrace{(0, d_{t+1} d_{t+2} \dots)}_{g} \times 10^{e-t}], \end{aligned}$$

onde $0,1 \leq f < 1$ e $0 \leq g < 1$.

1. *Truncamento*: $\bar{x} = \pm(0, d_1 d_2 \dots d_t) \times 10^e = \pm f \times 10^e$.
   - $|E_a(x)| = |x - \bar{x}| = g \times 10^{e-t} < 10^{e-t}$;
   - $|E_r(x)| = \dfrac{|x - \bar{x}|}{|\bar{x}|} = \dfrac{g \times 10^{e-t}}{f \times 10^e} < \dfrac{10^{e-t}}{0,1 \times 10^e} = \dfrac{10^{e-t}}{10^{e-1}} = 10^{-t+1}$.
2. *Arredondamento*:

$$\bar{x} = \begin{cases} \pm f \times 10^e, & g < \frac{1}{2}, \\ \pm(f \times 10^e + 10^{e-t}) & g \geq \frac{1}{2}. \end{cases}$$

   - Se $g < 1/2$:
     – $|E_a(x)| = |x - \bar{x}| = g \times 10^{e-t} < \dfrac{1}{2} \times 10^{e-t}$;

  - $|E_r(x)| = \dfrac{|x - \bar{x}|}{|\bar{x}|} = \dfrac{g \times 10^{e-t}}{f \times 10^e} < \dfrac{0,5 \times 10^{e-t}}{0,1 \times 10^e} = \dfrac{1}{2} \times 10^{-t+1}$.

- Se $g \geq 1/2$:
  - $|E_a(x)| = |x - \bar{x}| = | \pm (f \times 10^e + g \times 10^{e-t} - f \times 10^e - 10^{e-t})|$.
    Uma vez que $1/2 \leq g < 1$, $|E_a(x)| = |g - 1| \times 10^{e-t} \leq \dfrac{1}{2} \times 10^{e-t}$
  - $|E_r(x)| = \dfrac{|E_a(x)|}{|\bar{x}|} \leq \dfrac{1/2 \times 10^{e-t}}{f \times 10^e + 10^{e-t}} < \dfrac{1/2 \times 10^{e-t}}{f \times 10^e} <$
    $\dfrac{0,5 \times 10^{e-t}}{0,1 \times 10^e} = \dfrac{1}{2} \times 10^{-t+1}$

- Logo, em todo caso, $|E_a(x)| \leq \frac{1}{2} \times 10^{e-t}$ e $|E_r(x)| < \frac{1}{2} \times 10^{-t+1}$.

Apesar de gerar erros menores, nem sempre o arredondamento é empregado: *tempo de execução.*

No exemplo visto:

$$x = +0,2142857 \cdots \times 10^1 \qquad = 0,2142 \times 10^1 + 0,857 \cdots \times 10^{-3}$$

- *Truncamento:* $\bar{x}_1 = 0,2142 \times 10^1$.

  $|E_a(x)| = 0,000857 \cdots = 0,857 \ldots 10^{-3} < 10^{-3}$

- *Arredondamento:* $\bar{x}_2 = 0,2143 \times 10^1$ (pois $g = 0,857 \cdots \geq 0,5$).

  $|E_a(x)| = 0,000143 = 0,143 \cdots \times 10^{-3} < 0,5 \times 10^{-3}$.

Exercício

- Qual o erro relativo para o exemplo?
- Como seria o truncamento e o arredondamento no sistema binário? Quais os erros absolutos e relativos em cada caso?

1.6 Erros nas operações de ponto flutuante

- *Exemplo 1 (adição):* Dados:

  $$x = 0,937 \times 10^4, \qquad y = 0,1272 \times 10^2,$$

  com base $\beta = 10$ e $t = 4$, obter $x + y$.

  - *Alinham-se* os pontos decimais dos 2 valores.

– Mantissa do valor de *menor expoente* é deslocada para direita. Assim:

$$x = 0,937 \times 10^4, \qquad y = 0,001272 \times 10^4.$$

Logo,

$$x + y = (0,937 + 0,001272) \times 10^4 = 0,938272 \times 10^4$$

– Como $t = 4$, temos $\overline{x+y} = 0,9382 \times 10^4$ por truncamento, ou $\overline{x+y} = 0,9383 \times 10^4$ por arredondamento.

- *Exemplo 2 (multiplicação):* Considere os valores do exemplo 1:

$$x = 0,937 \times 10^4, \qquad y = 0,1272 \times 10^2.$$

– Multiplicando x por y:

$$\begin{aligned} xy &= (0,937 \times 10^4) \times (0,1272 \times 10^2) \\ &= (0,937 \times 0,1272) \times 10^6 \\ &= 0,1191864 \times 10^6 \,. \end{aligned}$$

– Como $t = 4$, temos $\overline{xy} = 0,1191 \times 10^6$ por truncamento, ou $\overline{xy} = 0,1192 \times 10^6$ por arredondamento

Mesmo que os valores envolvidos sejam representados com exatidão no sistema, o resultado de operações com tais valores pode não ser exato.

- O módulo do erro relativo neste caso será limitado superiormente, como visto:
  – $|E_r(OP)| < 10^{-t+1}$ no truncamento;
  – $|E_r(OP)| < 1/2 \times 10^{-t+1}$ no arredondamento;

Se as parcelas da operação a ser feita são aproximadas, por outro lado:

1. Adição: $x + y$

   No caso, $x + y = (\bar{x} + E_a(x)) + (\bar{y} + E_a(y)) = (\bar{x} + \bar{y}) + (E_a(x) + E_a(y))$.

   Logo,

$$\begin{aligned} E_a(x+y) &= E_a(x) + E_a(y) \\ E_r(x+y) &= \frac{E_a(x+y)}{\bar{x}+\bar{y}} \\ &= E_r(x)\left(\frac{\bar{x}}{\bar{x}+\bar{y}}\right) + E_r(y)\left(\frac{\bar{y}}{\bar{x}+\bar{y}}\right) . \end{aligned}$$

2. subtração: $x - y$

   Análogo ao caso anterior:

$$\begin{aligned} E_a(x-y) &= E_a(x) - E_a(y) \\ E_r(x-y) &= \frac{E_a(x) - E_a(y)}{\bar{x} - \bar{y}} \\ &= E_r(x)\left(\frac{\bar{x}}{\bar{x}-\bar{y}}\right) - E_r(y)\left(\frac{\bar{y}}{\bar{x}-\bar{y}}\right). \end{aligned}$$

3. Multiplicação: xy

$$\begin{aligned} xy &= (\bar{x} + E_a(x))(\bar{y} + E_a(y)) \\ &= \bar{x}\bar{y} + \bar{x}E_a(y) + \bar{y}E_a(x) + E_a(x)\,E_a(y) \end{aligned}$$

   Como $E_a(x)\,E_a(y) \approx 0$, tem-se $E_a(xy) \approx \bar{x}E_a(y) + \bar{y}E_a(x)$

   O erro relativo é

$$E_r(xy) \approx \frac{\bar{x}E_a(y) + \bar{y}E_a(x)}{\bar{x}\bar{y}} = \frac{E_a(x)}{\bar{x}} + \frac{E_a(y)}{\bar{y}} = E_r(x) + E_r(y)$$

4. Divisão: x/y

$$x/y = \frac{\bar{x} + E_a(x)}{\bar{y} + E_a(y)} = \frac{\bar{x} + E_a(x)}{\bar{y}}\left(\frac{1}{1 + \dfrac{E_a(y)}{\bar{y}}}\right)$$

   Representando o último termo por série infinita:

$$\frac{1}{1 + \dfrac{E_a(y)}{\bar{y}}} = 1 - \frac{E_a(y)}{\bar{y}} + \left(\frac{E_a(y)}{\bar{y}}\right)^2 - \left(\frac{E_a(y)}{\bar{y}}\right)^3 + \ldots$$

   e desprezando-se os termos com potências maiores que 1, obtém-se

$$\frac{x}{y} = \frac{\bar{x} + E_a(x)}{\bar{y}}\left(\frac{1}{1 + \dfrac{E_a(y)}{\bar{y}}}\right) \approx \frac{\bar{x}}{\bar{y}} + \frac{E_a(x)}{\bar{y}} - \frac{\bar{x}E_a(y)}{\bar{y}^2} - \frac{E_a(x)E_a(y)}{\bar{y}^2}$$

Como o último termo é desprezível, resta

$$\frac{x}{y} \approx \frac{\bar{x}}{\bar{y}} + \frac{E_a(x)}{\bar{y}} - \frac{\bar{x}E_a(y)}{\bar{y}^2}$$

Logo,

$$E_a(x/y) \approx \frac{E_a(x)}{\bar{y}} - \frac{\bar{x}E_a(y)}{\bar{y}^2} = \frac{\bar{y}E_a(x) - \bar{x}E_a(y)}{\bar{y}^2}$$

e

$$E_r(x/y) = \left(\frac{\bar{y}E_a(x) - \bar{x}E_a(y)}{\bar{y}^2}\right)\frac{\bar{y}}{\bar{x}} = \frac{E_a(x)}{\bar{x}} - \frac{E_a(y)}{\bar{y}} = E_r(x) - E_r(y)\,.$$

1.7 Efeitos numéricos

- Além dos erros causados pelas operações aritméticas, outros efeitos numéricos contribuem para o erro:
  - Cancelamento;
  - propagação do erro;
  - instabilidade numérica;
  - mal condicionamento.
- Falaremos dos 2 primeiros.

Cancelamento

Ocorre devido ao efeito da normalização na *subtração* de valores quase iguais.

- Exemplo (FRANCO, 2006): $\sqrt{9876} - \sqrt{9875}$.

  Num sistema de base $\beta = 10$ e com $t = 10$, teríamos:

  $$\sqrt{9876} = 0,9937806599 \times 10^2, \qquad \sqrt{9875} = 0,9937303457 \times 10^2.$$

  Logo, o resultado da subtração é $0,0000503142 \times 10^2$.

- Após a normalização:

  $$\sqrt{9876} - \sqrt{9875} = 0,5031420000 \times 10^{-2}\,.$$

  Os quatro zeros ao final da mantissa não são significativos – quatro casas decimais foram perdidas.
  - Operações posteriores envolvendo este resultado poderão ter sua precisão reduzida.

- Neste caso específico, é possível obter um resultado melhor considerando-se a identidade

$$\sqrt{x} - \sqrt{y} = \frac{x - y}{\sqrt{x} + \sqrt{y}}$$

- Portanto,

$$\sqrt{9876} - \sqrt{9875} = \frac{1}{\sqrt{9876} - \sqrt{9875}} = 0,5031418679 \times 10^{-2}$$

- O processo de cancelamento também pode ocorrer numa *soma*, quando a magnitude dos valores sendo somados é muito diferente.

  - Ex.: num sistema de base $\beta = 10$ com $t = 4$ dígitos, calcular o valor $a + b$, com $a = 1000$ e $b = 0,1$:

$$\begin{array}{r} 0,1000 \times 10^4 \\ +\,0,00001 \times 10^4 \\ \hline 0,10001 \times 10^4 \end{array}$$

  - Como $t = 4$, tanto truncamento quanto arredondamento levam o resultado a $0,1000 \times 10^4 = a$.

Propagação de erros

Fenômeno resultante da perda de acurácia que ocorrem em parcelas intermediárias de uma operação.

- Arredondamentos ou truncamentos ocorrem ao longo do processo, causando problemas como cancelamento;
- Os resultados parciais obtidos com erro são em seguida utilizados em novas operações, levando a novos resultados errôneos.
- Exemplo (FRANCO, 2006): somar $\frac{1}{3}$ dez vezes consecutivas, num sistema decimal com $t = 3$ casas de precisão.
  - $1/3 = 0,3333\ldots$, logo, temos como representação por ponto flutuante o valor (aproximado) $0,333 \times 10^0$.
  - O resultado final é $0,331 \times 10^1$, ou seja, 3,31.
- O resultado obtido tem um erro absoluto da ordem de 10^{-2}.
- Reduzindo o número de operações, reduz-se também o erro, eliminando o efeito da propagação:

– $0,333 \times 10 = 3,33$

- No caso, substituíram-se as somas consecutivas por um produto, produzindo um resultado com erro menor.
- No entanto, nem sempre há uma maneira trivial de resolver tais problemas.

1.8 Exercícios

1. Seja um sistema de aritmética de ponto flutuante de base decimal e quatro dígitos, com expoente $e \in [-99, +99]$. Dados os números:

$$x = 0,7237 \times 10^4, \qquad y = 0,2145 \times 10^{-3}, \qquad z = 0,2585 \times 10^1\,,$$

efetue as seguintes operações e obtenha o erro relativo no resultado, supondo que x, y e z são exatamente representados:

(a) $x + y + z$
(b) $x - y - z$
(c) x/y
(d) $(xy)/z$
(e) $x(y/z)$

2. Considerando-se $a = 0,3491 \times 10^4$ e $b = 0,2345 \times 10^0$, calcule as operações a seguir, processadas em uma máquina com 4 dígitos significativos. Respeite a precedência imposta pelos parênteses.

(a) $(b + a) - a$
(b) $b + (a - a)$

3. Reescreva os números $(27)_{10}$, $(0,138)_{10}$ e $(45,128)_{10}$ no sistema binário.

4. Considere o sistema binário com $t = 8$ dígitos na mantissa e $e \in [-4, +4]$. Dados os números:

$$x_1 = 0,10110011 \times 2^2 \qquad\qquad x_2 = 0,10110010 \times 2^2\,.$$

Qual dos 2 valores mais se aproxima de $(2,8)_{10}$?

5. Considere uma máquina cujo sistema de representação é definido por $\beta = 10$, $t = 4$, $m = -5$ e $M = 5$. Pede-se:

(a) Qual o menor e maior número em módulo representados nessa máquina?
(b) Como será representado o número 73,758 nesta máquina, se for usado truncamento? E arredondamento?
(c) Se $a = 42450$ e $b = 3$ qual o resultado de $a + b$?

Referências

1. FRANCO, N. B. *Cálculo numérico*. São Paulo: Pearson Prentice Hall, 2006.

2. RUGGIERO, M. A. G.; LOPES, V. L. R. *Cálculo numérico: aspectos teóricos e computacionais*. 2ª. ed. São Paulo: Makron Books. 1996.

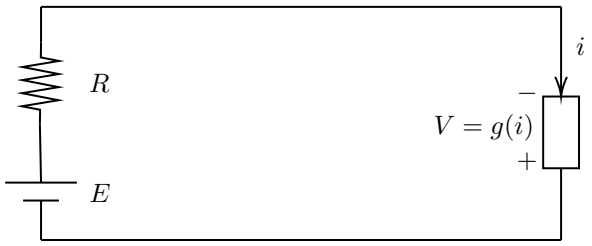
Os materiais de parte desta seção foram gentilmente cedidos por Mauricio C. Escarpinati (FACOM/UFU)

Adaptações: Renato Pimentel, FACOM/UFU

2 Zeros reais de funções reais

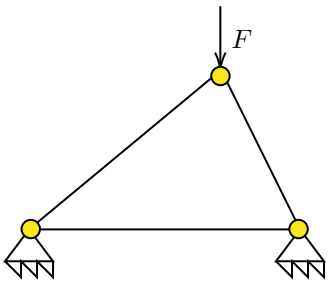
2.1 Introdução

- Em muitas áreas, são frequentes situações em que é necessária a resolução de uma equação do tipo $f(x) = 0$.
- Ex.: circuito elétrico (lei de Kirchhoff):



$$E - Ri - g(i) = 0$$

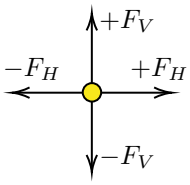
- Ex.: estruturas



Em cada nó:

$\sum F_H = 0$

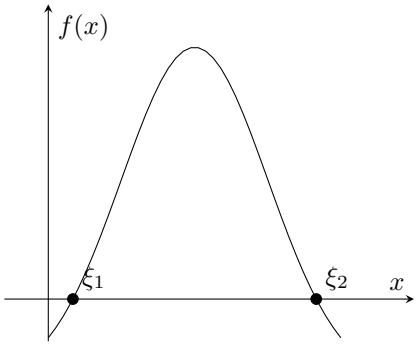
$\sum F_V = 0$



Zero da função

$\xi \in \mathbb{R}$ é um *zero* da função $f(x)$ – ou *raiz* da equação $f(x) = 0$ – se $f(\xi) = 0$.

- Zeros podem ser *reais* ou *complexos*;
- Entretanto, serão tratados aqui os *zeros reais* de $f(x)$.



Zeros reais: representados sobre o *eixo das abscissas*.

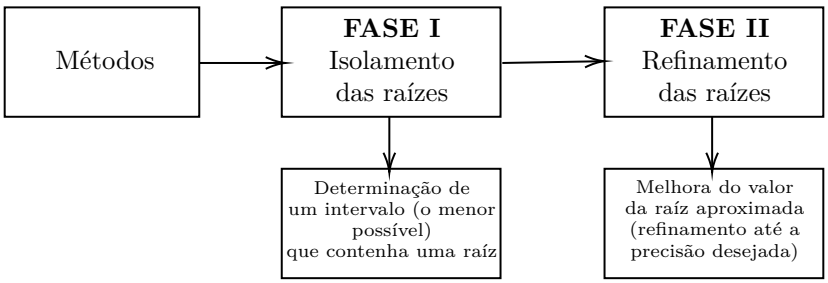
- A solução de funções mais simples, ex.: *equação do segundo grau* $ax^2 + bx + c = 0$, pode ser obtida diretamente – a menos de erros como de representação e causados por operações aritméticas em ponto flutuante:

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

- Polinômios de grau mais alto e funções mais complicadas: praticamente impossível achar os zeros de forma exata.

2.2 Fases da determinação dos zeros

Etapas usuais para determinação dos zeros



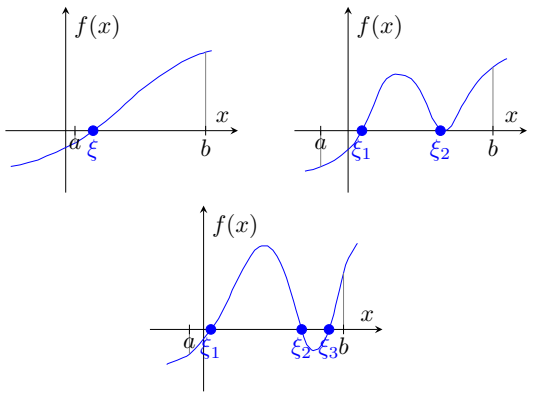
Fase I: Isolamento das raízes

- Realização de uma análise *teórica* e *gráfica* da função de interesse;
- Precisão das análises é relevante para o sucesso da fase posterior.

Teorema de Bolzano (valor intermediário)

Sendo $f(x)$ contínua em um intervalo $[a, b]$, se $f(a) \cdot f(b) < 0$ então *existe pelo menos um* ponto $\xi \in [a, b]$ que é *zero* de $f(x)$.

- Exemplos (RUGGIERO; LOPES, 1996):



- *Exemplo 1*: $f(x) = x^3 - 9x + 3$

x	$-\infty$	-100	-10	-5	-3	-1	0	1	2	3	4	5
$f(x)$	$-$	$-$	$-$	$-$	$+$	$+$	$+$	$-$	$-$	$+$	$+$	$+$

- $f(x)$ é contínua, $\forall x \in \mathbb{R}$.
- Localização das raízes:

$$\xi_1 \in [-5, -3], \qquad \xi_2 \in [0, 1], \qquad \xi_3 \in [2, 3].$$

- Não é preciso olhar para valores no intervalo $(5, \infty)$: polinômio de grau 3 possui no máximo 3 raízes distintas.
- *Exemplo 2*: $f(x) = \sqrt{x} - 5e^{-x}$

x	0	1	2	3	$\ldots$
$f(x)$	$-$	$-$	$+$	$+$	$\ldots$

- $f(x)$ admite ao menos um zero no intervalo $[1, 2]$. O zero é *único*?
- *Análise do sinal* de $f'(x)$:

$$f'(x) = \frac{1}{2\sqrt{x}} + 5e^{-x} > 0, \forall x > 0$$

- Logo, $f(x)$ admite um *único zero*, localizado no intervalo $[1, 2]$.
  - $f(x)$ é *estritamente crescente*

Sob as hipóteses do teorema anterior, se $f'(x)$ é definida e preserva o sinal em (a, b), então tal intervalo contém um único zero de $f(x)$.

Análise gráfica

A *análise gráfica* da função $f(x)$ é fundamental para se obter boas aproximações para os zeros.

Basta seguir uma das alternativas:

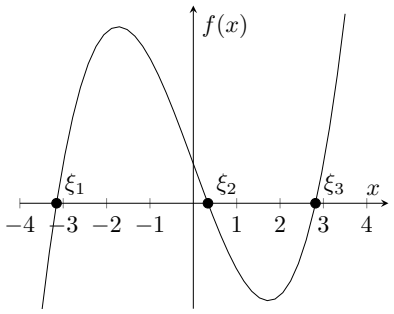
1. esboçar o gráfico de $f(x)$ e localizar as abcissas dos pontos onde a curva intercepta o eixo $\overrightarrow{ox}$;
2. Reescrever $f(x) = 0$ como uma equação equivalente, $g(x) = h(x)$; esboçar os gráficos de $g(x)$ e $h(x)$ no mesmo eixo cartesiano e localizar os pontos onde ambas se interceptam – uma vez que $f(\xi) = 0 \iff g(\xi) = h(\xi)$.
3. Emprego de *softwares* que traçam gráficos de funções.

Processo 1: esboço do gráfico

Retornando ao ex. 1: $f(x) = x^3 - 9x + 3$

- $f'(x) = 3x^2 - 9 = 3(x^2 - 3)$.
- Logo, $f'(x) = 0 \iff x = \pm\sqrt{3}$.

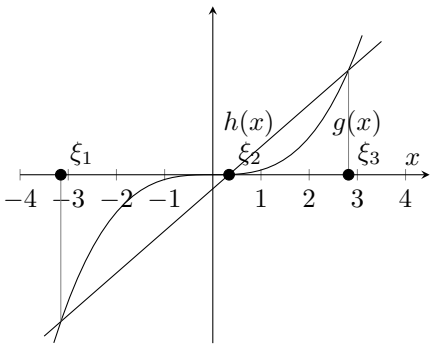
x	$f(x)$
-4	-25
-3	3
$-\sqrt{3}$	13,3923
-1	11
0	3
1	-5
$\sqrt{3}$	$-7,3923$
2	-7
3	3



Processo 2

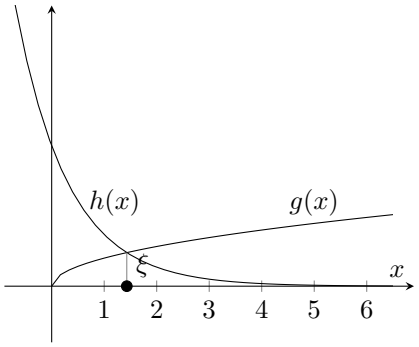
$f(x) = x^3 - 9x + 3$: $g(x) = h(x)$, com

- $g(x) = x^3$;
- $h(x) = 9x - 3$.



No caso do ex. 2 – $f(x) = \sqrt{x} - 5e^{-x}$: Mais conveniente adotar o processo 2.

- $g(x) = \sqrt{x}$;
- $h(x) = 5e^{-x}$.



- $\xi \in [1, 2]$.

Fase II: refinamento

- Aplicação de métodos numéricos destinados ao refinamento de raízes
  - Diferenciação dos métodos: *Modo de refinamento*.
  - Método *iterativo*: Caracterizado por uma série de instruções executáveis sequencialmente, algumas das quais repetidas em ciclos (*iterações*).

Critério de parada

- x_k suficientemente próximo da raiz exata?
- Como verificar tal questionamento?

- Interpretações para raiz aproximada:

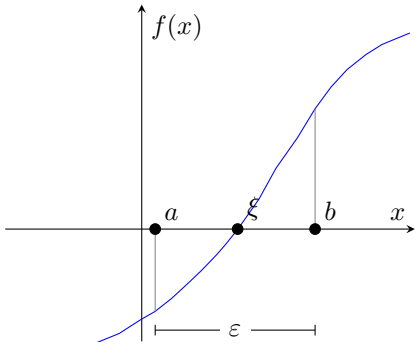
  $\bar{x}$ é raiz aproximada com precisão (ou *tolerância*) ε se:

  - $|\bar{x} - \xi| < \varepsilon$ ou
  - $|f(\bar{x})| < \varepsilon$.

Como proceder se não se conhece ξ?

Redução do intervalo que contém a raiz a cada iteração:

- Obtenção de um intervalo $[a, b]$ tal que $\xi \in [a, b]$ e $b - a = \varepsilon$.
  - Logo, $|x - \xi| < \varepsilon$, $\forall x \in [a, b]$.
  - $\forall x \in [a, b]$ pode ser tomado como $\bar{x}$.



Nem sempre é possível satisfazer ambos os critérios:

- $|\bar{x} - \xi| < \varepsilon$ ou
- $|f(\bar{x})| < \varepsilon$.

Métodos numéricos são desenvolvidos de modo a satisfazer *pelo menos um* dos critérios.

- Dependendo da ordem de grandeza dos valores, é aconselhável usar o *teste do erro relativo:*

$$\bar{x} \approx \xi \text{ se } \frac{|f(\bar{x})|}{L} < \varepsilon,$$

  onde $L = |f(x)|$ para algum x escolhido numa vizinhança de ξ.

- Estipula-se um *número máximo de iterações* nos programas, para evitar o laço infinito.

Métodos iterativos para obtenção de zeros reais de funções

Alguns métodos iterativos para a obtenção de zeros reais de funções:

1. *Bisseção*;
2. *Falsa Posição* (ou *regula falsi*);
3. Falsa Posição Modificado;
4. Ponto Fixo;
5. *Newton-Raphson*;
6. *Secante*.

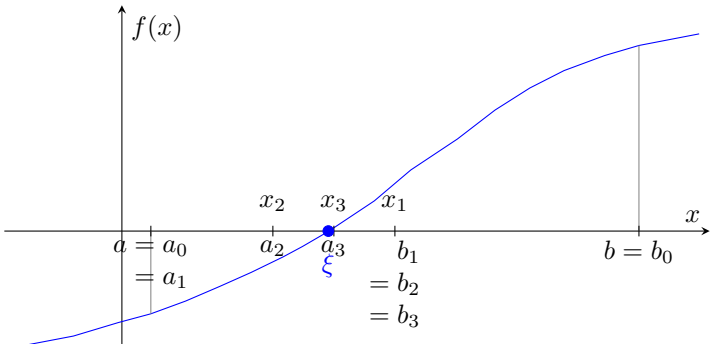
2.3 Método da bisseção

Princípio

Dada uma função $f(x)$ contínua no intervalo $[a, b]$, onde existe uma raiz única para $f(x) = 0$, é possível determinar tal raiz subdividindo sucessivas vezes o intervalo que a contém por seu ponto médio.

Em outras palavras, o objetivo é reduzir, por *divisões sucessivas ao meio*, a amplitude do intervalo que contém a raiz até se atingir a precisão requerida.

Graficamente:



Processo iterativo

- Inicialmente, $a_0 = a$ e $b_0 = b$.
- Define-se $x_1 = \dfrac{a_0 + b_0}{2}$.
- Como $\begin{cases} f(a_0) < 0 \\ f(b_0) > 0 \\ f(x_1) > 0, \end{cases}$ então $\xi \in (a_0, x_1)$.

- Define-se, portanto, $a_1 = a_0$ e $b_1 = x_1$.
- Define-se $x_2 = \dfrac{a_1 + b_1}{2}$.
- Como

$$\begin{cases} f(a_1) < 0 \\ f(b_1) > 0 \\ f(x_2) < 0, \end{cases}$$

então $\xi \in (x_2, b_1)$.

- Define-se $a_2 = x_2$ e $b_2 = b_1$.
- $x_3 = \dfrac{a_2 + b_2}{2}$,

e assim por diante.

Intervalo inicial

- Atribui-se $[a, b]$ como intervalo inicial
  - É necessário que $f(a)f(b) < 0$
- Inicialmente, $a_0 = a$ e $b_0 = b$.

Iterações - caso geral

- Determinação de qual o subintervalo – $[a_k, x_{k+1}]$ ou $[x_{k+1}, b_k]$ – que contém a raiz:
  - Verifica-se o produto $f(a_k)f(x_{k+1})$:
    - Se $f(a_k)f(x_{k+1}) < 0$:

$$\xi \in (a_k, x_{k+1}) \qquad \Longrightarrow \qquad a_{k+1} = a_k \qquad b_{k+1} = x_{k+1}$$

    - Caso contrário:

$$\xi \in (x_{k+1}, b_k) \qquad \Longrightarrow \qquad a_{k+1} = x_{k+1} \qquad b_{k+1} = b_k$$

Convergência

- Após n iterações, a raiz está contida no intervalo $[a_n, b_n]$ onde

$$b_n - a_n = \left(\frac{b_0 - a_0}{2^n} \right),$$

de modo que

$$|\xi - x_{n+1}| < \left(\frac{b_0 - a_0}{2^n} \right).$$

Condições de parada

- Se os valores fossem *exatos*:
  - $f(x) = 0$
  - $(x_k - x_{k+1})/x_k = 0$
- Porém, uma vez que são aproximados:
  - $|f(x)| \leq \varepsilon$
  - $|x_k - x_{k+1}|/|x_k| \leq \varepsilon$
  - (também pode-se usar o módulo do erro absoluto, $|x_k - x_{k+1}| \leq \varepsilon$).

Vantagens e desvantagens

Vantagens:

- Facilidade de implementação;
- Estabilidade e convergência para a solução procurada;
- Desempenho regular e previsível.
  - O número de iterações é dependente da tolerância considerada.

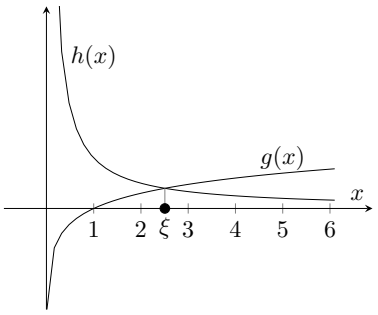
Desvantagens:

- Lentidão do processo de convergência – requer o cálculo de $f(x)$ em um elevado número de iterações;
- Necessidade de conhecimento prévio da região na qual se encontra a raiz de interesse (o que nem sempre é possível);
- Complexidade da extensão do método para problemas multivariáveis.

Exemplos

Exemplo: $f(x) = x \log(x) - 1$

- Fase I: Pelo processo 2 de análise gráfica visto:
$$x \log(x) - 1 = 0 \iff \log(x) = \frac{1}{x} \implies \begin{cases} g(x) = \log(x) \\ h(x) = \frac{1}{x} \end{cases}$$



- $\xi \in [2, 3]$.

Considerando o método da bisseção com $\varepsilon = 0,002$ e adotando $[a_0, b_0] = [2, 3]$ como intervalo inicial, tem-se:

- 1ª aproximação:
  - $x_1 = (a_0 + b_0)/2 = (2,00000 + 3,00000)/2$, então $x_1 = 2,50000$.
  - $f(x_1) = f(2,50000) = -0,00510$
  - $f(a_0) = f(2,00000) = -0,39794$
  - $f(b_0) = f(3,00000) = 0,43140$
  - Logo, $\xi \in [x_1, b_0]$
  - Teste de Parada: $|f(x_1)| = |-0,00510| = 0,00510 > 0,002$
- 2ª aproximação: $f(a_0)f(x_1) = (-0,39794).(-0,00510) > 0$. Logo, $a_1 = x_1 = 2,50000$ e $b_1 = b_0 = 3,00000$.
  - $x_2 = (a_1 + b_1)/2 = (2,50000 + 3,00000)/2$, então $x_2 = 2,75000$.
  - $f(x_2) = f(2,75000) = 0,20820$
  - $f(a_1) = f(2,50000) = -0,00510$
  - $f(b_1) = f(3,00000) = 0,43140$
  - Logo, $\xi \in [a_1, x_2]$.
  - Teste de Parada: $|f(x_2)| = |0,20820| = 0,20820 > 0,002$

Prosseguindo com os cálculos:

- $x_3 = 2,62500$, com $|f(x_3)| = 0,10020$
- $x_4 = 2,56250$, com $|f(x_4)| = 0,04720$
- $x_5 = 2,53125$, com $|f(x_5)| = 0,02090$
- $x_6 = 2,51563$, com $|f(x_6)| = 0,00790$
- $x_7 = 2,50781$, com $|f(x_7)| = 0,00140$

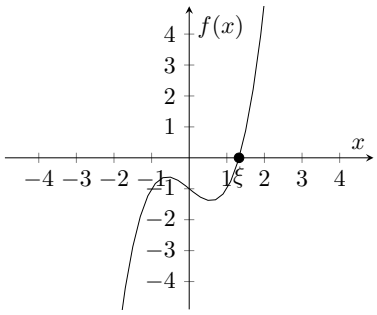
- Como $0,00140 < \varepsilon = 0,002$, o algoritmo termina e temos $\bar{x} = 2,50781$ como aproximação da raiz ξ.

- Aproximação para valor exato: $x = 2,50618$[2]

Exemplo: $f(x) = x^3 - x - 1$

- Fase I: Análise gráfica:

[2] https://www.wolframalpha.com/input/?i=log10%28x%29%3D1%2Fx



- $\xi \in [1, 2]$.

Usando a mesma tolerância do caso anterior ($\varepsilon = 0,002$):

k	a_k	b_k	$f(a_k)$	$f(b_k)$	x_{k+1}	$\lvert f(x_{k+1})\rvert$
0	$1,0000000$	$2,0000000$	$-1,000000$	$5,000000$	$1,50000000$	$0,875000$
1	$1,0000000$	$1,5000000$	$-1,000000$	$0,875000$	$1,25000000$	$0,296875$
2	$1,2500000$	$1,5000000$	$-0,296875$	$0,875000$	$1,37500000$	$0,224609$
3	$1,2500000$	$1,3750000$	$-0,296875$	$0,224609$	$1,31250000$	$0,051514$
4	$1,3125000$	$1,3750000$	$-0,051514$	$0,224609$	$1,34375000$	$0,082611$
5	$1,3125000$	$1,3437500$	$-0,051514$	$0,082611$	$1,32812500$	$0,014576$
6	$1,3125000$	$1,3281250$	$-0,051514$	$0,014576$	$1,32031250$	$0,018711$
7	$1,3203125$	$1,3281250$	$-0,018700$	$0,014576$	$1,32421875$	$0,002128$

- Aproximação pelo WolframAlpha: 1,3247[3]

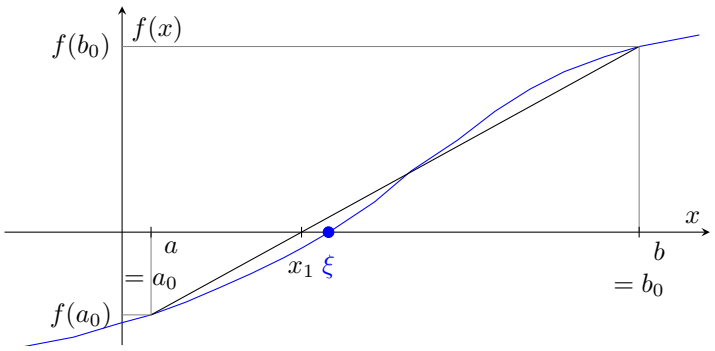
2.4 Método da falsa posição (*regula falsi*)

- *Método da Bisseção*: Calcula a *média aritmética* dos limites do intervalo $[a, b]$ que contém a raiz;
- *Método da Falsa Posição*: Calcula uma *média ponderada* dos limites do intervalo:

$$x_{k+1} = \frac{a_k f(b_k) - b_k f(a_k)}{f(b_k) - f(a_k)}\,.$$

- Graficamente (para etapa $k = 0$):

[3] https://www.wolframalpha.com/input/?i=x%5E3-x-1



- Por *semelhança de triângulos*, $\dfrac{f(b_0)-0}{b_0-x_1} = \dfrac{0-f(a_0)}{x_1-a_0}$, o que leva à equação anterior, para $k=0$:

$$x_1 = \frac{a_0 f(b_0) - b_0 f(a_0)}{f(b_0) - f(a_0)}\,.$$

- Levando-se em consideração que $f(b_0) = |f(b_0)|$ e $f(a_0) = -|f(a_0)|$, a equação anterior é equivalente a

$$x_1 = \frac{a_0|f(b_0)| + b_0|f(a_0)|}{|f(b_0)| + |f(a_0)|}\,,$$

  ou seja, x_1 é dado pela *média ponderada* entre a_0 e b_0, com pesos $|f(b_0)|$ e $|f(a_0)|$, respectivamente.

- Os fórmulas são válidas para qualquer etapa k do método.

Exercício

Verifique a semelhança de triângulos para o caso $f(a_0) > 0$, $f(b_0) < 0$: as fórmulas para x_1 se mantêm?

Intervalo inicial

- Atribui-se $[a, b]$ como intervalo inicial:

$$a_0 = a,$$
$$b_0 = b.$$

- Condições de Aplicação:
  - $f(a)f(b) < 0$;
  - sinal da derivada constante.

Subintervalos

- Subdivide-se o intervalo pelo *ponto de intersecção* da reta que liga $f(a)$ a $f(b)$ e o eixo das abscissas, definindo tal ponto como x_1.
- Verifica-se se, através do teste de parada, se x_1 é uma aproximação da raiz da equação (ξ):
  - Se verdadeiro $\Rightarrow$ x_1 é a raiz procurada;
  - Caso contrário $\Rightarrow$ define-se um novo intervalo.
- Calcula-se o produto $f(a_0)f(x_1)$.
  - Se $f(a_0)f(x_1) < 0$:

$$\xi \in (a_0, x_1) \qquad \Longrightarrow \qquad a_1 = a_0 \qquad b_1 = x_1$$

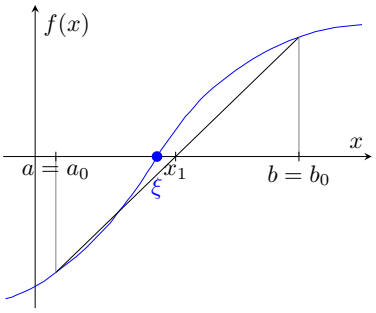
  - Caso contrário:

$$\xi \in (x_1, b_0) \qquad \Longrightarrow \qquad a_1 = x_1 \qquad b_1 = b_0$$

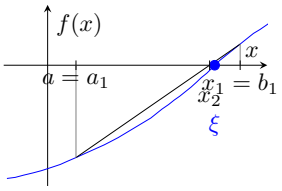
- Repete-se o processo até que o valor x_{k+1} atenda às condições de parada.

Graficamente

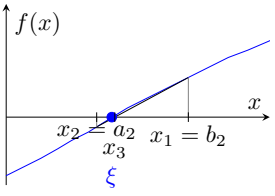
- $k = 0$:



- $k = 1$:



- $k = 2$:

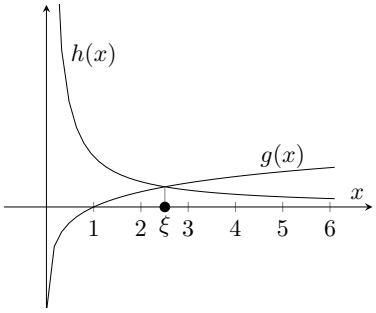


Exemplos

Exemplo: $f(x) = x\log(x) - 1$

- Já foi visto que, reescrevendo a equação $f(x) = 0$ como $g(x) = h(x)$:

$$x\log(x) - 1 = 0 \iff \log(x) = \frac{1}{x} \implies \begin{cases} g(x) = \log(x) \\ h(x) = \frac{1}{x} \end{cases}$$



- Logo, $\xi \in [2, 3]$.

Considerando o método da falsa posição com $\varepsilon = 0,002$ e adotando-se $[a_0, b_0] = [2, 3]$ como intervalo inicial, tem-se:

- 1ª aproximação:
  - $f(a_0) = f(2,00000) = -0,39794 < 0$
  - $f(b_0) = f(3,00000) = 0,43140 > 0$
  - Aproximação:

$$\begin{aligned} x_1 &= \frac{a_0 f(b_0) - b_0 f(a_0)}{f(b_0) - f(a_0)} \\ &= \frac{2,0 \cdot 0,43140 - 3,0 \cdot (-0,39794)}{0,43140 - (-0,39794)} = 2,4798 \end{aligned}$$

  - Teste de Parada: $|f(x_1)| = |f(2,4798)| = |-0,0219| > 0,002$
  - Novo intervalo:

$$f(a_0)f(x_1) = (-0,39794) \cdot (-0,0219) > 0 \Rightarrow \begin{cases} a_1 = x_1 = 2,4798 \\ b_1 = b_0 = 3,0 \end{cases}$$

- 2ª aproximação:
  - $f(a_1) = f(2,4798) = -0,0219$
  - $f(b_1) = f(3,00000) = 0,43140$

– Aproximação:

$$x_2 = \frac{a_1 f(b_1) - b_1 f(a_1)}{f(b_1) - f(a_1)} = \frac{2,4798 \cdot 0,43140 - 3,0 \cdot (-0,0219)}{0,43140 - (-0,0219)} = 2,5049$$

– Teste de Parada: $|f(x_2)| = |f(2,5049)| = |-0,0011| < 0,002$

– Portanto, com apenas *duas iterações*, obteve-se uma aproximação dentro da tolerância – usando bisseção, foram necessárias sete.

– Uma 3a. iteração levaria a $x_3 = 2,5061$ – valor muito próximo de 2,50618 (valor obtido pela ferramenta WolframAlpha).

Exemplo: $f(x) = x^3 - x - 1$

- Análise gráfica vista anteriormente (bisseção): único zero $\xi \in [1, 2]$.
- Usando a mesma tolerância do caso anterior ($\varepsilon = 0,002$):

k	a_k	b_k	$f(a_k)$	$f(b_k)$	x_{k+1}	$\lvert f(x_{k+1})\rvert$
0	1,000000	2,000000	−1,0000000	5,000000	1,1666667	0,578704
1	1,166667	2,000000	−0,5787037	5,000000	1,2531120	0,285363
2	1,253112	2,000000	−0,2853630	5,000000	1,2934374	0,129542
3	1,293437	2,000000	−0,1295421	5,000000	1,3112812	0,056588
4	1,311281	2,000000	−0,0565885	5,000000	1,3189885	0,024304
5	1,318988	2,000000	−0,0243037	5,000000	1,3222827	0,010362
6	1,322283	2,000000	−0,0103618	5,000000	1,3236843	0,004404
7	1,323684	2,000000	−0,0044039	5,000000	$1,3242795^4$	0,001869

- Neste caso o número de iterações foi o mesmo que o necessário por bisseção, e o erro é da mesma ordem em ambos os casos.

Vantagens e desvantagens

- Vantagens:
  - Estabilidade e convergência para a solução procurada;
  - Desempenho regular e previsível;
  - Cálculos mais simples que outros métodos, ex. método de Newton-Raphson.
- Desvantagens:
  - Lentidão do processo de convergência – requer o cálculo de $f(x)$ em um elevado número de iterações);

    Necessidade de conhecimento prévio da região na qual se encontra a raiz de interesse (o que nem sempre é possível).

Exercício

Usando algum *software*, desenhe um gráfico que mostra a evolução das iterações (gráfico de x_k em função do número k) do método da bisseção e do método da falsa posição, para o problema de achar o zero de $f(x) = x^3 - x - 1$.

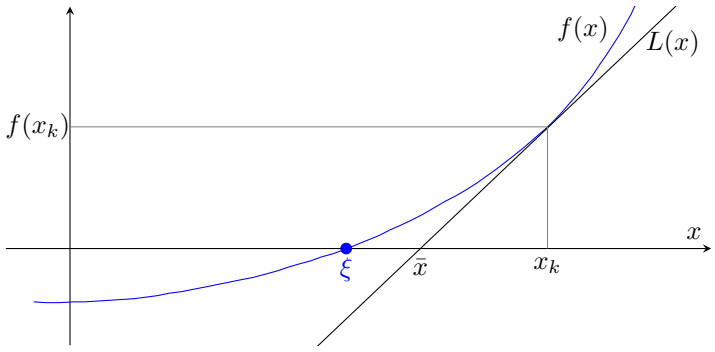
Qual o método com melhor precisão? E com melhor acurácia?

2.5 Método de Newton-Raphson

Princípio

Dada uma função $f(x)$ contínua no intervalo $[a, b]$, o qual contém um único zero de $f(x)$, é possível determinar uma aproximação tal zero a partir da *intersecção da tangente à curva de* $f(x)$ *num ponto* x_0 com o eixo das abscissas.

- Graficamente:



- Reta tangente: $L(x) = \alpha x + \beta$, α, $\beta \in \mathbb{R}$.
  - Para $x = x_k$: $L(x_k) = f(x_k)$. Além disso, $\alpha = f'(x_k)$ (a inclinação de $f(x)$ e $L(x)$ é a mesma). Logo, $f(x_k) = f'(x_k)x_k + \beta$.
  - Isolando-se β: $\beta = f(x_k) - f'(x_k)x_k$.
  - No ponto $\bar{x}$: $L(\bar{x}) = f'(x_k)\bar{x} + f(x_k) - f'(x_k)x_k = 0$. Portanto:

$$\bar{x} = x_k - \frac{f(x_k)}{f'(x_k)}$$

Logo, escolhido o ponto inicial x_0, a sequência será dada por

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)},$$

$k = 0, 1, 2, \ldots$

Na k-ésima iteração, dado o ponto $(x_k, f(x_k))$:

- Traça-se a reta $L_k(x)$ tangente à curva neste ponto:

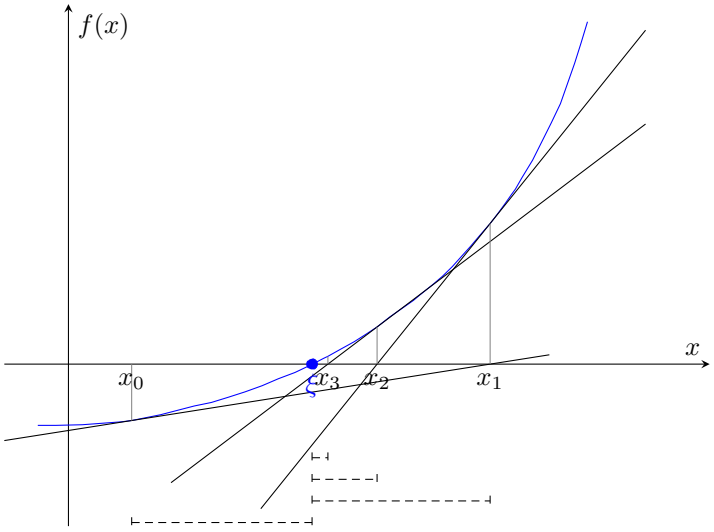
$$L_k(x) = f(x_k) + f'(x_k)(x - x_k)\,.$$

- Determina-se o zero de $L_k(x)$, um modelo linear que aproxima $f(x)$ em uma vizinhança x_k:

$$L_k(\bar{x}) = 0 \qquad \Leftrightarrow \qquad \bar{x} = x_k - f(x_k)/f'(x_k)\,.$$

- Faz-se $x_{k+1} = \bar{x}$.

Evolução – sucessivas iterações



Convergência

Teorema
Sejam $f \in C^2[a,b]$ – i.é. $f(x)$, $f'(x)$ e $f''(x)$ são contínuas no intervalo $[a,b]$.

Se $\xi \in [a,b]$ é zero de $f(x)$, e $f'(\xi) \neq 0$, então existe $\delta > 0$ tal que se $x_0 \in [\xi - \delta, \xi + \delta]$ então a sequência $\{x_k\}$ gerada pela fórmula

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

converge para ξ.

Critério de parada

A cada iteração, testa-se se a aproximação encontrada poderá ser considerada como a solução do problema, com base numa *tolerância* ε:

- $|f(x_k)| < \varepsilon$
- $|x_{k+1} - x_k|/|x_{k+1}| < \varepsilon$ (também pode-se considerar a diferença relativa).

Vantagens e desvantagens

Vantagens:

- Rapidez no processo de convergência;
- Desempenho elevado.

Desvantagens:

- Necessidade de um valor inicial x_0 (número de iterações dependerá do quão bom for a escolha de tal valor)
- Necessidade da obtenção de $f'(x)$, o que pode ser impossível em determinados casos;
- O cálculo do valor numérico de $f'(x)$ a cada iteração.

Exemplos

Exemplo: $f(x) = x^2 + x - 6$.

- Uma raiz de $f(x) = 0$ é o valor $\xi = 2$.
- Termo geral para x_{k+1}, a partir de x_k:

$$x_{k+1} = x_k - \frac{x_k^2 + x_k - 6}{2x_k + 1}$$

- Partindo de $x_0 = 1,5$:
  - $x_1 = 1,5 - (1,5^2 + 1,5 - 6)/(2 \cdot 1,5 + 1) = 2,062500000$
  - $x_2 = 2,000762195$
  - $x_3 = 2,000000116$
- Portanto, se a precisão exigida no resultado for de 6 casas decimais, a parada poderá ocorrer após a terceira iteração.

Exemplo: $f(x) = x^3 - x - 1$

- Único zero $\xi \in [1, 2]$.

- Termo geral para x_{k+1}, a partir de x_k:

$$x_{k+1} = x_k - \frac{x_k^3 - x_k - 1}{3x_k^2 - 1}$$

- Usando a tolerância $\varepsilon = 0,002$, e $x_0 = 1$:

k	x_{k+1}	$\lvert f(x_{k+1})\rvert$
0	$1,500000$	$0,875$
1	$1,3478261$	$0,1006822$
2	$1,3252004$	$0,0020584$
3	$1,3247182$	$9,24378 \times 10^{-7}$

- Com poucas iterações, o erro é substancialmente menor que o obtido pelos outros métodos vistos.

2.6 Método da secante

- Como visto, um problema do método de Newton, é a necessidade de se conhecer $f'(x)$, o que, em alguns casos, pode ser muito complexo:
  - ex.: $f(x) = x^2 3^x \cos 2x$
  - $f'(x) = 2x3^x \cos 2x + x^2 3x(\cos 2x)\ln 3 - 2x^2 3^x \operatorname{sen} 2x$
- Para contornar o problema da derivada, uma variação é proposta:
  - Sabendo-se que

$$f'(x_k) = \lim_{x \to x_k} \frac{f(x) - f(x_k)}{x - x_k},$$

tomando $x = x_{k-1}$ na equação acima, e usando tal aproximação para a fórmula de Newton-Raphson, temos:

$$x_{k+1} = x_k - \frac{f(x_k) \cdot (x_{k-1} - x_k)}{f(x_{k-1}) - f(x_k)}$$

Princípio
Dada uma função $f(x)$ contínua no intervalo $[a, b]$, o qual contém um único zero de $f(x)$, é possível determinar uma aproximação para tal zero a partir da *intersecção da secante à curva de* $f(x)$ *em 2 pontos* x_0 *e* x_1 com o eixo das abscissas.

- x_0 e x_1 são atribuídos em função da geometria do método e do comportamento da curva da equação nas proximidades da raiz.

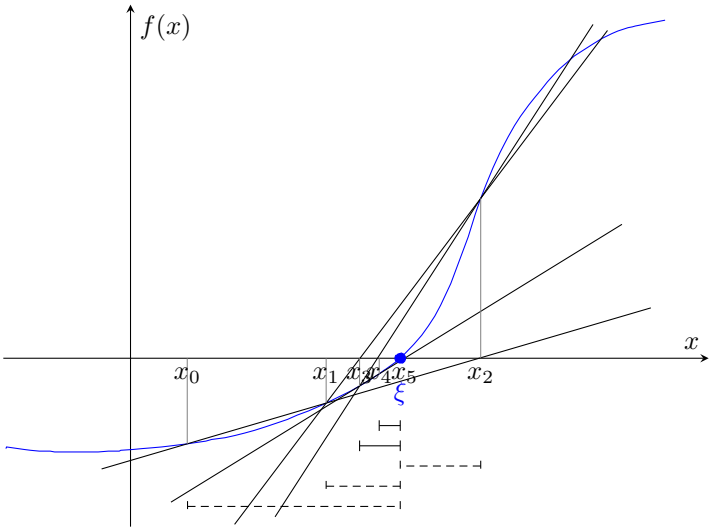
- A fórmula anterior pode ser simplificada em termos do denominador. Logo, escolhidos os pontos iniciais x_0 e x_1 a sequência será dada por

$$\begin{aligned} x_{k+1} &= x_k - \frac{f(x_k)\cdot(x_{k-1}-x_k)}{f(x_{k-1})-f(x_k)} \\ &= x_k - \frac{f(x_k)\cdot(x_k-x_{k-1})}{f(x_k)-f(x_{k-1})} \\ &= \frac{x_{k-1}f(x_k)-x_kf(x_{k-1})}{f(x_k)-f(x_{k-1})}\,. \end{aligned}$$

Na k-ésima iteração, dados os pontos $(x_k, f(x_k))$ e $(x_{k-1}, f(x_{k-1}))$:

- Obtém-se o ponto x_{k+1} como sendo a abscissa do ponto de intersecção do eixo $\overrightarrow{ox}$ e da reta que passa por tais pontos (*secante* à curva da função).

Evolução – sucessivas iterações



Critério de parada

A cada iteração, testa-se se a aproximação encontrada poderá ser considerada como a solução do problema, com base numa *tolerância* ε:

- $|f(x_k)| < \varepsilon$
- $|x_{k+1} - x_k|/|x_{k+1}| < \varepsilon$ (também se pode considerar a diferença absoluta).

Vantagens e desvantagens

Vantagens:

- Rapidez no processo de convergência;
- Cálculos mais convenientes que do método de Newton;
- Desempenho elevado.

Desvantagens:

- Necessidade de dois pontos de referência iniciais;
- Se o cálculo $f'(x)$ não for difícil, então é melhor optar pelo de Newton-Raphson;
- Se o gráfico da função for paralela a um dos eixos e/ou tangencia o eixo das abscissas $\overrightarrow{ox}$ em um ou mais pontos, não se deve usar o método da secante.

Exemplos

Exemplo: $f(x) = x^3 - x - 1$

- Único zero $\xi \in [1, 2]$.
- Calculo da 1ª aproximação, adotando tolerância $\varepsilon = 0,002$, $x_0 = 1,5$ e $x_1 = 1,7$:
  - $f(x_0) = 0,875$; $f(x_1) = 2,213$
  - Logo,
$$x_2 = \frac{1,5 \cdot 2,213 - 1,7 \cdot 0,875}{2,213 - 0,875} = 1,36921$$
  - Teste de Parada: $|f(x_2)| = |0,19769| = 0,19769 > \varepsilon$
  - Pontos a serem usados na próxima secante: $x_1 = 1,7$ e $x_2 = 1,36921$.
- Calculo da 2ª aproximação, com $x_1 = 1,7$ e $x_2 = 1,36921$:
  - $f(x_1) = 2,213$; $f(x_2) = 0,19769$
  - Logo,
$$x_3 = \frac{1,7 \cdot 0,19769 - 1,36921 \cdot 2,213}{0,19769 - 2,213} = 1,33676$$
  - Teste de Parada: $|f(x_3)| = |0,05194| = 0,05194 > \varepsilon$
  - Pontos a serem usados na próxima secante: $x_2 = 1,36921$ e $x_3 = 1,33676$.
- Calculo da 3ª aproximação, com $x_2 = 1,36921$ e $x_3 = 1,33676$:

- $f(x_2) = 0,19769$; $f(x_3) = 0,05194$
- Logo,

$$x_4 = \frac{1,36921 \cdot 0,05194 - 1,33676 \cdot 0,19769}{0,05194 - 0,19769} = 1,325196$$

- Teste de Parada: $|f(x_4)| = |0,00203959| = 0,00203959 > \varepsilon$
- Pontos a serem usados na próxima secante:
  $x_3 = 1,33676$ e $x_4 = 1,325196$.

- Calculo da 4ª aproximação, com $x_3 = 1,33676$ e $x_4 = 1,325196$:
  - $f(x_3) = 0,05194$; $f(x_4) = 0,00203959$
  - Logo,

$$x_5 = \frac{1,33676 \cdot 0,00203959 - 1,325196 \cdot 0,05914}{0,00203959 - 0,05914} = 1,324783$$

  - Teste de Parada: $|f(x_5)| = |0,00027| = 0,00027 < \varepsilon$

- Logo, o método é encerrado após a quarta iteração, com resultado que atende a tolerância, mas não tão preciso quanto o método de Newton-Raphson.

Exemplo: $f(x) = x^2 + x - 6$.

- Foi visto que $\xi = 2$ é raiz de $f(x) = 0$.
- Considerando $x_0 = 1,5$ e $x_1 = 1,7$, 1ª aproximação:

$$\begin{aligned} x_2 &= \frac{x_0 \cdot f(x_1) - x_1 \cdot f(x_0)}{f(x_1) - f(x_0)} \\ &= \frac{1,5 \cdot (-1,41) - 1,7 \cdot 2,25}{-1,41 + 2,25} = 2,03571 \end{aligned}$$

- 2ª aproximação:

$$x_3 = \frac{x_1 \cdot f(x_2) - x_2 \cdot f(x_1)}{f(x_2) - f(x_1)} = 1,99774$$

- 3ª aproximação:

$$x_4 = \frac{x_2 \cdot f(x_3) - x_3 \cdot f(x_2)}{f(x_3) - f(x_2)} = 1,99999$$

- A parada poderá ocorrer na terceira iteração, caso a precisão do cálculo com 5 casas decimais seja satisfatória para o contexto do trabalho.

2.7 Exercícios

1. Localize os intervalos contendo zeros para as funções a seguir:
   (a) $4\cos(x) - e^{2x}$
   (b) $\frac{x}{2} - \mathrm{tg}(x)$
   (c) $1 - x\ln x$
   (d) $2^x - 3x$
   (e) $x^3 + x - 1000$
2. Escreva o algoritmo, em pseudocódigo, para o método da bisseção.
3. Escreva o algoritmo, em pseudocódigo, para o método da falsa posição.
4. Escreva o algoritmo, em pseudocódigo, para o método de Newton-Raphson.
5. Escreva o algoritmo, em pseudocódigo, para o método da secante.
6. Verifique que $f(x) = x^3 - x - 1$ tem um, e apenas um zero no intervalo $[1, 2]$. Aproxime tal zero até que $|f| < 10^{-2}$ usando o método da bisseção.
7. Encontre uma aproximação para $\sqrt[3]{25}$ usando o algoritmo da bisseção (dica: considere $f(x) = x^3 - 25$). Aproxime tal zero até que $|f| < 10^{-2}$.
8. Repita o exercício anterior usando os métodos da falsa posição e secante.
9. Use o método de Newton para aproximar a solução das seguintes equações considerando precisão de 10^{-5}.
   (a) $x = \frac{2 - e^x + x^2}{3}$, $[0, 1]$
   (b) $x - \cos x = 0$, $[0, \pi/2]$
   (c) $x^3 + 3x^2 - 1 = 0$, $[-4, 0]$
   (d) $x - 0,8 - 0,2\,\mathrm{sen}\,x = 0$, $[0, \pi/2]$

Referências

1. BURDEN, R. L.; FAIRES, J. D. *Numerical Analysis*, 6th ed., Brooks/Cole Publishing Company, 1997.
2. FRANCO, N. B. *Cálculo numérico.* São Paulo: Pearson Prentice Hall, 2006.
3. RUGGIERO, M. A. G.; LOPES, V. L. R. *Cálculo numérico: aspectos teóricos e computacionais.* 2ª. ed. São Paulo: Makron Books. 1996.

Os materiais de parte desta seção foram gentilmente cedidos por Mauricio C. Escarpinati (FACOM/UFU)
Adaptações: Renato Pimentel, FACOM/UFU

3 Interpolação polinomial

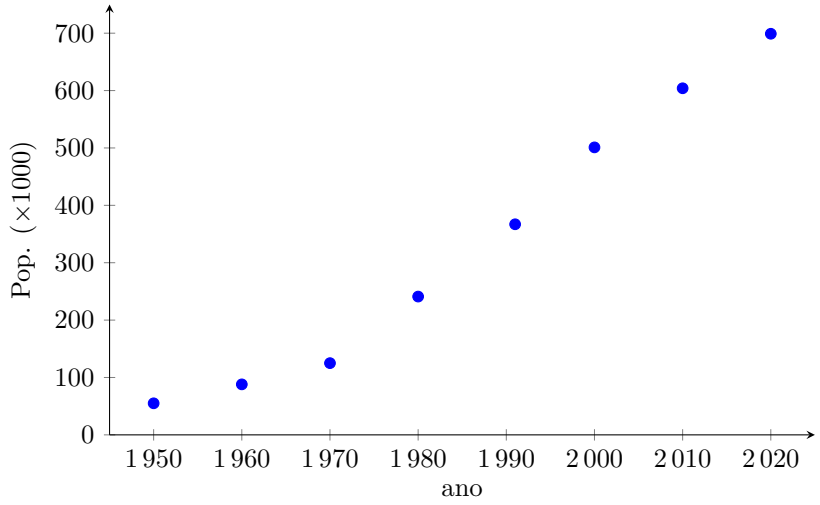
3.1 Introdução

- Como motivação, considere a tabela que segue, com a população (em milhares de pessoas) da cidade de Uberlândia em diferentes censos[5]:

1950	1960	1970	1980	1991	2000	2010	2020
55	88	125	241	367	501	604	699

- Usando tais dados, qual seria uma estimativa razoável da população da cidade no ano, por exemplo, de 2005? Ou mesmo em 1940 ou 2030?

- Graficamente:



Interpolação

Interpolar uma função $f(x)$ consiste em aproximar a mesma por uma outra função $g(x)$, escolhida em uma classe de funções previamente definida, e que satisfaça certas propriedades.

A função $g(x)$ é então usada em substituição a $f(x)$.

A necessidade de se efetuar tal substituição surge em diversas situações, ex.:

- Quando são conhecidos somente *valores numéricos* de $f(x)$ em alguns pontos – como no exemplo visto;

- Quando a função $f(x)$ é tal que operações como ex. sua integração ou diferenciação são difíceis ou inviáveis de serem realizadas.

[5] Fonte: IBGE

Polinômio de interpolação

- Diversas funções possam ser adotadas para representar os dados fornecidos.
- Em particular, é possível adotar uma *função polinomial*, i.e., uma função

$$P_n(x) = a_0 + a_1 x + a_2 x^2 + \cdots + a_n x^n \,,$$

onde n é um inteiro não-negativo, e $a_0, \ldots, a_n$ são constantes reais.

- Dados $n+1$ pontos (x_0, f_0), (x_1, f_1), $\ldots$, (x_n, f_n), o problema consiste em determinar um polinômio $P_n(x)$ de grau no máximo n tal que:

$$P_n(x_0) = f_0; \qquad P_n(x_1) = f_1; \qquad \ldots \qquad P_n(x_n) = f_n.$$

- Tal polinômio existe e é único, como veremos a seguir.

Exemplo

Dados os pontos $(-1, 15)$, $(0, 8)$ e $(3, -1)$, determinar o polinômio de interpolação para a função que passa por tais pontos.

- Temos

$$\begin{aligned} x_0 &= -1 & f_0 &= 15 = f(x_0) \\ x_1 &= 0 & f_1 &= 8 = f(x_1) \\ x_2 &= 3 & f_2 &= -1 = f(x_2) \end{aligned}$$

- $n = 2$, então o polinômio é da forma

$$P_2(x) = a_0 + a_1 x + a_2 x^2$$

tal que $P_2(x_k) = f_k$, $k = 0, 1, 2$.

- Isto é,

$$\begin{cases} a_0 + a_1 x_0 + a_2 x_0^2 = f_0 \\ a_0 + a_1 x_1 + a_2 x_1^2 = f_1 \\ a_0 + a_1 x_2 + a_2 x_2^2 = f_2. \end{cases}$$

- No caso geral, envolvendo $n + 1$ pontos, o sistema é dado por

$$\begin{cases} a_0 + a_1 x_0 + \cdots + a_n x_0^n = f_0 \\ a_0 + a_1 x_1 + \cdots + a_n x_1^n = f_1 \\ \qquad\qquad \cdots \\ a_0 + a_1 x_n + \cdots + a_n x_n^n = f_n. \end{cases}$$

- Podemos reescrever tal sistema na forma matricial $\mathbf{A}\alpha = \mathbf{b}$, onde $\alpha = [a_0, a_1, \ldots, a_n]^t$ e $\mathbf{A}_{n+1\times n+1}$ é uma matriz da forma

$$\mathbf{A} = \begin{pmatrix} 1 & x_0 \ldots\ldots x_0^n \\ 1 & x_1 \ldots\ldots x_1^n \\ \vdots & \vdots \quad \ddots \quad \vdots \\ 1 & x_n \ldots\ldots x_n^n \end{pmatrix},$$

  conhecida por *matriz de Vandermonde*.

- Uma vez que $x_0, x_1, \ldots, x_n$ são distintos, $\det \mathbf{A} \neq 0$, e portanto, o sistema admite *solução única*.

- Porém, dependendo do problema de interpolação, a matriz pode ser *mal condicionada* – ex. (RUGGIERO; LOPES, 1996) – o que impossibilita sua resolução numérica.

- Retomando o exemplo, temos um sistema da forma

$$\begin{cases} a_0 + a_1 x_0 + a_2 x_0^2 = f_0 \\ a_0 + a_1 x_1 + a_2 x_1^2 = f_1 \\ a_0 + a_1 x_2 + a_2 x_2^2 = f_2. \end{cases}$$

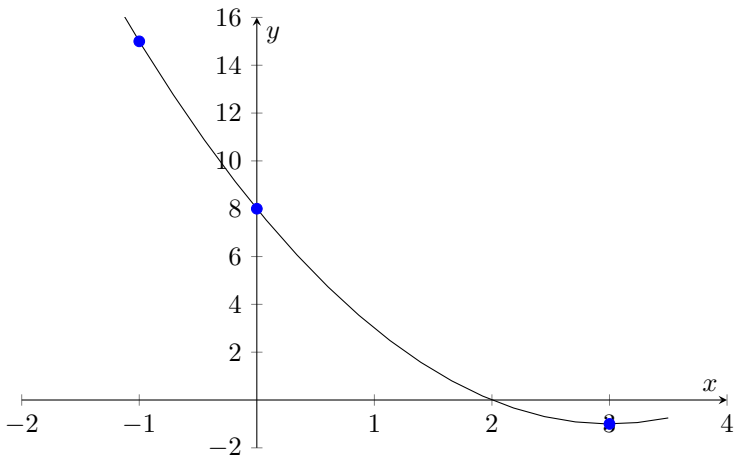
- Substituindo-se no sistema acima os valores dados:

$$\begin{cases} a_0 - a_1 + a_2 = 15 \\ a_0 = 8 \\ a_0 + 3a_1 + 9a_2 = 9, \end{cases}$$

  cuja solução é: $a_0 = 8$, $a_1 = -6$ e $a_2 = 1$. Logo, o polinômio é

$$P_2(x) = 8 - 6x + x^2 \,.$$

- Gráfico:



Observações

- Observe que nos pontos dados, o valor do polinômio encontrado e o valor da função, devem coincidir.
- A determinação do polinômio de interpolação por meio de solução de sistemas pode ser custosa, além da possibilidade de erros de arredondamento, fazendo com que a solução obtida seja incorreta. Há outros métodos para determinação de tal polinômio.

3.2 Fórmula de Lagrange

- A partir de $n+1$ pontos distintos x_0, x_1, ..., x_n, sejam os polinômios de grau n $\ell_k(x)$, $k = 0, 1, \ldots, n$, definidos por

$$\ell_k(x) = \frac{(x-x_0)\ldots(x-x_{k-1})(x-x_{k+1})\ldots(x-x_n)}{(x_k-x_0)\ldots(x_k-x_{k-1})(x_k-x_{k+1})\ldots(x_k-x_n)},$$

de modo que

$$\ell_k(x_j) = \begin{cases} 1, & k = j, \\ 0, & k \neq j. \end{cases}$$

- Se $f(x)$ é uma função tal que

$$f(x_0) = f_0 \qquad f(x_1) = f_1 \qquad \ldots \qquad f(x_n) = f_n,$$

i.e., possui $n+1$ valores conhecidos f_0, f_1, ..., f_n nos pontos dados, então o polinômio

$$P_n(x) = \sum_{k=0}^{n} f_k \ell_k(x) \tag{1}$$

é de grau no máximo n e é tal que $P_n(x_k) = f_k$, $k = 0, 1, \ldots, n$.

Definição
A expressão para $P_n(x)$ dada pela Eq. (1) é denominada *fórmula de Lagrange* para o polinômio de interpolação.

Exemplos

Exemplo (interpolação linear): dados dois pontos distintos $(x_0, f(x_0))$ e $(x_1, f(x_1))$, encontrar o polinômio interpolador na forma de Lagrange.

- *Solução:* Como $n = 1$, a interpolação é *linear*: o polinômio é de grau *no máximo 1* e tem a forma

$$P_1(x) = f(x_0)\ell_0(x) + f(x_1)\ell_1(x)$$

- Pela fórmula de Lagrange:

$$\ell_0(x) = \frac{x - x_1}{x_0 - x_1}, \qquad \ell_1(x) = \frac{x - x_0}{x_1 - x_0}.$$

- Logo, $P_1(x) = f(x_0)\dfrac{x - x_1}{x_0 - x_1} + f(x_1)\dfrac{x - x_0}{x_1 - x_0}$, i.e.:

$$P_1(x) = \frac{(x_1 - x)f(x_0) + (x - x_0)f(x_1)}{x_1 - x_0},$$

equação da reta que passa pelos pontos dados.

Exemplo: Considerando-se

x	-1	0	3
$f(x)$	15	8	-1

1. Determine o polinômio de interpolação pela fórmula de Lagrange;
2. Calcule uma aproximação para $f(2)$ usando a fórmula do item anterior.

- *Solução:* Sabe-se que

$$\begin{aligned} x_0 &= -1 & f_0 &= f(x_0) = 15 \\ x_1 &= 0 & f_1 &= f(x_1) = 8 \\ x_2 &= 3 & f_2 &= f(x_2) = -1, \end{aligned}$$

e $n = 2$.

- Logo, o polinômio de interpolação na forma de Lagrange é dado por

$$P_2(x) = \sum_{k=0}^{2} f_k \ell_k(x).$$

- Polinômios $\ell_k(x)$, $k = 0, 1, 2$:

$$\ell_0(x) = \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} = \frac{(x - 0)(x - 3)}{(-1 - 0)(-1 - 3)} = \frac{x^2 - 3x}{4},$$

$$\ell_1(x) = \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} = \frac{(x + 1)(x - 3)}{(0 + 1)(0 - 3)} = \frac{x^2 - 2x - 3}{-3},$$

$$\ell_2(x) = \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} = \frac{(x + 1)(x - 0)}{(3 + 1)(3 - 0)} = \frac{x^2 + x}{12}.$$

- Logo,

$$\begin{aligned} P_2(x) &= f_0\ell_0(x) + f_1\ell_1(x) + f_2\ell_2(x) \\ &= 15 \times \left[\frac{x^2 - 3x}{4}\right] + 8 \times \left[\frac{x^2 - 2x - 3}{-3}\right] - 1 \times \left[\frac{x^2 + x}{12}\right] \end{aligned}$$

- Simplificando,

$$P_2(x) = x^2 - 6x + 8$$

- Por fim, a aproximação em $x = 2$ é dada por

$$f(2) \approx P_2(2) = 2^2 - 6 \cdot 2 + 8 = 0.$$

Desvantagem

A forma de Lagrange para o polinômio interpolador possui uma desvantagem:

- Sempre que se deseja passar de um polinômio de grau n (construído sobre $n + 1$ pontos) para um de grau $n + 1$ (pela adição de um ponto extra, por exemplo), todo o trabalho precisa ser refeito.
- É de interesse, portanto, a possibilidade de se poder passar de um polinômio de grau n para o polinômio de grau $n + 1$ acrescentando-se apenas um novo termo.
- Isto é possível usando a *forma de Newton* do polinômio de interpolação.

3.3 Forma de Newton

Definição
A *forma de Newton* para o polinômio $P_n(x)$ que interpola $f(x)$ em $n+1$ pontos $x_0, x_1, \ldots, x_n$ é dada por

$$P_n(x) = d_0 + d_1(x - x_0) + d_2(x - x_0)(x - x_1) + \ldots \\ + d_n(x - x_0)(x - x_1)\ldots(x - x_{n-1}),$$

onde os valores dos coeficientes $d_k, k = 0, \ldots, n$ são dadas pelo *operador diferenças divididas* de ordem k entre os pontos $(x_j, f(x_j)), j = 0, \ldots, k$.

Operador diferenças divididas

Se $f(x)$ é uma função tabelada em $n+1$ pontos $x_0, x_1, \ldots, x_n$, então o *operador de diferenças divididas* é definido como segue:

$$\begin{array}{ll}
f[x_0] = f(x_0) & \text{(ordem zero)} \\
f[x_0, x_1] = \dfrac{f[x_1] - f[x_0]}{x_1 - x_0} = \dfrac{f(x_1) - f(x_0)}{x_1 - x_0} & \text{(ordem 1)} \\
f[x_0, x_1, x_2] = \dfrac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0} & \text{(ordem 2)} \\
f[x_0, x_1, x_2, x_3] = \dfrac{f[x_1, x_2, x_3] - f[x_0, x_1, x_2]}{x_3 - x_0} & \text{(ordem 3)} \\
\vdots \qquad\qquad \vdots & \vdots \\
f[x_0, x_1, \ldots, x_n] = \dfrac{f[x_1, x_2, \ldots, x_n] - f[x_0, x_1, \ldots, x_{n-1}]}{x_n - x_0} & \text{(ordem } n\text{)}
\end{array}$$

Ou seja, é possível construir a tabela a seguir, da esquerda para a direita, para obter as diferenças divididas:

x	Ordem 0	Ordem 1	Ordem 2	Ordem 3	$\ldots$	Ordem n
x_0	$f[x_0]$					
		$f[x_0, x_1]$				
x_1	$f[x_1]$		$f[x_0, x_1, x_2]$			
		$f[x_1, x_2]$		$f[x_0, x_1, x_2, x_3]$		
x_2	$f[x_2]$		$f[x_1, x_2, x_3]$			
		$f[x_2, x_3]$		$f[x_1, x_2, x_3, x_4]$	$\ddots$	
x_3	$f[x_3]$		$f[x_2, x_3, x_4]$	$\vdots$		$f[x_0, \ldots, x_n]$
		$f[x_3, x_4]$	$\vdots$	$\vdots$	$\iddots$	
x_4	$f[x_4]$	$\vdots$	$\vdots$	$f[x_{n-3}, \ldots, x_n]$		
$\vdots$	$\vdots$	$\vdots$	$f[x_{n-2}, x_{n-1}, x_n]$			
$\vdots$	$\vdots$	$f[x_{n-1}, x_n]$				
x_n	$f[x_n]$					

- *Exemplo:* se $f(x)$ é uma função tabelada como segue:

x	-1	0	1	2	3
$f(x)$	1	1	0	-1	-2

então sua tabela de diferenças divididas é dada por

x	Ordem 0	Ordem 1	Ordem 2	Ordem 3	Ordem 4
-1	1				
		0			
0	1		$-\frac{1}{2}$		
		-1		$\frac{1}{6}$	
1	0		0		$-\frac{1}{24}$
		-1		0	
2	-1		0		
		-1			
3	-2				

- $f[x_0, x_1] = \dfrac{f[x_1] - f[x_0]}{x_1 - x_0} = \dfrac{1-1}{1} = 0$
- $f[x_1, x_2] = \dfrac{f[x_2] - f[x_1]}{x_2 - x_1} = \dfrac{0-1}{1-0} = -1$

  $\vdots$
- $f[x_3, x_4] = \dfrac{-2-(-1)}{3-2} = \dfrac{-1}{1} = -1$

  $\vdots$
- $f[x_0, x_1, x_2] = \dfrac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0} = \dfrac{-1-0}{1-(-1)} = -\dfrac{1}{2}$

  $\vdots$

Forma de Newton para o polinômio interpolador

- Sejam $x_0 < x_1 < \cdots < x_n$ $n+1$ pontos em que são conhecidos valores de uma determinada função f, função contínua e com tantas derivadas contínuas quanto necessárias num intervalo $[a, b]$.
- Sejam também $a = x_0$ e $b = x_n$.
- Se $p_0(x)$ é o polinômio de grau 0 que intercepta $f(x)$ em x_0, então

$$p_0(x) = f(x_0) = f[x_0]\,.$$

- Logo, para qualquer $x \in [a, b]$, $x \neq x_0$:

$$f[x_0, x] = \frac{f[x] - f[x_0]}{x - x_0} = \frac{f(x) - f(x_0)}{x - x_0}\,. \tag{2}$$

- Da mesma forma, considerando-se agora os pontos x_0 e x_1, podemos definir, para $x \neq x_0$, $x \neq x_1$:

$$f[x_0, x_1, x] = \frac{f[x_0, x] - f[x_0, x_1]}{x - x_1}\,. \tag{3}$$

  Considera-se aqui o fato de que $f[x_0, x_1, \ldots, x_k] = f[x_{j_0}, x_{j_1}, \ldots, x_{j_k}]$, onde $j_0, j_1, \ldots, j_k$ é qualquer permutação de $0, 1, \ldots, k$.
  (em particular, $f[x_0, x_1, x_2] = f[x_0, x_2, x_1] = f[x_2, x_1, x_0] = \ldots$)

- De (2):

$$f(x) = f[x_0] + (x - x_0) f[x_0, x]$$

- Substituindo (2) em (3):

$$\begin{aligned} f[x_0, x_1, x](x - x_1) &= \frac{f[x] - f[x_0]}{x - x_0} - f[x_0, x_1] \\ \Rightarrow f(x) &= f[x_0] + (x - x_0) f[x_0, x_1] + (x - x_0)(x - x_1) f[x_0, x_1, x] \end{aligned}$$

- Ou seja,
  - Considerando-se somente x_0, temos:

$$f(x) = \underbrace{f[x_0]}_{p_0(x)} + (x - x_0) f[x_0, x]$$

– Considerando-se x_0 e x_1, temos

$$f(x) = \underbrace{f[x_0] + (x - x_0)f[x_0, x_1]}_{p_1(x)} + (x - x_0)(x - x_1)f[x_0, x_1, x] \quad (4)$$

– $p_0(x)$ é o polinômio de grau 0 (i.e., constante) que interpola $f(x)$ em x_0, e $p_1(x)$ é o polinômio de grau *no máximo* 1 que interpola $f(x)$ em x_0 e x_1 (interpolação linear).

- Por recorrência, é possível expandir tal raciocínio até que sejam considerados todos os pontos $x_0, x_1, \ldots, x_n$:
  – Para $x \in [a, b], x \neq x_k, \forall k = 0, \ldots, n$:

$$f[x_0, x_1, \ldots, x_n, x] = \frac{f[x_0, x_1, \ldots, x_{n-1}, x] - f[x_0, x_1, \ldots, x_n]}{x - x_n}$$

  – Logo,

$$\begin{aligned} f(x) = f[x_0] &+ (x - x_0)f[x_0, x_1] + (x - x_0)(x - x_1)f[x_0, x_1, x_2] + \ldots \\ &+ (x - x_0)(x - x_1)\ldots(x - x_{n-1})f[x_0, x_1, \ldots, x_n] \\ &+ (x - x_0)(x - x_1)\ldots(x - x_n)f[x_0, x_1, \ldots, x_n, x], \end{aligned}$$

  – O polinômio de grau no máximo n que interpola $f(x)$ nos pontos $x_0, x_1, \ldots, x_n$[6] é, portanto,

$$\begin{aligned} p_n(x) = f[x_0] &+ (x - x_0)f[x_0, x_1] + (x - x_0)(x - x_1)f[x_0, x_1, x_2] + \ldots \\ &+ (x - x_0)(x - x_1)\ldots(x - x_{n-1})f[x_0, x_1, \ldots, x_n] \end{aligned}$$

Exemplo: Considerando-se

x	-1	0	3
$f(x)$	15	8	-1

1. Determine o polinômio de interpolação pela forma de Newton;
2. Calcule uma aproximação para $f(2)$ usando a fórmula obtida no item anterior.

- *Solução:* Sabe-se que

$$\begin{aligned} x_0 &= -1 & f_0 &= f(x_0) = 15 \\ x_1 &= 0 & f_1 &= f(x_1) = 8 \\ x_2 &= 3 & f_2 &= f(x_2) = -1, \end{aligned}$$

e $n = 2$.

[6] Prova: ver, ex.: (FRANCO, 2006)

- Logo, o polinômio de interpolação na forma de Newton é dado por

$$P_2(x) = f[x_0] + (x - x_0)f[x_0, x_1] + (x - x_0)(x - x_1)f[x_0, x_1, x_2]$$

- Tabela de diferenças divididas:

x	Ordem 0	Ordem 1	Ordem 2
-1	**15**		
		-7	
0	8		**1**
		-3	
3	-1		

- Portanto,

$$\begin{aligned} P_2(x) &= \mathbf{15} + (x - (-1))(\mathbf{-7}) + (x - (-1))(x - 0)\mathbf{1} \\ &= 15 - 7(x + 1) + x(x + 1) \\ &= x^2 - 6x + 8\,. \end{aligned}$$

- Logo,

$$f(2) = 2^2 - 6 \cdot 2 + 8 = 0\,.$$

3.4 Erro na interpolação

- Ao se aproximar uma função $f(x)$ por um polinômio interpolador de grau menor ou igual a n, comete-se um erro $E_n(x) = f(x) - p_n(x)$.
- Ex.: isolando-se $f(x)$ na Eq. (2):

$$\begin{aligned} f(x) &= f(x_0) + (x - x_0)f[x_0, x] \\ &= p_0(x) + E_0(x) \end{aligned}$$

  - $E_0(x) = f(x) - p_0(x) = (x - x_0)f[x_0, x]$ é o *erro absoluto* cometido ao se aproximar $f(x)$ por $p_0(x)$.

- Da mesma, forma, observando-se a Eq. (4), temos que

$$E_1(x) = f(x) - p_1(x) = (x - x_0)(x - x_1)f[x_0, x_1, x]\,.$$

- Prosseguindo:

$$\begin{aligned} E_2(x) &= (x-x_0)(x-x_1)(x-x_2)f[x_0,x_1,x_2,x]\,, \\ &\vdots \qquad\qquad\qquad\qquad \vdots \\ E_n(x) &= (x-x_0)(x-x_1)\ldots(x-x_n)f[x_0,x_1,\ldots,x_n,x] \\ &= f(x)-p_n(x),\ \forall x\in[x_0,x_n]\,. \end{aligned}$$

- *Problema:* determinação de $f[x_0, x_1, \ldots, x_n, x]$.

Teorema

- Sejam $x_0 < x_1 < x_2 < \cdots < x_n$ $(n+1)$ pontos;
- Seja $f(x)$ função real com derivadas até ordem $(n+1)$, $\forall x \in [x_0, x_n]$;
- Seja $p_n(x)$ o polinômio que interpola $f(x)$ nos $(n+1)$ pontos.
- Então, $\forall x \in [x_0, x_n]$:

$$E_n(x) = f(x) - p_n(x) = (x-x_0)(x-x_1)\ldots(x-x_n)\frac{f^{(n+1)}(\xi_x)}{(n+1)!}\,, \quad (5)$$

  para algum valor $\xi_x \in (x_0, x_n)$.

- Demonstração: ver ex.: RUGGIERO; LOPES (1996)
- Note, do teorema, que $\dfrac{f^{(n+1)}(\xi_x)}{(n+1)!} = f[x_0, x_1, \ldots, x_n, x]$.

Exemplo

Obter $\ln(3,7)$ por *interpolação linear*, onde $\ln(x)$ está tabelada como segue:

x	1	2	3	4
$\ln(x)$	0	0,6931	1,0986	1,3863

- $x = 3,7 \in (3,\ 4)$: escolhe-se $x_0 = 3$ e $x_1 = 4$.
- Logo,

$$\begin{aligned} p_1(x) &= f(x_0) + (x-x_0)f[x_0,x_1] \\ &= 1,0986 + (x-3)\frac{(1,3863-1,0986)}{4-3} \\ &= 1,0986 + (x-3)(0,2877) \end{aligned}$$

- Aproximação: $p_1(3,7) = 1,3000$ (com 4 casas decimais)
- Erro: $E_1(3,7) = \ln(3,7) - p_1(3,7) = 1,3083 - 1,3 = 8,3 \times 10^{-3}$.
- Do teorema, $E_1(x) = (x - x_0)(x - x_1)f''(\xi_x)/2$, $\xi_x \in (x_0, x_1)$.
- Para $x = 3,7$, considerando que $f''(x) = -1/x^2$:

$$E_1(3,7) = (3,7-3)(3,7-4)\frac{-1}{2\xi_x^2} = 8,3 \times 10^{-3}$$

- Resolvendo-se, $\xi_x = 3,5578$.

Observação
Somente foi possível determinar ξ_x porque no exemplo, $f(x)$ – e $f''(x)$ – são funções conhecidas. Logo, a fórmula vista tem uso limitado.

Limitante superior para o erro

- *Corolário 1:* sob as hipóteses do teorema anterior, se $f^{(n+1)}(x)$ for contínua em $[x_0, x_n]$, então

$$|E_n(x)| = |f(x) - p_n(x)| \leq |(x - x_0)(x - x_1)\dots(x - x_n)|.\frac{M_{n+1}}{(n+1)!}\,,$$

  onde $M_{n+1} = \max_{x\in[x_0,x_n]} |f^{(n+1)}(x)|$.

- *Corolário 2:* Além das hipóteses anteriores, se os pontos forem *igualmente espaçados*, i.e.,

$$x_1 - x_0 = x_2 - x_1 = \cdots = x_n - x_{n-1} = h > 0\,,$$

  então

$$|E_n(x)| = |f(x) - p_n(x)| < \frac{h^{n+1}M_{n+1}}{4(n+1)}\,.$$

Exercício
Seja $f(x) = e^x + x - 1$ tabelada como segue. Obter $f(0,7)$ por interpolação linear e analisar o erro obtido, encontrando os limitantes superiores por ambos os corolários.

x	0	0,5	1	1,5	2
$f(x)$	0	1,1487	2,7183	4,9811	8,3890

Estimativa para o erro

- Na maior parte das vezes, a função $f(x)$ é dada apenas na forma de tabela.
- Nestes casos, $|E_n(x)|$ não pode ser obtido, apenas uma estimativa.
- Construindo-se a tabela de diferenças divididas, até ordem $(n+1)$, pode se usar o *maior valor* (em módulo) das mesmas como uma aproximação para $\dfrac{M_{n+1}}{(n+1)!}$ em $[x_0, x_n]$:

$$|E_n(x)| \approx |(x-x_0)(x-x_1)\dots(x-x_n)| \times \max\left(|\text{diferenças divididas até ordem } (n+1)|\right)$$

Exemplo

Seja $f(x)$ dada por:

x	0,2	0,34	0,4	0,52	0,6	0,72
$f(x)$	0,16	0,22	0,27	0,29	0,32	0,37

1. Obter $f(0,47)$ usando um polinômio de grau 2.
2. Dar uma estimativa para o erro.

Tabela de diferenças divididas:

x	Ordem 0	Ordem 1	Ordem 2	Ordem 3
$0,2$	0,16			
		0,4286		
0,34	0,22		2,0235	
		0,8333		$-17,8963$
$x_0 = 0,4$	**0,27**		$-3,7033$	
		0,1667		**18,2494**
$x_1 = 0,52$	0,29		**1,0415**	
		0,375		$-2,6031$
$x_2 = 0,6$	0,32		0,2085	
		0,4167		
0,72	0,37			

- 3 pontos de interpolação ($n = 2$):
  - 2 devem ser 0,4 e 0,52.
  - Outro pode ser tanto 0,34 quanto 0,6 (será considerado este último no exemplo)

- Logo,

$$\begin{aligned} p_2(x) &= f(x_0) + (x - x_0)f[x_0, x_1] + (x - x_0)(x - x_1)f[x_0, x_1, x_2] \\ &= 0,27 + (x - 0,4)0,1667 + (x - 0,4)(x - 0,52)(1,0415) \end{aligned}$$

1. $p_2(0,47) = 0,2780 \approx f(0,47)$.
2. Erro:

$$\begin{aligned} |E_2(0,47)| &\approx |(0,47 - 0,4)(0,47 - 0,52)(0,47 - 0,6)||18,2492| \\ &\approx 8,303 \times 10^{-3}\,. \end{aligned}$$

3.5 Exercícios

1. Para o último exemplo visto, aproxime $f(0,47)$ usando $p_2(x)$ e os pontos 0,34, 0,4 e 0,52. Estime qual o erro cometido ao se fazer tal aproximação.
2. Considere a tabela:

x	1	3	4	5
$f(x)$	0	6	24	60

   (a) Determinar o polinômio de interpolação, na forma de Lagrange, sobre todos os pontos.
   (b) Calcular $f(3,5)$.
3. Sabendo-se que $e = 2,72$, $\sqrt{e} = 1,65$ e que a equação $x - e^{-x} = 0$ tem uma raiz em $[0,1]$, determinar o valor dessa raiz, usando a Fórmula de Lagrange sobre 3 pontos.
4. Considerando-se a tabela com a evolução da população de Uberlândia, estime qual a população de Uberlândia em 2005, usando polinômios de grau 1, 2, e 3. Para cada caso, forneça uma estimativa para o erro.
5. Usando o polinômio de grau 3 do item anterior, determine em quais momentos a população de Uberlândia atingiu as marcas de 400 000 e 650 000 habitantes.
6. Dada a função $f(x) = 4x^5 - 2x + 2$, tabelá-la nos pontos 0, ± 1 e ± 2 e construir o polinômio de interpolação no intervalo $[-2,2]$.
7. Para o item anterior, forneça limitantes superiores para o erro em $x = -0,5$, uma vez que $f(x)$ é conhecida e os pontos são igualmente espaçados.
8. Escreva um algoritmo para gerar, a partir de n pontos $x_0, \ldots, x_n$, as diferenças divididas até ordem n.

Referências

1. BURDEN, R. L.; FAIRES, J. D. *Numerical Analysis*, 6th ed., Brooks/Cole Publishing Company, 1997.

2. FRANCO, N. B. *Cálculo numérico*. São Paulo: Pearson Prentice Hall, 2006.

3. RUGGIERO, M. A. G.; LOPES, V. L. R. *Cálculo numérico: aspectos teóricos e computacionais*. 2ª. ed. São Paulo: Makron Books. 1996.

Os materiais de parte desta seção foram gentilmente cedidos por Mauricio C. Escarpinati (FACOM/UFU)

Adaptações: Renato Pimentel, FACOM/UFU

4 Teoria da aproximação: método dos mínimos quadrados

4.1 Introdução

Vimos que uma forma de se trabalhar com uma função dada em termos de uma tabela de valores é o uso da *interpolação polinomial*.

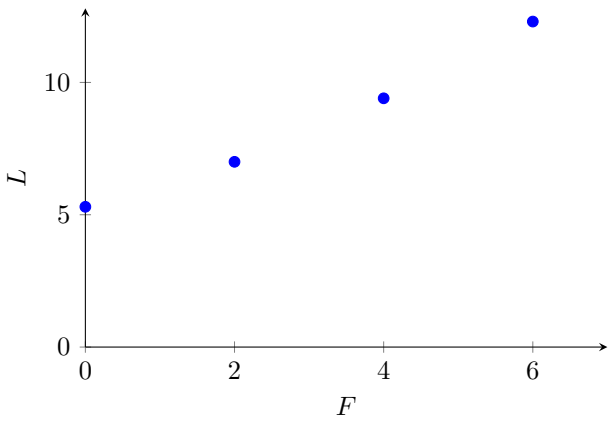
- Contudo, não se aconselha o uso da interpolação polinomial quando:
  1. É preciso do valor da função em algum ponto *fora do intervalo* de tratamento (*extrapolação*);
  2. Os valores tabelados são resultados de experimento, porque estes valores conterão erros inerentes ao processo de obtenção de dados (Capítulo 1), imprevisíveis.
- Logo, precisa-se ajustar aos dados uma função que seja uma *aproximação* – o melhor possível – dos mesmos, permitindo inclusive extrapolações com algum nível tolerável de erro (margem de segurança).

Motivação (BURDEN; FAIRES, 1997)
Sabe-se pela *Lei de Hooke* que quando uma força é aplicada sobre uma mola, seu comprimento aumenta. Tal aumento é correspondente a uma *função linear* da força aplicada, com uma razão de proporcionalidade K (constante da mola):

- Seja E o comprimento da mola em repouso, e L o comprimento da mola quando sujeita à uma força F.
- Então:

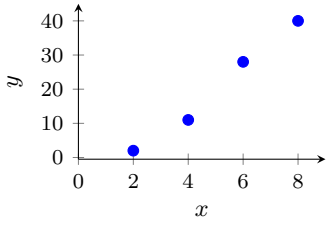
$$F(L) = K(L - E)$$

- Exemplo, se uma mola possui, $E = 5,3$ unidades de comprimento, e, após aplicação de forças de 2, 4 e 6 unidades de força, respectivamente, a mola se estender a comprimentos 7, 9,4 e 12,3, obtém-se o gráfico:



- Note que os pontos não estão sobre uma reta. Logo, não existe função linear que interpole todos.
- Seja agora o exemplo que segue:

x_i	f_i
2	2
4	11
6	28
8	40



- Interpolação exige que uma função ou polinômio seja definido de modo a assumir o valor f_i para todo x_i correspondente.
- Os pontos dados sugerem uma *relação linear* existe entre x e f.
  - Embora não exista reta passe por todos os pontos simultaneamente.
- Nesta situação, interpolação "forçada" em todos os pontos possivelmente introduz *oscilações* indesejadas.
- *Melhor alternativa*: determinar qual a *melhor linha* que representa os pontos, mesmo que não passe por nenhum dos mesmos, como no gráfico: a que *mais se aproxima* $\Rightarrow$ *ajuste de curvas*.

4.2 Método dos mínimos quadrados (caso discreto)

- Dados m pontos tabelados (x_1, f_1), (x_2, f_2), $\ldots$, (x_m, f_m), com $x_i \in [a, b]$, $\forall i$, deseja-se *ajustar* uma função $\varphi(x)$ aos mesmos.

- A função φ é uma *combinação linear* de funções $g_1(x)$, $g_2(x)$, ..., $g_n(x)$:

$$\varphi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \cdots + \alpha_n g_n(x),$$

  onde $\alpha_i \in \mathbb{R}$, $\forall i$. Deve se considerar $m \geq n$.

- Se $d_i = f_i - \varphi(x_i)$ é o *desvio* em x_i, então o *método dos mínimos quadrados* consiste em determinar os coeficientes α_1, α_2, ..., α_n tais que a *soma dos quadrados dos desvios*,

$$\sum_{i=1}^{m} d_i^2 = \sum_{i=1}^{m} \left[f_i - \varphi(x_i)\right]^2 .$$

  seja mínima.

- No caso de ambos os exemplos vistos (Lei de Hooke e dos 4 pontos), podemos definir:

  - $g_1(x) = 1$,
  - $g_2(x) = x$.

- Logo,

$$\varphi(x) = \alpha_1 + \alpha_2 x\,.$$

- Note que em ambos os casos o número de pontos é $m = 4$, e $n = 2$ funções são usadas para definir φ.

Observação
Embora φ seja dada por uma combinação linear de funções (coeficientes α_i reais e constantes), as funções $g_i(x)$ podem ser não-lineares, ex.: $g_1(x) = \operatorname{sen}(x)$, $g_2(x) = x^2$, etc.

Determinação dos coeficientes

- Como visto, é preciso minimizar a soma dos quadrados dos desvios para melhor ajustar uma curva aos pontos.

- Seja então $F(\alpha_1, \alpha_2, \ldots, \alpha_n)$ tal soma:

$$F(\alpha_1, \alpha_2, \ldots, \alpha_n) = \sum_{i=1}^{m} d_i^2 = \sum_{i=1}^{m} \left[f_i - \varphi(x_i)\right]^2 .$$

- Minimizar a função implica encontrar pontos críticos, i.e. os pontos $(\alpha_1, \alpha_2, \ldots, \alpha_n)$ onde

$$\frac{\partial F}{\partial \alpha_j}\Big|_{(\alpha_1, \alpha_2, \ldots, \alpha_n)} = 0,\ j = 1, 2, \ldots, n$$

- Para cada $j = 1, 2, \ldots, n$:

$$\frac{\partial F}{\partial \alpha_j}|_{(\alpha_1, \alpha_2, \ldots, \alpha_n)} = 2\sum_{i=1}^{m} [f_i - \alpha_1 g_1(x_i) - \cdots - \alpha_n g_n(x_i)] [-g_j(x_i)]$$

- Como a derivada deve ser nula no ponto crítico, resta

$$\sum_{i=1}^{m} [f_i - \alpha_1 g_1(x_i) - \cdots - \alpha_n g_n(x_i)] [g_j(x_i)] = 0, j = 1, 2, \ldots, n.$$

- Ou seja, obtém-se o sistema:

$$\begin{cases} \left[\sum_{i=1}^{m} g_1(x_i)g_1(x_i)\right] \alpha_1 + \cdots + \left[\sum_{i=1}^{m} g_n(x_i)g_1(x_i)\right] \alpha_n = \sum_{i=1}^{m} f_i g_1(x_i) \\ \left[\sum_{i=1}^{m} g_1(x_i)g_2(x_i)\right] \alpha_1 + \cdots + \left[\sum_{i=1}^{m} g_n(x_i)g_2(x_i)\right] \alpha_n = \sum_{i=1}^{m} f_i g_2(x_i) \\ \vdots \\ \left[\sum_{i=1}^{m} g_1(x_i)g_n(x_i)\right] \alpha_1 + \cdots + \left[\sum_{i=1}^{m} g_n(x_i)g_n(x_i)\right] \alpha_n = \sum_{i=1}^{m} f_i g_n(x_i), \end{cases}$$

  linear com n equações e n incógnitas $(\alpha_1, \alpha_2, \ldots, \alpha_n)$.

- O sistema pode ser reescrito na forma matricial $\mathbf{A}\boldsymbol{\alpha} = \mathbf{b}$,

$$\begin{cases} a_{11}\alpha_1 + a_{12}\alpha_2 + \cdots + a_{1n}\alpha_n = b_1 \\ a_{21}\alpha_1 + a_{22}\alpha_2 + \cdots + a_{2n}\alpha_n = b_2 \\ \vdots \\ a_{n1}\alpha_1 + a_{n2}\alpha_2 + \cdots + a_{nn}\alpha_n = b_n, \end{cases} \tag{6}$$

  onde:

  - $\mathbf{A} = (a_{ij})$ e $a_{ij} = \sum_{i=1}^{m} g_j(x_i)g_i(x_i) = a_{ji}$ (matriz simétrica).
  - $\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_n)^t$
  - $\mathbf{b} = (b_1, \ldots, b_n)^t$, tal que $b_i = \sum_{i=1}^{m} f_i g_i(x_i)$.

Algumas considerações sobre o sistema $\mathbf{A}\boldsymbol{\alpha} = \mathbf{b}$:

- O produto $\sum_{i=1}^{m} g_j(x_i)g_i(x_i)$ representa um *produto escalar* entre as funções g_i e g_j.

- Seja $\mathbf{g}_\ell = (g_\ell(x_1), g_\ell(x_2), \ldots, g_\ell(x_m))^t$. Se $g_1(x)$, $g_2(x)$, $\ldots$, $g_n(x)$ forem tais que os vetores $\mathbf{g_1}$, $\mathbf{g_2}$, $\ldots$, $\mathbf{g_n}$ sejam linearmente independentes, então:
  - $\det \mathbf{A} \neq 0$, logo o sistema (6) admite solução única $\bar{\alpha}_1$, $\bar{\alpha}_2$, $\ldots$, $\bar{\alpha}_n$;
  - A função $F(\alpha_1, \ldots, \alpha_n)$ atinge seu *mínimo* em $(\bar{\alpha}_1, \ldots, \bar{\alpha}_n)$.

4.3 Caso linear

- No caso dos exemplos, dado que $\varphi = \alpha_1 + \alpha_2 x$ – i.e. $g_1(x) = 1$, $g_2(x) = x$ - obtém-se o sistema:

$$\begin{cases} 4\alpha_1 + \left(\sum_{i=1}^{4} x_i\right)\alpha_2 = \sum_{i=1}^{4} f_i \\ \left(\sum_{i=1}^{4} x_i\right)\alpha_1 + \left(\sum_{i=1}^{4} x_i^2\right)\alpha_2 = \sum_{i=1}^{4} x_i f_i \end{cases}$$

  (considerando-se que o número de pontos é $m = 4$ para ambos).

- Para o segundo exemplo, os pontos são tabelados como

x_i	2	4	6	8
f_i	2	11	28	40

- Assim:

$$\sum_{i=1}^{4} x_i = 20, \qquad \sum_{i=1}^{4} f_i = 81, \qquad \sum_{i=1}^{4} x_i^2 = 120, \qquad \sum_{i=1}^{4} x_i f_i = 536.$$

- Logo, chega-se ao sistema

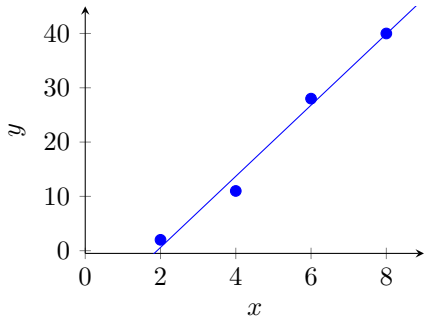
$$\begin{cases} 4\alpha_1 + 20\alpha_2 = 81 \\ 20\alpha_1 + 120\alpha_2 = 536, \end{cases}$$

  cuja solução é $\alpha_1 = -12,5$, $\alpha_2 = 6,55$.

- Portanto, para os pontos dados, a reta que melhor os aproxima é dada por

$$\varphi(x) = -12,5 + 6,55x,$$

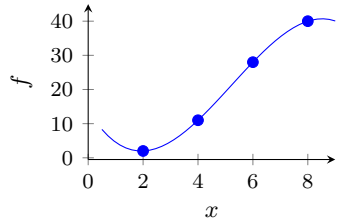
  dada pela reta no gráfico que segue:



- É possível, por exemplo, estimar que para $x = 10$ e $x = 1$ tem-se $f = 53$ e $f = -5,95$, respectivamente.

E se fosse usada a interpolação polinomial?
Neste caso, teríamos

$$f(x) = -0,27083x^3 + 4,25x^2 - 13,41667x + 14$$



Para $x = 10$ e $x = 1$ tem-se $f = 34$ e $f = 4,5625$, respectivamente. Qual a abordagem seria mais adequada?

4.4 Caso não linear

- Em certos casos, a família de funções é *não-linear* nos parâmetros α_i a serem determinados.
- Exemplo: ajuste de uma exponencial do tipo

$$f(x) \approx \varphi(x) = \alpha_1 e^{-\alpha_2 x}, \qquad \alpha_1 > 0,\ \alpha_2 > 0$$

- Note que a φ é não linear em relação a α_2 – ex.: ao se dobrar o valor de α_2, o valor de φ é multiplicado por 2?

Linearização
Em casos como este, faz-se uma *linearização* do problema, por meio de alguma transformação apropriada.

- Exemplo:

$$y \approx \alpha_1 e^{-\alpha_2 x} \quad \Rightarrow \quad z = \ln(y) \approx \ln(\alpha_1) - \alpha_2 x$$

- Se $a_1 = \ln(\alpha_1)$ e $a_2 = -\alpha_2$, então aplica-se o método dos mínimos quadrados em

$$\psi(x) = a_1 + a_2 x \approx z$$

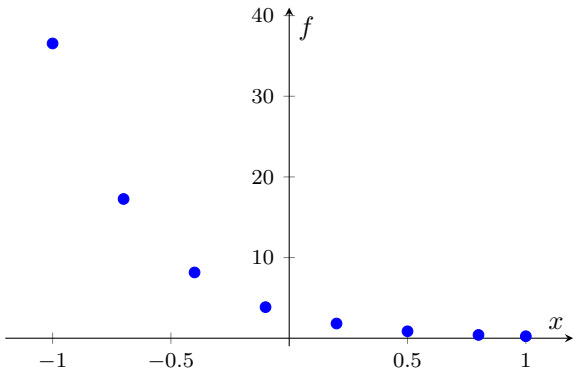
  - Uma vez obtidos a_1 e a_2, calculam-se α_1 e α_2.

- *Observação:* Os parâmetros obtidos não são ótimos pelo critério dos mínimos quadrados, pois o ajuste é sobre o problema linearizado ao invés do original
- No exemplo, a_1 e a_2 ajustam a função $\psi(x)$ à $z(x)$ no sentido dos mínimos quadrados.
- Não se pode afirmar que α_1 e α_2 ajustam $\varphi(x)$ à $y = f(x)$ pelo mesmo critério.

Exemplo

x	$-1,0$	$-0,7$	$-0,4$	$-0,1$	0,2	0,5	0,8	1,0
$f(x)$	36,547	17,264	8,155	3,852	1,820	0,860	0,406	0,246

- Diagrama de dispersão:



- Ajustar $y \approx \varphi_(x) = \alpha_1 e^{-\alpha_2 x}$.

- Como visto, a linearização é dada por $z = \ln(y) \approx \ln(\alpha_1 e^{-\alpha_2 x}) = \ln(\alpha_1) - \alpha_2 x = \psi(x)$.
- Logo, ao invés de y, será ajustada $z = \ln(y)$ por mínimos quadrados, encontrando-se $\psi(x) = a_1 + a_2 x$, onde:

$$a_1 = \ln(\alpha_1) \qquad\qquad a_2 = -\alpha_2 \, .$$

  - Ou seja, tem-se $g_1(x) = 1$ e $g_2(x) = x$.

- Os pontos são dados, portanto, por

x	$-1,0$	$-0,7$	$-0,4$	$-0,1$	0,2	0,5	0,8	1,0
$z = \ln(y)$	3,599	2,849	2,099	1,349	0,599	-0,151	-0,901	-1,402

- a_1 e a_2 são solução do sistema

$$\begin{cases} \left(\sum_{i=1}^{8} g_1(x_i) g_1(x_i)\right) a_1 + \left(\sum_{i=1}^{8} g_2(x_i) g_1(x_i)\right) a_2 = \sum_{i=1}^{8} z(x_i) g_1(x_i) \\ \left(\sum_{i=1}^{8} g_1(x_i) g_2(x_i)\right) a_1 + \left(\sum_{i=1}^{8} g_2(x_i) g_2(x_i)\right) a_2 = \sum_{i=1}^{8} z(x_i) g_2(x_i) \end{cases}$$

  linear da forma $\mathbf{Aa} = \mathbf{b}$, de 2 equações e 2 incógnitas (a_1 e a_2).

- Como $g_1(x) = 1$:

$$\sum_{i=1}^{8} g_1(x_i) g_1(x_i) = \sum_{i=1}^{8} 1 = a_{11} = 8$$

- Como $g_2(x) = x$:

$$\sum_{i=1}^{8} g_2(x_i) g_2(x_i) = \sum_{i=1}^{8} x_i^2 = a_{22} = 3,59$$

- As outras 2 entradas da matriz (simétrica) são:

$$a_{12} = a_{21} = \sum_{i=1}^{8} g_2(x_i) g_1(x_i) = \sum_{i=1}^{8} g_1(x_i) g_2(x_i) = \sum_{i=1}^{8} x_i = 0,3$$

- Finalmente, do lado direito do sistema:

$$b_1 = \sum_{i=1}^{8} z(x_i) g_1(x_i) = \sum_{i=1}^{8} z(x_i) = 8,041$$
$$b_2 = \sum_{i=1}^{8} z(x_i) g_2(x_i) = \sum_{i=1}^{8} z(x_i) x_i = -8,646$$

- Logo,

$$\mathbf{A} = \begin{pmatrix} 8 & 0,3 \\ 0,3 & 3,59 \end{pmatrix}, \qquad \mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}, \qquad \mathbf{b} = \begin{pmatrix} 8,041 \\ -8,646 \end{pmatrix}.$$

- Deve-se então resolver o sistema

$$\begin{cases} 8,0a_1 + 0,3a_2 = 8,041 \\ 0,3a_1 + 3,59a_2 = -8,646\,, \end{cases}$$

  cuja solução é $a_1 = 1,099$ e $a_2 = -2,5$.

- Finalmente, são calculados os valores de α_1 e α_2:
  - De $a_1 = \ln(\alpha_1)$ obtém-se: $\alpha_1 = e^{a_1} = e^{1,099} = 3,001$.
  - De forma similar, $\alpha_2 = -a_2 = 2,5$.

- Portanto, a curva que melhor ajusta o problema não linear é dada por $\varphi(x) = 3,001e^{-2,5x}$.

Outros exemplos de ajustes não lineares:

- *Hipérbole*: $y \approx \dfrac{1}{\alpha_1 + \alpha_2 x} = \varphi(x)$.
  - Define-se $z = 1/y \approx \alpha_1 + \alpha_2 x$.
- *Curva exponencial*: $y \approx \alpha_1 \alpha_2^x = \varphi(x)$.
  - Se $y > 0$, define-se $z = \ln(y) \approx \ln(\alpha_1) + x \ln(\alpha_2) = a_1 + a_2 x = \psi(x)$.
- *Curva geométrica*: $y \approx \alpha_1 x^{\alpha_2} = \varphi(x)$.
  - Se $x > 0$, $y > 0$, define-se $z = \ln(y) \approx \ln(\alpha_1) + \alpha_2 \ln(x) = a_1 + a_2 \ln(x) = a_1 + a_2 t = \psi(t)$.
- *Curva trigonométrica*: $y \approx \alpha_1 + \alpha_2 \cos(\omega x) = \varphi(x)$
  - Se $t = \cos(\omega x)$, então $\varphi(t) = \alpha_1 + \alpha_2 t$ e assim minimiza-se a soma dos quadrados dos desvios em y.

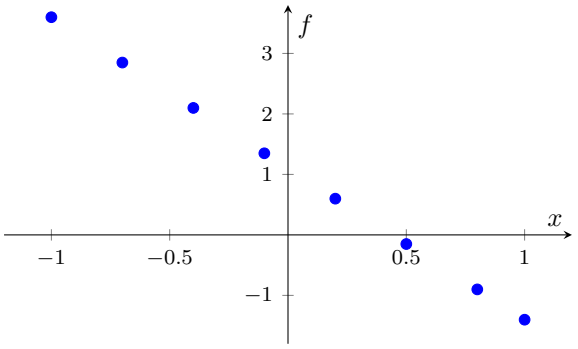
Teste de alinhamento

- Já escolhidos os valores de $\alpha_1, \alpha_2, \ldots, \alpha_n$, é possível verificar se a escolha é adequada $\Rightarrow$ *teste de alinhamento*:

  1. fazer a linearização da função não linear escolhida;
  2. fazer o diagrama de dispersão dos novos dados;
  3. se os pontos de tal diagrama estiverem alinhados (ou aproximadamente alinhados), então a função não linear escolhida é de fato adequada para representar os pontos.

No caso do exemplo anterior, verifica-se que a escolha de $\varphi_(x) = \alpha_1 e^{-\alpha_2 x}$ foi boa.

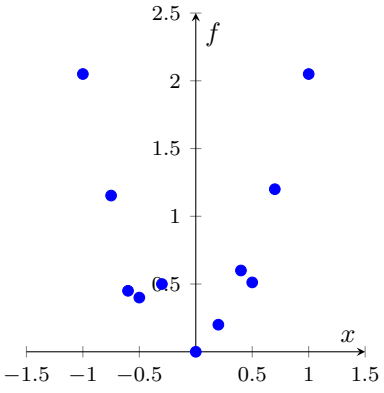
x	$-1,0$	$-0,7$	$-0,4$	$-0,1$	0,2	0,5	0,8	1,0
$z = \ln(y)$	3,599	2,849	2,099	1,349	0,599	-0,151	-0,901	-1,402



4.5 Exercícios

1. Seja agora o seguinte conjunto de pontos:

x_i	f_i
-1	2,05
$-0,75$	1,153
$-0,6$	0,45
$-0,5$	0,4
$-0,3$	0,5
0	0
0,2	0,2
0,4	0,6
0,5	0,512
0,7	1,2
1,0	2,05



Determine uma aproximação para um polinômio de grau 2 usando o MMQ. Dica: use simplesmente o termo quadrático do polinômio.

2. Escreva como ficaria o sistema linear a ser resolvido para um conjunto de m pontos, considerando-se o polinômio de grau 2 a ser aproximado, dado por $\varphi(x) = \alpha_1 x^2 + \alpha_2 x + \alpha_3$.

3. Usando os pontos dados no capítulo de interpolação para a população da cidade de Uberlândia, obtenha a aproximação por mínimos quadrados, considerando:

   (a) $\varphi_1(x) = \alpha_1 x + \alpha_2$

   (b) $\varphi_2(x) = \alpha_1 x^2 + \alpha_2 x + \alpha_3$

   (c) $\varphi_3(x) = \alpha_1 e^{\alpha_2 x}$

4. Usando cada função do exercício anterior, responda:

   (a) Qual a população da Uberlândia em 2005.

   (b) Quando Uberlândia atingiu as marcas de 400 000 e 650 000 habitantes.

5. Aproxime a tabela que segue por uma função $\varphi(x) = 1 + ae^{bx}$ usando mínimos quadrados.

x_i	0	0,5	1	2,5	3
f_i	2	2,6	3,7	13,2	21

6. Encontre a função f do tipo $y = f(x) = \frac{a}{b+x}$ que ajusta a tabela de pontos a seguir:

x_i	0	0,2	0,4	0,6	0,8	1
f_i	101	85	75	66	60	55

7. Considere a função tabelada pelos pontos:

t	-8	-6	-4	-2	0	2	4
y	30	10	9	6	5	4	4

   Qual das funções ajusta melhor os pontos da tabela?

   (a) $y(t) = \dfrac{1}{a+bt}$ (b) $y(t) = ab^t$

Referências

1. BURDEN, R. L.; FAIRES, J. D. *Numerical Analysis*, 6th ed., Brooks/Cole Publishing Company, 1997.

2. FRANCO, N. B. *Cálculo numérico.* São Paulo: Pearson Prentice Hall, 2006.

3. JUSTO, A. R. J. et al. *Cálculo Numérico: Um Livro Colaborativo. Versão Python.* [s.l.], 2020.

4. RUGGIERO, M. A. G.; LOPES, V. L. R. *Cálculo numérico: aspectos teóricos e computacionais.* 2ª. ed. São Paulo: Makron Books. 1996.

Os materiais de parte desta seção foram gentilmente cedidos por Mauricio C. Escarpinati (FACOM/UFU)

Adaptações: Renato Pimentel, FACOM/UFU

5 Sistemas lineares

5.1 Introdução

Sistemas lineares são capazes de modelar diversos problemas, como (FRANCO, 2006):

- Determinação do potencial em redes elétricas;
- Cálculos de tensão em estruturas metálicas;
- cálculo da razão de escoamento num sistema hidráulico com derivações (ramificações)
- Previsão da concentração de reagentes sujeitos a reações químicas simultâneas
- Métodos numéricos para resolução de problemas de equações diferenciais

O modelo matemático em tais exemplos se reduz ao problema de resolver um sistema com equações simultâneas.

- Mais difícil quando as equações são *não-lineares*;
- Maioria das aplicações, entretanto, envolve o caso linear.
  - Deve-se então escolher o *método numérico* apropriado para preservar a precisão e acurácia, quando em sistemas de grande porte.

Equação linear

Uma equação é *linear* quando cada termo possui *no máximo uma variável*, e as variáveis aparecem *somente na primeira potência.*

- A equação $3x + 4y - 10z = 3$, por exemplo, é linear;
- Já $xy - 3z = -3$ não é linear, pois embora x e y apareçam no primeiro termo com potência 1, somente uma delas poderia estar presente
- $x^3 + y - z = 0$ também é não-linear, devido à presença da potência 3 em x no primeiro termo.

Sistema linear

Um *sistema linear*, de forma geral, é definido por m equações lineares e envolvendo n variáveis ou incógnitas.

- Uma *solução* para tal sistema é um conjunto de valores para as n variáveis de modo que quando tais valores são substituídos nas m equações elas se satisfazem simultaneamente.

- Por exemplo, o sistema linear

$$\begin{cases} x + y + z = 1 \\ x - y - z = 1 \\ 2x + 3y - 4z = 9 \end{cases}$$

possui solução $x = 1$, $y = 1$ e $z = -1$.

  - Ao substituir os valores acima no sistema, todas as igualdades são satisfeitas.

Forma matricial

O sistema do exemplo pode ser escrito na *forma matricial* como

$$\begin{pmatrix} 1 & 1 & 1 \\ 1 & -1 & -1 \\ 2 & 3 & -4 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 9 \end{pmatrix}$$

- Quando se efetua a multiplicação da matriz pelo vetor do lado esquerdo, obtém-se o sistema na forma de equações anterior.

Forma geral de um sistema linear

Um sistema linear com m equações e n variáveis tem a forma geral

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \qquad\qquad\qquad\qquad\qquad\quad \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m \end{cases}$$

e respectiva forma matricial

$$\begin{pmatrix} a_{11} & a_{12} \cdots\cdots a_{1n} \\ a_{21} & a_{22} \cdots\cdots a_{2n} \\ \vdots & \vdots \quad \ddots \quad \vdots \\ a_{m1} & a_{m2} \cdots\cdots a_{mn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix}$$

ou $\mathbf{Ax} = \mathbf{b}$, onde $\mathbf{A}$ é a *matriz dos coeficientes*, $\mathbf{b}$ é o vetor do *termo independente* e $\mathbf{x}$ é o *vetor solução*.

5.2 Classificação de sistemas lineares

Sistemas lineares são classificados de acordo com o *número de soluções*:

- *Sistema possível* ou *consistente*:

  - *Determinado* (SPD): admite solução única;
  - *Indeterminado* (SPI): admite mais de uma solução.

- *Sistema impossível* ou *inconsistente*: Não admite solução (solução inexistente).

Sistema possível e determinado

O sistema

$$\begin{cases} x + y = 6 \\ x - y = 2 \end{cases}$$

admite como solução $x = 4$ e $y = 2$ (sistema possível).

- Como nenhum outro par de valores x e y satisfaz o problema, então o sistema acima é sistema possível e determinado (SPD).

Sistema possível e indeterminado

Já o sistema

$$\begin{cases} x + y = 1 \\ 2x + 2y = 2 \end{cases}$$

admite *infinitas soluções* do tipo $(x, 1 - x)^t$, ou seja, basta escolher um valor real de x e tomar $y = 1 - x$.

- Exemplos de soluções: $(0, 1)^t$, $(1, 0)^t$, $(1/2, 1/2)^t$, $(\pi, 1 - \pi)^t$, $(100, -99)^t$, etc.

- Logo o sistema acima é possível e indeterminado (SPI).

Sistema impossível

Por fim, o sistema

$$\begin{cases} x + y = 1 \\ x + y = 4 \end{cases}$$

não admite solução.

- Não é possível determinar valores de x e y de modo que simultaneamente $x + y = 1$ e $x + y = 4$.

- Logo o sistema acima é impossível (SI).

Sistemas homogêneos e solução trivial

Sistema homogêneo
Um sistema é *homogêneo* se possui o lado direito (termo independente) nulo, ou seja, temos $\mathbf{Ax} = \mathbf{0}$.

- Todo sistema homogêneo é possível, pois há pelo menos uma solução, a solução $\mathbf{x} = \mathbf{0}$.
- A solução acima é denominada *solução trivial* do sistema homogêneo.

Exemplo: o sistema

$$\begin{cases} x + y = 0 \\ 2x + 3y = 0 \end{cases}$$

é homogêneo. Note que $x = 0$ e $y = 0$ são valores de x, y que satisfazem ambas as equações do sistema simultaneamente.

Observações importantes
Embora para os exemplos vistos, considerou-se duas equações lineares e duas variáveis, a classificação de sistemas é válida no caso geral $m \times n$.

- Neste curso serão discutidos métodos numéricos para a resolução de sistemas lineares $n \times n$ – i.e. número de equações igual ao número de variáveis.
- Uma breve discussão teórica para o caso geral $m \times n$ pode ser encontrada em (RUGGIERO; LOPES, 1996).

Exercício

Para cada um dos 4 sistemas exemplificados anteriormente, trace no plano cartesiano (x, y) as retas correspondentes a cada uma de suas equações. Em cada caso, o que se observa em relação a tais retas?

Sistemas triangulares

Sistema triangular inferior
Um sistema $\mathbf{Ax} = \mathbf{b}$ é *triangular inferior* quando todas as entradas da matriz $n \times n$ de coeficientes *acima* da diagonal principal são nulas, ou seja,

$$a_{ij} = 0, \qquad i < j, \ \forall i = 1, \ldots, n-1, \ \forall j = 1, \ldots, n$$

- Logo,

$$A = \begin{pmatrix} a_{11} & 0 & \cdots & \cdots & 0 \\ a_{21} & a_{22} & \ddots & & \vdots \\ a_{31} & a_{32} & a_{33} & \ddots & \vdots \\ \vdots & \vdots & \vdots & \ddots & 0 \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{nn} \end{pmatrix}$$

- Possibilidade de resolução de forma *direta*.

Sistema triangular superior
Um sistema $\mathbf{Ax} = \mathbf{b}$ é *triangular superior* quando todas as entradas da matriz $n \times n$ de coeficientes *abaixo* da diagonal principal são nulas, ou seja,

$$a_{ij} = 0, \qquad i > j, \ \forall i = 1, \ldots, n, \ \forall j = 1, \ldots, n-1$$

- Logo,

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ 0 & a_{22} & a_{23} & \cdots & a_{2n} \\ \vdots & \ddots & a_{33} & \cdots & a_{3n} \\ \vdots & & \ddots & \ddots & \vdots \\ 0 & \cdots & \cdots & 0 & a_{nn} \end{pmatrix}$$

- Possibilidade de resolução de forma *retroativa*.

Solução retroativa
Exemplo: dado o sistema

$$\begin{cases} 3x_1 + 4x_2 - 5x_3 + x_4 = -10 \\ x_2 + x_3 - 2x_4 = -1 \\ 4x_3 - 5x_4 = 3 \\ 2x_4 = 2 \end{cases}$$

- Primeiro passo para resolução:

$$x_4 = \frac{2}{2} = 1$$

- Segundo passo para resolução:

$$\begin{gathered} 4x_3 - 5x_4 = 3 \\ 4x_3 - 5 \cdot 1 = 3 \\ x_3 = 2 \end{gathered}$$

- Terceiro passo para resolução:

$$\begin{gathered} x_2 + x_3 - 2x_4 = -1 \\ x_2 + 2 - 2 \cdot 1 = -1 \\ x_2 = -1 \end{gathered}$$

- Quarto e último passo para resolução:

$$3x_1 + 4x_2 - 5x_3 + x_4 = -10$$
$$3x_1 + 4(-1) - 5 \cdot 2 + 1 = -10$$
$$x_1 = 1$$

No caso geral:

```
x[n]=b[n]/a[n][n]
para k = n-1 : 1
   s = 0
   para j = k+1 até n
      s = s + a[k][j]*x[j]
   x[k] = (b[k]-s)/a[k][k]
```

Sistemas equivalentes

Dois sistemas lineares são equivalentes quando admitem *a mesma solução*

- Por exemplo, os sistemas

$$\begin{cases} x_1 + x_2 = 6 \\ x_1 - x_2 = 2 \end{cases}$$

e

$$\begin{cases} 2x_1 + 2x_2 = 12 \\ 2x_2 = 4 \end{cases}$$

possuem a mesma solução $(4, 2)^t$

- Note que o segundo sistema é triangular superior.

Métodos numéricos

A resolução numérica de sistemas lineares $n \times n$ compreende duas classes de métodos numéricos:

1. *Métodos diretos:* Solução pode ser encontrada, de forma exata – a menos de erros de truncamento/arredondamento – a partir de um número finito de passos. Exemplos:
   - Método da eliminação de Gauss.
   - Fatoração LU (Decomposição LU).

2. *Métodos iterativos:* Solução a partir de uma *sequência de aproximações* para o valor do vetor solução $\mathbf{x}$, até que seja obtido um valor $\mathbf{x}^*$ que satisfaça à precisão pré-estabelecida, sob certas condições. Exemplos:

   - Método de Jacobi;
   - Método de Gauss-Seidel.

5.3 Método da eliminação de Gauss

Princípio:

- Transformação do sistema linear a ser resolvido em um sistema linear triangular superior *equivalente*;
- Resolução do sistema linear triangular de forma retroativa.

A transformação do sistema linear em triangular superior equivalente envolve algumas etapas, como:

- Troca da ordem das linhas;
- Multiplicação de uma das equações por um número real não nulo;
- Substituição de uma das equações por uma *combinação linear* dela mesma com outra equação.

Matriz aumentada

A *matriz aumentada* do sistema, de ordem $n \times (n+1)$, é o ponto de partida do método da eliminação de Gauss, sendo dada por

$$\mathbf{A}^{(0)}|\mathbf{b}^{(0)} = \mathbf{A}|\mathbf{b} = \left(\begin{array}{cccc|c} a_{11}^{(0)} & a_{12}^{(0)} & \dots & a_{1n}^{(0)} & b_1^{(0)} \\ a_{21}^{(0)} & a_{22}^{(0)} & \dots & a_{2n}^{(0)} & b_2^{(0)} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1}^{(0)} & a_{n2}^{(0)} & \dots & a_{nn}^{(0)} & b_n^{(0)} \end{array}\right),$$

onde o superíndice (0) denota que estamos no passo inicial do método. Assume-se que $\det(\mathbf{A}) \neq 0$, de forma que seja sempre possível reescrever o sistema de modo que $a_{11}^{(0)} \neq 0$.

Etapa 1

- Deve-se eliminar x_1 das equações $i = 2, 3, \dots, n$.

  Para isto, da i-ésima equação subtrai-se a 1a. equação multiplicada por um *multiplicador*

$$m_{i1} = \frac{a_{i1}^{(0)}}{a_{11}^{(0)}}, \quad i = 2, \ldots, n\,,$$

onde o termo $a_{11}^{(0)} \neq 0$ é denominado *pivô* para esta etapa.

- Ao final, obtém-se

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left(\begin{array}{cccc|c} a_{11}^{(1)} & a_{12}^{(1)} & \ldots & a_{1n}^{(1)} & b_1^{(1)} \\ \mathbf{0} & a_{22}^{(1)} & \ldots & a_{2n}^{(1)} & b_2^{(1)} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \mathbf{0} & a_{n2}^{(1)} & \ldots & a_{nn}^{(1)} & b_n^{(1)} \end{array}\right)$$

A matriz acima é tal que:

- A primeira linha se mantém:

$$\begin{aligned} a_{1j}^{(1)} &= a_{1j}^{(0)}, \quad j = 1, \ldots, n \\ b_1^{(1)} &= b_1^{(0)}. \end{aligned}$$

- Para as linhas $i = 2, \ldots, n$:

$$\begin{aligned} a_{i1}^{(1)} &= 0, \\ a_{ij}^{(1)} &= a_{ij}^{(0)} - m_{i1} a_{1j}^{(0)}, \quad j = 2, \ldots, n \\ b_i^{(1)} &= b_i^{(0)} - m_{i1} b_1^{(0)}. \end{aligned}$$

Etapa 2

- Existe ao menos um elemento $a_{i2}^{(1)} \neq 0$, para $i = 2, \ldots, n$. Caso contrário, $\det(\mathbf{A}^{(1)}) = 0$, o que leva a $\det(\mathbf{A}) = 0$, contrariando a hipótese inicial.
- Logo, é possível reescrever a matriz $\mathbf{A}^{(1)}|\mathbf{b}^{(1)}$ de forma que o novo pivô, $a_{22}^{(1)}$, seja não nulo (*troca-se* a segunda linha por outra linha abaixo da mesma, caso necessário).
- Elimina-se x_2 das equações $i = 3, \ldots, n$, subtraindo-se da i-ésima linha da matriz aumentada a 2a. linha multiplicada por

$$m_{i2} = \frac{a_{ai2}^{(1)}}{a_{22}^{(1)}}, \quad i = 3, \ldots, n.$$

Ao final do processo, obtém-se

$$\mathbf{A}^{(2)}|\mathbf{b}^{(2)} = \left(\begin{array}{ccccc|c} a_{11}^{(2)} & a_{12}^{(2)} & a_{13}^{(2)} & \dots & a_{1n}^{(2)} & b_1^{(2)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \dots & a_{2n}^{(2)} & b_2^{(2)} \\ 0 & \mathbf{0} & a_{33}^{(2)} & \dots & a_{3n}^{(2)} & b_3^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & \mathbf{0} & a_{n3}^{(2)} & \dots & a_{nn}^{(2)} & b_n^{(2)} \end{array}\right), \text{ onde}$$

- $$a_{ij}^{(2)} = a_{ij}^{(1)}, \quad i = 1, 2 \text{ e } j = 1, \dots, n$$
$$b_i^{(2)} = b_i^{(1)}, \quad i = 1, 2.$$

- Para as linhas $i = 3, \dots, n$:

$$a_{i2}^{(2)} = 0,$$
$$a_{ij}^{(2)} = a_{ij}^{(1)} - m_{i2} a_{2j}^{(1)}, \quad j = 3, \dots, n$$
$$b_i^{(2)} = b_i^{(1)} - m_{i2} b_2^{(1)}.$$

Sistema triangular equivalente

Após $(n-1)$ etapas obtém-se

$$\mathbf{A}^{(n-1)}|\mathbf{b}^{(n-1)} = \left(\begin{array}{ccccc|c} a_{11}^{(n-1)} & a_{12}^{(n-1)} & a_{13}^{(n-1)} & \dots & a_{1n}^{(n-1)} & b_1^{(n-1)} \\ 0 & a_{22}^{(n-1)} & a_{23}^{(n-1)} & \dots & a_{2n}^{(n-1)} & b_2^{(n-1)} \\ \vdots & \ddots & a_{33}^{(n-1)} & \dots & a_{3n}^{(n-1)} & b_3^{(n-1)} \\ \vdots & & \ddots & \ddots & \vdots & \vdots \\ 0 & \dots & \dots & 0 & a_{nn}^{(n-1)} & b_n^{(n-1)} \end{array}\right).$$

O sistema $\mathbf{A}^{(n-1)}\mathbf{x} = \mathbf{b}^{(n-1)}$ é triangular superior e equivalente ao sistema original $\mathbf{Ax} = \mathbf{b}$.

Exemplo (RUGGIERO; LOPES, 1996)

$$\begin{cases} 3x_1 + 2x_2 + 4x_3 = 1 \\ x_1 + x_2 + 2x_3 = 2 \\ 4x_1 + 3x_2 - 2x_3 = 3 \end{cases}$$

Etapa 1: eliminar x_1 das eqs. 2 e 3

- Matriz aumentada inicial:

$$\mathbf{A}^{(0)}|\mathbf{b}^{(0)} = \left(\begin{array}{ccc|c} a_{11}^{(0)} & a_{12}^{(0)} & a_{13}^{(0)} & b_1^{(0)} \\ a_{21}^{(0)} & a_{22}^{(0)} & a_{23}^{(0)} & b_2^{(0)} \\ a_{31}^{(0)} & a_{32}^{(0)} & a_{33}^{(0)} & b_3^{(0)} \end{array}\right) = \left(\begin{array}{ccc|c} 3 & 2 & 4 & 1 \\ 1 & 1 & 2 & 2 \\ 4 & 3 & -2 & 3 \end{array}\right)$$

- Dados:

$$\text{Pivô: } a_{11}^{(0)} = 3 \qquad m_{21} = 1/3 \qquad m_{31} = 4/3$$

- Operações:

$$L_2 \leftarrow L_2 - m_{21}L_1 \qquad L_3 \leftarrow L_3 - m_{31}L_1$$

Etapa 2: eliminar x_2 da eq. 3

- Matriz aumentada após etapa 1:

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left(\begin{array}{ccc|c} 3 & 2 & 4 & 1 \\ \mathbf{0} & 1/3 & 2/3 & 5/3 \\ \mathbf{0} & 1/3 & -22/3 & 5/3 \end{array}\right) = \left(\begin{array}{ccc|c} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & b_1^{(1)} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & b_2^{(1)} \\ 0 & a_{32}^{(1)} & a_{33}^{(1)} & b_3^{(1)} \end{array}\right)$$

- Dados:

$$\text{Pivô: } a_{22}^{(1)} = 1/3 \qquad m_{32} = \frac{1/3}{1/3} = 1$$

- Operação:

$$L_3 \leftarrow L_3 - m_{32}L_2$$

Sistema triangular equivalente

- Após as 2 etapas anteriores, obtém-se

$$\mathbf{A}^{(2)}|\mathbf{b}^{(2)} = \left(\begin{array}{ccc|c} 3 & 2 & 4 & 1 \\ 0 & 1/3 & 2/3 & 5/3 \\ 0 & \mathbf{0} & -8 & 0 \end{array}\right)$$

- Logo, resolver $\mathbf{Ax} = \mathbf{b}$ é equivalente a resolver o sistema

$$\begin{cases} 3x_1 + 2x_2 + 4x_3 = 1 \\ 1/3x_2 + 2/3x_3 = 5/3 \\ -8x_3 = 0 \end{cases}$$

- A solução do sistema é dada por $\mathbf{x}^* = (-3, 5, 0)^t$.

Exemplo (FRANCO, 2006)

$$\begin{cases} 3x_1 + 3x_2 + x_3 = 7 \\ 2x_1 + 2x_2 - x_3 = 3 \\ x_1 - x_2 + 5x_3 = 5 \end{cases}$$

- Matriz aumentada inicial:

$$\mathbf{A}^{(0)}|\mathbf{b}^{(0)} = \left(\begin{array}{ccc|c} 3 & 3 & 1 & 7 \\ 2 & 2 & -1 & 3 \\ 1 & -1 & 5 & 5 \end{array}\right)$$

- Após a etapa 1, obtém-se

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left(\begin{array}{ccc|c} 3 & 3 & 1 & 7 \\ 0 & \mathbf{0} & -5/3 & -5/3 \\ 0 & -2 & 14/3 & 8/3 \end{array}\right)$$

- O elemento $a_{22}^{(1)} = 0$. Neste caso, é necessário permutar as linhas L_2 e L_3 da matriz para prosseguir.

- Após a permutação, obtém-se a matriz aumentada

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left(\begin{array}{ccc|c} 3 & 3 & 1 & 7 \\ 0 & -2 & 14/3 & 8/3 \\ 0 & 0 & -5/3 & -5/3 \end{array}\right)$$

- Como o sistema já está na forma triangular superior, pode-se fazer a solução retroativa imediatamente, o que resulta na solução $\mathbf{x}^* = (1, 1, 1)^t$.

Algoritmo da eliminação de Gauss

```
// Eliminação
para k = 1 : n-1
   para i = k+1 : n
      m = a[i][k]/a[k][k]
      a[i][k]=0
      para j = k+1 : n
         a[i][j] = a[i][j] - m*a[k][j]
      b[i] = b[i] - m*b[k]

// Solução retroativa
x[n]=b[n]/a[n][n]
para k = n-1 : 1
   s = 0
   para j = k+1 : n
      s = s + a[k][j]*x[j]
```

```
x[k] = (b[k]-s)/a[k][k]
```

Estratégias de pivotamento

- A cada etapa k do método da eliminação de Gauss requer a definição de *multiplicadores*

$$m_{ik} = \frac{a_{ik}^{(k-1)}}{a_{kk}^{(k-1)}}, \quad i = k+1, \ldots, n$$

- O pivô, que aparece no denominador de tais multiplicadores, deve ser não nulo. Viu-se um exemplo em que uma permutação de linhas foi necessária.
- Quando o pivô não é nulo, mas é próximo de zero, resultados imprecisos poderão ocorrer, devido à aritmética de precisão finita dos cálculos computacionais (situação de *mal condicionamento*).
- *Estratégias de pivotamento* podem contornar tais problemas.

Pivotamento parcial

- No início da etapa k, escolhe para pivô o elemento de maior módulo entre os coeficientes

$$a_{ik}^{(k-1)}, \quad i = k, k+1, \ldots, n$$

- Trocam-se as linhas i e k, caso necessário.

Exemplo (RUGGIERO; LOPES, 1996)

Seja o seguinte caso, após etapa 1:

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left(\begin{array}{cccc|c} 3 & 2 & 1 & -1 & 5 \\ 0 & 1 & 0 & 3 & 6 \\ 0 & -3 & -5 & 7 & 7 \\ 0 & 2 & 4 & 0 & 15 \end{array}\right)$$

Para etapa $k = 2$:

- Escolher novo pivô:

$$\max_{i=2,3,4} |a_{i2}^{(1)}| = |a_{32}^{(1)}| = 3$$

Logo, pivô é $a_{32}^{(1)} = -3$, encontrado na linha $i = 3$.

- Trocam-se as linhas $k = 2$ e $i = 3$, obtendo

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left(\begin{array}{cccc|c} 3 & 2 & 1 & -1 & 5 \\ 0 & -3 & -5 & 7 & 7 \\ 0 & 1 & 0 & 3 & 6 \\ 0 & 2 & 4 & 0 & 15 \end{array}\right).$$

- Os multiplicadores são

$$m_{32} = \frac{1}{-3} = -1/3 \qquad\qquad m_{42} = \frac{2}{-3} = -2/3\,.$$

- O módulo dos multiplicadores é sempre *menor que 1*, o que evita a ampliação de erros de arredondamento.

Exemplo (RUGGIERO; LOPES, 1996)

- Seja agora o sistema

$$\begin{cases} 0,0002x_1 + 2x_2 = 5 \\ 2x_1 + 2x_2 = 6 \end{cases}$$

- Considerando-se aritmética de 3 dígitos, e a princípio sem usar o pivotamento parcial:

$$\mathbf{A}^{(0)}|\mathbf{b}^{(0)} = \left(\begin{array}{cc|c} 0,2 \times 10^{-3} & 0,2 \times 10^{1} & 0,5 \times 10^{1} \\ 0,2 \times 10^{1} & 0,2 \times 10^{1} & 0,6 \times 10^{1} \end{array}\right)$$

- Na etapa 1:

$$\text{Pivô: } 0,2 \times 10^{-3} \qquad m_{21} = \frac{0,2 \times 10^{1}}{0,2 \times 10^{-3}} = 0,1 \times 10^{5} \qquad a_{21}^{(1)} = 0$$

Calculando-se a linha 2:

$$\begin{aligned} a_{22}^{(1)} = a_{22}^{(0)} - a_{12}^{(0)} \times m_{21} &= 0,2 \times 10^{1} - (0,2 \times 10^{1}) \times (0,1 \times 10^{5}) \\ &= 0,2 \times 10^{1} - 0,2 \times 10^{5} = -0,2 \times 10^{5} \\ b_{2}^{(1)} = b_{2}^{(0)} - b_{1}^{(0)} \times m_{21} &= 0,6 \times 10^{1} - (0,5 \times 10^{1}) \times (0,1 \times 10^{5}) \\ &= 0,6 \times 10^{1} - 0,5 \times 10^{5} = -0,5 \times 10^{5} \end{aligned}$$

- Logo,

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left(\begin{array}{cc|c} 0,2 \times 10^{-3} & 0,2 \times 10^{1} & 0,5 \times 10^{1} \\ 0 & -0,2 \times 10^{5} & -0,5 \times 10^{5} \end{array}\right)$$

- A solução do sistema $\mathbf{A}^{(1)}\mathbf{x} = \mathbf{b}^{(1)}$ é

$$-0,2 \times 10^5 x_2 = -0,5 \times 10^5 \Rightarrow x_2 = (0,5)/(0,2) = 0,25 \times 10^1$$

$$\begin{aligned} 0,2 \times 10^{-3} x_1 + 0,2 \times 10^1 \times 0,25 \times 10^1 &= 0,5 \times 10^1 \\ \Rightarrow 0,2 \times 10^{-3} x_1 &= 0,5 \times 10^1 - 0,5 \times 10^1 = 0 \end{aligned}$$

- Logo, $\mathbf{x}^* = (0,\ 2, 5)^t$.
- $\mathbf{x}^*$ não satisfaz equação 2:

$$2 \times 0 + 2 \times 2,5 = 5 \neq 6\,.$$

Exercício

Refaça a solução, usando o pivotamento parcial. Verifique se a solução obtida satisfaz ambas as equações do sistema.

5.4 Fatoração LU

O objetivo da fatoração LU é fatorar a matriz dos coeficientes $\mathbf{A}$ do sistema linear em um produto de duas matrizes $\mathbf{L}$ (triangular inferior – ***lower*** *triangular*) e $\mathbf{U}$ (triangular superior – ***upper*** *triangular*)):

$$\mathbf{LU} = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ \ell_{21} & 1 & \ddots & \vdots \\ \ell_{31} & \ell_{32} & \ddots & 0 \\ \vdots & \vdots & & 1 \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{n,n-1} \end{pmatrix} \begin{pmatrix} u_{11} & u_{12} & u_{13} & \cdots & u_{1n} \\ 0 & u_{22} & u_{23} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & & \vdots \\ & & & \ddots & u_{n-1,n} \\ 0 & \cdots & & 0 & u_{nn} \end{pmatrix}$$

- Uma vez que $\mathbf{A} = \mathbf{LU}$, resolver o sistema linear $\mathbf{Ax} = \mathbf{b}$ é equivalente a resolver o sistema $\mathbf{Ly} = \mathbf{b}$, e em seguida o sistema $\mathbf{Ux} = \mathbf{y}$.

$$\begin{aligned} \mathbf{Ax} = \mathbf{b} &\Rightarrow \\ (\mathbf{LU})\mathbf{x} = \mathbf{b} &\Rightarrow \\ \mathbf{L}(\mathbf{Ux}) = \mathbf{b} & \end{aligned}$$

- O produto $\mathbf{Ux}$ gera um vetor coluna $n \times 1$, tal como o próprio vetor $\mathbf{x}$.

- Referindo-se a tal vetor como $\mathbf{y}$ e substituindo-se na última passagem:

$$\mathbf{L}\mathbf{y} = \mathbf{b}\,.$$

- A resolução deste sistema é *direta* (matriz triangular inferior com diagonal unitária) e fornece as componentes $y_1, \ldots, y_n$ do vetor coluna $\mathbf{y}$.

- Agora, basta resolver de forma *retroativa* o sistema

$$\mathbf{U}\mathbf{x} = \mathbf{y}\,,$$

uma vez que $\mathbf{U}$ é matriz triangular superior, e obter a solução do sistema original, $\mathbf{x}$.

Considerações

- Teoricamente e computacionalmente, a fatoração LU é equivalente ao método da eliminação de Gauss. Ambos requerem $O(n^3)$ operações aritméticas.

- Na prática, na fatoração LU guardamos em $\mathbf{L}$ os multiplicadores usados para transformar $\mathbf{A}$ numa matriz triangular superior $\mathbf{U}$.

- A informação contida em $\mathbf{L}$ é particularmente útil se precisamos resolver um sistema linear $\mathbf{A}\mathbf{x} = \mathbf{b}'$, com a mesma matriz $\mathbf{A}$ mas um diferente vetor do lado direito, pois não precisamos fatorar novamente a matriz $\mathbf{A}$ como no MEG – bastante comum em aplicações!

Obtenção dos fatores L e U

A obtenção dos fatores podem ser feitas de duas formas:

1. Através de fórmulas para os elementos ℓ_{ij} e u_{ij};

2. Usando a ideia básica do método da eliminação de Gauss (RUGGIERO; LOPES, 1996)

Fórmulas para os elementos ℓ_{ij} e u_{ij}

- *1a. linha de* $\mathbf{U}$: Faz-se o produto da 1a. linha de $\mathbf{L}$ por todas as colunas de $\mathbf{U}$, e a iguala com todos os elementos da 1a. linha de $\mathbf{A}$, assim:

$$\begin{cases} 1 \cdot u_{11} = a_{11} \Rightarrow u_{11} = a_{11}\,, \\ 1 \cdot u_{12} = a_{12} \Rightarrow u_{12} = a_{12}\,, \\ \qquad\qquad \vdots \\ 1 \cdot u_{1n} = a_{1n} \Rightarrow u_{1n} = a_{1n}\,, \end{cases}$$

- ou seja,

$$u_{1j} = a_{1j}, \qquad\qquad j = 1, 2, \ldots, n\,.$$

- *1a. coluna de* **L**: Faz-se o produto de todas as linhas de **L** (da 2a. até a n-ésima, pois $\ell_{11} = 1$) pela primeira coluna de **U**, e a iguala com todos os elementos da 1a. coluna de **A** (abaixo da diagonal principal):

$$\begin{cases} \ell_{21} \cdot u_{11} = a_{21} \Rightarrow \ell_{21} = \dfrac{a_{21}}{u_{11}}\,, \\ \ell_{31} \cdot u_{11} = a_{31} \Rightarrow \ell_{31} = \dfrac{a_{31}}{u_{11}}\,, \\ \qquad\qquad \vdots \\ \ell_{n1} \cdot u_{11} = a_{n1} \Rightarrow \ell_{n1} = \dfrac{a_{n1}}{u_{11}}\,, \end{cases}$$

- ou seja,

$$\ell_{i1} = \frac{a_{i1}}{u_{11}}, \qquad\qquad i = 2, \ldots, n\,.$$

- *2a. linha de* **U**: Faz-se o produto da 2a. linha de **L** por todas as colunas de **U**, (da 2a. até a n-ésima, pois $u_{21} = 0$), e iguala com os elementos da 2a. linha de **A**, (da diagonal principal em diante):

$$\begin{cases} \ell_{21} \cdot u_{12} + u_{22} = a_{22} \Rightarrow u_{22} = a_{22} - \ell_{21} u_{12}\,, \\ \ell_{21} \cdot u_{13} + u_{23} = a_{23} \Rightarrow u_{23} = a_{23} - \ell_{21} u_{13}\,, \\ \qquad\qquad \vdots \\ \ell_{21} \cdot u_{1n} + u_{2n} = a_{2n} \Rightarrow u_{2n} = a_{2n} - \ell_{21} u_{1n}\,, \end{cases}$$

- ou seja,

$$u_{2j} = a_{2j} - \ell_{21} u_{1j}, \qquad\qquad j = 2, \ldots, n\,.$$

- *2a. coluna de* **L**: Faz-se o produto de todas as linhas de **L** (da 3a. até a n-ésima, pois $\ell_{12} = 0$ e $\ell_{22} = 1$) pela primeira coluna de **U**, e a iguala com todos os elementos da 1a. coluna de **A** (abaixo da diagonal principal):

$$\begin{cases} \ell_{31}\cdot u_{12}+\ell_{32}\cdot u_{22}=a_{32}\Rightarrow \ell_{32}=\dfrac{a_{32}-\ell_{31}\cdot u_{12}}{u_{22}}\,, \\ \ell_{41}\cdot u_{12}+\ell_{42}\cdot u_{22}=a_{42}\Rightarrow \ell_{42}=\dfrac{a_{42}-\ell_{41}\cdot u_{12}}{u_{22}}\,, \\ \qquad\qquad\vdots \\ \ell_{n1}\cdot u_{12}+\ell_{n2}\cdot u_{22}=a_{n2}\Rightarrow \ell_{n2}=\dfrac{a_{n2}-\ell_{n1}\cdot u_{12}}{u_{22}}\,, \end{cases}$$

- ou seja,

$$\ell_{i2}=\frac{a_{i2}-\ell_{i1}\cdot u_{12}}{u_{22}}, \qquad\qquad i=3,\,\ldots,\,n\,.$$

- Estendendo-se os cálculos para a 3a. linha de **U**, depois para a 3a. coluna de **L**, 4a. linha de **U**, depois para a 4a. coluna de **L**, etc., chega-se às fórmulas gerais da i-ésima linha de **U** e da j-ésima coluna de **L**:

$$\begin{cases} u_{ij}=a_{ij}-\displaystyle\sum_{k=1}^{i-1}\ell_{ik}u_{kj}\,, & j\geq i\,; \\ \ell_{ij}=\left(a_{ij}-\displaystyle\sum_{k=1}^{j-1}\ell_{ik}u_{kj}\right)\Big/u_{jj}\,, & i>j\,. \end{cases}$$

Método 2: eliminação de Gauss

Considerando-se o método de Gauss, e partindo de um sistema teórico de dimensão 3:

$$\begin{cases} a_{11}x_1+a_{12}x_2+a_{13}x_3=b_1 \\ a_{21}x_1+a_{22}x_2+a_{23}x_3=b_2 \\ a_{31}x_1+a_{32}x_2+a_{33}x_3=b_3 \end{cases}$$

- Diferente do método original, considera-se somente a matriz de coeficientes:

$$\mathbf{A}^{(0)}=\begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & a_{13}^{(0)} \\ a_{21}^{(0)} & a_{22}^{(0)} & a_{23}^{(0)} \\ a_{31}^{(0)} & a_{32}^{(0)} & a_{33}^{(0)} \end{pmatrix}=\mathbf{A}$$

- Supondo-se $a_{11}^{(0)}\neq 0$, os multiplicadores da etapa 1 são:

$$m_{21}=\frac{a_{21}^{(0)}}{a_{11}^{(0)}} \qquad\qquad m_{31}=\frac{a_{31}^{(0)}}{a_{11}^{(0)}}$$

- Para eliminar x_1 das linhas $i = 2, 3$, multiplica-se a linha 1 por m_{i1} e subtrai-se o resultado da linha i:

$$\begin{aligned} a_{1j}^{(1)} &= a_{1j}^{(0)} && \text{para } j = 1, 2, 3 \\ a_{ij}^{(1)} &= a_{ij}^{(0)} - m_{i1} a_{1j}^{(0)} && \text{para } i = 2, 3 \text{ e } j = 1, 2, 3 \end{aligned}$$

Exercício

Mostre que a matriz obtida após a etapa 1, $\mathbf{A}^{(1)}$, é tal que

$$\mathbf{M}^{(0)} \mathbf{A}^{(0)} = \mathbf{A}^{(1)} ,$$

onde

$$\mathbf{M}^{(0)} = \begin{pmatrix} 1 & 0 & 0 \\ -m_{21} & 1 & 0 \\ -m_{31} & 0 & 1 \end{pmatrix}$$

- Supondo-se agora que o o novo pivô $a_{22}^{(1)} \neq 0$, define-se o multiplicador

$$m_{32} = \frac{a_{32}^{(1)}}{a_{22}^{(1)}} .$$

- Para eliminar x_2 da linha 3, multiplica-se a linha 2 por m_{32} e subtrai-se o resultado da linha 3, de modo que:

$$\begin{aligned} a_{1j}^{(2)} &= a_{1j}^{(1)} && \text{para } j = 1, 2, 3 \\ a_{2j}^{(2)} &= a_{2j}^{(1)} && \text{para } j = 2, 3 \\ a_{3j}^{(2)} &= a_{3j}^{(1)} - m_{32} a_{2j}^{(1)} && \text{para } j = 2, 3 \end{aligned}$$

Exercício

Mostre que a matriz obtida após a etapa 2, $\mathbf{A}^{(2)}$, é tal que

$$\mathbf{M}^{(1)} \mathbf{A}^{(1)} = \mathbf{A}^{(2)} ,$$

onde

$$\mathbf{M}^{(1)} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -m_{32} & 1 \end{pmatrix}$$

- Do processo anterior,

$$\mathbf{A}^{(2)} = \mathbf{M}^{(1)} \mathbf{A}^{(1)} = \mathbf{M}^{(1)} \mathbf{M}^{(0)} \mathbf{A}^{(0)} = \mathbf{M}^{(1)} \mathbf{M}^{(0)} \mathbf{A}$$

- A matriz $\mathbf{A}^{(2)}$ é triangular superior;
- Uma vez que

$$\left(\mathbf{M}^{(0)}\right)^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ m_{21} & 1 & 0 \\ m_{31} & 0 & 1 \end{pmatrix} \text{ e } \left(\mathbf{M}^{(1)}\right)^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & m_{32} & 1 \end{pmatrix}$$

(exercício), então

$$\left(\mathbf{M}^{(0)}\right)^{-1} \left(\mathbf{M}^{(1)}\right)^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ m_{21} & 1 & 0 \\ m_{31} & m_{32} & 1 \end{pmatrix}$$

(exercício).

- Portanto,

$$\mathbf{A} = (\mathbf{M}^{(1)}\mathbf{M}^{(0)})^{-1}\mathbf{A}^{(2)} = (\mathbf{M}^{(0)})^{-1}(\mathbf{M}^{(1)})^{-1}\mathbf{A}^{(2)}\,.$$

- I.e.,

$$\mathbf{A} = \begin{pmatrix} 1 & 0 & 0 \\ m_{21} & 1 & 0 \\ m_{31} & m_{32} & 1 \end{pmatrix} \begin{pmatrix} a_{11}^{(2)} & a_{12}^{(2)} & a_{13}^{(2)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} \\ 0 & 0 & a_{23}^{(2)} \end{pmatrix} = \mathbf{LU}$$

- Ou seja, $\mathbf{L} = (\mathbf{M}^{(0)})^{-1}(\mathbf{M}^{(1)})^{-1}$ e $\mathbf{U} = \mathbf{A}^{(2)}$.

Exemplo

$$\begin{cases} 3x_1 + 2x_2 + 4x_3 = 1 \\ x_1 + x_2 + 2x_3 = 2 \\ 4x_1 + 3x_2 + 2x_3 = 3 \end{cases}$$

- Neste caso,

$$\mathbf{A}^{(0)} = \begin{pmatrix} 3 & 2 & 4 \\ 1 & 1 & 2 \\ 4 & 3 & 2 \end{pmatrix}$$

- Dados iniciais:

$$\text{Pivô: } a_{11}^{(0)} = 3 \qquad m_{21} = \frac{a_{21}^{(0)}}{a_{11}^{(0)}} = \frac{1}{3} \qquad m_{31} = \frac{a_{31}^{(0)}}{a_{11}^{(0)}} = \frac{4}{3}$$

- Fazendo-se

$$L_1 \leftarrow L_1 \qquad L_2 \leftarrow L_2 - m_{12}L_1 \qquad L_3 \leftarrow L_3 - m_{13}L_1\,,$$

obtém-se

$$\mathbf{A}^{(1)} = \begin{pmatrix} 3 & 2 & 4 \\ \mathbf{0} & 1/3 & 2/3 \\ \mathbf{0} & 1/3 & -10/3 \end{pmatrix}$$

- Dado que agora $a_{21}^{(1)}$ e $a_{31}^{(1)}$ são nulos, podem-se armazenar os multiplicadores m_{21} e m_{31} nestas posições:

$$\mathbf{A}^{(1)} = \begin{pmatrix} 3 & 2 & 4 \\ 1/3 & 1/3 & 2/3 \\ 4/3 & 1/3 & -10/3 \end{pmatrix}$$

- Para a etapa 2:

$$\text{Pivô: } a_{22}^{(1)} = 1/3 \qquad m_{32} = \frac{a_{32}^{(1)}}{a_{22}^{(1)}} = \frac{1/3}{1/3} = 1$$

- Fazendo-se

$$L_1 \leftarrow L_1 \qquad L_2 \leftarrow L_2 \qquad L_3 \leftarrow L_3 - m_{32}L_2\ :$$

$$\mathbf{A}^{(2)} = \begin{pmatrix} 3 & 2 & 4 \\ 1/3 & 1/3 & 2/3 \\ 4/3 & 1 & -4 \end{pmatrix}$$

Logo, os fatores $\mathbf{L}$ e $\mathbf{U}$ são:

$$\mathbf{L} = \begin{pmatrix} 1 & 0 & 0 \\ 1/3 & 1 & 0 \\ 4/3 & 1 & 1 \end{pmatrix} \text{ e } \mathbf{U} = \begin{pmatrix} 3 & 2 & 4 \\ 0 & 1/3 & 2/3 \\ 0 & 0 & -4 \end{pmatrix}.$$

Resolução do sistema

- Resolvendo-se $\mathbf{Ly} = \mathbf{b}$:

$$\begin{cases} y_1 & = 1 \\ 1/3y_1 + y_2 & = 2 \\ 4/3y_1 + y_2 + y_3 & = 3 \end{cases}$$

Solução:$\mathbf{y} = (1, 5/3, 0)^t$.

- Resolvendo-se agora $\mathbf{Ux} = \mathbf{y}$:

$$\begin{cases} 3x_1 + 2x_2 + 4x_3 = 1 \\ 1/3x_2 + 2/3x_3 = 5/3 \\ -4x_3 = 0 \end{cases}$$

Solução:$\mathbf{y} = (-3, 5, 0)^t$.

Pivotamento parcial

- O pivotamento parcial pode ser usado na fatoração LU, visando as mesmas melhorias discutidas no método de eliminação de Gauss.
- A *permutação de linhas* pode ser necessária inclusive quando estamos resolvendo o sistema sem considerar a estratégia, ex.: quando vetor nulo ou valor muito próximo de zero.
- Para isto, considera-se a definição de *matriz de permutação*:

  Matriz de permutação

  Uma *matriz de permutação* de ordem n é uma matriz quadrada $n \times n$ obtida a partir da matriz identidade $\mathbf{I}_n$, pela troca de suas linhas.

- Uma matriz de permutação $\mathbf{P}$, quando multiplicada à esquerda por uma matriz quadrada $\mathbf{A}$, provoca troca entre as linhas de $\mathbf{A}$, exatamente da forma como foram trocadas as linhas da matriz identidade que definem $\mathbf{P}$.
- Exemplo:

$$\mathbf{P} = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix} \text{ e } \mathbf{A} = \begin{pmatrix} 3 & 1 & 4 \\ 1 & 5 & 9 \\ 2 & 6 & 5 \end{pmatrix}$$

- Fazendo-se a multiplicação:

$$\mathbf{PA} = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} 3 & 1 & 4 \\ 1 & 5 & 9 \\ 2 & 6 & 5 \end{pmatrix} = \begin{pmatrix} 1 & 5 & 9 \\ 2 & 6 & 5 \\ 3 & 1 & 4 \end{pmatrix}$$

Dado um sistema linear $\mathbf{Ax} = \mathbf{b}$, e os fatores $\mathbf{L}$ e $\mathbf{U}$ obtidos pelo método de eliminação de Gauss com pivotamento parcial. Então:

- $\mathbf{L}$ e $\mathbf{U}$ são fatores de $\mathbf{A}'$, onde $\mathbf{A}'$ é a matriz $\mathbf{A}$ com as linhas permutadas: $\mathbf{A}' = \mathbf{PA}$.
- As mesmas permutações são efetuadas no vetor $\mathbf{b}$. Seja então $\mathbf{b}' = \mathbf{Pb}$.

- O sistema linear $\mathbf{A}'\mathbf{x} = \mathbf{b}'$ é equivalente ao original e, se $\mathbf{A}' = \mathbf{LU}$, temos que

$$\mathbf{A}'\mathbf{x} = \mathbf{b}' \Rightarrow \mathbf{PAx} = \mathbf{Pb} \Rightarrow \mathbf{LUx} = \mathbf{Pb}\,.$$

- Assim, resolvem-se os sistemas:

  1. $\mathbf{Ly} = \mathbf{Pb}$
  2. $\mathbf{Ux} = \mathbf{y}$

Exemplo

$$\begin{cases} 3x_1 - 4x_2 + x_3 = 9 \\ x_1 + 2x_2 + 2x_3 = 3 \\ 4x_1 - 3x_3 = -2 \end{cases}$$

- Neste caso,

$$\mathbf{A}^{(0)} = \begin{pmatrix} 3 & -4 & 1 \\ 1 & 2 & 2 \\ 4 & 0 & -3 \end{pmatrix}$$

- Etapa 1: permutam-se as linhas 1 e 3, pois o pivô é $A_{31}^{(0)} = 4$.

$$\mathbf{A}'^{(0)} = \begin{pmatrix} 4 & 0 & -3 \\ 1 & 2 & 2 \\ 3 & -4 & 1 \end{pmatrix}, \quad \mathbf{P}^{(0)} = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix} \quad \text{e } \mathbf{A}'^{(0)} = \mathbf{P}^{(0)}\mathbf{A}^{(0)}$$

- Após a eliminação em $\mathbf{A}'^{(0)}$:

$$\mathbf{A}^{(1)} = \begin{pmatrix} 4 & 0 & -3 \\ 1/4 & 2 & 11/4 \\ 3/4 & -4 & 13/4 \end{pmatrix}$$

- Etapa 2: permutam-se as linhas 2 e 3, pois o pivô é $A_{32}^{(1)} = -4$.

$$\mathbf{A}'^{(1)} = \begin{pmatrix} 4 & 0 & -3 \\ 3/4 & -4 & 13/4 \\ 1/4 & 2 & 11/4 \end{pmatrix}, \mathbf{P}^{(1)} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix} \text{ e } \mathbf{A}'^{(1)} = \mathbf{P}^{(1)}\mathbf{A}^{(1)}$$

- Após a eliminação em $\mathbf{A}'^{(1)}$:

$$\mathbf{A}^{(2)} = \begin{pmatrix} 4 & 0 & -3 \\ 3/4 & -4 & 13/4 \\ 1/4 & -1/2 & 35/8 \end{pmatrix}$$

- Logo, os fatores $\mathbf{L}$ e $\mathbf{U}$ são:

$$\mathbf{L} = \begin{pmatrix} 1 & 0 & 0 \\ 3/4 & 1 & 0 \\ 1/4 & -1/2 & 1 \end{pmatrix} \text{ e } \begin{pmatrix} 4 & 0 & -3 \\ 0 & -4 & 13/4 \\ 0 & 0 & 35/8 \end{pmatrix}.$$

- $\mathbf{A}' = \mathbf{PA}$, onde $\mathbf{P} = \mathbf{P}^{(1)}\mathbf{P}^{(0)}$, i.e.:

$$\mathbf{A}' = \mathbf{PA} = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 3 & -4 & 1 \\ 1 & 2 & 2 \\ 4 & 0 & -3 \end{pmatrix} = \begin{pmatrix} 4 & 0 & -3 \\ 3 & -4 & 1 \\ 1 & 2 & 2 \end{pmatrix}$$

- Resolução do sistema $\mathbf{Ly} = \mathbf{Pb}$:
  - $$\mathbf{Pb} = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 9 \\ 3 \\ -2 \end{pmatrix} = \begin{pmatrix} -2 \\ 9 \\ 3 \end{pmatrix}$$
  - Logo, resolve-se
    $$\begin{cases} y_1 & & & = -2 \\ 3/4y_1 & +y_2 & & = 9 \\ 1/4y_1 & -1/2y_2 & +y_3 & = 3 \end{cases}$$
    resultando em $\mathbf{y} = (-2, 21/2, 35/4)^t$.

- Resolução do sistema $\mathbf{Ux} = \mathbf{y}$:
  - $$\begin{cases} 4x_1 + 0x_2 - 3x_3 = -2 \\ -4x_2 + 13/4x_3 = 21/2 \\ 35/8x_3 = 35/4 \end{cases}$$
  - Logo, a solução do problema é $\mathbf{x} = (1, -1, 2)^t$

Vetor das permutações

- A permutações de linha feitas na permutação podem ser representados por um vetor $\mathbf{p}$, $n \times 1$.
- A k-ésima entrada do vetor, $k = 1, \ldots, n$ é definida por

$$p_k = i, \qquad\qquad i = 1, \ldots, n\,,$$

  se na etapa k a i-ésima linha da matriz original $\mathbf{A}^{(0)}$ for a linha pivotal.
- Inicialmente, $\mathbf{p} = (1, 2, \ldots, n)^t$.
- *Exemplo:* no caso do exemplo anterior:
  1. Inicialmente: $\mathbf{p} = (1, 2, 3)^t$;
  2. **Etapa 1**: linha 3 é pivotal $\Rightarrow$ $\mathbf{p} = (3, 2, 1)^t$;
  3. **Etapa 2**: linha 3 de $\mathbf{A}^{(1)}$ é pivotal $\Rightarrow$ $\mathbf{p} = (3, 1, 2)^t$.

Algoritmo da fatoração LU com pivotamento parcial

```
// Cálculo dos fatores
para i = 1 : n
   p[i] = i

para k = 1 : n-1
   pv = abs(a[k][k])
   r = k
   para i = k+1 : n
   se (abs(a[i][k]) > pv)
      pv = abs(a[i][k])
      r = i

   se (pv = 0)
      fim // matriz é singular, algoritmo termina

   se (r =/= k) // troca de linhas
      aux = p[k]
      p[k] = p[r]
      p[r] = aux
      para j = 1 : n
         aux = a[k][j]
         a[k][j] = a[r][j]
         a[r][j] = aux

   para i = k+1 : n
      m = a[i][k]/a[k][k]
      a[i][k] = m
      para j = k+1 : n
         a[i][j] = a[i][j] - m*a[k][j]

// Resolução dos sistemas triangulares
```

```
// c = Pb
para i = 1 : n
   r = p[i]
   c[i] = b[r]



// Sistema Ly=c
y[1] = c[1]
para k = 2 : n
   s = 0
   para j = 1 : k-1
      s = s + a[k][j]*y[j]
   y[k] = c[k] - s

// Sistema Ux=y
x[n]=b[n]/a[n][n]
para k = n-1 : 1
   s = 0
   para j = k+1 : n
      s = s + a[k][j]*x[j]
   x[k] = (b[k]-s)/a[k][k]
```

5.5 Erros e refinamento da solução

Avaliação de erros

No sistema $\mathbf{Ax} = \mathbf{b}$, onde

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} \ldots\ldots a_{1n} \\ a_{21} & a_{22} \ldots\ldots a_{2n} \\ \vdots & \vdots \quad \ddots \quad \vdots \\ a_{n1} & a_{n2} \ldots\ldots a_{nn} \end{pmatrix}, \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \mathbf{b} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix},$$

o *erro da solução* é dado por $\mathbf{e} = \mathbf{x} - \bar{\mathbf{x}}$.

- Procedimento para determinação do erro:
  1. Determinar $\bar{\mathbf{b}} = \mathbf{A}\bar{\mathbf{x}}$;
  2. Estimar o *resíduo*, dado por $\mathbf{r} = \mathbf{b} - \bar{\mathbf{b}} = \mathbf{b} - \mathbf{A}\bar{\mathbf{x}}$.

Resíduo

Temos que

$$\mathbf{r} = \mathbf{b} - \bar{\mathbf{b}} = \mathbf{Ax} - \mathbf{A}\bar{\mathbf{x}} = \mathbf{A}\left(\mathbf{x} - \bar{\mathbf{x}}\right) = \mathbf{Ae}\,.$$

- Verifica-se que:
  - O resíduo não é o erro, apenas uma estimativa do mesmo;
  - Quanto menor for o resíduo, menor será o erro.

Refinamento da solução a partir do resíduo

- *Exemplo:* refinar a solução do sistema

$$\begin{cases} 1,5x_1 + 5,4x_2 + 3,3x_3 = 10 \\ 4,2x_1 + 2,3x_2 + 4,5x_3 = 11,7 \\ 2,7x_1 + 5,7x_2 + 7,8x_3 = 8,9\,, \end{cases}$$

  cuja solução encontrada pelo método de Gauss é dada pelo *vetor solução* $\mathbf{x}^{(0)} = (3,1252,\ 1,7121,\ -1,1918)$.

- O resíduo calculado é dado por

$$\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)} = \begin{pmatrix} -0,0002 \\ -0,0006 \\ -0,0010 \end{pmatrix}$$

- Vê-se pelo resíduo que a precisão alcançada não foi satisfatória.

- Com o intuito de melhorar a solução, considera-se um novo vetor $\mathbf{x}^{(1)}$ chamado de *vetor solução melhorado.*

- De forma que

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \boldsymbol{\delta}^{(0)}\,,$$

  onde $\boldsymbol{\delta}^{(0)}$ é o *vetor de correção.*

- Assim:

$$\begin{gathered} \mathbf{A}\mathbf{x}^{(1)} = \mathbf{b} \Rightarrow \\ \mathbf{A}\left(\mathbf{x}^{(0)} + \boldsymbol{\delta}^{(0)}\right) = \mathbf{b} \Rightarrow \\ \mathbf{A}\mathbf{x}^{(0)} + \mathbf{A}\boldsymbol{\delta}^{(0)} = \mathbf{b} \Rightarrow \\ \mathbf{A}\boldsymbol{\delta}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)} \Rightarrow \\ \mathbf{A}\boldsymbol{\delta}^{(0)} = \mathbf{r}^{(0)} \end{gathered}$$

- Retornando-se ao exemplo,

$$\begin{pmatrix} 1,5 & 5,4 & 3,3 \\ 4,2 & 2,3 & 4,5 \\ 2,7 & 5,7 & 7,8 \end{pmatrix} \begin{pmatrix} \delta_1 \\ \delta_2 \\ \delta_3 \end{pmatrix} = \begin{pmatrix} -0,0002 \\ -0,0006 \\ -0,0010 \end{pmatrix},$$

  o vetor de correção encontrado é $\boldsymbol{\delta}^{(0)} = (0,0000,\ 0,0001,\ 0,0002)^t$.

- Desta forma, a *solução melhorada* será dada por

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \boldsymbol{\delta}^{(0)} = \begin{pmatrix} 3,1252 \\ 1,7122 \\ -1,1916 \end{pmatrix},$$

  cujo novo resíduo é dado por

$$\mathbf{r}^{(1)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(1)} = \begin{pmatrix} 0,0000 \\ 0,0000 \\ 0,0000 \end{pmatrix}.$$

- Em exemplos onde o resíduo ainda não seja satisfeito pode-se utilizar o mesmo procedimento:

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \boldsymbol{\delta}^{(1)}.$$

- Assim, o novo vetor correção $\boldsymbol{\delta}^{(1)}$, será calculado por

$$\mathbf{A}\boldsymbol{\delta}^{(1)} = \mathbf{r}^{(1)}$$

- Acha-se assim, sempre uma solução melhorada e com resíduo tendendo a zero.

5.6 Métodos iterativos

Como motivação para uso de métodos iterativos no lugar de métodos diretos, é possível citar a ocorrência em *larga escala* de sistemas lineares em cálculos de engenharia e modelagem científica, tais como:

- Simulações de processos químicos;
- Simulações de dispositivos e circuitos;
- Modelagem de processos geocientíficos e geoambientais;
- Análise estrutural;
- Biologia estrutural;
- Modelagem de processos físicos.
- Em tais problemas: tendência à existência de matrizes de coeficientes *grandes* e *esparsas*:
  - Grandes ⇒ Comum para $n > 100\,000$;
  - Esparsas ⇒ Maioria dos coeficientes *nulos*.

- Resolução de sistemas esparsos por métodos diretos:
  - Processos de *triangularização* e *fatoração*: Onerosos, por não preservarem a esparsidade original, que pode ser útil por facilitar a resolução do sistema.
- Métodos mais apropriados para a resolução de sistemas de natureza esparsa: *Métodos iterativos*: Exs.:
  - Gauss-Jacobi
  - Gauss-Seidel

Funcionamento

A partir de uma estimativa inicial $\mathbf{x}^{(0)}$, métodos iterativos consistem em encontrar uma sequência de estimativas $\mathbf{x}^{(k)}$ que convirja para uma solução do sistema de equações lineares após um número suficientemente grande de iterações:

$$\begin{pmatrix} x_1^{(0)} \\ x_2^{(0)} \\ x_3^{(0)} \\ \vdots \\ x_n^{(0)} \end{pmatrix} \Rightarrow \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \\ x_3^{(1)} \\ \vdots \\ x_n^{(1)} \end{pmatrix} \Rightarrow \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \\ \vdots \\ x_n^{(2)} \end{pmatrix} \Rightarrow \cdots \Rightarrow \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \\ x_3^{(k)} \\ \vdots \\ x_n^{(k)} \end{pmatrix}$$

- Transforma-se o sistema linear $\mathbf{Ax} = \mathbf{b}$ num sistema $\mathbf{x} = \mathbf{Cx} + \mathbf{g}$, de modo que, conhecida a estimativa inicial $\mathbf{x}^{(0)}$:

$$\begin{aligned} \mathbf{x}^{(1)} &= \mathbf{C}\mathbf{x}^{(0)} + \mathbf{g} && \text{Primeira aproximação} \\ \mathbf{x}^{(2)} &= \mathbf{C}\mathbf{x}^{(1)} + \mathbf{g} && \text{Segunda aproximação} \\ &\vdots \\ \mathbf{x}^{(k+1)} &= \mathbf{C}\mathbf{x}^{(k)} + \mathbf{g} \end{aligned}$$

- A sequência de aproximações $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \ldots, \mathbf{x}^{(k)}, \ldots$ é tal que se

$$\lim_{k \to \infty} \mathbf{x}^{(k)} = \alpha$$

então $\alpha = \mathbf{C}\alpha + \mathbf{g}$, i.e., α é solução de $\mathbf{Ax} = \mathbf{b}$.

Vantagem

Menos suscetíveis ao acúmulo de erros de arredondamento do que métodos diretos, como o método de eliminação de Gauss.

- Como todo processo iterativo, estes métodos sempre apresentarão um resultado aproximado, que será tão próximo do real conforme o número de iterações realizadas.
- Além disto, também é preciso ter cuidado com a convergência de tais métodos.

5.7 Método de Gauss-Jacobi

Toma-se o sistema original

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \qquad\qquad\qquad\qquad \vdots \qquad\quad \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

e – supondo-se $a_{ii} \neq 0, i = 1, \ldots, n$ – isola-se o vetor $\mathbf{x}$ pela diagonal:

$$\begin{cases} x_1 = \dfrac{1}{a_{11}}\left(b_1 - a_{12}x_2 - a_{13}x_3 - \cdots - a_{1n}x_n\right) \\ x_2 = \dfrac{1}{a_{22}}\left(b_2 - a_{21}x_1 - a_{23}x_3 - \cdots - a_{2n}x_n\right) \\ \quad\vdots \qquad\qquad\qquad\qquad \vdots \\ x_n = \dfrac{1}{a_{nn}}\left(b_n - a_{n1}x_1 - a_{n2}x_2 - \cdots - a_{n,n-1}x_{n-1}\right) \end{cases}$$

Assim, obtém-se $\mathbf{x} = \mathbf{C}\mathbf{x} + \mathbf{g}$, onde:

$$\mathbf{C} = \begin{pmatrix} 0 & -a_{12}/a_{11} & -a_{13}/a_{11} & \cdots & -a_{1n}/a_{11} \\ -a_{21}/a_{22} & 0 & -a_{23}/a_{22} & \cdots & -a_{2n}/a_{22} \\ -a_{31}/a_{33} & -a_{32}/a_{33} & \ddots & & \vdots \\ \vdots & \vdots & & \ddots & -a_{n-1,n}/a_{n-1,n-1} \\ -a_{n1}/a_{nn} & -a_{n2}/a_{nn} & \cdots & -a_{n,n-1}/a_{nn} & 0 \end{pmatrix}$$

$$\text{e } \mathbf{g} = \begin{pmatrix} b_1/a_{11} \\ b_2/a_{22} \\ \vdots \\ b_n/a_{nn} \end{pmatrix}.$$

- Distância entre duas iterações:

$$d^{(k)} = \max_i \left| x_i^{(k)} - x_i^{(k-1)} \right|$$

- Critério de parada:

$$d_r^{(k)} = \frac{d^{(k)}}{\max_i \left| x_i^{(k)} \right|} < \varepsilon$$

Exemplo (RUGGIERO; LOPES, 1996)

$$\begin{cases} 10x_1 + 2x_2 + x_3 = 7 \\ x_1 + 5x_2 + x_3 = -8 \\ 2x_1 + 3x_2 + 10x_3 = 6 \end{cases}$$

- Determinação de $\mathbf{C}$ e $\mathbf{g}$:

$$\mathbf{C} = \begin{pmatrix} 0 & -1/5 & -1/10 \\ -1/5 & 0 & -1/5 \\ -1/5 & -3/10 & 0 \end{pmatrix} \text{ e } \mathbf{g} = \begin{pmatrix} 7/10 \\ -8/5 \\ 3/5 \end{pmatrix}.$$

- Serão considerados $\mathbf{x}^{(0)} = [0,7,\ -1,6,\ 0,6]^t = \mathbf{g}$ e $\varepsilon = 0,05$.

- A partir da estimativa inicial, obtém-se:

$$\mathbf{x}^{(1)} = \mathbf{C}\mathbf{x}^{(0)} + \mathbf{g} = \begin{pmatrix} 0,96 \\ -1,86 \\ 0,94 \end{pmatrix}.$$

  – A partir dos valores obtidos,

$$\left| x_1^{(1)} - x_1^{(0)} \right| = 0,26 \quad \left| x_2^{(1)} - x_2^{(0)} \right| = 0,26 \quad \left| x_3^{(1)} - x_3^{(0)} \right| = 0,34$$

  Logo, $d^{(1)} = \max(0,26,\ 0,26,\ 0,34) = 0,34$ e portanto

$$d_r^{(1)} = \frac{d^{(1)}}{\max(|0,96|, |-1,86|, |0,94|)} = \frac{0,34}{1,86} \approx 0,1828 > \varepsilon$$

- Prosseguindo:

$$\mathbf{x}^{(2)} = \mathbf{C}\mathbf{x}^{(1)} + \mathbf{g} = \begin{pmatrix} 0,978 \\ -1,98 \\ 0,966 \end{pmatrix} \qquad d_r^{(2)} = \frac{0,12}{1,98} = 0,0606 > \varepsilon\,,$$

$$\mathbf{x}^{(3)} = \mathbf{C}\mathbf{x}^{(2)} + \mathbf{g} = \begin{pmatrix} 0,9994 \\ -1,9888 \\ 0,9984 \end{pmatrix} \qquad d_r^{(3)} = \frac{0,0324}{1,9888} = 0,0163 < \varepsilon\,.$$

- Logo, a solução aproximada $\bar{\mathbf{x}}$ do sistema por Gauss-Jacobi é

$$\bar{\mathbf{x}} = \mathbf{x}^{(3)} = \begin{pmatrix} 0,9994 \\ -1,9888 \\ 0,9984 \end{pmatrix}.$$

Observação
Embora se considerou $\mathbf{x}^{(0)} = \mathbf{g}$, a escolha é arbitrária, pois a convergência ou não do método independe da aproximação inicial escolhida.

5.8 Método de Gauss-Seidel

- Similarmente ao método de Gauss-Jacobi, conhecida a estimativa inicial, $\mathbf{x}^{(0)}$, obtém-se consecutivamente os vetores $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$, ..., $\mathbf{x}^{(k)}$.
- Todavia, ao se calcular $x_j^{(k+1)}$, usam-se todos os valores que já foram calculados $x_1^{(k+1)}$, $x_2^{(k+1)}$, ..., $x_{j-1}^{(k+1)}$ e os valores $x_{j+1}^{(k)}$, $x_{j+2}^{(k)}$, ..., $x_n^{(k)}$ restantes.
- Logo, sendo conhecida aproximação $\mathbf{x}^{(k)}$ anterior, obtém-se $\mathbf{x}^{(k+1)}$ por meio da sequência de operações

$$\begin{cases} x_1^{(k+1)} = \dfrac{1}{a_{11}}\left(b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)}\right) \\ x_2^{(k+1)} = \dfrac{1}{a_{22}}\left(b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)}\right) \\ x_3^{(k+1)} = \dfrac{1}{a_{33}}\left(b_3 - a_{31}x_1^{(k+1)} - a_{32}x_2^{(k+1)} - a_{34}x_4^{(k)} - \cdots - a_{3n}x_n^{(k)}\right) \\ \quad\vdots \qquad\qquad\qquad\qquad \vdots \\ x_n^{(k+1)} = \dfrac{1}{a_{nn}}\left(b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \cdots - a_{n,n-1}x_{n-1}^{(k+1)}\right) \end{cases}$$

Exemplo (RUGGIERO; LOPES, 1996)

$$\begin{cases} 5x_1 + x_2 + x_3 = 5 \\ 3x_1 + 4x_2 + x_3 = 6 \\ 3x_1 + 3x_2 + 6x_3 = 0 \end{cases}$$

- Considerar $\mathbf{x}^{(0)} = [0, 0, 0]^t$ e $\varepsilon = 0,05$.

- Processo iterativo:

$$\begin{cases} x_1^{(k+1)} = 1 - 0,2x_2^{(k)} - 0,2x_3^{(k)} \\ x_2^{(k+1)} = 1,5 - 0,75x_1^{(k+1)} - 0,25x_3^{(k)} \\ x_3^{(k+1)} = 0 - 0,5x_1^{(k+1)} - 0,5x_2^{(k+1)} \,. \end{cases}$$

- Iteração $k = 0$:

$$\begin{cases} x_1^{(1)} = 1 - 0 - 0 = 1 \\ x_2^{(1)} = 1,5 - 0,75 \times 1 - 0 = 0,75 \\ x_3^{(1)} = -0,5 \times 1 - 0,5 \times 0,75 = -0,875 \,. \end{cases}$$

  Portanto, $\mathbf{x}^{(1)} = (1,\ 0,75,\ -0,875)^t$.

- Diferença:

$$\left|x_1^{(1)} - x_1^{(0)}\right| = 1 \qquad \left|x_2^{(1)} - x_2^{(0)}\right| = 0,75 \qquad \left|x_3^{(1)} - x_3^{(0)}\right| = 0,875$$

  Logo, $d^{(1)} = \max\left(1,\ 0,75,\ 0,875\right) = 1$ e portanto

$$d_r^{(1)} = \frac{d^{(1)}}{\max\left(|1|, |0,75|, |-0,875|\right)} = 1 > \varepsilon$$

- Iteração $k = 1$:

$$\begin{cases} x_1^{(2)} = 1 - 0,2 \times 0,75 + 0,2 \times 0,875 = 1,025 \\ x_2^{(2)} = 1,5 - 0,75 \times 1,025 + 0,25 \times 0,875 = 0,95 \\ x_3^{(2)} = -0,5 \times 1,025 - 0,5 \times 0,95 = -0,9875 \,. \end{cases}$$

  Portanto, $\mathbf{x}^{(2)} = (1,025,\ 0,95,\ -0,9875)^t$.

- Diferença:

$$\left|x_1^{(2)} - x_1^{(1)}\right| = 0,025 \quad \left|x_2^{(2)} - x_2^{(1)}\right| = 0,20 \quad \left|x_3^{(2)} - x_3^{(1)}\right| = 0,1125$$

  Logo, $d^{(2)} = \max\left(0,025,\ 0,20,\ 0,1125\right) = 0,2$ e portanto

$$d_r^{(2)} = \frac{d^{(2)}}{\max\left(|1,025|, |0,95|, |-0,9875|\right)} = \frac{0,2}{1,025} \approx 0,1951 > \varepsilon$$

- Prosseguindo:

$$\mathbf{x}^{(3)} = \begin{pmatrix} 1,0075 \\ 0,9912 \\ -0,9993 \end{pmatrix} \qquad\qquad d_r^{(3)} = 0,0409 < \varepsilon\,.$$

- Logo, a solução aproximada $\bar{\mathbf{x}}$ do sistema por Gauss-Seidel é

$$\bar{\mathbf{x}} = \mathbf{x}^{(3)} = \begin{pmatrix} 1,0075 \\ 0,9912 \\ -0,9993 \end{pmatrix}.$$

Forma matricial do Gauss-Seidel

- O esquema iterativo do método de Gauss-Seidel pode ser reescrito na forma matricial.

  Para isto, considera-se a forma

$$\mathbf{A} = \mathbf{L} + \mathbf{D} + \mathbf{R}$$

  onde:

  - $\mathbf{L}$: Matriz triangular inferior com diagonal nula (contém todos os elementos a_{ij} de $\mathbf{A}$ abaixo da diagonal, e entradas restantes nulas);
  - $\mathbf{D}$: Matriz diagonal com $d_{ii} = a_{ii} \neq 0$, $i = 1, \ldots, n$;
  - $\mathbf{R}$: Matriz triangular superior com diagonal nula (contém todos os elementos a_{ij} de $\mathbf{A}$ acima da diagonal, e entradas restantes nulas).

- Portanto, obtém-se, no sistema original,

$$\mathbf{Ax} = \mathbf{b} \Rightarrow (\mathbf{L} + \mathbf{D} + \mathbf{R})\mathbf{x} = \mathbf{b}\,.$$

- Da identidade anterior, segue – isolando-se $\mathbb{D}$ do lado esquerdo – que:

$$\mathbf{Dx} = \mathbf{b} - \mathbf{Lx} - \mathbf{Rx}\,.$$

- Multiplicando-se pela inversa de $\mathbf{D}$ à esquerda, obtém-se

$$\mathbf{x} = \mathbf{D}^{-1}\mathbf{b} - \mathbf{D}^{-1}\mathbf{Lx} - \mathbf{D}^{-1}\mathbf{Rx}$$

- No caso específico do Gauss-Seidel, $\mathbf{x}^{(k+1)}$ é dado por, na forma acima:

$$\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}\mathbf{b} - \mathbf{D}^{-1}\mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{D}^{-1}\mathbf{R}\mathbf{x}^{(k)}\,.$$

- Agora, pode-se escrever o método na forma $\mathbf{x}^{(k+1)} = \mathbf{C}\mathbf{x}^{(k)} + \mathbf{g}$, considerando $\mathbf{A} = \mathbf{D}(\mathbf{L_1} + \mathbf{I} + \mathbf{R_1})$, onde I é a identidade $(n \times n)$ e:

$$\mathbf{L_1} = \begin{pmatrix} 0 & \cdots & \cdots & 0 \\ a_{21}/a_{22} & \ddots & & \vdots \\ a_{31}/a_{33} & a_{32}/a_{33} & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1}/a_{nn} & a_{n2}/a_{nn} & \cdots a_{n,n-1}/a_{nn} & 0 \end{pmatrix},$$

$$\mathbf{R_1} = \begin{pmatrix} 0 & a_{12}/a_{11} & a_{13}/a_{11} & \cdots & a_{1n}/a_{11} \\ \vdots & \ddots & a_{23}/a_{22} & \cdots & a_{2n}/a_{22} \\ \vdots & & \ddots & & \vdots \\ \vdots & & & \ddots & a_{n-1,n}/a_{n-1,n-1} \\ 0 & \cdots & \cdots & 0 & \end{pmatrix}.$$

- $\mathbf{L_1}$ e $\mathbf{R_1}$ são obtidas a partir das duas fatorações de $\mathbf{A}$: $\mathbf{L_1} = \mathbf{D}^{-1}\mathbf{L}$ e $\mathbf{R_1} = \mathbf{D}^{-1}\mathbf{R}$.

- De $\mathbf{A}\mathbf{x} = \mathbf{b}$:

$$\begin{aligned} \mathbf{D}(\mathbf{L_1} + \mathbf{I} + \mathbf{R_1})\mathbf{x} = \mathbf{b} \Leftrightarrow \\ (\mathbf{L_1} + \mathbf{I} + \mathbf{R_1})\mathbf{x} = \mathbf{D}^{-1}\mathbf{b} \Leftrightarrow \\ \mathbf{x} = -\mathbf{L_1}\mathbf{x} - \mathbf{R_1}\mathbf{x} + \mathbf{D}^{-1}\mathbf{b}\,. \end{aligned}$$

- Logo,

$$\mathbf{x}^{(k+1)} = -\mathbf{L_1}\mathbf{x}^{(k+1)} - \mathbf{R_1}\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b}\,.$$

- Basta agrupar os fatores envolvendo $\mathbf{x}$ da iteração $(k+1)$ do lado esquerdo: de $(\mathbf{I} + \mathbf{L_1})\mathbf{x}^{(k+1)} = -\mathbf{R_1}\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b}$ obtém-se

$$\mathbf{x}^{(k+1)} = \underbrace{-\left(\mathbf{I} + \mathbf{L_1}\right)^{-1}\mathbf{R_1}}_{C}\,\mathbf{x}^{(k)} + \underbrace{\left(\mathbf{I} + \mathbf{L_1}\right)^{-1}\mathbf{D}^{-1}\mathbf{b}}_{g}\,.$$

Critérios de convergência

- *Processo iterativo*: Convergência para a solução exata *não* garantida para qualquer sistema.

- Necessidade de determinação de certas condições que devem ser satisfeitas por um sistema linear para a garantia da convergência do método.

- Critérios de determinação das condições de convergência:
  1. Critério de Sassenfeld
  2. Critério das linhas

Critério de Sassenfeld

- A partir das quantidades β_i dadas por

$$\beta_1 = \frac{1}{|a_{11}|} \cdot \sum_{j=2}^{n} |a_{1j}| \ ,$$
$$\beta_i = \frac{1}{|a_{ii}|} \cdot \left[\sum_{j=1}^{i-1} |a_{ij}| \cdot \beta_j + \sum_{j=i+1}^{n} |a_{ij}| \right] \ , i = 2, \ldots, n \, ,$$

  o *critério de Sassenfeld* garante que o método de Gauss-Seidel converge para o sistema $\mathbf{Ax} = \mathbf{b}$ se $M < 1$, onde

$$M = \max_{1 \leq i \leq n} \beta_i$$

Exemplo

$$\begin{cases} 2x_1 + x_2 - 0,2x_3 + 0,2x_4 = 0,4 \\ 0,6x_1 + 3x_2 - 0,6x_3 - 0,3x_4 = -7,8 \\ -0,1x_1 - 0,2x_2 + x_3 + 0,2x_4 = 1 \\ 0,4x_1 + 1,2x_2 + 0,8x_3 + 4x_4 = -10 \end{cases}$$

- Pelo critério de Sassenfeld:

$$\beta_1 = \frac{1}{2}(1 + 0,2 + 0,2) = 0,7 \, ,$$
$$\beta_2 = \frac{1}{3}(0,6 \times 0,7 + 0,6 + 0,3) = 0,44 \, ,$$
$$\beta_3 = \frac{1}{1}(0,1 \times 0,7 + 0,2 \times 0,44 + 0,2) = 0,358 \, ,$$
$$\beta_4 = \frac{1}{4}(0,4 \times 0,7 + 1,2 \times 0,44 + 0,8 \times 0,358) = 0,2736 \, .$$

- Logo,

$$M = \max_{1 \leq i \leq 4} \beta_i = \max\{0,7,\ 0,44,\ 0,358,\ 0,2736\} = 0,7 < 1$$

- Portanto, a convergência da solução do sistema pelo método de Gauss-Seidel está garantida para o sistema.

Critério das linhas

- Segundo tal critério, o método de Gauss-Seidel (bem como o método de Gauss-Jacobi) converge para a solução do sistema se

$$\sum_{j=1, j\neq i}^{n} |a_{ij}| < |a_{ii}| \, , \; i = 1, 2, \ldots, n \, .$$

- No caso do exemplo anterior:

$$\begin{aligned}
|a_{11}| = 2 &> |a_{12}| + |a_{13}| + |a_{14}| = 1 + 0,2 + 0,2 = 1,4 \\
|a_{22}| = 3 &> |a_{21}| + |a_{23}| + |a_{24}| = 0,6 + 0,6 + 0,3 = 1,5 \\
|a_{33}| = 1 &> |a_{31}| + |a_{32}| + |a_{34}| = 0,1 + 0,2 + 0,2 = 0,5 \\
|a_{44}| = 4 &> |a_{41}| + |a_{42}| + |a_{43}| = 0,4 + 1,2 + 0,8 = 2,4
\end{aligned}$$

- Logo, o sistema também atende ao critério das linhas.

Observações

- Tanto o critério de Sassenfeld quanto o critério das linhas são condições *suficientes*, porém não necessárias, para a convergência do método de Gauss-Seidel para um dado sistema linear.
  - Um dado sistema linear pode não satisfazer estes critérios e ainda convergir.
- Um sistema pode não satisfazer o critério das linhas, porém sua convergência será garantida se satisfizer o critério de Sassenfeld.
- A convergência do método de Gauss-Jacobi, considera-se apenas o critério das linhas.

5.9 Exercícios

1. Resolver o sistema abaixo, com precisão de 4 casas decimais, usando o Método de Eliminação de Gauss sem estratégia de pivotamento.

$$\begin{cases}
1,5x_1 + 5,4x_2 + 3,3x_3 = 10 \\
4,2x_1 + 2,3x_2 + 4,5x_3 = 11,7 \\
2,7x_1 + 5,7x_2 + 7,8x_3 = 8,9
\end{cases}$$

2. Repita a resolução do sistema anterior, agora usando pivotamento. Compare os resultados, substituindo-se os valores x_1, x_2, x_3 encontrados em ambos os casos no sistema e verificando se as equações do mesmo são satisfeitas.

3. É possível resolver o sistema do item 1 por meio de um método iterativo? Analise, usando o critério de Sassenfeld.

4. Usando fatoração LU com pivotamento parcial, resolva o sistema

$$\begin{pmatrix} 3,0 & -1,0 & 1,0 \\ 0,5 & 2,0 & 1,0 \\ 4,0 & -2,0 & 6,0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5,0 \\ -0,5 \\ 12,0 \end{pmatrix}$$

5. Considere o sistema dado por

$$\begin{cases} 2,0x + 5,0y = -3,0 \\ 3,0x + 1,0y = 2,0 \end{cases}$$

   (a) Use Gauss-Seidel e aproximação inicial $\mathbf{x}^{(0)} = (0,0)^t$ para encontrar a solução, com 4 iterações ao máximo e tolerância 0,01 (o que for atingido primeiro).

   (b) Refaça o item anterior, permutando-se as equações. O que se pode concluir, ao comparar os resultados obtidos em cada um dos casos?

6. O sistema dado por

$$\begin{pmatrix} 3,3330 & 15920 & -10,333 \\ 2,2220 & 16,710 & 9,6120 \\ 1,5611 & 5,1791 & 1,6852 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 15913 \\ 28,544 \\ 8,4254 \end{pmatrix}$$

   tem como solução dada pelo método da eliminação de Gauss o vetor $\bar{\mathbf{x}} = (1,2001,\ 0,99991,\ 0,92538)^t$, para 5 dígitos significativos.

   (a) Encontre o resíduo a partir de tal solução, e promova o refinamento da mesma a partir de tal informação.

   (b) Verifique se a nova solução satisfaz o sistema: qual o novo resíduo?

7. Seja o sistema

$$\begin{pmatrix} 5 & 2 & -2 \\ 3 & 3 & -1 \\ 1 & 2 & 5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}.$$

   (a) Verifique se o mesmo satisfaz o critério das linhas e o de Sassenfeld.

(b) O sistema pode ser reescrito como

$$\begin{pmatrix} 5 & 1 & 2 \\ -2 & 5 & 2 \\ -1 & 3 & 3 \end{pmatrix} \begin{pmatrix} x_3 \\ x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}.$$

O método de Gauss-Seidel converge para o mesmo? Justifique.

8. Classifique os sistemas abaixo com relação à quantidade de soluções, usando o método de eliminação de Gauss e três casas decimais.

(a)
$$\begin{cases} 3x_1 - 2x_2 + 5x_3 + x_4 = 7 \\ -6x_1 + 4x_2 - 8x_3 + x_4 = -9 \\ 9x_1 - 6x_2 + 19x_3 + x_4 = 23 \\ 6x_1 - 4x_2 - 6x_3 + 15x_4 = 11 \end{cases}$$

(b)
$$\begin{cases} 0,252x_1 + 0,36x_2 + 0,12x_3 = 7 \\ 0,112x_1 + 0,16x_2 + 0,24x_3 = 8 \\ 0,147x_1 + 0,21x_2 + 0,25x_3 = 9 \end{cases}$$

9. Calcule a fatoração LU de $\mathbf{A}$, se possível:

$$\mathbf{A} = \begin{pmatrix} 1 & 1 & 1 \\ 2 & 1 & -1 \\ 3 & 2 & 0 \end{pmatrix}.$$

10. Aplique analítica e graficamente os métodos de Gauss-Jacobi e Gauss-Seidel no sistema:

$$\begin{cases} 2x_1 + 5x_2 = -3 \\ 3x_1 + x_2 = 2 \end{cases}$$

11. Resolva o sistema abaixo com o método da eliminação de Gauss com pivotamento parcial, e aritmética de ponto flutuante com dois dígitos significativos:

$$\begin{pmatrix} 3,1 & -1,3 & 1,2 \\ 0,5 & 2,2 & 1,1 \\ 4,2 & -2,0 & 6,0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5,5 \\ 0,77 \\ 13 \end{pmatrix}.$$

12. Refinamento do item anterior:

(a) Calcule o resíduo da solução obtida.

(b) É necessário resolver um sistema linear para obter o vetor de correção. Mostre que é possível empregar Gauss-Seidel para resolver tal sistema.

(c) Calcule uma iteração do método de Gauss-Seidel, partindo da aproximação inicial $(0, 0, 0)^t$ e obtenha uma nova solução para o sistema dado.

Referências

1. FRANCO, N. B. *Cálculo numérico.* São Paulo: Pearson Prentice Hall, 2006.

2. RUGGIERO, M. A. G.; LOPES, V. L. R. *Cálculo numérico: aspectos teóricos e computacionais.* 2ª. ed. São Paulo: Makron Books. 1996.

3. VALLE, M. E. *MS211 – Cálculo Numérico. Aula 2 – Eliminação de Gauss e Fatoração LU.* Disponível em: http://www.ime.unicamp.br/~valle/Teaching/MS211/Aula02.pdf. Acesso em: 23 de mar. de 2021

Os materiais de parte desta seção foram gentilmente cedidos por Mauricio C. Escarpinati (FACOM/UFU)
Adaptações: Renato Pimentel, FACOM/UFU

6 Sistemas não lineares

6.1 Introdução

- Foi vista anteriormente a solução numérica de sistemas lineares, que modelam diversos problemas reais;
- Entretanto, a necessidade de se obter a solução de um sistema de equações não lineares também é comum.

Sistema não linear

Dada uma função não linear $\mathbf{F} : \mathbf{D} \subset \mathbb{R}^n \to \mathbb{R}^n$, $\mathbf{F} = (f_1, \ldots, f_n)^t$, o objetivo é encontrar soluções para

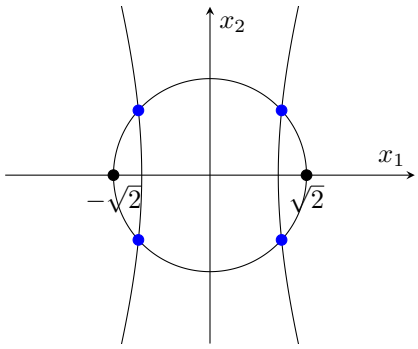
$$\mathbf{F}(\mathbf{x}) = \mathbf{0},$$

ou, equivalentemente:

$$\begin{cases} f_1(x_1,\, x_2,\, \ldots,\, x_n) = 0 \\ f_2(x_1,\, x_2,\, \ldots,\, x_n) = 0 \\ \qquad\qquad\qquad\qquad\quad \vdots \\ f_n(x_1,\, x_2,\, \ldots,\, x_n) = 0 \end{cases}$$

Exemplo

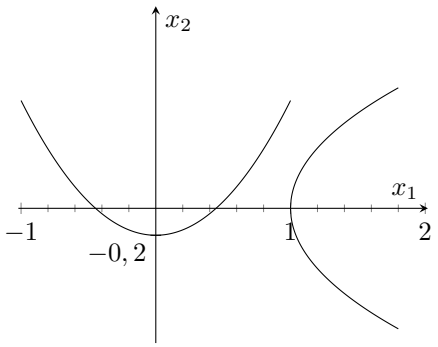
$$\begin{cases} f_1(x_1, x_2) = x_1^2 + x_2^2 - 2 = 0 \\ f_2(x_1, x_2) = x_1^2 - \dfrac{x_2^2}{9} - 1 = 0 \end{cases}$$



- Sistema admite quatro soluções (pontos onde as curvas correspondentes a f_1 e f_2 se interceptam).

Exemplo

$$\begin{cases} f_1(x_1, x_2) = x_1^2 - x_2 - 0,2 = 0 \\ f_2(x_1, x_2) = x_2^2 - x_1 + 1 = 0 \end{cases}$$



- Sistema não tem solução (não existe ponto onde as curvas $x_1^2 - x_2 = 0,2$ e $x_2^2 - x_1 = -1$ se interceptam).

Notação

- Usa-se a notação

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \qquad \mathbf{F}(\mathbf{x}) = \begin{pmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_n(\mathbf{x}) \end{pmatrix} = \begin{pmatrix} f_1(x_1,\, x_2,\, \ldots,\, x_n) \\ f_2(x_1,\, x_2,\, \ldots,\, x_n) \\ \vdots \\ f_n(x_1,\, x_2,\, \ldots,\, x_n) \end{pmatrix}.$$

- Desta forma, pode-se escrever o sistema não-linear na forma

$$\mathbf{F}(\mathbf{x}) = \mathbf{0}\,.$$

- Cada $f_i(\mathbf{x})$ é uma função não linear em $\mathbf{x}$.
  - $f_i : \mathbb{R}^n \to \mathbb{R}, i = 1, \ldots, n$
  - Logo, $\mathbf{F}(\mathbf{x})$ é não linear em $\mathbf{x}$, e $f_i : \mathbb{R}^n \to \mathbb{R}^n$.
- No caso de sistemas lineares, $\mathbf{F}(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b} = \mathbf{0}$.

Resolução

- Seja $\mathbf{F}$ definida num conjunto aberto $\mathbf{D} \subset \mathbb{R}^n$ e com derivadas contínuas em $\mathbf{D}$.
- Assume-se que existe ao menos um ponto $\boldsymbol{\xi} \in \mathbf{D}$ tal que

$$\mathbf{F}(\boldsymbol{\xi}) = \mathbf{0}\,.$$

Vetor gradiente

O vetor das derivadas parciais de $f_i(x_1, \ldots, x_n)$, dado por

$$\boldsymbol{\nabla} f_i(\mathbf{x}) = \begin{pmatrix} \dfrac{\partial f_i}{\partial x_1}(\mathbf{x}) \\ \dfrac{\partial f_i}{\partial x_2}(\mathbf{x}) \\ \vdots \\ \dfrac{\partial f_i}{\partial x_n}(\mathbf{x}) \end{pmatrix}$$

é denominado *vetor gradiente* de f_i.

Matriz jacobiana

A matriz das derivadas parciais de $\mathbf{F}(\mathbf{x})$, dada por

$$\mathbf{J}(\mathbf{x}) = \begin{pmatrix} \leftarrow \boldsymbol{\nabla} f_1(\mathbf{x})^t \rightarrow \\ \leftarrow \boldsymbol{\nabla} f_2(\mathbf{x})^t \rightarrow \\ \vdots \\ \leftarrow \boldsymbol{\nabla} f_n(\mathbf{x})^t \rightarrow \end{pmatrix} = \begin{pmatrix} \dfrac{\partial f_1}{\partial x_1}(\mathbf{x}) & \dfrac{\partial f_1}{\partial x_2}(\mathbf{x}) \cdots \cdots \dfrac{\partial f_1}{\partial x_n}(\mathbf{x}) \\ \dfrac{\partial f_2}{\partial x_1}(\mathbf{x}) & \dfrac{\partial f_2}{\partial x_2}(\mathbf{x}) \cdots \cdots \dfrac{\partial f_2}{\partial x_n}(\mathbf{x}) \\ \vdots & \vdots \quad \ddots \quad \vdots \\ \dfrac{\partial f_n}{\partial x_1}(\mathbf{x}) & \dfrac{\partial f_n}{\partial x_2}(\mathbf{x}) \cdots \cdots \dfrac{\partial f_n}{\partial x_n}(\mathbf{x}) \end{pmatrix}$$

é denominada *matriz jacobiana* de $\mathbf{F}$.

Exemplo

Dado o sistema

$$\mathbf{F}(\mathbf{x}) = \begin{pmatrix} x_1^3 - 3x_1x_2^2 + 1 \\ 3x_1^2x_2 - x_2^3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

a matriz jacobiana será dada por

$$\mathbf{J}(\mathbf{x}) = \begin{pmatrix} 3x_1^2 - 3x_2^2 & -6x_1x_2 \\ 6x_1x_2 & -3x_2^2 \end{pmatrix}.$$

Exemplo – tridiagonal de Broyden

Dado o sistema

$$\mathbf{F}(\mathbf{x}) = \begin{pmatrix} -2x_1^2 + 3x_1 - 2x_2 + 1 \\ \vdots \\ -x_{i-1} - 2x_i^2 + 3x_i - 2x_{i+1} + 1 \\ \vdots \\ -x_{n-1} - 2x_n^2 + 3x_n \end{pmatrix} = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ \vdots \\ 0 \end{pmatrix},$$

a matriz jacobiana será dada por

$$\mathbf{J}(\mathbf{x}) = \begin{pmatrix} -4x_1+3 & -2 & 0 & \cdots & 0 \\ -1 & -4x_2+3 & -2 & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & -1 & -4x_{n-1}+3 & -2 \\ 0 & \cdots & 0 & -1 & -4x_n-3 \end{pmatrix}.$$

Métodos para resolução de sistemas não lineares

- Métodos *iterativos* – i.e. dado ponto inicial $\mathbf{x}^{(0)}$, geram sequência $\{\mathbf{x}^{(k)}\}$ de vetores.
- Caso haja convergência:

$$\lim_{k\to\infty} \mathbf{x}^{(k)} = \boldsymbol{\xi}\,,$$

  onde $\boldsymbol{\xi}$ é uma solução do sistema não linear $\mathbf{F}(\mathbf{x}) = \mathbf{0}$.

- *Critério de parada* – uma vez que na solução exata $\boldsymbol{\xi}$, $\mathbf{F}(\boldsymbol{\xi}) = \mathbf{0}$:

  1. Verificar se todas as componentes de $\mathbf{F}(\mathbf{x}^{(k)})$ tem módulo pequeno.
     - Como $\mathbf{F}(\mathbf{x}^{(k)}) \in \mathbb{R}^n$, verifica-se se $\|\mathbf{F}(\mathbf{x}^{(k)})\| < \varepsilon$.
     - Em geral, usa-se a *norma infinito*: dado um vetor $\mathbf{v} \in \mathbb{R}^n$,

$$\|\mathbf{v}\|_\infty = \max_{1\le i\le n} |v_i|\,.$$

  2. Outro critério: verificar se $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|$ está próximo de zero:

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|_\infty < \varepsilon\,.$$

- *Número máximo de iterações*: para detecção de convergência, interromper os cálculos se número máximo k_{max} foi atingido, mas critério de parada não.
  - Também pode se interromper o processo se $\|\mathbf{F}(\mathbf{x}^{(k)})\|$ for maior que um certo valor, ex.: se $\|\mathbf{F}(\mathbf{x}^{(k)})\|_\infty > 10^{20}$.

6.2 Método de Newton

- Método mais usado para resolver sistemas não lineares;
- Extensão do método de Newton-Raphson para sistemas.

  Método visto consiste em usar uma *aproximação linear* de uma função $f(x)$ em torno de um ponto x_k, dado pela reta tangente a $f(x_k)$.
- Agora, constrói-se da mesma forma um modelo local linear para um sistema de equações não lineares.
- Dada uma aproximação $\mathbf{x}^{(k)} \in \mathbf{D} \subset \mathbb{R}^n$, considera-se a *expansão em série de Taylor* em torno de tal ponto:

$$\mathbf{F}(\mathbf{x}) = \mathbf{F}(\mathbf{x}^{(k)}) + \mathbf{J}(\mathbf{x}^{(k)}) \left(\mathbf{x} - \mathbf{x}^{(k)}\right) + \mathbf{O}\left(\left(\mathbf{x} - \mathbf{x}^{(k)}\right)^2\right) ,$$

  para $\mathbf{x} \in \mathbf{D}$. $\mathbf{J}(\mathbf{x}^{(k)})$ é a matriz jacobiana de $\mathbf{F}$ em $\mathbf{x}^{(k)}$. $\mathbf{O}\left(\left(\mathbf{x} - \mathbf{x}^{(k)}\right)^2\right)$ representa as infinitas parcelas restantes da soma, cuja maior contribuição é dada pelo termo quadrático em $\mathbf{x}$. Ao se truncar a série de Taylor após a n-ésima parcela da série, obtém-se uma aproximação para o valor de $\mathbf{F}$ em $\mathbf{x}$.
- Truncando-se a série no termo linear, em particular, temos um *modelo linear* para $\mathbf{F}(\mathbf{x})$ em torno de $\mathbf{x}^{(k)}$:

$$\mathbf{F}(\mathbf{x}) \approx \mathbf{L}_k(\mathbf{x}) = \mathbf{F}(\mathbf{x}^{(k)}) + \mathbf{J}(\mathbf{x}^{(k)}) \left(\mathbf{x} - \mathbf{x}^{(k)}\right) .$$

- Como visto para o método de Newton-Raphson, a aproximação seguinte do método iterativo será o *zero* do modelo linear:

$$\mathbf{L}_k(\mathbf{x}^{(k+1)}) = \mathbf{F}(\mathbf{x}^{(k)}) + \mathbf{J}(\mathbf{x}^{(k)}) \left(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\right) = \mathbf{0} .$$

- Ao se isolar $\mathbf{F}(\mathbf{x}^{(k)})$ do lado direito da equação acima, obtém-se o *sistema linear*

$$\mathbf{J}(\mathbf{x}^{(k)})\mathbf{s}^{(k)} = -\mathbf{F}(\mathbf{x}^{(k)}) ,$$

  cuja solução é o *passo de Newton* $\mathbf{s}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$.
- A partir de $\mathbf{s}^{(k)}$ obtém-se a aproximação do passo seguinte:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{s}^{(k)} .$$

Considerações

- Uma iteração do método de Newton requer:
  1. A avaliação da matriz jacobiana em $\mathbf{x}^{(k)}$;
  2. A resolução do sistema $\mathbf{J}(\mathbf{x}^{(k)})\mathbf{s}^{(k)} = -\mathbf{F}(\mathbf{x}^{(k)})$.
- O item 2, portanto, envolve o uso de um método numérico para resolução de sistemas lineares.
  - Podem ser empregados métodos diretos, baseados na fatoração da matriz jacobiana.
  - Métodos iterativos são possíveis, porém obtêm uma solução aproximada do sistema linear;
    o passo de Newton $\mathbf{s}^{(k)}$ não é calculado exatamente (*método de Newton inexato*).
- Sob condições adequadas relacionadas ao ponto $\mathbf{x}^{(0)}$, a função $\mathbf{F}$ e a matriz jacobiana $\mathbf{J}$, a sequência $\{\mathbf{x}^{(k)}\}$ converge para a solução de $\mathbf{F}(\mathbf{x}) = \mathbf{0}$ com taxa quadrática.
  - Convergência *local*, no sentido de que $\mathbf{x}^{(0)}$ deve ser suficientemente próximo de $\boldsymbol{\xi}$.

Algoritmo

```
// Dados: x = x0, número máx. iterações kmax
// e tolerâncias epsilon1, epsilon2
k = 0
Fx = F(x) // F no ponto inicial
modS = epsilon2+1
enquanto (k<=kmax) e (abs(Fx)>epsilon1) e (modS>epsilon2)
   k = k+1
   SistemaLinear ( J(x), s, -Fx) // obtenção de s
   x = x+s // próxima aproximação
   modS = abs(s) // módulo do passo de Newton s^(k)
   Fx = F(x)

// saída: valor x
```

Exemplo I

Aplicar o método de Newton, a partir de $\mathbf{x}^{(0)} = (1, 5)^t$, à resolução do sistema não linear

$$\mathbf{F}(x_1, x_2) = \begin{pmatrix} x_1 + x_2 - 3 \\ x_1^2 + x_2^2 - 9 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

cujas soluções são $\boldsymbol{\xi}_1 = (3, 0)^t$ e $\boldsymbol{\xi}_2 = (0, 3)^t$, considerando $\varepsilon = \varepsilon_1 = \varepsilon_2 = 10^{-4}$.

- Matriz jacobiana:

$$\mathbf{J}(\mathbf{x}) = \begin{pmatrix} 1 & 1 \\ 2x_1 & 2x_2 \end{pmatrix}.$$

Etapa $k = 0$

- Função $\mathbf{F}$ em $\mathbf{x}^{(0)}$:

$$\mathbf{F}(\mathbf{x}^{(0)}) = \begin{pmatrix} 3 \\ 17 \end{pmatrix}. \text{ Logo, } \|\mathbf{F}(\mathbf{x}^{(0)})\|_\infty = 17 >> \varepsilon_1$$

- Matriz jacobiana em $\mathbf{x}^{(0)}$:

$$\mathbf{J}(\mathbf{x}^{(0)}) = \begin{pmatrix} 1 & 1 \\ 2 & 10 \end{pmatrix}.$$

- Cálculo do passo de Newton:

$$\begin{pmatrix} 1 & 1 \\ 2 & 10 \end{pmatrix}\mathbf{s} = \begin{pmatrix} -3 \\ -17 \end{pmatrix} \quad \Rightarrow \quad \mathbf{s} = \begin{pmatrix} -13/8 \\ -11/8 \end{pmatrix} = \begin{pmatrix} -1,625 \\ -1,375 \end{pmatrix}.$$

- Próxima aproximação:

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \mathbf{s} = \begin{pmatrix} 1 \\ 5 \end{pmatrix} + \begin{pmatrix} -13/8 \\ -11/8 \end{pmatrix} = \begin{pmatrix} -0,625 \\ 3,625 \end{pmatrix} = \begin{pmatrix} -5/8 \\ 29/8 \end{pmatrix},$$

- Critério de parada:

$$\|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|_\infty = \max\{1,625,\ 1,375\} = 1,625 >> \varepsilon_2\,.$$

- Portanto, prossegue-se para a etapa 1.

Etapa $k = 1$

- Função $\mathbf{F}$ em $\mathbf{x}^{(1)}$:

$$\mathbf{F}(\mathbf{x}^{(1)}) = \begin{pmatrix} 0 \\ 145/32 \end{pmatrix} = \begin{pmatrix} 0 \\ 4,53125 \end{pmatrix}.$$

$$\text{Logo, } \|\mathbf{F}(\mathbf{x}^{(1)})\|_\infty = 4,53125 >> \varepsilon_1$$

- Matriz jacobiana em $\mathbf{x}^{(1)}$:

$$\mathbf{J}(\mathbf{x}^{(1)}) = \begin{pmatrix} 1 & 1 \\ -5/4 & 29/4 \end{pmatrix}.$$

- Cálculo do passo de Newton:

$$\begin{pmatrix} 1 & 1 \\ -5/4 & 29/4 \end{pmatrix} \mathbf{s} = \begin{pmatrix} 0 \\ -4,531 \end{pmatrix} \quad \Rightarrow \quad \mathbf{s} = \begin{pmatrix} 0,533 \\ -0,533 \end{pmatrix}.$$

- Próxima aproximação:

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \mathbf{s} = \begin{pmatrix} -0,625 \\ 3,625 \end{pmatrix} + \begin{pmatrix} 0,533 \\ -0,533 \end{pmatrix} = \begin{pmatrix} -0,092 \\ 3,0917 \end{pmatrix},$$

- Critério de parada:

$$\|\mathbf{x}^{(2)} - \mathbf{x}^{(1)}\|_\infty = 0,533 >> \varepsilon_2 \,.$$

- Portanto, prossegue-se para a etapa 2.

6.3 Método de Newton modificado

- Como visto, o método de Newton é computacionalmente caro, pois requer a cada etapa ambos os cálculos da matriz jacobiana $\mathbf{J}(\mathbf{x}^{(k)})$ e de um sistema linear para se obter o passo de Newton $\mathbf{s}^{(k)}$.
- O *método de Newton modificado* usa, a cada iteração k, $\mathbf{J}(\mathbf{x}^{(0)})$, em vez de $\mathbf{J}(\mathbf{x}^{(k)})$.
- Ou seja, em qualquer etapa k, $\mathbf{s}^{(k)}$ é solução do sistema linear

$$\mathbf{J}(\mathbf{x}^{(0)})\mathbf{s}^{(k)} = -\mathbf{F}(\mathbf{x}^{(k)}) \,.$$

- *Vantagens:*
  - Matriz jacobiana calculada única vez, então para todo k o sistema linear terá a mesma matriz de coeficientes;
  - Usando-se fatoração LU, os fatores L e U são portanto calculados uma vez somente;

    A partir da 2a. iteração, $\mathbf{s}^{(k)}$ é dado a partir de 2 sistemas triangulares.

Exemplo II

Aplicar o método de Newton modificado, a partir de $\mathbf{x}^{(0)} = (1, 5)^t$, à resolução do sistema não linear visto anteriormente:

$$\mathbf{F}(x_1, x_2) = \begin{pmatrix} x_1 + x_2 - 3 \\ x_1^2 + x_2^2 - 9 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

- Matriz jacobiana:

$$\mathbf{J}(\mathbf{x}) = \begin{pmatrix} 1 & 1 \\ 2x_1 & 2x_2 \end{pmatrix}.$$

- Em $\mathbf{x}^{(0)}$:

$$\mathbf{F}(\mathbf{x}^{(0)}) = \begin{pmatrix} 3 \\ 17 \end{pmatrix}, \qquad \mathbf{J}(\mathbf{x}^{(0)}) = \begin{pmatrix} 1 & 1 \\ 2 & 10 \end{pmatrix}.$$

- A fatoração LU de $\mathbf{J}(\mathbf{x}^{(0)})$ é dada por (com pivotamento parcial):

$$\underbrace{\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}}_{\mathbf{P}} \underbrace{\begin{pmatrix} 1 & 1 \\ 2 & 10 \end{pmatrix}}_{\mathbf{J}(1,5)} = \underbrace{\begin{pmatrix} 1 & 0 \\ 1/2 & 1 \end{pmatrix}}_{\mathbf{L}} \underbrace{\begin{pmatrix} 2 & 10 \\ 0 & -4 \end{pmatrix}}_{\mathbf{U}}.$$

- *Etapa* $k = 0$: $\mathbf{s}^{(0)} = (-1,625,\ -1,375)^t$ é obtido resolvendo-se os sistemas:

$$\underbrace{\begin{pmatrix} 1 & 0 \\ 1/2 & 1 \end{pmatrix}}_{\mathbf{L}} \underbrace{\begin{pmatrix} y_1 \\ y_2 \end{pmatrix}}_{\mathbf{y}} = \underbrace{\begin{pmatrix} -17 \\ -3 \end{pmatrix}}_{-\mathbf{P}\mathbf{F}(\mathbf{x}^{(0)})}, \text{ e após } \underbrace{\begin{pmatrix} 2 & 10 \\ 0 & -4 \end{pmatrix}}_{\mathbf{U}} \underbrace{\begin{pmatrix} s_1^{(0)} \\ s_2^{(0)} \end{pmatrix}}_{\mathbf{s}^{(0)}} = \underbrace{\begin{pmatrix} -17 \\ 5,5 \end{pmatrix}}_{\mathbf{y}}.$$

- Obtém-se a partir de $\mathbf{s}^{(0)}$ o valor $\mathbf{x}^{(1)} = (-0,625,\ 3,625)^t$, mesmo valor obtido para o método de Newton sem modificação.
- $\mathbf{F}(\mathbf{x}^{(1)}) = (0,\ 4,53125)^t$.
- *Etapa* $k = 1$:

$$\mathbf{J}(\mathbf{x}^{(0)})\mathbf{s} = -\mathbf{F}(\mathbf{x}^{(1)}) = -\begin{pmatrix} 0 \\ 4,53125 \end{pmatrix}$$

  Obtém-se $\mathbf{s} = (0,56640625,\ -0,56640625)^t$.

  – Logo, $\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \mathbf{s} = (-0,05859375,\ 3,05859375)^t$.

6.4 Métodos quase-Newton

- *Motivação:* gerar sequência $\{\mathbf{x}^{(k)}\}$ convergente, sem atualizar $\mathbf{J}(\mathbf{x})$ a cada iteração – como visto para o método de Newton modificado, onde se calcula apenas $\mathbf{J}(\mathbf{x_0})$.
  - Entretanto, ao se usar $\mathbf{J}(\mathbf{x_0})$ a taxa quadrática de convergência é substituída por uma taxa linear – portanto, *mais lenta*.
- Nos métodos quase-Newton, em qualquer etapa k, $\mathbf{s}^{(k)}$ é solução do sistema linear

$$\mathbf{B}^{(k)}\mathbf{s} = -\mathbf{F}(\mathbf{x}^{(k)})\,.$$

- Atualiza-se a matriz $\mathbf{B}^{(k)}$ a cada iteração.

Atualização das matrizes $\mathbf{B}^{(k)}$

- A cada iteração, impõe-se que as matrizes satisfaçam

$$\mathbf{B}^{(k+1)}\left(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\right) = \mathbf{F}(\mathbf{x}^{(k+1)}) - \mathbf{F}(\mathbf{x}^{(k)})\,.$$

  Considera-se aqui o fato de que

$$\mathbf{L}_{k+1}(\mathbf{x}) = \mathbf{F}(\mathbf{x}^{(k+1)}) + \mathbf{B}^{(k+1)}\left(\mathbf{x} - \mathbf{x}^{(k+1)}\right)$$

  é um modelo linear que aproxima $\mathbf{F}(\mathbf{x})$ em torno do ponto $\mathbf{x}^{(k+1)}$. Note que $\mathbf{L}_{k+1}(\mathbf{x}^{(k+1)}) = \mathbf{F}(\mathbf{x}^{(k+1)})$ é satisfeita independentemente da escolha de $\mathbf{B}^{(k+1)}$.
- Impondo-se também que o mesmo valha no ponto $\mathbf{x}^{(k)}$, i.e. $\mathbf{L}_{k+1}(\mathbf{x}^{(k)}) = \mathbf{F}(\mathbf{x}^{(k)})$, obtém-se

$$\mathbf{L}_{k+1}(\mathbf{x}^{(k)}) = \mathbf{F}(\mathbf{x}^{(k+1)}) + \mathbf{B}^{(k+1)}\left(\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)}\right) = \mathbf{F}(\mathbf{x}^{(k)})\,.$$

- A partir da última equação chega-se a condição dada:

$$\mathbf{B}^{(k+1)}\underbrace{\left(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\right)}_{\mathbf{s}^{(k)}} = \mathbf{F}(\mathbf{x}^{(k+1)}) - \mathbf{F}(\mathbf{x}^{(k)})\,.$$

- Definindo-se $\mathbf{y}^{(k)} = \mathbf{F}(\mathbf{x}^{(k+1)}) - \mathbf{F}(\mathbf{x}^{(k)})$, reescreve-se a condição acima como

$$\mathbf{B}^{(k+1)}\mathbf{s}^{(k)} = \mathbf{y}^{(k)} \qquad \textit{(equação secante)}\,. \tag{7}$$

- Os métodos quase-Newton são também conhecidos como *métodos secantes*.
- *Caso* $n = 1$: O método da secante visto anteriormente no curso – usado para se encontrar um zero real de uma função real – consiste em aproximar $f(x) : \mathbb{R} \to \mathbb{R}$ por uma reta $r(x)$, que passa pelos pontos $(x_k, f(x_k))$ e $(x_{k+1}, f(x_{k+1}))$. Logo,

$$r(x) = f(x_{k+1}) + b(x - x_{k+1}) .$$

- Impondo-se as condições $r(x_k) = f(x_k)$ e $r(x_{k+1}) = f(x_{k+1})$, obtém-se

$$b = \frac{f(x_{k+1}) - f(x_k)}{x_{k+1} - x_k} \quad \Rightarrow \quad bs_k = y_k .$$

  b satisfaz a equação secante para 1 dimensão, portanto, e neste caso, a escolha é única.

- *Caso* $n > 1$: a equação secante (7) não é suficiente para se determinar uma matriz $\mathbf{B}^{(k+1)}$ única: sistema tem n equações e n^2 variáveis (SPI) – os valores $b_{ij}^{(k+1)}$.
- Métodos quase-Newton impõem condições adicionais para tornar (7) um SPD (solução única), como:
- restringir a variação de $\mathbf{B}^{(k+1)}$ em relação a $\mathbf{B}^{(k)}$ a um certo valor mínimo;
- preservar algum aspecto da matriz jacobiana, ex.: simetria, esparsidade.

Ex.: método de Broyden

Método quase-Newton que define

$$\mathbf{B}^{(k+1)} = \mathbf{B}^{(k)} + \mathbf{u}^{(k)} \left(\mathbf{s}^{(k)}\right)^t ,$$

onde

$$\mathbf{u}^{(k)} = \frac{\left(\mathbf{y}^{(k)} - \mathbf{B}^{(k)}\mathbf{s}^{(k)}\right)}{\left(\mathbf{s}^{(k)}\right)^t \mathbf{s}^{(k)}} .$$

Ou seja, a partir de uma aproximação inicial $\mathbf{x}^{(0)}$ e uma matriz $\mathbf{B}^{(0)}$:

1. Resolver o sistema: $\mathbf{B}^{(k)}\mathbf{s}^{(k)} = -\mathbf{F}(\mathbf{x}^{(k)})$;
2. Definir: $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{s}^{(k)}$;
3. Calcular: $\mathbf{B}^{(k+1)} = \mathbf{B}^{(k)} + \dfrac{1}{\left(\mathbf{s}^{(k)}\right)^t \mathbf{s}^{(k)}} \mathbf{F}(\mathbf{x}^{(k+1)}) \left(\mathbf{s}^{(k)}\right)^t$.

Exemplo III

Obter $\mathbf{x}^{(2)}$ pelo método de Broyden, a partir de $\mathbf{x}^{(0)} = (1,5)^t$ e $\mathbf{B}^{(0)} = \begin{pmatrix} 1 & 1 \\ 2 & 10 \end{pmatrix}$, a resolução do sistema não linear visto anteriormente:

$$\mathbf{F}(x_1, x_2) = \begin{pmatrix} x_1 + x_2 - 3 \\ x_1^2 + x_2^2 - 9 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Iteração $k = 0$:

$$\underbrace{\begin{pmatrix} 1 & 1 \\ 2 & 10 \end{pmatrix}}_{\mathbf{B}^{(0)}} \underbrace{\begin{pmatrix} s_1^{(0)} \\ s_2^{(0)} \end{pmatrix}}_{\mathbf{s}^{(0)}} = \underbrace{\begin{pmatrix} -3 \\ -17 \end{pmatrix}}_{-\mathbf{F}(\mathbf{x}^{(0)})} \quad \Rightarrow \quad \mathbf{s}^{(0)} = \begin{pmatrix} -1,62 \\ -1,38 \end{pmatrix}.$$

$$\mathbf{x}^{(1)} = \underbrace{\begin{pmatrix} 1 \\ 5 \end{pmatrix}}_{\mathbf{x}^{(0)}} + \underbrace{\begin{pmatrix} -1,62 \\ -1,38 \end{pmatrix}}_{\mathbf{s}^{(0)}} = \begin{pmatrix} -0,62 \\ 3,62 \end{pmatrix}.$$

$$\mathbf{B}^{(1)} = \underbrace{\begin{pmatrix} 1 & 1 \\ 2 & 10 \end{pmatrix}}_{\mathbf{B}^{(0)}} + \frac{1}{\underbrace{4,53}_{(\mathbf{s}^{(0)})^t\mathbf{s}^{(0)}}} \underbrace{\begin{pmatrix} 0 \\ 4,53 \end{pmatrix}}_{-\mathbf{F}(\mathbf{x}^{(1)})} \underbrace{\begin{pmatrix} -1,62 & -1,38 \end{pmatrix}}_{(\mathbf{s}^{(0)})^t}$$

$$= \begin{pmatrix} 1 & 1 \\ 2 & 10 \end{pmatrix} + \frac{1}{4,53} \begin{pmatrix} 0 & 0 \\ -7,36 & -6,23 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0,38 & 8,62 \end{pmatrix}.$$

Iteração $k = 1$:

$$\underbrace{\begin{pmatrix} 1 & 1 \\ 0,38 & 8,62 \end{pmatrix}}_{\mathbf{B}^{(1)}} \underbrace{\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix}}_{\mathbf{s}^{(1)}} = \underbrace{\begin{pmatrix} 0 \\ 4,53 \end{pmatrix}}_{-\mathbf{F}(\mathbf{x}^{(1)})} \quad \Rightarrow \quad \mathbf{s}^{(1)} = \begin{pmatrix} 0,55 \\ -0,55 \end{pmatrix}.$$

$$\mathbf{x}^{(2)} = \underbrace{\begin{pmatrix} -0,62 \\ 3,62 \end{pmatrix}}_{\mathbf{x}^{(1)}} + \underbrace{\begin{pmatrix} 0,55 \\ -0,55 \end{pmatrix}}_{\mathbf{s}^{(1)}} = \begin{pmatrix} -0,07 \\ 3,07 \end{pmatrix}.$$

6.5 Exercícios

1. Prosseguir com as etapas seguintes do Exemplo I (método de Newton) até que $\|\mathbf{F}(\mathbf{x}^{(k)})\|_\infty < 10^{-4}$ ou $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|_\infty < 10^{-4}$.

2. Prosseguir com as etapas seguintes do Exemplo II (método de Newton modificado) até que $\|\mathbf{F}(\mathbf{x}^{(k)})\|_\infty < 10^{-4}$ ou $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|_\infty < 10^{-4}$.

3. Escrever o algoritmo para o método de Newton modificado.

4. Usando uma linguagem de programação e precisão dupla, implemente os métodos de Newton e Newton modificado.

5. Usando os programas escritos, resolva os problemas a seguir com $\varepsilon = 10^{-7}$:

   (a)
   $$\begin{cases} x_1^2 + x_2^2 - 2 = 0 \\ e^{x_1 - 1} + x_2^3 - 2 = 0\,, \end{cases} \qquad \mathbf{x}^{(0)} = (1,5,\ 2,0)^t.$$

   (b)
   $$\begin{cases} 4x_1 - x_1^3 + x_2 = 0 \\ \dfrac{-x_1^2}{9} + \dfrac{4x_2 - x_2^2}{4} = -1\,, \end{cases} \qquad \mathbf{x}^{(0)} = (-1,\ -2)^t.$$

   (c)
   $$\begin{cases} \dfrac{2x_1 - x_1^2 + 8}{9} + \dfrac{4x_2 - x_2^2}{4} = 0 \\ 8x_1 - 4x_1^2 + x_2^2 + 1 = 0\,, \end{cases} \qquad \mathbf{x}^{(0)} = (-1,\ -1)^t.$$

   (d) (Função de Rosenbrock)
   $$\begin{cases} 10(x_2 - x_1^2) = 0 \\ 1 - x_1 = 0\,, \end{cases} \qquad \mathbf{x}^{(0)} = (-1,2,\ 1)^t.$$

Referências

1. RUGGIERO, M. A. G.; LOPES, V. L. R. *Cálculo numérico: aspectos teóricos e computacionais*. 2ª. ed. São Paulo: Makron Books. 1996.

2. VALLE, M. E. *MS211 – Cálculo Numérico. Aula 11 — Sistemas Não-lineares e o Método de Newton.* Disponível em: http://www.ime.unicamp.br/~valle/Teaching/MS211/Aula11.pdf. Acesso em: 23 de mar. de 2021

3. VALLE, M. E. *MS211 – Cálculo Numérico. Aula 12 — Variações do Método de Newton para Sistemas Não-Lineares.* Disponível em: http://www.ime.unicamp.br/~valle/Teaching/MS211/Aula12.pdf. Acesso em: 23 de mar. de 2021

Adaptações: Renato Pimentel, FACOM/UFU

7 Integração numérica

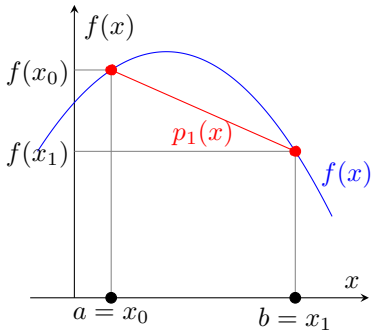
7.1 Introdução

- Em determinadas situações, integrais são difíceis, ou mesmo impossíveis de se resolver analiticamente.

  Exemplo: o valor de $f(x)$ é conhecido apenas em alguns pontos, num intervalo $[a, b]$. Como não se conhece a expressão analítica de $f(x)$, não é possível calcular

$$\int_a^b f(x)dx$$

- Em tais casos: forma de obtenção de uma aproximação para a integral de $f(x)$ num intervalo $[a, b]$: *Métodos numéricos.*
- *Ideia básica da integração numérica*: substituição da função $f(x)$ por um *polinômio* que a aproxime razoavelmente no intervalo $[a, b]$.
- *Integração numérica de uma função $f(x)$ num intervalo $[a, b]$*: cálculo da área delimitada por essa função, recorrendo à *interpolação polinomial*, como forma de obtenção de um polinômio – $p_n(x)$.



- As fórmulas terão a expressão abaixo:

$$\int_a^b f(x)dx \approx A_0 f(x_0) + A_1 f(x_1) + \cdots + A_n f(x_n)\,,$$
$$x_i \in [a, b], i = 0,\, 1,\, \ldots,\, n$$

- *Fórmulas de integração* (fórmulas de quadratura):

$$I_n(f) = \sum_{i=0}^{n} A_i f(x_i)\,. \tag{8}$$

  - $x_0, \ldots, x_n$: $n+1$ pontos conhecidos, pertencentes ao intervalo $[a, b]$ (*nós de integração*).
  - $A_0, \ldots, A_n$: coeficientes a determinar, independentes de $f(x)$ (*pesos*).

- Do Cálculo, a integral definida (de Riemann) de f contínua em $[a, b]$ é

$$I(f) = \int_a^b f(x)dx = \lim_{n\to\infty} \sum_{i=0}^{n} f(x_i)\Delta x\,, \qquad \Delta x = (b-a)/n\,.$$

O uso desta técnica decorre do fato de:

- Por vezes, $f(x)$ ser uma função muito difícil de integrar, contrariamente a um polinômio;
- conhecer-se o resultado analítico do integral, mas seu cálculo ser somente aproximado;
- a única informação sobre $f(x)$ ser um conjunto de pares ordenados.

Métodos de integração numérica mais utilizados

Fórmulas de Newton-Cotes

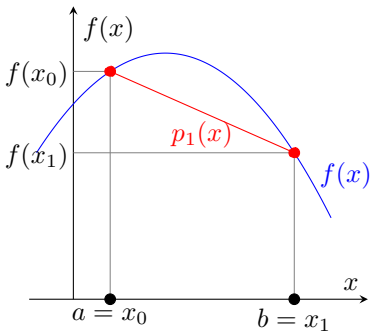
Ideia de *polinômio* que *interpole* $f(x)$ em nós de integração em $[a, b]$ que sejam *igualmente espaçados*:

Intervalo $[a, b]$ particionado em n subintervalos $[x_i, x_{i+1}]$, $i = 0, 1, \ldots, n-1$, de comprimento $h = (b-a)/n = x_{i+1} - x_i$.

- Fórmulas de Newton-Cotes fechadas ($x_0 = a$ e $x_n = b$):
  - *Regra dos trapézios*;
  - *Regra 1/3 de Simpson.*
- Fórmulas de Newton-Cotes abertas:
  - Nós de integração x_i têm de pertencer ao intervalo aberto de a até b.

7.2 Regra dos trapézios

- *Regra dos trapézios simples:* consiste em considerar um polinômio de primeiro grau que aproxima uma função $f(x)$, ou seja, $n = 1$.
- Este polinômio terá a forma $p_1(x) = a_0 + a_1 x$ e trata-se da equação da reta que une dois pontos: $(a = x_0, f(x_0))$ e $(b = x_1, f(x_1))$.



Regra dos trapézios simples

- *Área do trapézio:* dada por

$$A = h\frac{T+t}{2}\,,$$

  onde h = altura do trapézio, T = base maior e t = base menor.

- De acordo com o gráfico:

$$\begin{aligned} h &= b - a = x_1 - x_0\,, \\ T &= f(a) = f(x_0)\,, \\ t &= f(b) = f(x_1)\,. \end{aligned}$$

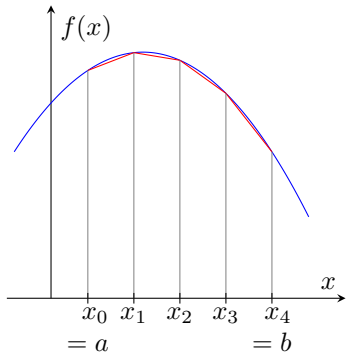
- Logo,

$$\int_a^b f(x)dx \approx T_1(f) = \frac{x_1 - x_0}{2}\left[f(x_0) + f(x_1)\right]\,. \tag{9}$$

- Intervalo $[a, b]$ relativamente pequeno:
  - aproximação do valor do integral é aceitável.
- Intervalo $[a, b]$ de grande amplitude:
  - Aproximação defasada.
  - Pode-se subdividi-lo em n sub-intervalos, e em cada um a função é aproximada por uma função linear.
  - A amplitude dos sub-intervalos será $h = (b - a)/n$.
  - A integral no intervalo é dado pela soma dos integrais definidos pelos sub-intervalos.
  - Regra dos trapézios simples aplicada aos sub-intervalos.
  - Uso da *Regra dos Trapézios Composta (Repetida)*: soma da área de n trapézios, cada qual definido pelo seu sub-intervalo.

Regra dos trapézios composta

- Intervalo $[a, b]$ de grande amplitude.
- Soma da área de n trapézios, cada qual definido pelo seu sub-intervalo.



- Fórmula:

$$I(f) = \int_a^b f(x)dx \approx T_n(f) = \frac{h}{2}\left[f(x_0) + f(x_1)\right] + \frac{h}{2}\left[f(x_1) + f(x_2)\right] + \cdots + \frac{h}{2}\left[f(x_{n-1}) + f(x_n)\right] .$$

- Como somente os termos $f(x_0)$ e $f(x_n)$ não se repetem, esta fórmula pode ser simplificada em:

$$\begin{aligned} I(f) \approx T_n(f) &= \frac{h}{2}\left\{f(x_0) + 2\left[f(x_1) + \cdots + f(x_{n-1})\right] + f(x_n)\right\} \\ &= \frac{h}{2}\left(f(x_0) + 2f(x_1) + \cdots + 2f(x_{n-1}) + f(x_n)\right) . \end{aligned}$$

Exemplo

Estimar o valor de $\int_0^4 (1 + x^2)^{-1/2} dx$, com valores tabelados como abaixo:

x_i	$f_i = (1 + x_i^2)^{-1/2}$
0,0	1,00000
0,5	0,89445
1,0	0,70711
1,5	0,55475
2,0	0,44722
2,5	0,37138
3,0	0,31623
3,5	0,27473
4,0	0,24254

- Regra dos trapézios simples – 2 pontos ($x_0 = 0,0$ e $x_1 = 4,0$):

$$T_1(f) = \frac{x_1 - x_0}{2}\,(f_0 + f_1) = 2(1,00000 + 0,24254) = 2,48508\,.$$

- Regra dos trapézios composta – 3 pontos ($x_0 = 0,0$, $x_1 = 2,0$ e $x_2 = 4,0$; $h = (4,0 - 0,0)/2 = 2,0$):

$$T_2(f) = \frac{h}{2}(f_0 + 2f_1 + f_2) = (1,00000 + 2 \times 0,44722 + 0,24254) = 2,1369\,.$$

- Regra dos trapézios composta – 9 pontos ($x_0 = 0,0$, $x_1 = 0,5$, ..., $x_8 = 4,0$; $h = (4,0 - 0,0)/8 = 0,5$):

$$T_8(f) = \frac{h}{2}\,[f_0 + 2(f_1 + f_2 + \cdots + f_7) + f_8] = \cdots = 2,0936\,.$$

- A aproximação $T_8(f)$ é melhor, uma vez que $I = 2,0947125472\ldots$

Erro da regra dos trapézios

- Foi visto ao se estudar o erro pela interpolação polinomial que

$$f(x) = p_1(x) + (x - x_0)(x - x_1)\frac{f''(\xi_x)}{2}\,, \qquad \xi_x \in (x_0, x_1)\,.$$

- Ao se integrar ambos os lados no intervalo $[x_0, x_1]$:

$$\begin{aligned} I(f) = \int_{x_0}^{x_1} f(x)dx &= \int_{x_0}^{x_1} p_1(x)dx + \int_{x_0}^{x_1} (x - x_0)(x - x_1)\frac{f''(\xi_x)}{2}dx \\ &= T_1(f) + E_T\,, \end{aligned}$$

  onde ξ_x varia com o valor de x, e assim

$$E_T = \frac{1}{2}\int_{x_0}^{x_1} (x - x_0)(x - x_1)f''(\xi_x)dx\,. \tag{10}$$

- Seja $g(x) = (x - x_0)(x - x_1)$. Observa-se que $\forall x \in (x_0, x_1)$, $g(x) < 0$.
- Supondo-se $f''(x)$ contínua em $[x_0, x_1]$, existem valores reais p e P tais que $p \leq f''(x) \leq P$. Logo, $p \leq f''(\xi_x) \leq P$ e, como $g(x) \leq 0$,

$$pg(x) \geq g(x)f''(\xi_x) \geq Pg(x)\,.$$

(o sinal de desigualdade é trocado ao se multiplicar a inequação por $g(x)$). Integrando-se a a mesma no intervalo $[x_0, x_1]$:

$$P \underbrace{\int_{x_0}^{x_1} g(x)dx}_{<0} \leq \int_{x_0}^{x_1} g(x)f''(\xi_x)dx \leq p \underbrace{\int_{x_0}^{x_1} g(x)dx}_{<0},$$

o que leva a

$$p \leq \underbrace{\frac{\int_{x_0}^{x_1} g(x)f''(\xi_x)dx}{\int_{x_0}^{x_1} g(x)dx}}_{=A} \leq P\,.$$

Teorema do valor médio para integrais
Se $f''(x)$ é contínua em $[x_0, x_1]$, como suposto, e $p \leq A \leq P$, então existe $c \in [x_0, x_1]$ tal que $f''(c) = A$, i.e.

$$\int_{x_0}^{x_1} g(x)f''(\xi_x)dx = f''(c)\int_{x_0}^{x_1} g(x)dx\,.$$

- Portanto, o erro cometido E_T – Eq. (10) – é tal que

$$E_T = \frac{1}{2}\int_{x_0}^{x_1} g(x)f''(\xi_x)dx = \frac{1}{2}f''(c)\int_{x_0}^{x_1} g(x)dx,\ c \in [x_0, x_1]\,.$$

- Como (*exercício*) $\int_{x_0}^{x_1} g(x)dx = \dfrac{-h^3}{6}$, onde $h = x_1 - x_0$,

$$E_T = -\frac{h^3}{12}f''(c),\ c \in [x_0, x_1]\,.$$

- As considerações vistas são para o caso da regra dos trapézios simples.
- No caso da regra dos trapézios composta:

$$\begin{aligned} I(f) = \int_{x_0}^{x_1} f(x)dx &= \sum_{i=0}^{n-1}\left[\frac{h}{2}\left(f(x_i) + f(x_{i+1})\right) - \frac{h^3}{12}f''(c_i)\right] \\ &= \frac{h}{2}\sum_{i=0}^{n-1}\left(f(x_i) + f(x_{i+1})\right) - \frac{h^3}{12}\sum_{i=0}^{n-1} f''(c_i) \\ &= T_n(f) + E_T\,, \end{aligned}$$

onde agora $h = (b-a)/n = (x_n - x_0)/n$.

Estimativa do erro

- Supondo que f'' é contínua em $[a, b]$, uma generalização do teorema do valor intermediário garante que existe $\xi_x \in (a, b)$ tal que

$$E_T = -\frac{h^3}{12} \sum_{i=0}^{n-1} f''(c_i) = -nf''(\xi_x)\frac{h^3}{12}\,.$$

- Ainda, pela mesma hipótese de continuidade de $f''(x)$ em $[a, b]$, existe $M_2 = \max_{x\in[a,b]} |f''(x)|$. Como $n = (b - a)/h$,

$$|E_T| = |I(f) - T_n(f)| \leq \frac{b-a}{12}h^2 M_2\,.$$

- *Observação:* como na estimativa acima, eliminou-se n, a desigualdade independe do número de pontos, sendo válida tanto para a regra dos trapézios simples quanto para a composta.

Exemplo

Dado $I(f) = \int_0^1 e^x dx$:

1. Aproxime $I(f)$ usando a regra do trapézio com 10 subintervalos. Estime o erro cometido.

2. Qual o número de subdivisões de modo que o erro seja inferior a 10^{-3}?

Solução:

1. $x_i = 0,1i$, $i = 0, 1, \ldots, 10$ dividem $[0, 1]$ em 10 subintervalos, com $h = 0,1$. Pela regra dos trapézios composta:

$$T_{10}(f) = \frac{0,1}{2}\left(e^0 + 2e^{0,1} + \cdots + 2e^{0,9} + e\right) = 1,719713\,.$$

Neste caso, a solução exata é conhecida, dada por

$$I(f) = \int_0^1 e^x dx = e^1 - 1 \approx 1,718282\,,$$

de modo que $|E_T| = |I(f) - T_{10}(f)| = 0,001431$. Usando-se a estimativa, uma vez que $M_2 = \max_{0\leq x\leq 1} |e^x| = e$:

$$0,001431 = |E_T| \leq \frac{b-a}{12}h^2 M_2 = \frac{1,0-0,0}{12}(0,1)^2 e = 0,002265\,.$$

(neste caso, foi possível calcular $|E_T|$ porque o valor da integral é conhecido).

2. Para que $|E_T| = |I(f) - T_n(f)| < 10^{-3}$:

   Dado que $|E_T| \leq \dfrac{b-a}{12}h^2 M_2$, basta considerar $\dfrac{b-a}{12}h^2 M_2 < 10^{-3}$:

$$\frac{b-a}{12}h^2 M_2 = \frac{e}{12}h^2 < 10^{-3} \quad \Rightarrow \quad h < \sqrt{\frac{12 \times 10^{-3}}{e}}\,.$$

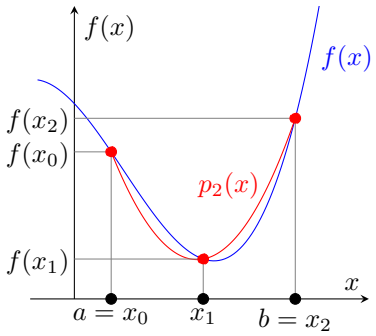
   Uma vez que $n = (b-a)/h$:

$$n = \frac{b-a}{h} = \frac{1}{h} > \sqrt{\frac{e}{12 \times 10^{-3}}} = 15,03759\,.$$

   Como $n > 15,03759$ e $n \in \mathbb{N}$, o número de subdivisões deverá ser pelo menos 16 ($n \geq 16$).

7.3 Regra 1/3 de Simpson

- *Regra 1/3 de Simpson simples*: considera-se um *polinômio de segundo grau* $p_2(x)$ que aproxima uma função $f(x)$.
- Tal polinômio é a equação da parábola que passa por três pontos igualmente espaçados $(x_0, f(x_0))$, $(x_1, f(x_1))$ e $(x_2, f(x_2))$.



- A regra dos trapézios simples pode ser deduzida considerando-se a fórmula de Lagrange para $n = 1$: encontra-se o polinômio $p_1(x)$ que interpola os 2 pontos $x_0 = a$, $x_1 = b$ com pesos $A_i = \int_a^b L_i(x)dx$, $i = 0, 1$ – vide Eq. (8). L_i são os polinômios de Lagrange.
- Na *regra 1/3 de Simpson*, novamente pode se usar fórmula de Lagrange para $n = 2$, para encontrar o polinômio $p_2(x)$ que interpola $f(x)$ nos

pontos $x_0 = a$, $x_1 = x_0 + h = (a+b)/2$ e $x_2 = x_0 + 2h = b$:

$$A_0 = \int_a^b L_0(x)dx = \int_{x_0}^{x_2} \frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)}dx = \frac{h}{3}\,,$$
$$A_1 = \int_a^b L_1(x)dx = \int_{x_0}^{x_2} \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)}dx = \frac{4h}{3}\,,$$
$$A_2 = \int_a^b L_2(x)dx = \int_{x_0}^{x_2} \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)}dx = \frac{h}{3}\,.$$

(é possível resolver as integrais acima com a mudança de variáveis $x - x_0 = zh$, de forma que $dx = hdz$ e $x = x_0 + zh$).

Regra 1/3 de Simpson simples

- Logo, pela regra 1/3 de Simpson:

$$I(f) \approx S_2^{(1/3)}(f) = \frac{h}{3}\left[f(x_0) + 4f(x_1) + f(x_2)\right]\,.$$

  – Note que $S_2^{(1/3)}(f) = \int_a^b p_2(x)dx$.

- Supondo-se $f^{(4)}$ contínua em $[a,b] = [x_0, x_2]$, o erro da fórmula de Simpson é

$$E_S = -\frac{h^5}{90}f^{(4)}(c),\ c \in [x_0, x_2]\,.$$

Regra 1/3 de Simpson composta

- Similar ao visto para a regra dos trapézios composta: intervalo $[a,b]$ de grande amplitude, tornando inviável o uso de apenas 3 nós de integração – E_S pode ser muito alto.
- Consideram-se $n+1$ nós de integração igualmente espaçados no intervalo $[a,b]$, com n *par*.
- Aplica-se a regra 1/3 de Simpson em cada *par de subintervalos* $[x_{2i-2}, x_{2i}]$, para $i = 1, \ldots, n/2$.
- Em cada par de subintervalos:

$$\int_{x_{2i-2}}^{x_{2i}} f(x)dx = \frac{h}{3}\left[f(x_{2i-2}) + 4f(x_{2i-1}) + f(x_{2i})\right] + \left[-\frac{h^5}{90}f^{(4)}(c_i)\right],$$
$$c_i \in [x_{2i-2}, x_{2i}],\ i = 1,\ 2,\ \ldots,\ \frac{n}{2}\,.$$

- Logo,

$$\begin{aligned} I(f) = &\int_{x_0}^{x_n} f(x)dx = \sum_{i=1}^{n/2} \int_{x_{2i-2}}^{x_{2i}} f(x)dx \\ =&\sum_{i=1}^{n/2} \left\{ \frac{h}{3} \left[f(x_{2i-2}) + 4f(x_{2i-1}) + f(x_{2i}) \right] - \frac{h^5}{90} f^{(4)}(c_i) \right\} \\ =&\frac{h}{3} \sum_{i=1}^{n/2} \left[f(x_{2i-2}) + 4f(x_{2i-1}) + f(x_{2i}) \right] - \frac{h^5}{90} \sum_{i=1}^{n/2} f^{(4)}(c_i) \\ =&S_n^{(1/3)}(f) + E_S \, . \end{aligned}$$

Concluindo, a fórmula da regra 1/3 de Simpson composta é dada por

$$\begin{aligned} S_n^{(1/3)}(f) &= \frac{h}{3} \sum_{i=1}^{n/2} \left[f(x_{2i-2}) + 4f(x_{2i-1}) + f(x_{2i}) \right] \\ &= \frac{h}{3} \Big[f(x_0) + 4f(x_1) + 2f(x_2) + 4f(x_3) + \ldots \\ &\qquad + 2f(x_{n-2}) + 4f(x_{n-1}) + f(x_n) \Big] \, . \end{aligned}$$

Estimativa do erro

- Similar ao visto previamente para a regra dos trapézios, supondo que a derivada de quarta ordem de $f(x)$, $f^{(4)}$, seja contínua em $[a, b]$, uma generalização do teorema do valor intermediário garante que existe $\xi_x \in (a, b)$ tal que

$$E_S = -\frac{h^5}{90} \sum_{i=1}^{n/2} f^{(4)}(c_i) = -\frac{n}{2} f^{(4)}(\xi_x) \frac{h^5}{90} \, .$$

- Ainda, existe $M_4 = \max_{x \in [a,b]} |f^{(4)}(x)|$. Como $n = (b - a)/h$,

$$|E_S| = |I(f) - S_n^{(1/3)}(f)| \leq \frac{(b-a)}{180} h^4 M_4 \, .$$

Exemplo

Dado $I(f) = \int_0^1 e^x dx$:

1. Aproxime $I(f)$ usando a regra 1/3 de Simpson com 10 subintervalos. Estime o erro cometido.

2. Qual o número de subdivisões de modo que o erro seja inferior a 10^{-3}?

Solução:

1. $x_i = 0,1i$, $i = 0,\ 1,\ \ldots,\ 10$, dividem $[0,1]$ em 10 subintervalos, com $h = 0,1$. Pela regra 1/3 de Simpson composta:

$$S_{10}^{(1/3)}(f) = \frac{0,1}{3}\Big(e^0 + 4e^{0,1} + 2e^{0,2} + \ldots + 2e^{0,8} + 4e^{0,9} + e\Big) = 1,7183\,.$$

O erro é dado por $|E_S| = |I(f) - S_{10}^{(1/3)}(f)| = 9,5347 \times 10^{-7}$. Usando-se a estimativa, uma vez que $M_4 = \max_{0\leq x\leq 1} |e^x| = e$:

$$|E_T| \leq \frac{b-a}{180}h^4 M_4 = \frac{1,0-0,0}{180}(0,1)^4 e = 1,51016 \times 10^{-6}\,.$$

De fato, $|E_T| = 9,5347 \times 10^{-7} < 1,51016 \times 10^{-6}$.

2. Para que $|E_S| = |I(f) - S_n^{(1/3)}(f)| < 10^{-3}$:

Dado que $|E_S| \leq \dfrac{b-a}{180}h^4 M_4$, basta considerar $\dfrac{b-a}{180}h^4 M_4 < 10^{-3}$:

$$\frac{b-a}{180}h^4 M_4 = \frac{e}{180}h^4 < 10^{-3} \quad \Rightarrow \quad h < \sqrt[4]{\frac{180 \times 10^{-3}}{e}}\,.$$

Uma vez que $n = (b-a)/h$:

$$n = \frac{b-a}{h} = \frac{1}{h} > \sqrt[4]{\frac{e}{180 \times 10^{-3}}} = 1,9713\,.$$

Como $n > 1,9713$ e $n/2 \in \mathbb{N}$ (deve ser par), o número de subdivisões deverá ser pelo menos 2. ($n = 2,\ 4,\ \ldots$).

7.4 Regra 3/8 de Simpson

- Na *regra 3/8 de Simpson*, expande-se o grau do polinômio para $n = 3$:

  para estimar a integral de $f(x)$, aproxima-se a mesma, via interpolação, por um polinômio de grau no máximo 3 $p_3(x)$ – interpolação cúbica – que passa por quatro pontos $(x_0, f(x_0))$, $(x_1, f(x_1))$, $(x_2, f(x_2))$ e $(x_3, f(x_3))$, igualmente espaçados por uma distância h.

- No caso simples, em que $x_0 = a$ e $x_3 = b$:

$$\int_{a=x_0}^{b=x_1} f(x)dx \approx \int_{a=x_0}^{b=x_1} p_3(x)dx = \sum_{i=0}^{3} A_i f(x_i)\,.$$

- Os pesos A_i podem ser obtidos por Lagrange ($A_i = \int_a^b L_i dx$, $i = 0, \ldots, 3$), e são dados por

$$A_0 = \frac{3h}{8}\,, \qquad A_1 = \frac{9h}{8}\,, \qquad A_2 = \frac{9h}{8}\,, \qquad A_3 = \frac{3h}{8}\,.$$

- Logo, pela regra 3/8 de Simpson:

$$I(f) \approx S_3^{(3/8)}(f) = \frac{3h}{8}\left[f(x_0) + 3f(x_1) + 3f(x_2) + f(x_3)\right]\,.$$

- A *regra 3/8 de Simpson composta* considera $n+1$ pontos $x_0, \ldots, x_n$ igualmente espaçados com espaçamento h entre si com $n \mod 3 = 0$ (o número de subintervalos n deve ser *múltiplo de 3*), de modo que aplica-se a regra 3/8 de Simpson simples a cada *trio de subintervalos* $[x_{3i-3}, x_{3i}]$, para $i = 1, \ldots, n/3$. Obtém-se

$$\begin{aligned} I(f) = S_n^{(3/8)} &= \frac{3h}{8}\sum_{i=1}^{n/3}\left[f(x_{3i-3}) + 3f(x_{3i-2}) + 3f(x_{3i-1}) + f(x_{3i})\right] \\ &= \frac{3h}{8}\Big[f(x_0) + 3f(x_1) + 3f(x_2) + 2f(x_3) + 3f(x_4) + \ldots \\ &\qquad + 2f(x_{n-3}) + 3f(x_{n-2}) + 3f(x_{n-1}) + f(x_n)\Big]\,. \end{aligned}$$

7.5 Teorema geral do erro

- Seja $f(x) \in C^{n+2}[a, b]$ – i.e., as derivadas de f até ordem $n + 2$ são contínuas em $[a, b]$.
- Seja n o grau do polinômio que interpola $f(x)$ em pontos $a = x_0 < x_1 < \cdots < x_n = b$ (caso simples).
- Então, o *erro na integração numérica* E_n pelas fórmulas de Newton-Cotes, é:

  1. Se n é ímpar:

$$E_n = \frac{h^{n+2} f^{(n+1)}(\xi_x)}{(n+1)!}\int_0^n u(u-1)\ldots(u-n)du,\ \xi_x \in [a, b]\,;$$

2. Se n é par:

$$E_n = \frac{h^{n+3} f^{(n+2)}(\xi_x)}{(n+2)!} \int_0^n \left(u - \frac{n}{2}\right) u(u-1)\ldots(u-n)du,\ \xi_x \in [a,b]\,.$$

7.6 Exercícios

1. Calcular usando a regra do trapézio composta:

$$\int_0^{1,2} e^x \cos x dx\,.$$

Considere os dados da tabela:

x	0	0,2	0,4	0,6	0,8	1,0	1,2
e^x	1	1,221	1,492	1,822	2,226	2,718	3,3220
$\cos x$	1	0,980	0,921	0,825	0,697	0,540	0,362

2. Repita o exercício anterior, usando a regra 1/3 de Simpson:
   - simples (nos pontos 0, 0,6, 1,2);
   - composta.
3. Repita o exercício 1, usando a regra 3/8 de Simpson composta.
4. Para os itens 1 e 2, estime os erros obtidos.
5. A velocidade vertical de um foguete lançado verticalmente do chão é tabelada como a seguir:

$t\,(s)$	0	5	10	15	20
$v\,(m/s)$	0	18,47	54,89	104,12	161,06

Usando a regra 1/3 de Simpson, calcular a altura da foguete após 20 segundos.

6. Determine a distância entre x_i e x_{i+1}, para que se possa avaliar a integral $\int_0^{\pi/2} \cos x dx$ com erro inferior a $\varepsilon = 10^{-5}$ pela regra 1/3 de Simpson.
7. Faça a dedução da regra dos trapézios simples – $T_1(f)$, dada pela Eq. (9) – usando a fórmula de Lagrange. Considere uma função $f(x)$ cujos valores sejam conhecidos em 2 pontos $(x_0, f(x_0))$ e $(x_1, f(x_1))$, onde se deseja saber qual o valor da integral definida de f no intervalo definido por tais pontos.

8. Usando o teorema geral do erro, obtenha a expressão do erro para o caso simples (em que o número de intervalos é $n = 3$) da regra 3/8 de Simpson.

9. Considerando que $M_4 = \max_{x\in[a,b]} |f^{(4)}(x)|$, estime, a partir da expressão obtida no item anterior, qual o limitante superior do módulo do erro obtido quando se usa a regra 3/8 de Simpson sobre n pontos (composta), para n múltiplo de 3.

10. Calcule o erro obtido ao se usar a regra 3/8 de Simpson ao empregá-la no cálculo numérico da integral do exercício 1.

11. Determine a distância entre x_i e x_{i+1}, para que se possa avaliar a integral $\int_0^{\pi/2} \cos x dx$ com erro inferior a $\varepsilon = 10^{-5}$ pela regra 3/8 de Simpson.

Referências

1. FRANCO, N. B. *Cálculo numérico.* São Paulo: Pearson Prentice Hall, 2006.

2. RUGGIERO, M. A. G.; LOPES, V. L. R. *Cálculo numérico: aspectos teóricos e computacionais.* 2ª. ed. São Paulo: Makron Books. 1996.

3. VALLE, M. E. *MS211 – Cálculo Numérico. Aula 18 — Integração Numérica.* Disponível em: http://www.ime.unicamp.br/~valle/Teaching/MS211/Aula18.pdf. Acesso em: 23 de mar. de 2021

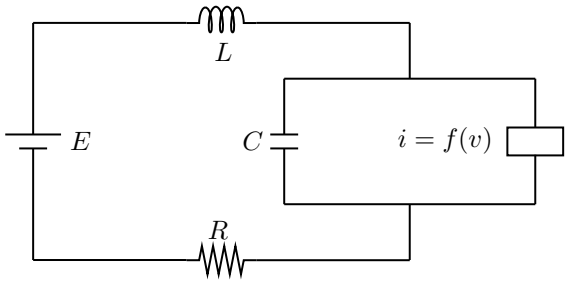
Os materiais de parte desta seção foram gentilmente cedidos por Mauricio C. Escarpinati (FACOM/UFU)

Adaptações: Renato Pimentel, FACOM/UFU

8 Resolução numérica de equações diferenciais ordinárias

8.1 Introdução

- *Equações diferenciais*: comuns em modelos de diversas áreas, como: mecânica de fluidos, fluxo de calor, vibrações, reações químicas, economia, biologia, etc.
- *Exemplo:* circuito elétrico



  - Caixa retangular à direita: *diodo* com função característica $f(v)$ – corrente em função da tensão v.

- O modelo que descreve tal circuito – dado pela aplicação das leis de Kirchhoff – é:

$$\begin{cases} L\dfrac{di}{dt} = E - Ri - v = I(i,v) \\ -C\dfrac{dv}{dt} = f(v) - i = V(i,v)\,, \end{cases}$$

  onde E, R, C e L são constantes positivas e $vf(v) \geq 0, \forall v$.

- Equações do sistema: *equações diferenciais* (ED): envolvem a *derivada* das funções.

Equações diferenciais ordinárias e parciais

- ED com *apenas uma* variável independente: equação diferencial *ordinária* (EDO).

  - Exemplos de EDOs:

$$\frac{dy}{dx} = x + y\,; \qquad y' = x^2 + y^2\,; \qquad y'' + (1 - y^2)y' = 0\,.$$

– Na expressão acima, se $y = y(x)$, então $y' = \dfrac{dy}{dx}$ e $y'' = \dfrac{d^2y}{dx^2}$.

- ED com *mais de uma* variável independente: equação diferencial *parcial* (EDP).

  – Exemplo de EDP:

$$\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = 0\,,$$

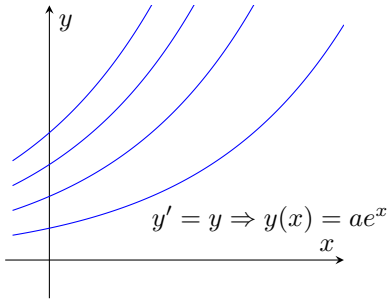
  com $u \equiv u(x, y)$, e $\frac{\partial^2 u}{\partial^2}$ indicando a segunda derivada parcial de u em relação a uma das variáveis independentes. Reescrevendo a equação acima com *notação compacta*: $u_{xx} + u_{yy} = 0$.

Solução de EDO

- *Solução*: função da variável independente que satisfaça a equação.
- Exemplos:

  1. $\dfrac{dy}{dx} = y \Rightarrow$ solução: $y(x) = ae^x$, $a \in \mathbb{R}$ (EDO de *primeira ordem*);
  2. $u''' = 0 \Rightarrow$ solução:$u(x) = p_2(x)$ – qualquer *polinômio de grau 2. EDO de terceira ordem.*[7]

- Solução, portanto, *não é única* (família de funções):



Tipos de problemas envolvendo EDOs

- Solução de EDOs não única.
- Para individualizar solução: impõem-se condições suplementares. Exemplos:

$$y(0) = 1 \qquad y'(4) = 5 \qquad y(2) + 5y'(3) = 6$$

[1] *ordem de uma EDO*: ordem mais alta de derivação na equação.

- *Problema de valor inicial (PVI)*: Se, numa *EDO de ordem* m, a função e suas derivadas até ordem $m-1$ são especificadas num *mesmo ponto*. Exemplos:

$$\begin{cases} y'(x) = y \\ y(0) = 1 \end{cases}$$

$$\begin{cases} y''' + (x+1)y'' + \cos xy' - (x^2-1)y = x^2 + y^2 \operatorname{sen}(x+y) \\ y(0) = 1,1\,, \quad y'(0) = 2,2\,, \quad y''(0) = 3,3\,. \end{cases}$$

- *Problema de valor de contorno (PVC)*: Se, numa *EDO de ordem* m, com $m \geq 2$, as m condições não são todas no mesmo ponto.
- Exemplo: barra de comprimento L sujeita à carga uniforme q.
  - Se no ponto $x_0 = 0$, barra está presa, e em $x_L = L$ está apenas apoiada:

$$\begin{cases} y^{(4)}(x) + ky(x) = q \\ y(0) = y'(0) = 0 \\ y(L) = y''(L) = 0\,. \end{cases}$$

    y: *deflexão vertical* da barra; k: constante que depende do material da barra.
- É comum problemas de contorno não terem solução única:
- Exemplo: PVC

$$\begin{cases} y'' = 0 \\ y(-1) = 0 \\ y(1) - 2y'(1) = 0 \end{cases}$$

tem solução $y(x) = \alpha(1+x)$, $\alpha \in \mathbb{R}$.

8.2 Problemas de valor inicial

- Serão estudados métodos numéricos para resolução do PVI da forma

$$\begin{cases} y' = f(x,y) \\ y(x_0) = y_0\,, \end{cases}$$

onde f é uma função de ambas x (variável independente) e y (variável dependente).

- A equação $y(x_0) = y_0$ é a *condição inicial* do PVI, com x_0 e y_0 dados.
- A solução do PVI, caso exista, é uma função y que depende de x e satisfaz a condição inicial. Assume-se que a mesma é única.

Métodos numéricos

- A partir do PVI, os métodos numéricos fornecem aproximações para y nos pontos $x_1, x_2, \ldots, x_n$.
- Considerando-se pontos igualmente espaçados:

$$x_k - x_{k-1} = h, \qquad k = 1, 2, \ldots, n$$

  h: *tamanho do passo* dos métodos.

- A cada x_k, calcula-se a *aproximação* $y_k \approx y(x_k)$, baseando-se em informações do(s) ponto(s) anterior(es):
  - Em *métodos de passo simples*: y_k é obtido com base apenas em y_{k-1}. Exs.: método de Euler, métodos de série de Taylor, métodos de Runge-Kutta.
  - Em *métodos de passo múltiplo*: y_k é obtido com base em mais pontos além de y_{k-1}. Ex.: método de Adams-Bashforth.

8.3 Método de Euler

- Dado o PVI

$$\begin{cases} y' = f(x, y) \\ y(x_0) = y_0 \,, \end{cases}$$

  uma vez que se conhece $y'(x_0)$ – dado por $f(x_0, y_0)$, aproxima-se y pela reta $r_0(x)$ que passa por (x_0, y_0) com coeficiente angular $y'(x_0)$:

$$r_0(x) = y(x_0) + (x - x_0)y'(x_0) \,.$$

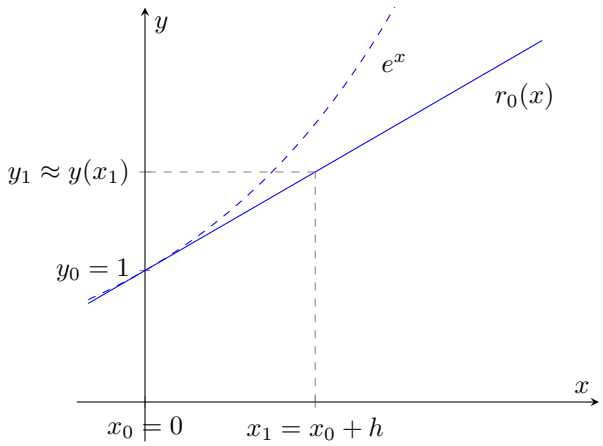
  A partir de r_0, obtém-se y_1, dado por

$$y_1 = r_0(x_1) = y(x_0) + (x_1 - x_0)y'(x_0) = y_0 + hy'(x_0) = y_0 + hf(x_0, y_0) \,.$$

  Repete-se o raciocínio a partir do ponto x_1, e assim sucessivamente:

$$y_{k+1} = y_k + hf(x_k, y_k) \,, \qquad k = 0, 1, 2, \ldots$$

- Graficamente:



Estimativa do erro

- Se $y(x)$ é função suave então, pela série de Taylor centrada em x_k:

$$y(x_k + h) = y(x_k) + y'(x_k)h + \frac{1}{2}y''(\xi)h^2\,,$$

onde $x_k < \xi < x_k + h$. Logo,

$$y(x_{k+1}) = y(x_k) + f(x_k, y(x_k))h + \frac{1}{2}y''(\xi)h^2\,.$$

- Assumindo $y_k = y(x_k)$, e considerando que $y_{k+1} = y_k + f(x_k, y_k)h$, o *erro local* (para uma única iteração) do método de Euler em x_{k+1} é

$$E(x_{k+1}) = |y(x_{k+1}) - y_{k+1}| = \frac{1}{2}|y''(\xi)|h^2 \leq \frac{M_2}{2}h^2\,,$$

onde $M_2 = \max_{x\in[x_k,x_{k+1}]} |y''(x)|$.

Exemplo

Para o PVI

$$\begin{cases} y' = y \\ y(0) = 1\,, \end{cases}$$

use o método de Euler para calcular $y(0,04)$ com uma tolerância $\varepsilon = 5 \times 10^{-4}$ e trabalhando com quatro casas decimais.

- *Resposta:* inicialmente, é preciso estimar o *tamanho do passo* h, a partir do erro:

  Sabendo-se que a solução analítica do PVI é $y(x) = e^x$,

  $$M_2 = \max_{x\in[0,\,0{,}04]} |y''(x)| = e^{0{,}04} = 1{,}0408\,.$$

  Uma vez que $E(x_{k+1}) \leq (1/2)M_2h^2$, basta tomar h tal que $(1/2)M_2h^2 < \varepsilon$:

  $$\frac{1{,}0408}{2}h^2 < \varepsilon \quad \Leftrightarrow \quad h^2 < \frac{10^{-3}}{1{,}0408} \quad \Leftrightarrow \quad h < 0{,}0310\,.$$

- Como se deseja calcular $y(0,04)$, considera-se $h = 0,02$.

- Uma vez que $h = 0,02$:

  $$y(0,04) = y(0 + 2 \times 0{,}02) \approx y_2\,,$$

  i.e. são calculados 2 passos do método.

- Passo 1:

  $$y_1 = y_0 + hf(x_0, y_0) = y_0(1 + h) = 1{,}02\,.$$

- Passo 2:

  $$y_2 = y_1 + hf(x_1, y_1) = y_1(1 + h) = 1{,}02^2 = 1{,}0404\,.$$

- Portanto, $y(0,04) \approx 1,0404$. O erro cometido é

  $$E(0,04) = |1{,}0408 - 1{,}0404| = 4 \times 10^{-4} < 5 \times 10^{-4} = \varepsilon\,.$$

8.4 Métodos de série de Taylor

- Se $y(x)$ é suficientemente suave, então a *série de Taylor* de y centrada em x_k é

  $$\begin{aligned} y(x) = y(x_k) + y'(x_k)(x - x_k) + y''(x_k)\frac{(x - x_k)^2}{2!} + \ldots \\ + \frac{y^{(p)}(x_k)}{p!}(x - x_k)^p + \frac{y^{(p+1)}(\xi)}{(p+1)!}(x - x_k)^{p+1}\,, \quad \xi \in (x_k, x)\,. \end{aligned}$$

- Logo, quando avaliada em $x = x_{k+1}$, dado que $x_{k+1} - x_k = h$:

$$y(x_{k+1}) = y(x_k) + y'(x_k)h + \frac{1}{2!}y''(x_k)h^2 + \cdots + \frac{1}{p!}y^{(p)}(x_k)h^p + \frac{1}{(p+1)!}y^{(p+1)}(\xi)h^{p+1}\,, \quad \xi \in (x_k, x_{k+1})\,.$$

- O *método de série de Taylor* de ordem p é dado ao se desconsiderar os termos de ordem superior a p, i.e., se $y_k^{(j)}$ representa a aproximação para a j-ésima derivada de y em x_k, e aproximações y_1, y_2, $\ldots$, y_k em x_1, x_2, $\ldots$, x_k já tenham sido calculadas:

$$y_{k+1} = y_k + y_k'h + \frac{1}{2!}y_k''h^2 + \cdots + \frac{1}{p!}y_k^{(p)}h^p\,. \tag{11}$$

- Em particular, o método de série de Taylor de ordem 1 é o *método de Euler* visto.

Estimativa do erro

- Assumindo que $y_k = y(x_k)$, o erro (local) de um método de série de Taylor de ordem p é dado por

$$E(x_{k+1}) = \left|\frac{1}{(p+1)!}y^{(p+1)}(\xi)h^{p+1}\right|\,,$$

  onde $x_k < \xi < x_{k+1}$.

- Definindo-se

$$M_{p+1} = \max_{x\in[x_k,x_{k+1}]} |y^{(p+1)}(x)|\,,$$

  obtém-se um limitante superior para o erro:

$$E(x_{k+1}) \leq \frac{M_{p+1}}{(p+1)!}h^{p+1} = Ch^{p+1}\,,$$

  com $C = \dfrac{M_{p+1}}{(p+1)!}$.

Método de série de Taylor de ordem 2

- Para $p = 2$, a Eq. (11) é dada por

$$y_{k+1} = y_k + y'_k h + \frac{1}{2} y''_k h^2 \,. \tag{12}$$

- Dado que $y'(x) = f(x, y(x))$,

$$y''(x) = f_x(x, y(x)) + f_y(x, y(x)) y'(x) = f_x + f_y f \,,$$

onde $f_x = \dfrac{\partial f}{\partial x}(x, y(x))$ – o mesmo para f_y.

- Portanto, reescreve-se a Eq. (12) como

$$y_{k+1} = y_k + h f(x_k, y_k) + \frac{1}{2} h^2 \left(f_x(x_k, y_k) + f_y(x_k, y_k) f(x_k, y_k) \right) . \tag{13}$$

Exemplo

Para o PVI

$$\begin{cases} y' = y \\ y(0) = 1 \,, \end{cases}$$

use o método de série de Taylor de ordem 2 para calcular $y(0,04)$ com uma tolerância $\varepsilon = 5 \times 10^{-4}$ e trabalhando com quatro casas decimais.

- *Resposta:* inicialmente, é preciso estimar o *tamanho do passo* h, a partir do erro:

  Sabendo-se que a solução analítica do PVI é $y(x) = e^x$, e que o método de série de Taylor de ordem 2 é tal que

$$E(x_{k+1}) \leq \frac{M_3}{6} h^3,$$

  obtém-se

$$M_3 = \max_{x \in [0,\, 0,04]} |y'''(x)| = e^{0,04} = 1,0408 \,.$$

  Basta tomar h tal que $(1/6) M_3 h^3 < \varepsilon$:

$$\frac{1,0408}{6} h^3 < \varepsilon \quad \Leftrightarrow \quad h^3 < \frac{3 \times 10^{-3}}{1,0408} \quad \Leftrightarrow \quad h < 0,1423 \,.$$

- Como se deseja calcular $y(0,04)$, pode se considerar $h = 0,04$ neste caso.

- Passo do método: a partir da Eq. (13),

$$\begin{aligned} y_1 &= y_0 + hf(x_0, y_0) + \frac{1}{2}h^2 \left(f_x(x_0, y_0) + f_y(x_0, y_0)f(x_0, y_0)\right) \\ &= y_0 + hy_0 + \frac{1}{2}h^2(0 + 1 \times y_0) \\ &= y_0(1 + h + h^2/2) = 1,0408\,. \end{aligned}$$

- Considerando-se as 4 casas decimais, portanto, o erro é nulo.

Exemplo

Calcular $y(2,1)$ usando o método de Taylor de segunda ordem para o PVI:

$$\begin{cases} xy' = x - y \\ y(2) = 2\,. \end{cases}$$

- *Resposta*: $f(x, y) = y' = (x - y)/x = 1 - y/x$.
- Logo, considerando-se $h = 0,1$:

$$\begin{aligned} y_1 &= y_0 + hf(x_0, y_0) + \frac{1}{2}h^2 \left(f_x(x_0, y_0) + f_y(x_0, y_0)f(x_0, y_0)\right) \\ &= y_0 + h\frac{x_0 - y_0}{x_0} + \frac{1}{2}h^2 \left(\frac{y_0}{x_0^2} - \frac{1}{x_0} \times \frac{x_0 - y_0}{x_0}\right) \\ &= 2 + 0,2 \times 0 + \frac{1}{2}(0,1)^2 \times (1/2 - 1/2 \times 0) \\ &= 2 + 0,0025 = 2,0025\,. \end{aligned}$$

- Neste caso, $y''' = -y''/x + 2y'/x^2 - 2y/x^3$.
- Como não se conhece a solução analítica y do problema, ou alguma informação sobre a mesma – e.g. $y'''(x) = K$, não é possível calcular o erro.

Exemplo

A população p de algumas lagartas podem ser descritas pelo PVI

$$\begin{cases} \dfrac{dp}{dt} = rp\left(1 - \dfrac{p}{k}\right) - \dfrac{p^2}{1 + p^2} \\ p(0) = p_0\,, \end{cases}$$

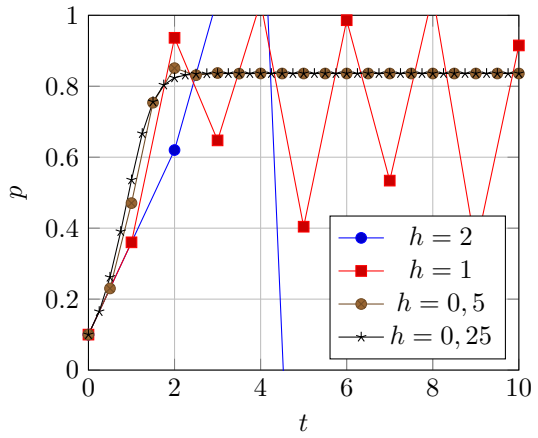
em que p_0 é a população inicial (no instante $t = 0$), r está relacionado à taxa de reprodução da lagarta e k à quantidade de folhas disponíveis na planta. O termo $p^2/(1 + p^2)$ descreve a predação da lagarta (por pássaros, por exemplo). Considerando $r = 3$, $k = 1$ e $p_0 = 0,1$, qual será a população de lagartas no instante $t = 10$?

- Com os valores dados, o PVI anterior é reescrito como

$$\begin{cases} \dfrac{dp}{dt} = 3p\,(1-p) - \dfrac{p^2}{1+p^2} \\ p(0) = 0,1\,. \end{cases}$$

- Estima-se p para $0 \leq t \leq 10$, usando um método numérico.

- No caso do método de Euler, para diferentes valores de h:



- Aproximações para $p(10)$:

h	2	1	0,5	0,25
$p(10)$	$-1,07 \times 10^5$	0,91505	0,83597	0,83597

Observações:

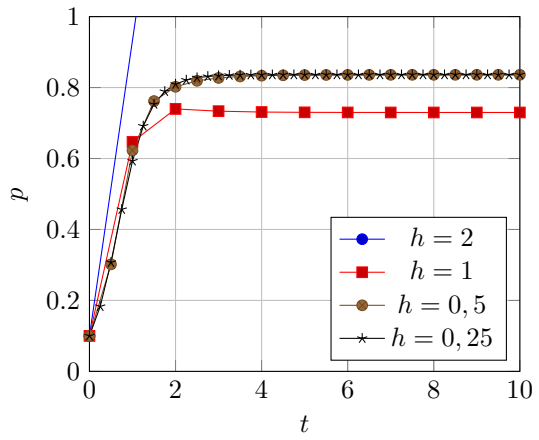
- O método se mostrou instável para $h \geq 1$;

- Pela tabela, resultados semelhantes foram obtidos considerando $h = 0,5$ e $h = 0,25$.

- Contudo, ao se observar o gráfico, percebem-se algumas diferenças nas primeiras iterações para $h = 0,5$.

- Concluindo, pode-se acreditar que um bom resultado foi obtido com $h = 0,25$.

- No caso do método de Taylor de ordem 2, para diferentes valores de h:



- Aproximações para $p(10)$:

h	2	1	0,5	0,25
$p(10)$	$3,24 \times 10^{69}$	0,72977	0,83597	0,83597

Observações:

- Diferente do método de Euler, o método de ordem 2 não divergiu para $h = 1$. Porém, embora o resultado seja estável, converge para um valor diferente da solução exata (boa *precisão* mas acurácia *deficiente*!)
- Resultados semelhantes foram obtidos considerando $h \leq 0,5$.
- Concluindo, pode-se acreditar que um resultado satisfatório foi obtido com $h = 0,5$.

Conclusões sobre o exemplo:

- Comparando os métodos de ordem 1 (Euler) e ordem 2, é melhor optar pelo último.
- Porém, para aplicar um método de série de Taylor de ordem 2, é preciso conhecer as derivadas parciais de f.
  - No caso, $f_t = 0$ e $f_p = 3 - 6p - (2p)/(1 + p^2)^2$.
- A seguir, serão apresentados métodos de ordem maiores ou iguais a 2 que não requerem as derivadas parciais de f.

8.5 Métodos de Runge-Kutta

- Em métodos de série de Taylor de ordem p, o erro é tal que

$$E(x_{k+1}) \leq \frac{M_{p+1}}{(p+1)!} h^{p+1} \,,$$

de modo que o erro tende a cair quanto maior a ordem do método (pois em geral, $h << 1$).

- No caso de ordens 1 (método de Euler) e 2:

$$y_{k+1} = y_k + hf(x_k, y_k) \,,$$

$$y_{k+1} = y_k + hf(x_k, y_k) + \frac{1}{2} h^2 \left(f_x(x_k, y_k) + f_y(x_k, y_k) f(x_k, y_k) \right) \,.$$

- O termo adicional do método de ordem 2 envolve o cálculo das *derivadas parciais* de $f(x, y(x))$. Métodos onde $p > 2$ são em geral impraticáveis, a não ser para expressões mais simples de f – Ex: $y'''(x) = f_{xx} + f_{xy} f + (f_{yx} + f_{yy} f) f + f_y (f_x + f_y f)$.

- A ideia básica dos *métodos de Runge-Kutta* é aproveitar as qualidades dos métodos de série de Taylor enquanto eliminam sua maior restrição: o cálculo das derivadas parciais de $f(x, y(x))$.

- Métodos de Runge-Kutta se caracterizam por 3 propriedades:

  1. Métodos de *passo 1* – y_{k+1} é aproximado em termos do ponto x_k apenas;
  2. Não exigem o cálculo de nenhuma derivada de $f(x, y(x))$ – sendo penalizados com o preço de se calcular $f(x, y)$ em vários pontos;
  3. Ao se expandir $f(x, y(x))$ por Taylor em torno de (x_n, y_n) e agrupar os termos semelhantes, sua expressão coincide com a do método de série de Taylor de mesma ordem.

- *Forma geral*: os métodos de Runge-Kutta são dados por:

$$y_{k+1} = y_k + h\phi(x_k, y_k), \qquad\qquad k = 0, 1, \ldots$$

onde ϕ é uma função de x e y que depende diretamente de f e do tamanho do passo h.

- Em particular, o *método de Euler* é um método de Runge-Kutta de 1a. ordem – basta considerar $\phi = f$.

  – É fácil verificar que o método de Euler satisfaz as 3 propriedades dos métodos de Runge-Kutta.

Métodos de Runge-Kutta de 2ª ordem

- *Forma geral:* dados a_1, a_2, b_1, $b_2 \in \mathbb{R}$:

$$y_{k+1} = y_k + ha_1 f(x_k, y_k) + ha_2 f(x_k + b_1 h, y_k + b_2 h f(x_k, y_k))\,.$$

- Em particular, se $a_1 = a_2 = 1/2$ e $b_1 = b_2 = 1$, obtém-se o *método de Heun (Euler aperfeiçoado).*

Método de Heun

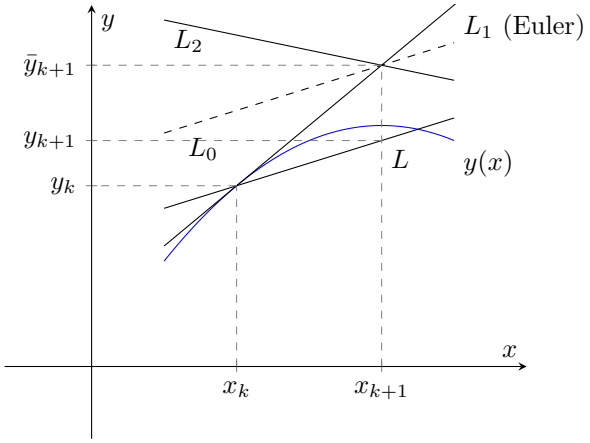
- O *método de Heun* consiste em modificações sobre o método de Euler, de forma a se conseguir uma ordem mais elevada.
- Por esta razão, é também denominado *método Euler aperfeiçoado* ou *método Euler melhorado.*
- Seu termo geral é dado por

$$y_{k+1} = y_k + \frac{1}{2}h(k_1 + k_2)\,,$$

onde

$$k_1 = f(x_k, y_k), \qquad k_2 = f(x_k + h, y_k + hk_1)\,. \tag{14}$$

- A melhoria sobre o método de Euler consiste em aproximar o próximo ponto da solução por meio da *inclinação média* da função y estimada nos pontos (x_k, y_k) e $(x_{k+1}, \bar{y}_{k+1})$ – $\bar{y}_{k+1}$ é a estimativa pelo método de Euler.
- Graficamente:



- A partir de (x_k, y_k) – e supondo que $y_k = y(x_k)$ – obtém-se, pelo método de Euler, $\bar{y}_{k+1}$ em $x = x_{k+1}$ – isto equivale a traçar a reta L_1 que passa por (x_k, y_k) com inclinação dada por $y'(x_k) = f(x_k, y_k)$, e em seguida tomar $\bar{y}_{k+1}$ como a coordenada y de tal reta quando $x = x_{k+1}$.
- A estimativa para a derivada de y no ponto $(x_{k+1}, \bar{y}_{k+1})$ é dada por $f(x_{k+1}, \bar{y}_{k+1}) = f(x_k + h, y_k + hf(x_k, y_k))$ – que corresponde ao coeficiente angular da reta L_2 que passa por tal ponto.
- A reta L_0 (tracejada) que passa por $(x_{k+1}, \bar{y}_{k+1})$ tem como inclinação a *média aritmética das inclinações* das retas L_1 (oriunda do método de Euler) e L_2.
- A reta L que passa por (x_k, y_k) com a mesma inclinação de L_0 é dada por

$$L_0 : z(x) = y_k + (x - x_k)\left[f(x_k, y_k) + f(x_k + h, y_k + hf(x_k, y_k))\right]/2$$

- Finalmente, o método de Heun considera $y_{k+1} = z(x_{k+1})$, ou seja,

$$y_{k+1} = y_k + \frac{1}{2}h\left[\underbrace{f(x_k, y_k)}_{k_1} + \underbrace{f(x_k + h, y_k + h\overbrace{f(x_k, y_k)}^{k_1})}_{k_2}\right].$$

- Portanto, $\phi = (k_1 + k_2)/2$, onde k_1 e k_2 são dados como na Eq. (14).
- O método satisfaz as 3 propriedades dos métodos de Runge-Kutta, pois é passo 1 (obtém-se y_{k+1} a partir de informações da aproximação y_k somente) e não envolve cálculos de derivada de $f(x, y)$. A demonstração da propriedade 3 (expansão por Taylor) pode ser vista em (RUGGIERO; LOPES, 1996).

Métodos de Runge-Kutta de ordem superior

- 3ª ordem:

$$y_{k+1} = y_k + \frac{1}{9}h\left(2k_1 + 3k_2 + 4k_3\right),$$

  i.e., $\phi = (2k_1 + 3k_2 + 4k_3)/9$, onde

$$k_1 = f(x_k, y_k), \quad k_2 = f\left(x_k + \frac{1}{2}h, y_k + \frac{1}{2}hk_1\right),$$
$$k_3 = f\left(x_k + \frac{3}{4}h, y_k + \frac{3}{4}hk_2\right).$$

- 4^{a} ordem:

$$y_{k+1} = y_k + \frac{1}{6}h\left(k_1 + 2k_2 + 2k_3 + k_4\right) ,$$

  i.e., $\phi = (k_1 + 2k_2 + 2k_3 + k_4)/6$, onde

$$k_1 = hf(x_k, y_k) , \quad k_2 = hf\left(x_k + \frac{1}{2}h, y_k + \frac{1}{2}hk_1\right) ,$$
$$k_3 = hf\left(x_k + \frac{1}{2}h, y_k + \frac{1}{2}hk_2\right) , \quad k_4 = hf(x_k + h, y_k + hk_3) .$$

- i.e.:

$$\phi(x_k, y_k) = \frac{1}{6}\left[f(x_k, y_k) + 2f\left(x_k + \frac{1}{2}h, y_k + \frac{1}{2}hk_1\right) + 2f\left(x_k + \frac{1}{2}h, y_k + \frac{1}{2}hk_2\right) + f(x_k + h, y_k + hk_3)\right] .$$

Exemplo
Para o PVI

$$\begin{cases} y' = y \\ y(0) = 1 , \end{cases}$$

use o método de Heun e o método de Runge-Kutta de ordem 4 para calcular $y(0,04)$ com $h = 0,04$. Compare com a solução analítica $y(0,04) = e^{0,04}$.

- *Resposta*: pelo método de Heun:

$$\begin{aligned} y_1 &= y_0 + \frac{1}{2}h\left(f(x_0, y_0) + f(x_0 + h, y_0 + hf(x_0, y_0))\right) \\ &= y_0 + \frac{1}{2} \times 0,04\left(y_0 + (y_0 + hy_0)\right) \\ &= 1 + \frac{1}{2} \times 0,04(1 + 1 + 0,04) \\ &= 1,0408 \end{aligned}$$

- Como a solução analítica é conhecida, o erro absoluto pode ser estimado, e, neste caso, $|e^{0,04} - y_1| = 1,0774 \times 10^{-5}$.

- Pelo método de Runge-Kutta de 4ª ordem:

$$
\begin{aligned}
k_1 &= f(x_0, y_0) = y_0\,, \\
k_2 &= f\left(x_0 + \frac{1}{2}h, y_0 + \frac{1}{2}hk_1\right) = y_0\left(1 + \frac{h}{2}\right)\,, \\
k_3 &= f\left(x_0 + \frac{1}{2}h, y_0 + \frac{1}{2}hk_2\right) = y_0\left(1 + \frac{h}{2} + \frac{h^2}{4}\right)\,, \\
k_4 &= f\left(x_0 + h, y_0 + hk_3\right) = y_0\left(1 + h + \frac{h^2}{2} + \frac{h^3}{4}\right)\,.
\end{aligned}
$$

- Portanto,

$$
\begin{aligned}
y_1 &= y_0 + \frac{1}{6}h(k_1 + 2k_2 + 2k_3 + k_4) = y_0\left(1 + h + \frac{h^2}{2} + \frac{h^3}{6} + \frac{h^4}{24}\right) \\
&= 1,04081077333333\,.
\end{aligned}
$$

- Neste caso, $|e^{0,04} - y_1| = 8,5906 \times 10^{-10}$.

Exemplo

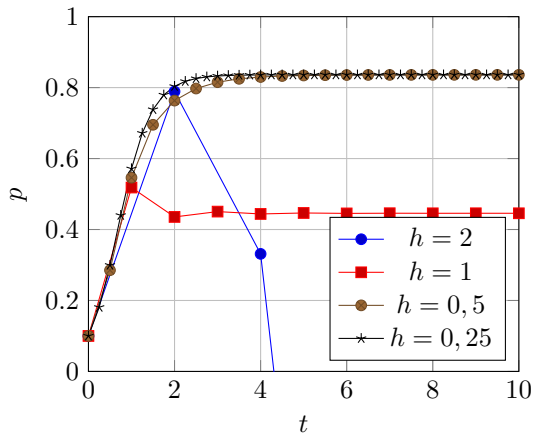
- Considere o PVI

$$
\begin{cases}
\dfrac{dp}{dt} = 3p\,(1-p) - \dfrac{p^2}{1+p^2} \\
p(0) = 0,1\,.
\end{cases}
$$

  (modelo da população das lagartas).

- Use o método de Heun e o método de Runge-Kutta de 4ª ordem para estimar p no intervalo $0 \leq t \leq 10$.

- No caso do método de Heun, para diferentes valores de h:

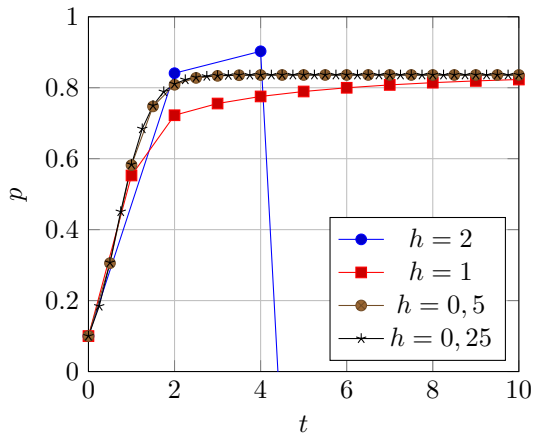


- Aproximações para $p(10)$:

h	2	1	0,5	0,25
$p(10)$	$-1,80 \times 10^{16}$	0,44578	0,83597	0,83597

Observações:

- O método apresenta erro significativo para $h \geq 1$ – para $h = 1$, especificamente, o método é preciso, porém de má acurácia, uma vez converge para um valor distante da solução, a exemplo do visto para o método de série de Taylor de ordem 2;
- Resultados semelhantes foram obtidos considerando $h \leq 0,5$.
- Concluindo, pode-se acreditar que um resultado satisfatório foi obtido com $h = 0,5$.
- No caso do método de Runge-Kutta de 4ª ordem, para diferentes valores de h:



- Aproximações para $p(10)$:

h	2	1	0,5	0,25
$p(10)$	$-8,34 \times 10^{284}$	0,82311	0,83597	0,83597

Observações:

- O método apresenta erro significativo para $h \geq 1$.
- Resultados semelhantes foram obtidos considerando $h \leq 0,5$.
- Concluindo, pode-se acreditar que um resultado satisfatório foi obtido com $h = 0,5$.

8.6 Exercícios

1. Escreva o algoritmo do método de Euler.
2. Escreva o algoritmo do método de Heun.
3. Escreva o algoritmo do método de Runge-Kutta de 4ª ordem.
4. Dado o PVI

$$\begin{cases} y' = 4 - 2x \\ y(0) = 2\,, \end{cases}$$

   e considerando, com exceção do último item abaixo, $h = 0,25$:

   (a) Encontre uma aproximação para $y(1)$ usando o método de Heun.

   (b) Compare os resultados com a solução exata, dada por $y(x) = -x^2 + 4x + 2$. Justifique.

   (c) Espera-se o mesmo erro usando o método de Euler? Justifique.

   (d) Calcule qual o tamanho do passo h para que se tenha um erro abaixo de $\varepsilon = 10^{-7}$ para o método de Euler e para o método de série de Taylor de ordem 2.

5. Considere o PVI

$$\begin{cases} y' = (y^2 - 1)/(x^2 + 1) \\ y(0) = 1\,. \end{cases}$$

   (a) Calcule aproximações para $y(1)$, usando o método de Euler para $h = 0,2$ e $h = 0,25$

   (b) Repita o item anterior, agora usando o método de Heun.

6. Dado o PVI

$$\begin{cases} y' = -y + t + 1 \\ y(0) = 1\,. \end{cases}$$

   com solução exata $y(t) = e^{-t} + t$:

   (a) Aproxime o valor $y(5)$ usando o método de Euler para $h = 0,5$.

   (b) Determine o valor ótimo de h para calcular $y(5)$ com uma tolerância $\varepsilon = 10^{-6}$.

7. Use o método de série de Taylor de ordem 2 com $h = 0,1$ para calcular a solução do PVI

$$\begin{cases} y' = 2 + t * \text{sen}\,(ty) \\ y(0) = 0 \end{cases}$$

no intervalo $0 \leq t \leq 2$.

8. Dado o PVI

$$\begin{cases} y' + y = x \\ y(0) = 0\,, \end{cases}$$

(a) Escreva a fórmula da iteração do método de Taylor de 2ª ordem aplicado ao PVI, considerando $h = 0,1$;

(b) Verifique que $y(x) = e^{-x} + x - 1$ é solução do PVI.

Referências

1. BURDEN, R. L.; FAIRES, J. D. *Numerical Analysis*, 6th ed., Brooks/Cole Publishing Company, 1997.

2. RUGGIERO, M. A. G.; LOPES, V. L. R. *Cálculo numérico: aspectos teóricos e computacionais*. 2^{a}. ed. São Paulo: Makron Books. 1996.

3. VALLE, M. E. *MS211 – Cálculo Numérico. Aula 20 — Solução Numérica de Problemas de Valor Inicial: Método de Euler e Métodos de Série de Taylor*. Disponível em: http://www.ime.unicamp.br/~valle/Teaching/MS211/Aula20.pdf. Acesso em: 23 de mar. de 2021

Adaptações: Renato Pimentel, FACOM/UFU

9 Resolução numérica de equações diferenciais parciais

9.1 Introdução

- Como visto para o caso de EDOs, vários problemas de engenharia e outras áreas podem ser modelados por *equações diferenciais parciais* (*EDPs*):
  - Velocidade e pressão de um fluido;
  - Temperatura na previsão do tempo;
  - trajetória de um satélite artificial, etc.
- Se problema depende de muitas variáveis, então modelo envolve derivadas com respeito a cada uma destas variáveis.
- Portanto, o modelo será dado em termos de uma EDP ou um *sistema de EDPs*.
- Em geral, EDPs *mais complexas* que EDOs $\Rightarrow$ (maior número de variáveis, por ex.).
  - Soluções exatas raramente podem ser obtidas.
  - *Discretizações* são usadas $\Rightarrow$ Representações discretas (finitas) do problema.

9.2 Classificação das equações

Dada a expressão

$$a(x,y)u_{xx} + b(x,y)u_{xy} + c(x,y)u_{yy} + d(x,y,u_x,u_y,u) = 0\,, \qquad (15)$$

e definindo-se o *discriminante* $\Delta = b^2 - 4ac$, então é possível classificar a Eq. (15) como:

1. *Equação parabólica*: se $\Delta = 0$;
2. *Equação elíptica*: se $\Delta < 0$;
3. *Equação hiperbólica*: se $\Delta > 0$.

- Classificação: *razões didáticas*.
- Obs.: Como a, b e c dependem de x e y – caso 2D – equação pode ser de tipos diferentes em regiões distintas de seu domínio. Serão considerados somente os casos em que a, b e c não variam.

Exemplo: equação do calor

- A EDP

$$\frac{\partial u}{\partial t}(x,t) - \alpha^2 \frac{\partial^2 u}{\partial x^2}(x,t) = 0 \tag{16}$$

  (ou, em sua *forma compacta*, $u_t - \alpha^2 u_{xx} = 0$), é uma *equação parabólica*.

- A Eq. (16) acima, juntamente com condições iniciais e de contorno apropriadas, pode ser usada para modelar o fluxo de calor ao longo de uma barra de comprimento L – onde se assume temperatura uniforme ao longo das demais direções (y e z).



- Neste caso, α é dada em termos das propriedades de condutividade térmica do material da barra. A Eq. (16) é conhecida como *equação do calor* ou *equação de difusão*.

- As condições típicas no problema do calor são uma condição inicial (no instante $t = 0$) especificando a distribuição ao longo da barra,

$$u(x,0) = q(x)\,, \qquad\qquad 0 \le x \le L\,, \tag{17}$$

- e condições de contorno para as suas extremidades: se a barra é mantida aquecida a temperaturas fixas U_1 e U_2 nestes pontos, então as condições são dadas por

$$u(0,t) = U_1\,, \qquad\qquad u(L,t) = U_2\,, \tag{18}$$

  e neste caso, a temperatura ao longo da barra tende à distribuição linear dada por

$$\lim_{t\to\infty} u(x,t) = U_1 + \frac{U_2 - U_1}{L} x\,.$$

- Por outro lado, se a barra é mantida isolada de forma que nenhum calor seja perdido em suas extremidades, então as condições de contorno são dadas por

$$\frac{\partial u}{\partial x}(0,t) = 0\,, \qquad\qquad \frac{\partial u}{\partial x}(L,t) = 0\,,$$

  então a temperatura tenderá a uma temperatura constante, com o passar do tempo.

Exemplo: equações de Poisson e Laplace

- A *equação de Poisson*, EDP dada por

$$\frac{\partial^2 u}{\partial x^2}(x,y) + \frac{\partial^2 u}{\partial y^2}(x,y) = f(x,y) \tag{19}$$

  (ou, em sua forma compacta, $u_{xx} + u_{yy} = f(x,y)$), é uma *equação elíptica*.

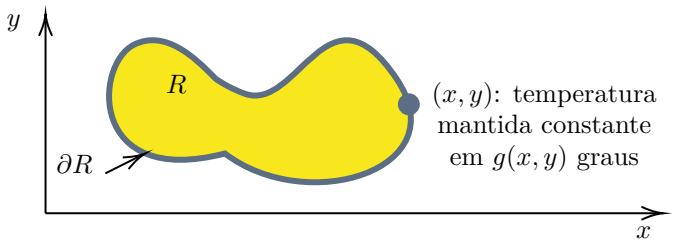
- A Eq. (19) acima, em conjunto com condições de contorno apropriadas, permite a modelagem de vários problemas físicos independentes do tempo, como a distribuição de calor em estado estacionário (em regime permanente) numa região plana, por exemplo, ou problemas bidimensionais de escoamentos incompressíveis de fluidos.

- Em particular, para o problema da distribuição de calor, $f(x,y) = 0$ e a Eq. (19) é reescrita como a *equação de Laplace*

$$\frac{\partial^2 u}{\partial x^2}(x,y) + \frac{\partial^2 u}{\partial y^2}(x,y) = 0\,.$$

- Se a temperatura no interior da região R é dada em termos da distribuição da temperatura em sua borda ∂R, então definem-se as *condições de contorno de Dirichlet*, dadas por

$$u(x,y) = g(x,y)\,, \qquad \text{para todo } (x,y) \in \partial R\,.$$



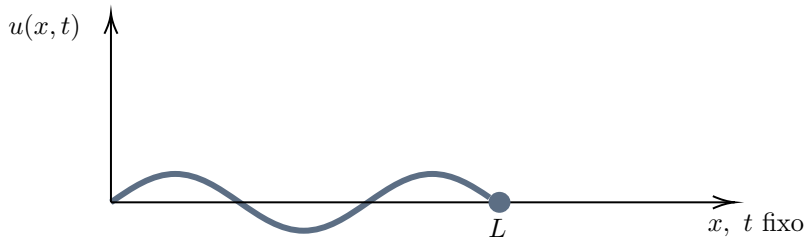
Exemplo: equação de onda

- A EDP

$$\alpha^2 \frac{\partial^2 u}{\partial x^2}(x,t) = \frac{\partial^2 u}{\partial t^2}(x,t)\,, \qquad 0 < x < L,\ t > 0 \tag{20}$$

  (ou, em sua forma compacta, $\alpha^2 u_{xx} = u_{tt}$), é uma *equação hiperbólica*.

- A Eq. (20) acima, juntamente com condições iniciais e de contorno apropriadas, modela o movimento oscilatório de uma corda totalmente esticada de comprimento L fixa nas extremidades.



- Considera-se que os efeitos de amortecimento sejam desprezíveis e que a amplitude das oscilações não seja tão elevada.
- A posição e velocidade iniciais são dadas por

$$u(x,0) = f(x)\,, \qquad u_t(x,0) = g(x)\,, \qquad 0 \leq x \leq L\,,$$

e as extremidades são fixadas, logo

$$u(0,t) = 0\,, \qquad u(L,t) = 0\,.$$

- Problemas físicos envolvendo EDPs hiperbólicas tipicamente envolvem vibração e ondas, mas há outras situações, como alguns modelos biológicos predador-presa (ecologia), fenômenos cosmológicos e até mesmo de mecânica quântica (equação de Klein-Gordon).

9.3 Diferenças finitas

- *Ideia geral*: *Discretização* do domínio físico do problema; substituição das derivadas parciais por aproximações envolvendo valores numéricos.
- *Discretização*: geração de uma *malha* de pontos numa dada direção.
- Assim, se x_0 é um ponto do domínio e $h > 0$, então a *malha* de passo h associada a x_0 é o conjunto de pontos:

$$x_i = x_0 \pm ih\,, \qquad i = 1,\, 2,\, \ldots,\, n\,.$$

- *Exemplo*: para o caso da equação do calor na barra visto, é possível dividir o intervalo $[0, L]$ em n subintervalos (ou $n+1$ pontos)

$$x_i = ih\,, \qquad \text{com } h = \frac{L}{n} \text{ e } i = 0,\, 1,\, 2,\, \ldots,\, n\,.$$

- Se $y \equiv y(x)$ é a função cujos valores serão aproximados ao longo da malha, e a mesma possui derivadas até ordem $q+1$ no domínio, é possível estimar suas derivadas por *série de Taylor*.

- Para $q = 1$, há 3 possibilidades:

  1. *Diferenças finitas avançadas* ou *progressivas*:

$$y'(x) = \frac{y(x+h) - y(x)}{h} - \frac{h}{2}y''(\xi)\,, \qquad \xi \in (x, x+h)\,.$$

  2. *Diferenças finitas atrasadas* ou *regressivas*:

$$y'(x) = \frac{y(x) - y(x-h)}{h} + \frac{h}{2}y''(\xi)\,, \qquad \xi \in (x-h, x)\,.$$

  3. *Diferenças finitas centradas*:

$$y'(x) = \frac{y(x+h) - y(x-h)}{2h} + \frac{h^2}{3!}y'''(\xi)\,, \quad \xi \in (x-h, x+h)\,.$$

Erro e ordem de aproximação

- Numa fórmula de diferenças finitas $F(x)$ para aproximar a derivada de ordem q de uma função $y(x)$, o erro cometido é dado por

$$E(x) = y^{(q)}(x) - F(x)$$

- A fórmula é de *ordem* p se $E(x) = h^p R(x)$, onde $R(x)$ independe de h. *Notação:* $E(x) = O(h^p)$.

- *Exemplo:* para fórmula de diferenças centradas:

$$F(x) = \frac{y(x+h) - y(x-h)}{2h} \text{ e } E(x) = \frac{h^2}{3!}y'''(\xi)\,, \xi \in (x-h, x+h)\,,$$

  logo, tal fórmula é de segunda ordem.

Aproximação para segunda derivada

É possível, a partir das expansões por Taylor em torno de um ponto x para $x+h$ e $x-h$, chegar à expressão

$$y''(x) = \frac{y(x+h) - 2y(x) + y(x-h)}{h^2} + \frac{h^2}{12} y^{(4)}(\xi)\,, \qquad \xi \in (x-h, x+h)\,,$$

- uma aproximação de ordem 2.

Aproximação de derivadas parafunções de várias variáveis

No caso de uma função $u(x,t)$, como a presente na EDP (16), as diferenças finitas podem ser usadas como aproximações das derivadas parciais:

1. Diferença avançada:

$$u_t(x,t) \approx \frac{u(x,t+k) - u(x,t)}{k}$$

2. Diferença atrasada:

$$u_t(x,t) \approx \frac{u(x,t) - u(x,t-k)}{k}$$

2. Diferenças centrais:

$$\begin{aligned} u_x(x,t) &\approx \frac{u(x+h,t) - u(x-h,t)}{2h}\,, \\ u_{xx}(x,t) &\approx \frac{u(x+h,t) - 2u(x,t) + u(x-h,t)}{h^2}\,, \\ u_{tt}(x,t) &\approx \frac{u(x,t+k) - 2u(x,t) + u(x,t-h)}{k^2}\,, \\ u_{xt}(x,t) &\approx \tfrac{u(x+h,t+k) - u(x+h,t-k) - u(x-h,t+k) + u(x-h,t-k)}{4hk}\,. \end{aligned} \tag{21}$$

9.4 Equações parabólicas

- As técnicas para resolução numérica de EDPs parabólicas serão vistas para o problema da equação de calor (16), juntamente com a condição inicial (17) e condições de contorno semelhantes às dadas em (18):

$$\begin{cases} u_t - \alpha^2 u_{xx} = 0\,, \quad 0 \le x \le L \text{ e } 0 < t < T \\ u(x,0) = q(x)\,, \quad 0 \le x \le L\,, \\ u(0,t) = f(t)\,, \quad 0 < t < T\,, \\ u(L,t) = g(t)\,, \quad 0 < t < T\,. \end{cases}$$

- Um problema como o dado acima, em que as condições de contorno são definidas em termos da função u, é conhecido por *problema de Dirichlet*.

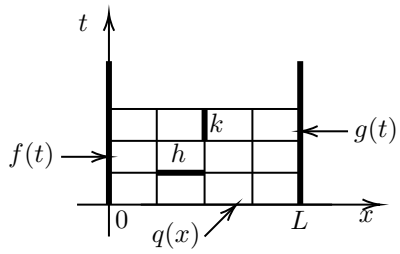
Discretização

- Como mencionado, para o caso da equação do calor na barra, o intervalo $[0, L]$ será distribuído em $n+1$ pontos igualmente espaçados:

$$x_i = ih\,, \qquad \text{com } h = \frac{L}{n} \text{ e } i = 0,\, 1,\, 2,\, \ldots,\, n\,.$$

- De forma análoga, para o *avanço temporal* define-se:

$$t_j = jk\,, \qquad \text{com } k = \frac{T}{m} \text{ e } j = 0,\, 1,\, 2,\, \ldots,\, m\,.$$



Aproximação para u_{xx}

A segunda derivada parcial u_{xx} num ponto (x_i, t_j) pode ser aproximada pela diferença finita centrada (21):

$$u_{xx}(x_i, t_j) \approx \frac{u(x_i + h, t_j) - 2u(x_i, t_j) + u(x_i - h, t_j)}{h^2}\,,$$

com erro local $O(h^2)$.

- Se u_{ij} corresponde à aproximação de u no ponto (x_i, t_j), então

$$u_{xx}(x_i, t_j) \approx \frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{h^2}\,.$$

Aproximação para u_t

A derivada parcial u_t num ponto (x_i, t_j) é aproximada pela diferença finita avançada

$$u_t(x_i, t_j) \approx \frac{u(x_i, t_j + k) - u(x_i, t_j)}{k}\,,$$

com erro local $O(k)$.

- Se u_{ij} corresponde à aproximação de u no ponto (x_i, t_j), então

$$u_t(x_i, t_j) \approx \frac{u_{i,j+1} - u_{i,j}}{k} \,,$$

Método explícito

- Ao se substituir as aproximações anteriores na equação do calor (16), obtém-se

$$\frac{u_{i,j+1} - u_{i,j}}{k} = \alpha^2 \left(\frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{h^2} \right) .$$

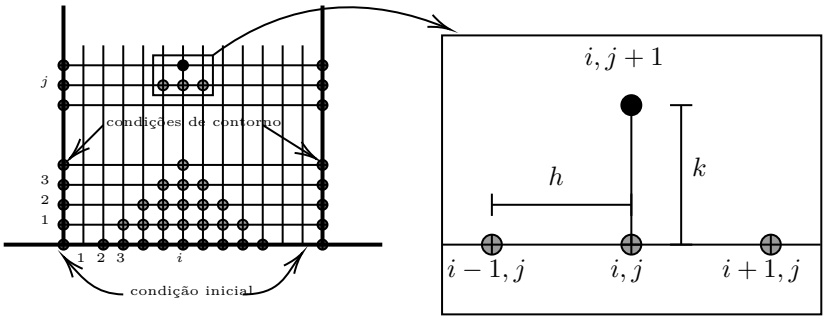
- Isolando-se $u_{i,j+1}$:

$$u_{i,j+1} = \sigma u_{i-1,j} + (1 - 2\sigma) u_{i,j} + \sigma u_{i+1,j} \,,$$

  onde $\sigma = k\alpha^2/h^2$.

- O método é portanto *explícito*, pois calcula-se $u_{i,j+1}$ de forma explícita, sem qualquer complicação, a partir de valores $u_{i-1,j}$, $u_{i,j}$ e $u_{i+1,j}$, todos conhecidos, num nível temporal (valor t) anterior, como evidenciado visualmente na *molécula computacional*.

Molécula computacional



Com base nas condições de contorno, escreve-se a *equação vetorial*

$$\mathbf{u}_{j+1} = \mathbf{A}\mathbf{u}_j + \mathbf{b}_j \,, \qquad \text{para } j = 0,\, 1,\, \ldots,\, m-1 \,,$$

onde a *matriz de amplificação* $\mathbf{A}$ – matriz tridiagonal $(n-1) \times (n-1)$ – é dada por

$$\mathbf{A} = \begin{pmatrix} 1-2\sigma & \sigma & 0 & \cdots & 0 \\ \sigma & 1-2\sigma & \sigma & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & \sigma & 1-2\sigma & \sigma \\ 0 & \cdots & 0 & \sigma & 1-2\sigma \end{pmatrix},$$

$\mathbf{u}_j = (u_{1,j},\, u_{2,j},\, \ldots,\, u_{n-1,j})^t$ e $\mathbf{b}_j = (\sigma f(jk),\, 0,\, \ldots,\, 0,\, \sigma g(jk))^t$.

- Da condição inicial, $\mathbf{u}_0 = (q(x_1),\, q(x_2),\, \ldots,\, q(x_{n-1}))^t$.
- As aproximações para as derivadas espaciais e temporal são, respectivamente, $O(h^2)$ e $O(k)$: método é *consistente*, pois ordem mais baixa do erro é linear.
- Tal fato não garante que $u_{i,j}$ seja uma boa aproximação de $u(x_i, t_j)$.
- É possível demonstrar que a aproximação será boa se, e somente se,

$$\sigma = \frac{k}{h^2}\alpha^2 \leq \frac{1}{2}$$

  (*critério de estabilidade de von Neumann*).
- A condição é bastante restritiva uma vez que, por exemplo, para $\alpha = 1$, e $h = 0,01$, o passo temporal seria $\Delta t = k \leq 1/20000$.
- *Convergência = consistência + estabilidade*[8]: para EDPs *lineares*, os métodos numéricos convergem se forem consistentes e estáveis.

Exemplo

Aplicar o método explícito para o problema de Dirichlet

$$\begin{cases} u_t = u_{xx}\,, \quad 0 \leq x \leq 1 \text{ e } 0 < t < 1\,, \\ u(x,0) = x(1-x)\,, \quad 0 \leq x \leq 1\,, \\ u(0,t) = 0\,, \quad 0 < t < 1\,, \\ u(1,t) = 0\,, \quad 0 < t < 1\,. \end{cases}$$

usando $h = 1/4$ e $k = 1/4$.

- Neste caso, $\sigma = k/h^2 = 4$, e a equação vetorial é dada por

$$\begin{pmatrix} u_{1,j+1} \\ u_{2,j+1} \\ u_{3,j+1} \end{pmatrix} = \begin{pmatrix} -7 & 4 & 0 \\ 4 & -7 & 4 \\ 0 & 4 & -7 \end{pmatrix} \begin{pmatrix} u_{1,j} \\ u_{2,j} \\ u_{3,j} \end{pmatrix}, \quad \text{para } j = 0,\, 1,\, 2,\, 3\,,$$

  uma vez que $x_0 = 0$, $x_1 = 1/4$, $x_2 = 1/2$, $x_3 = 3/4$, $x_4 = 1$ e $t_0 = 0$, $t_1 = 1/4$, $t_2 = 1/2$, $t_3 = 3/4$, $t_4 = 1$.

[1] Teorema de equivalência de Lax

- Da condição inicial, $\mathbf{u}_0 = (0,1875,\ 0,25,\ 0,1875)^t$.
- Da equação vetorial, obtém-se

$$\begin{aligned}
\mathbf{u}_1 &= (-0,3125,\ -0,25,\ -0,3125)^t\,,\\
\mathbf{u}_2 &= (1,1875,\ -0,75,\ 1,1875)^t\,,\\
\mathbf{u}_3 &= (-11,312,\ 14,75,\ -11,312)^t\,,\\
\mathbf{u}_4 &= (138,19,\ -193,75,\ 138,19)^t\,.
\end{aligned}$$

- Resultado *inconsistente*: não há fonte de calor; em $t = 1$, temperatura é maior que temperatura inicial da barra.

Exercício

Resolver o problema de Dirichlet apresentado, agora considerando $\sigma = 1/6$ e $k = 1/54$. Faça a implementação e obtenha os valores de u para $t = 1$. *Dica:* considere um arquivo como saída, e imprima, a cada linha, o valor da variável t – dado por jk – e os valores de u nos pontos de colocação.

- *Solução até o primeiro nível*:

  Como $\sigma = 1/6$, $\alpha = 1$ e $k = 1/54$: $h = \sqrt{k/\sigma} = \sqrt{6/54} = 1/3$.

  Logo, a discretização espacial é dada por $x_0 = 0$, $x_1 = 1/3$, $x_2 = 2/3$ e $x_3 = 1$.

- A matriz de amplificação neste caso é dada por

$$\mathbf{A} = \begin{pmatrix} 2/3 & 1/6 \\ 1/6 & 2/3 \end{pmatrix}.$$

- Da condição inicial, $\mathbf{u}_0 = (u_{1,0},\ u_{2,0})^t = (2/9,\ 2/9)^t$.
- Logo, no primeiro nível de avanço temporal – i.e. em $t = t_1 = 1/54$:

$$\begin{aligned}
\mathbf{u}_1 &= (u_{1,1},\ u_{2,1})^t\\
&= (5/27, 5/27)^t = (0,1851852,\ 0,1851852)^t\,.
\end{aligned}$$

Método implícito

Usando-se a diferença finita atrasada, a derivada parcial u_t num ponto (x_i, t_j) é aproximada por

$$u_t(x_i, t_j) \approx \frac{u(x_i, t_j) - u(x_i, t_j - k)}{k}\,,$$

com erro local $O(k)$.

- Se u_{ij} corresponde à aproximação de u no ponto (x_i, t_j), então

$$u_t(x_i, t_j) \approx \frac{u_{i,j} - u_{i,j-1}}{k},$$

- Ao se substituir a aproximação temporal anterior na equação do calor (16), obtém-se

$$\frac{u_{i,j} - u_{i,j-1}}{k} = \alpha^2 \left(\frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{h^2} \right).$$

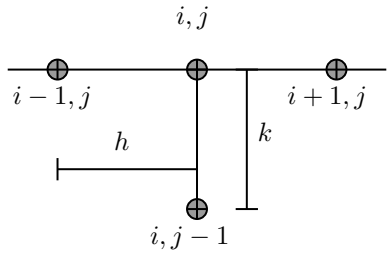
- Reorganizando-se os termos:

$$-\sigma u_{i-1,j} + (1 + 2\sigma)u_{i,j} - \sigma u_{i+1,j} = u_{i,j-1},$$

onde $\sigma = k\alpha^2/h^2$.

- O método é portanto *implícito*, pois valores desconhecidos na linha j são especificados em termos de valores conhecidos de linhas anteriores $j - 1$, $j - 2$, ... Neste caso, não é possível o cálculo direto de $u_{i,j}$, sendo necessária a solução de um *sistema linear*.

Molécula computacional



Obtém-se o *sistema tridiagonal* de $n - 1$ equações e $n - 1$ incógnitas

$$\begin{pmatrix} 1+2\sigma & -\sigma & 0 & \cdots & 0 \\ -\sigma & 1+2\sigma & -\sigma & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & -\sigma & 1+2\sigma & -\sigma \\ 0 & \cdots & 0 & -\sigma & 1+2\sigma \end{pmatrix} \begin{pmatrix} u_{1,j} \\ u_{2,j} \\ \vdots \\ u_{n-2,j} \\ u_{n-1,j} \end{pmatrix}$$

$$= \begin{pmatrix} u_{1,j-1} \\ u_{2,j-1} \\ \vdots \\ u_{n-2,j-1} \\ u_{n-1,j-1} \end{pmatrix} + \begin{pmatrix} \sigma f(jk) \\ 0 \\ \vdots \\ 0 \\ \sigma g(jk) \end{pmatrix},$$

ou, na notação vetorial, $\mathbf{A}\mathbf{u}_j = \mathbf{u}_{j-1} + \mathbf{b}_j$.

- Assim como no caso explícito, as aproximações para as derivadas espaciais e temporal são, respectivamente, $O(h^2)$ e $O(k)$ (portanto, método é consistente)
- No método implícito, porém, *não há restrição* para h e k – e consequentemente σ – i.e. o método implícito é *incondicionalmente estável.*
- É possível demonstrar que quando $h \to 0$ e $k \to 0$ a solução numérica $u_{i,j}$ converge para a solução exata $u(x_i, t_j)$ (teorema de equivalência de Lax).

Exemplo

Aplicar o método implícito para o problema de Dirichlet

$$\begin{cases} u_t = u_{xx}\,, \quad 0 \le x \le 1 \text{ e } 0 < t < 1\,, \\ u(x,0) = x(1-x)\,, \quad 0 \le x \le 1\,, \\ u(0,t) = 0\,, \quad 0 < t < 1\,, \\ u(1,t) = 0\,, \quad 0 < t < 1\,. \end{cases}$$

usando $h = 1/4$ e $k = 1/4$.

- Neste caso, $\sigma = k/h^2 = 4$, e o sistema linear é dado por

$$\begin{pmatrix} 9 & -4 & 0 \\ -4 & 9 & -4 \\ 0 & -4 & 9 \end{pmatrix} \begin{pmatrix} u_{1,j} \\ u_{2,j} \\ u_{3,j} \end{pmatrix} = \begin{pmatrix} u_{1,j-1} \\ u_{2,j-1} \\ u_{3,j-1} \end{pmatrix}, \quad \text{para } j = 1,\, 2,\, 3,\, 4\,,$$

  uma vez que $x_0 = 0$, $x_1 = 1/4$, $x_2 = 1/2$, $x_3 = 3/4$, $x_4 = 1$ e $t_0 = 0$, $t_1 = 1/4$, $t_2 = 1/2$, $t_3 = 3/4$, $t_4 = 1$.
- Da condição inicial, $\mathbf{u}_0 = (0,1875,\, 0,25,\, 0,1875)^t$.
- Do sistema linear acima:

$$\begin{aligned} \mathbf{u}_1 &= (0,054847,\, 0,076531,\, 0,054847)^t\,, \\ \mathbf{u}_2 &= (0,016321,\, 0,023011,\, 0,016321)^t\,, \\ \mathbf{u}_3 &= (0,0048763,\, 0,0068913,\, 0,0048763)^t\,, \\ \mathbf{u}_4 &= (0,0014582,\, 0,0020619,\, 0,0014582)^t\,. \end{aligned}$$

- Neste caso, o resultado é consistente com a física do problema.

9.5 Exercícios

1. Escreva o algoritmo do método explícito para resolução da equação do calor, considerando como dados de entrada: tamanho L da barra, tempo máximo T, constante α e inteiros n e m.

2. Considere o problema

$$\begin{cases} u_t = u_{xx}\,, \quad 0 \leq x \leq 1 \text{ e } t > 0\,, \\ u(x,0) = 2x\,, \quad 0 \leq x \leq 1/2\,, \\ u(x,0) = 2 - 2x\,, \quad 1/2 < x \leq 1\,, \\ u(0,t) = 0\,, \quad t > 0\,, \\ u(1,t) = 0\,, \quad t > 0\,. \end{cases}$$

   Resolva o problema usando o método explícito, com $h = 0,05$ e $k = \frac{5}{11}h^2$.

3. É possível adotar $k = \frac{5}{9}h^2$ para o problema anterior? Justifique.

4. Refaça o problema do item 2, trabalhando com método implícito, e adotando $h = 0,05$ e $k = \frac{5}{9}h^2$.

5. Considere o problema

$$\begin{cases} u_t = au_{xx} + bu_x\,, \quad a > 0\,, 0 \leq x \leq L \text{ e } 0 < t < T\,, \\ u(x,0) = q(x)\,, \quad 0 < x < L\,, \\ u(0,t) = f(t)\,, \quad 0 < t < T\,, \\ u(L,t) = g(t)\,, \quad 0 < t < T\,. \end{cases}$$

   Mostre que, discretizando a EDP pelo método explícito e usando diferenças centrais para aproximar u_x, obtém-se

$$u_{i,j+1} = \left(\sigma - \frac{bk}{2h}\right) u_{i-1,j} + (1 - 2\sigma)u_{i,j} + \left(\sigma + \frac{bk}{2h}\right) u_{i+1,j}\,.$$

6. Considere o problema de Dirichlet usado nos exemplos:

$$\begin{cases} u_t = u_{xx}\,, \quad 0 \leq x \leq 1 \text{ e } 0 < t < T\,, \\ u(x,0) = x(1-x)\,, \quad 0 \leq x \leq 1\,, \\ u(0,t) = 0\,, \quad 0 < t < T\,, \\ u(1,t) = 0\,, \quad 0 < t < T\,. \end{cases}$$

   Verifique que

$$u(x,t) = \frac{8}{\pi^3} \sum_{n=1}^{\infty} \frac{\operatorname{sen}(2n+1)\pi x}{(2n+1)^3} e^{-((2n+1)\pi)^2 t}$$

é a solução exata do problema.

Referências

1. BURDEN, R. L.; FAIRES, J. D. *Numerical Analysis*, 6th ed., Brooks/Cole Publishing Company, 1997.

2. FRANCO, N. B. *Cálculo numérico*. São Paulo: Pearson Prentice Hall, 2006.

3. VALLE, M. E. *MS211 – Cálculo Numérico. Aula 24 — Método das Diferenças Finitas para a Equação do Calor*. Disponível em: http://www.ime.unicamp.br/~valle/Teaching/MS211/Aula24.pdf. Acesso em: 23 de mar. de 2021

Adaptações: Renato Pimentel, FACOM/UFU

10 Introdução à otimização: programação linear e modelagem

10.1 Definição e Origens da Pesquisa Operacional

O que é a Pesquisa Operacional

Segundo Marins (2011)
"É o uso do método científico com o objetivo de prover departamentos executivos de elementos quantitativos para a tomada de decisões com relação a operações sob seu controle"

Origens

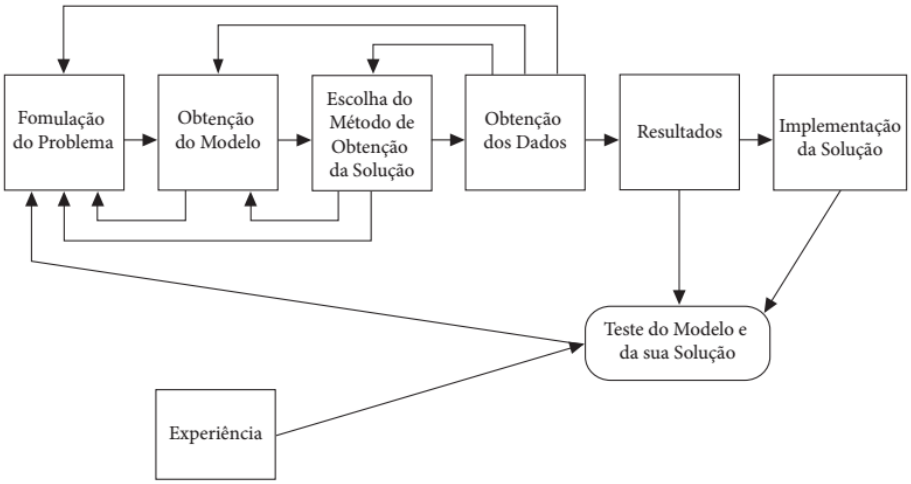
- Termo *Pesquisa Operacional*: tradução direta de *Operational research*.
- Inglaterra (1934): invenção do *radar*.
- 1936: Estação de Pesquisa Manor Bawdsey (Suffolk) – como interceptar *aviões inimigos*?
- A. P. Rowe (1938), superintendente da estação: criação do termo.
  - *Eficiência* de técnicas de operações a partir de experimentos com interceptação.
  - Análise científica do *uso operacional* de recursos militares: *II Guerra Mundial*.

Alguns temas pesquisados:

- Teoria de estoques
- Teoria de filas
- Reposição de equipamentos
- Agendamento de tarefas em máquinas
- Teoria de jogos
- Fluxos de redes
- *Otimização* linear

10.2 Fases de Resolução de Problemas

Fases da PO

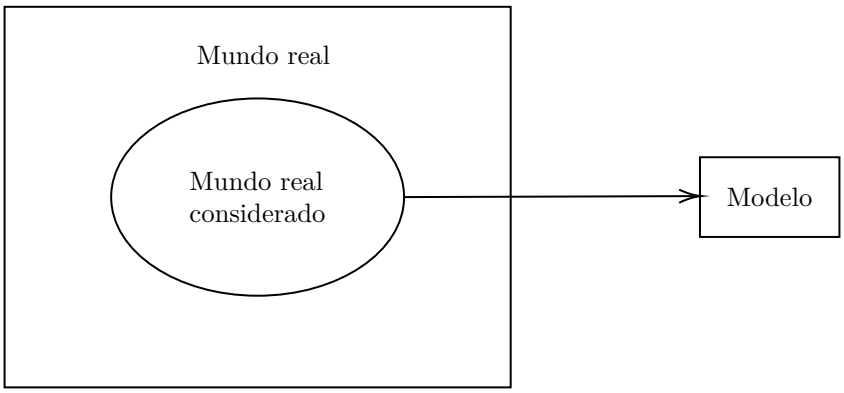


Formulação do problema

- Problemas reais: forma vaga e imprecisa
- Algumas questões:
  - Quem tomará decisões?
  - Quais os objetivos?
  - Que aspectos estão sujeitos ao controle dos decisores (*variáveis de decisão*) e sob quais limitações (*restrições*)?
  - Quais aspectos fogem do controle dos decisores?

Construção do modelo

- *Modelos*: representações *simplificadas* da realidade
- Modelagem: 2 características importantes:
  - Permite analisar o problema, indicando relações entre variáveis, quais dados relevantes e variáveis de maior importância
  - Permite estudo de alternativas de ação sem interromper sistema em estudo.
- Podem ser *físicos* (ex.: maquetes), *analógicos* (ex.: organograma) e *matemáticos*.



Obtenção da solução

- Típico de PO: modelo *matemático*.
- Varia conforme a área (programação linear, programação em redes, teoria de filas, etc.)
- Técnicas novas surgem constantemente
- *Softwares*:
  - Solver do Excel
  - LINDO – Linear Discrete Optimizer (`www.lindo.com`)
  - ILOG (`www.ibm.com/products/ilog-cplex-optimization-studio`)
  - Simulações: PROMODEL (`www.belge.com.br/promodel.php`) e ARENA (`www.paragon.com.br`)
  - etc.

Exemplo de problema: cerca (Taha)

Exemplo 10.1. *Um fazendeiro comprou L metros de uma tela e pretende cercar uma pequena área da fazenda para criação de gado. O fazendeiro somente sabe fazer ângulos retos. O fazendeiro quer que a área cercada seja a maior possível.*

- Área deve ser *retangular* (ângulos retos)
- Se l e c são respectivamente a *largura* e o *comprimento* do retângulo, queremos *maximizar*

$$z = l \times c\,,$$

sujeita às *restrições*:

- $2(l + c) = L$,

– $l \geq 0$, $c \geq 0$.

Infinitas soluções

- *viáveis*: atendem a *todas* restrições
- *ótima*: melhor solução viável

Formato geral
Maximizar ou *minimizar* uma
função objetivo sujeita a
restrições

Problema linear

Exemplo 10.2. *maximizar* $z = 2x_1 + 3x_2 + 4x_3$

$$\begin{array}{rcl} 3x_1 + 2x_2 + 1x_3 & \leq & \mathit{10} \\ 2x_1 + 3x_2 + 3x_3 & \leq & \mathit{15} \\ 1x_1 + 1x_2 - 1x_3 & \geq & \mathit{4} \\ x_1, x_2, x3 & \geq & \mathit{0} \end{array}$$

Obtenção da Solução

$$z = 15.55$$
$$x_1 = \frac{1}{3}, \quad x_2 = \frac{5}{9}, \quad x_3 = \frac{38}{9}$$

10.3 Principais Áreas da Pesquisa Operacional

Grandes Áreas

Programação Linear

- *Mix* de produção
- Mistura de matérias-primas
- Modelos de equilíbrio econômico
- Carteiras de investimentos
- Roteamento de veículos
- Jogos entre empresas

Modelos em Redes

- Rotas econômicas de transporte

- Distribuição e transporte de bens
- Alocação de pessoal
- Monitoramento de projetos

Teoria das Filas

- Congestionamento de tráfego
- Operações de hospitais
- Dimensionamento de equipes de serviço

10.4 Programação linear

Nesta seção, será considerada uma subclasse particular de problemas de PO, a dos problemas de *programação linear*.

A característica que define tal subclasse está no *modelo matemático* – que é composto exclusivamente de *equações lineares*.

O modelo matemático

Modelo de PL – como qualquer modelo de PO – possui 3 componentes básicos:

1. *Variáveis de decisão*, que se deseja determinar;
2. Uma ou um conjunto de *restrições* que a solução deve satisfazer;
3. Um *objetivo* (meta) a ser otimizado (*maximizado* ou *minimizado*).

Variáveis de Decisão

As variáveis de decisão são as *incógnitas* a serem determinadas pela solução do modelo e os *parâmetros* (coeficientes) são valores fixos no problema

Restrições

De modo a levarmos em conta as *limitações* físicas do sistema, o modelo deve incluir restrições que limitam as variáveis de decisão a seus valores possíveis (ou *viáveis*)

Função Objetivo

É uma função matemática que define a *qualidade* da solução em função das variáveis de decisão; é um *critério* de escolha das variáveis de decisão representado por uma função

Estrutura de Modelos Matemáticos

Pode-se dizer que:
O problema do modelo matemático de Pesquisa Operacional é escolher os *valores* das variáveis de decisão de forma a obter o melhor resultado da função objetivo sujeita às restrições especificadas.

Recomendações

- O decisor tem autoridade para escolher a quantidade (valor numérico) do item? Se sim, esta é uma variável de decisão;
- Ser preciso com relação às *unidades* de cada variável de decisão (ex.: se alguma moeda, alguma medida de comprimento, volume, massa ou tempo, etc.);
- Não confundir variáveis de decisão com os *parâmetros* do problema, como ex.: número de máquinas na fábrica, quantidade de cada recurso usado na fabricação de um produto, custos de produção, custos de transporte, etc.

Exemplo 10.3. *Um investidor possui* $\$90.000,00$ *para investir em ações. Ele está interessado em duas empresas:*

- *Tele Mundo, cujas ações custam* $\$50,00$ *cada e o retorno esperado é de* $\$6,00$ *ao ano;*
- *Cosmo Fonte, cujas ações custam* $\$30,00$ *cada e o retorno esperado é de* $\$4,00$ *ao ano.*

Além disso, ele não quer investir mais que $\$60.000,00$ *em uma única empresa. Como ele deve planejar seu investimento, de modo a maximizar seu lucro anual?*

- *Variáveis de decisão*: Correspondem às quantidades de ações em cada empresa (por exemplo: TM e CF, ou x_1 e x_2);
- *Parâmetros*: São os preços e retorno de cada ação;
- *Restrições*: São as limitações impostas pelo investidor e pela quantidade de dinheiro disponível para investir; além disso, por uma questão de lógica, ele não pode investir um valor *negativo* em cada ação;
- *Função Objetivo*: é a Função matemática que determina o retorno em função das variáveis de decisão e que (neste caso) deve ser maximizada.

Função objetivo

$$\max \quad L = 6TM + 4CF$$

Restrições

$$50TM + 30CF \leq 90.000$$

$$50TM \leq 60.000$$

$$30CF \leq 60.000$$

Condições de não-negatividade

$$TM \geq 0$$

$$CF \geq 0$$

Algumas observações

- Um tema comum na PO é a busca de uma *solução ótima*;
- É necessário que fique claro que essas soluções são ótimas *apenas* em relação ao modelo que está sendo usado;
- Como o modelo é apenas uma representação da realidade, *não* há garantia de que a solução ótima para o modelo se comprovará como a melhor possível que poderia ter sido implementada para o problema real;
- Entretanto, se o modelo for bem formulado e experimentado, as soluções tendem a ser uma boa representação para a solução a ser adotada no caso real.

Outro Exemplo

Exemplo 10.4. *Uma empresa precisa decidir quais modelos de geladeira produzir em sua nova planta. Existem dois modelos disponíveis: luxo e básico. No máximo,* 1500 *unidades do modelo luxo e* 6000 *unidades do modelo básico podem ser vendidas por mês. Empresa contratou* 25000 *homens-hora de trabalho por mês. Os modelos luxos precisam de* 10 *homens-hora de trabalho para serem produzidos e os modelos básicos,* 8 *homens-hora. A capacidade da linha de montagem é de* 4500 *geladeiras por mês, pois as geladeiras dividem a mesma linha. O lucro unitário do modelo luxo é* $\$100,00$ *por mês, enquanto o modelo básico lucra* $\$50,00$ *durante o mesmo período.*

Determine quanto produzir de cada geladeira, de modo a satisfazer todas as restrições e maximizar o lucro da empresa.

Variáveis de Decisão
Sejam x_1 e x_2 as quantidades (unidades) produzidas dos modelos luxo e básico, respectivamente.

Função Objetivo
Admitindo que a função lucro é uma função linear de x_1 e x_2, esse lucro deve ser maximizado por uma escolha de x_1 e x_2, tal que:

$$\max \;\; L = 100x_1 + 50x_2$$

Como existem recursos limitados, há restrições:

Restrições

1. $10x_1 + 8x_2 \leq 25000$ (homens-hora)
2. $x_1 + x_2 \leq 4500$ (linha de montagem)
3. $x_1 \leq 1500$ (máximo a ser vendido do luxo)
4. $x_2 \leq 6000$ (máximo a ser vendido do básico)
5. $x_1 \geq 0; x_2 \geq 0$ (não-negatividade)

Problemas de Programação Linear

Definição Formal
Um problema de Programação Linear (PL) é um problema de programação matemática em que as Funções Objetivos e de Restrição são *lineares*.

Forma Geral:

$$\max(\min) \;\; Z = \sum_{j=1}^{n} c_j x_j$$

sujeito a:

$$\sum_{j=1}^{n} a_{ij} x_j, \;\; \text{para } i = 1, 2, \ldots, m$$

$$x_i \geq 0, \;\; \forall i$$

Algumas Definições

Solução
Qualquer especificação de valores para as variáveis de decisão, independente de se tratar de uma escolha desejável ou permissível.

Solução Viável
Uma solução em que *todas* as restrições são satisfeitas. O conjunto de todos os pontos que satisfazem todas as restrições é chamado de *Conjunto Viável* (S).

Solução Ótima
Uma solução viável que tem o valor *mais favorável* da função objetivo, isto é, maximiza ou minimiza a função objetivo em toda a região viável. Pode ser única ou não.

Hipóteses da Programação Linear

Proporcionalidade
A contribuição de cada variável ao valor da função objetivo é *diretamente proporcional* ao valor da variável, conforme representado pelo termo $c_j x_j$ na função objetivo.

De modo semelhante, a contribuição de cada variável às restrições é proporcional ao valor da variável x_j, como representado pelo termo $a_{ij} x_j$ na restrição.

Aditividade
Toda função em um modelo de programação linear é a soma das contribuições individuais das respectivas variáveis.

Divisibilidade
As variáveis de decisão em um modelo de programação linear podem assumir quaisquer valores, inclusive valores não-inteiros, que satisfaçam as restrições funcionais e de não-negatividade.

Quando as variáveis do modelo de programação linear só puderem assumir valores inteiros, deve-se impor esta condição ao próprio modelo. Passa-se, então, a lidar com um modelo de *programação linear inteira*.

Certeza
O valor atribuído a cada parâmetro de um modelo de programação linear é assumido como uma *constante conhecida*.

10.5 Problemas clássicos

Problemas de mistura

Problemas de mistura consistem em combinar materiais obtidos da natureza (ou sobras de outros já previamente combinados) para gerar novos materiais ou produtos com características convenientes.

Exemplos de problema de mistura

1. *Rações:* Fábricas de rações produzem variados tipos de rações para determinados animais (bovinos, equinos, caprinos, caninos de pequenos e grande portes etc.)
    - Mistura de alimentos ou farinhas de restos de alimentos (milho, farelo de arroz, etc.)
    - Preços de mercados destes produtos são conhecidos
    - *Composição nutricional* é conhecida. Nutrição veterinária especifica necessidades mínimas e máximas dos nutrientes por kg para cada espécie de animal.

- Problema de *minimizar custo*: *quais devem ser as quantidades ideais de cada ingrediente por kg de modo que necessidades nutricionais sejam atendidas e o custo total dos ingredientes seja o menor possível?*

2. *Ligas metálicas:* Fundições produzem diversos tipos de aço a partir de diversos insumos: lingotes de ferro, grafite, sucatas industriais, etc.

   - Forno de alta temperatura para permitir a mistura
   - A *composição*, em termos de elementos como carbono, silício, manganês etc. é determinada por *normas técnicas* da metalurgia, bem como composição dos produtos a serem misturados.
   - Preços dos insumos podem variar substancialmente. Entretanto, são conhecidos.
   - *deve-se determinar as quantidades de cada insumo a serem fundidas, de modo que a composição atenda as normas e preço final seja menor possível*

3. *Areias para filtro (ETA)*

   - Permeabilidade: areias usadas em *estações de tratamento de água* para interceptar impurezas da água afluente
   - Unidades de filtração: areias de portos passíveis de exploração com composições distintas
   - Custos de dragagem, transporte, seleção e preparo variam p/ cada porto
   - Areias dispostas em camadas, devendo obedecer composições estabelecidas em norma
   - *Como combinar os volumes de areia de cada porto, de modo a atender às especificações, com menor custo possível?*

Formulação matemática do problema da mistura

- Obtenção de *produto* (mistura), combinando-se materiais disponíveis
- Materiais (ingredientes) possuem os *componentes* desejados na mistura
- Produtos devem satisfazer determinadas *especificações*
- *Objetivo*: determinar as quantidades dos ingredientes para criar mistura com composição especificada com menor custo possível (*minimização*).

Minimizar

$$f(x_1, \ldots, x_n) = c_1x_1 + c_2x_2 + \cdots + c_nx_n$$

Sujeito às restrições:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\cdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &= b_m \end{aligned}$$

$$x_1 \geq 0,\ x_2 \geq 0,\ \ldots,\ x_n \geq 0$$

- x_j: quantidade do ingrediente j por unidade da mistura;
- a_{ij}: quantidade ou fração do componente i no ingrediente j;
- b_i: quantidade ou fração do componente i na mistura;
- c_j: custo unitário do ingrediente j.

Exemplo: ração

Exemplo 10.5. *Queremos saber quais as quantidades ideais de cada ingrediente para fazer uma quantidade de ração para aves, com as necessidades nutricionais atendidas e o custo total dos ingredientes seja o menor possível. Temos disponíveis dois ingredientes (milho e farinha de osso), cujos custos (em \$ por Kg) e ingredientes (em unidades por Kg) estão listados na tabela a seguir:*

	Vitamina A	*Vitamina B*	*Proteínas*	*Custo*
Milho	*2*	*3*	*1*	*65*
Farinha de osso	*3*	*2*		*30*

Deseja-se que a ração contenha, no mínimo, 7 *unidades de vitamina A,* 9 *de vitamina B e* 1 *de proteína.*

Modelo Matemático

$$\min \quad C = 65x_1 + 30x_2$$

sujeito a:

$$\begin{aligned} 2x_1 + 3x_2 &\geq 7 \\ 3x_1 + 2x_2 &\geq 9 \\ 1x_1 + 0x_2 &\geq 1 \\ x_1 \geq 0; x_2 &\geq 0 \end{aligned}$$

Mix de produção

Problemas de mix de produção envolvem decidir quais produtos, e quanto fabricar de cada produto em um certo período.

Formulação matemática do *mix* de produção

- Tendo em vista a *capacidade limitada* de produção – máquinas, RH, capital, armazenagem, etc. – e os diversos produtos que a empresa pode fabricar e vender, deseja-se determinar *quais produtos fabricar* e *quanto fabricar* de cada produto, de modo a *maximizar* o lucro, num determinado *período*.

  Maximizar

$$f(x_1, \ldots, x_n) = \ell_1 x_1 + \ell_2 x_2 + \cdots + \ell_n x_n$$

  Sujeito às restrições:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &\leq C_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &\leq C_2 \\ &\cdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &\leq C_m \\ d_j \leq x_j \leq v_j, \qquad & j = 1, 2, \ldots, n \end{aligned}$$

- x_j: quantidade do produto j a ser produzida por período;
- C_i: capacidade do recurso i, $i = 1, 2, \ldots, m$ no período.
- a_{ij}: unidades do recurso i usadas para produzir uma unidade de j;
- d_j (v_j): produção mínima (máxima) do produto j no período;
- ℓ_j: lucro obtido pela empresa por cada unidade de j.

O Exemplo 10.4 visto anteriormente (problema das geladeiras) é um exemplo de problema de *mix* de produção.

Outro exemplo (MARINS, 2011)

Exemplo 10.6. *Uma empresa deseja programar a produção de um utensílio de cozinha e requer o uso de 2 recursos: mão-de-obra e material. Ela está considerando a fabricação de 3 modelos de acordo com os dados da tabela que segue, sendo que a disponibilidade diária de mão-de-obra é 150 horas, e o suprimento de material é 200 kg/dia.*

	Modelo		
	A	*B*	*C*
Mão-de-obra (horas/unidade)	*7*	*3*	*6*
Material (kg/unidade)	*4*	*4*	*5*
Lucro ($/unidade)	*4*	*2*	*3*

Modelagem

- x_a, x_b, x_c: produções diárias de A, B e C.
- Restrições:
  - $7x_a + 3x_b + 6x_c \leq 150$ (limitação de mão-de-obra)
  - $4x_a + 4x_b + 5x_c \leq 200$ (limitação de material)
  - $x_a \geq 0$, $x_b \geq 0$, $x_c \geq 0$ (não-negatividade)
- Função objetivo: maximização do lucro total
  $L = 4x_a + 2x_b + 3x_c$

10.6 Exercícios

1. Um sapateiro faz 6 sapatos por hora, se fizer somente sapatos, e 5 cintos por hora, se fizer somente cintos. Ele gasta 2 unidades de couro para fabricar 1 unidade de sapato e 1 unidade de couro para fabricar uma unidade de cinto. Sabendo-se que o total disponível de couro é de 6 unidades e que o lucro unitário por sapato é de \$5,00 e o do cinto é de \$2,00, pede-se: o modelo do sistema de produção do sapateiro, se o objetivo é maximizar seu lucro por hora.

2. Um vendedor de frutas pode transportar 800 caixas de frutas para sua região de vendas. Ele necessita transportar 200 caixas de laranjas a \$20,00 de lucro por caixa, pelo menos 100 caixas de pêssegos a \$10,00 de lucro por caixa, e no máximo 200 caixas de tangerinas a \$30,00 de lucro por caixa. De que forma deverá ele carregar o caminhão para obter o lucro máximo? Construa o modelo do problema.

3. Uma fundição tem de produzir 10 toneladas de um tipo de liga metálica e, para isso, tem disponível: lingotes de ferro, grafite e sucata. 2 componentes são relevantes para a liga: carbono e silício. A tabela fornece a fração destes elementos nos ingredientes disponíveis, seus custos unitários, suas disponibilidades em estoque, bem como a composição da liga de acordo com as especificações. Quais quantidades dos ingredientes devem compor a liga, de modo que as especificações sejam satisfeitas e o custo seja mínimo?

	Ingredientes			Especificações liga	
Composição (%)	Lingotes	Grafite	Sucata	Mínimo	Máximo
Carbono	0,0050	0,90	0,090	0,00	0,095
Silício	0,14	-	0,27	0,19	0,20
Custos (R\$/ton)	90	180	25		
Estoque (ton)	5	5	12		

4. Certa empresa fabrica 2 produtos P1 e P2. O lucro por unidade de P1 é de $100,00 e o lucro unitário de P2 é de $150,00. A empresa necessita de 2 horas para fabricar uma unidade de P1 e 3 horas para fabricar uma unidade de P2. O tempo mensal disponível para essas atividades é de 120 horas. As demandas esperadas para os 2 produtos levaram a empresa a decidir que os montantes produzidos de P1 e P2 não devem ultrapassar 40 unidades de P1 e 30 unidades de P2 por mês. Construa o modelo do sistema de produção mensal com o objetivo de maximizar o lucro da empresa.

5. Uma fábrica de aço precisa decidir como alocar o horário da semana seguinte em um laminador, que é uma máquina que, recebendo lâminas de aço como entrada, pode produzir dois produtos: tiras e bobinas, a diferentes razões:

   - Tiras: 200 tons/h;
   - Bobinas: 140 tons/h.

   O lucro para cada produto é dado como segue:

   - Tiras: $ 25/ton;
   - Bobinas: $ 30/ton.

   Com base nos pedidos já feitos, não se deve produzir durante a semana mais do que:

   - Tiras: 6000 tons;
   - Bobinas: 4000 tons.

   Dado que há uma disponibilidade de 40 horas semanais de produção à disposição, o problema consiste em decidir quantas toneladas de cada um dos dois produtos, de modo a maximizar o lucro. Formule o problema de modo a permitir a determinação de quantas toneladas de tiras e bobinas de aço devem ser produzidas.

6. Uma pessoa deseja balancear os alimentos que consome no café da manhã, de modo que minimize o custo. Para isso, ela pretende se alimentar de modo que consuma no mínimo 130 mg de cálcio e no máximo 480 kcal. O valor nutritivo e o preço por porção dos alimentos a serem considerados são dados por:

Tipo de alimento	Porção	Cálcio (mg)	Energia (kcal)	Preço (R$)
Leite achocolatado	100 ml	70	83	0,90
Pão de forma	100 g	2,5	343	0,10

   Faça a modelagem do problema.

Referências

1. ARENALES, M.; ARMENTANO, V.; MORABITO, R.; YANASSE, H. *Pesquisa operacional: para cursos de engenharia*. Rio de Janeiro: Elsevier Brasil, 2006.

2. GOLDBARG, M. C. & LUNA, H. P. L. *Otimização combinatória e programação linear*. Rio de Janeiro: Elsevier, 2000.

3. MARINS, F. A. S. *Introdução à pesquisa operacional*. São Paulo: Cultura Acadêmica, 2011.

4. NOGUEIRA, F. Notas de aula: Pesquisa Operacional I (UFJF)

5. TAHA, H. *Pesquisa operacional*. 8ª. ed. São Paulo: Prentice Hall, 2008.

6. TOLEDO, F. M. B. & SANTOS, M. O.; Notas de aula: Programação matemática e pesquisa operacional (ICMC/USP)

Os materiais de parte desta seção foram gentilmente cedidos por Paulo H. R. Gabriel e Ivan Sendin (FACOM/UFU)
Adaptações: Renato Pimentel, FACOM/UFU

11 Solução gráfica

11.1 Introdução

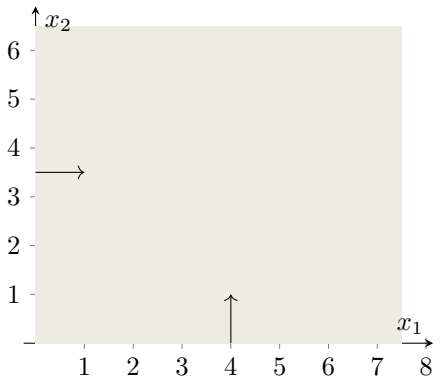
- A *visualização* de soluções de um problema pode ser útil para melhorar a intuição sobre o mesmo.
- Mesmo quando somente limitada a um desenho esquematizado sobre o plano.
- No caso de PL, permite delinear um *método de solução* – i.é., encontrar a *solução ótima*.
- Consideram-se aqui problemas com apenas *duas variáveis*
- (Representação das soluções factíveis e da solução ótima num *plano cartesiano*)

Nota
Vamos considerar, por questões de conveniência, todas as restrições sob a forma de *inequações*.

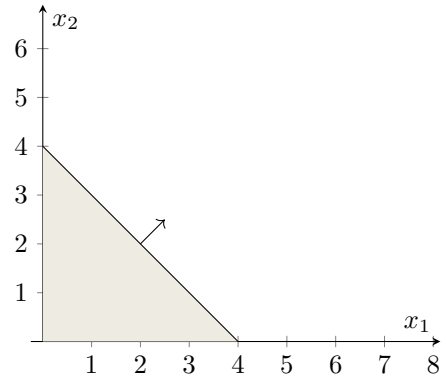
Exemplo 11.1. *Maximizar* $f(x_1, x_2) = x_1 + 2x_2$ *sujeito a:*

$$x_1 + x_2 \leq 4$$
$$x_1 \leq 2$$
$$x_2 \leq 3$$
$$x_1 \geq 0,\ x_2 \geq 0$$

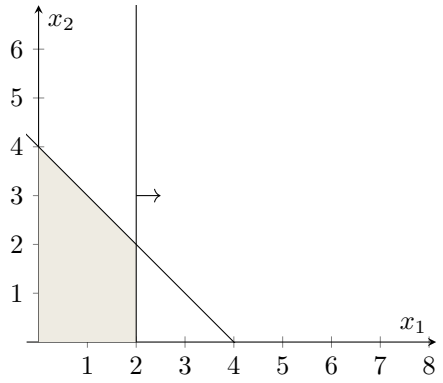
- Condições de *não-negatividade*:



- Adicionando a restrição $x_1 + x_2 \leq 4$ às de não-negatividade:

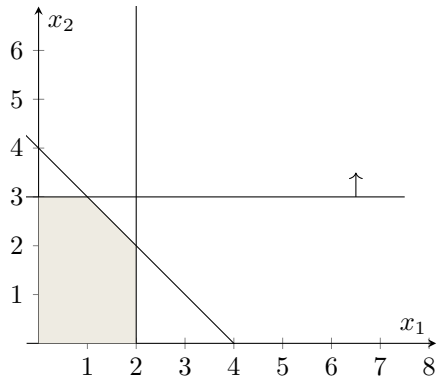


- Adicionando a restrição $x_1 \leq 2$ às anteriores:



- Por fim, adicionando a restrição $x_2 \leq 3$ às anteriores: obtém-se a *região factível* ou *região viável* do problema:

  qualquer ponto da região é uma *solução viável* do mesmo.



11.2 Solução ótima, curva de nível e vetor gradiente

Determinação da solução ótima

Considerando o exemplo, a função objetivo

$$f(x_1, x_2) = x_1 + 2x_2,$$

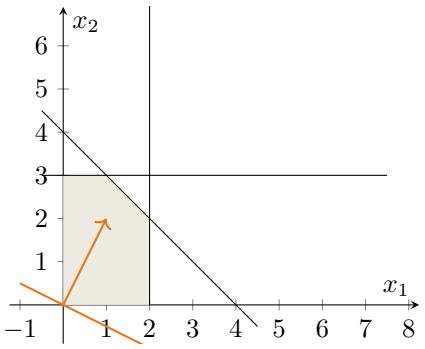
pode assumir infinitos valores – qualquer par $(x_1,\ x_2)$.

Os pontos (x_1, x_2) do $\mathbb{R}^2$ que resultam em $f = 0$ estão na reta $x_1 + 2x_2 = 0$. Esta reta define a *curva de nível 0* da função.

Curva de nível

A curva de nível f_0 de uma função f é dada pelo conjunto de pontos no $\mathbb{R}^2$ os quais, aplicados à função f, resultam em $f = f_0$.

- Representando a curva de nível 0 no gráfico, junto com o *sentido de crescimento*.



Vetor gradiente

O *vetor gradiente* de uma função $f(x_1, x_2)$, dado por

$$\nabla f(x_1, x_2) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2} \right)^t$$

indica o *sentido de maior crescimento* da função. Se a função for linear, o gradiente será constante (a direção e o sentido não variam)

- Consequentemente, indica a direção onde as curvas de f assumem valores *maiores*.
- No caso de *retas*, é constante e perpendicular às mesmas.

Observação

Na prática, também podemos testar tomando pontos de um lado e de outro de uma curva de nível, e verificando o valor de f.

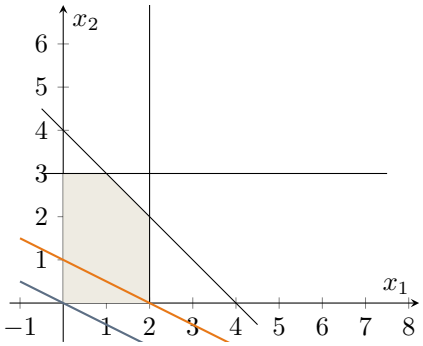
Temos, para a função objetivo do problema,

$$\nabla f(x_1, x_2) = \left(\frac{\partial}{\partial x_1}(x_1 + 2x_2), \frac{\partial}{\partial x_2}(x_1 + 2x_2) \right)^t = (1, 2)^t,$$

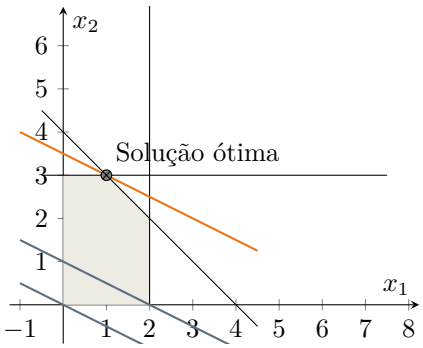
indicado pelo vetor representado no gráfico anterior.

Como se deseja *maximizar* a função objetivo, busca-se o *maior valor possível* de f dentro da região viável. Portanto, "caminha-se" no sentido para o qual o vetor gradiente aponta.

- Acrescentando-se agora ao gráfico a curva de nível 2:



- Ainda não se chegou à solução ótima.
- Acrescentando-se a curva de nível 7:



- Solução ótima obtida ($f(x_1, x_2) = 7$).
- Portanto, a solução do problema existe e é única: $(x_1, x_2) = (1, 3)$ – maximiza f, respeitando as restrições.

Considerações

1. O conjunto de todas as soluções viáveis de um modelo de PL é um *conjunto convexo*.
2. Toda *solução básica viável* (SBV) do sistema de equações lineares de um modelo de PL é um *ponto extremo* do conjunto de soluções viáveis.
3. Se uma função objetivo possui um único ponto de ótimo finito, então este é um *ponto extremo* do *conjunto convexo* de soluções viáveis.
4. Se a função objetivo assume o valor ótimo em mais de um ponto do conjunto de soluções viáveis (soluções múltiplas), então ela assume este valor para pelo menos *dois pontos extremos* do conjunto convexo e para qualquer *combinação convexa* desses pontos extremos, isto é, todos os pontos do segmento de reta que une estes dois pontos (em outras palavras, a aresta do polígono que contém estes dois pontos).

Solução do problema das geladeiras

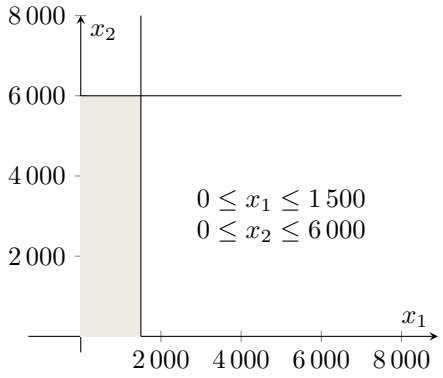
Voltando ao modelo da produção de geladeiras (*mix* de produção):

$$\max \quad L = 100x_1 + 50x_2$$

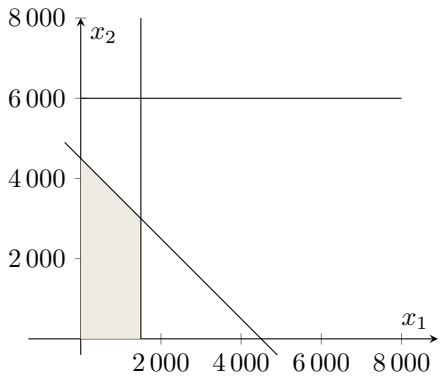
sujeito a

$$\begin{aligned} 10x_1 + 8x_2 &\leq 25000 \\ x_1 + x_2 &\leq 4500 \\ x_1 &\leq 1500 \\ x_2 &\leq 6000 \\ x_1 \geq 0; x_2 &\geq 0 \end{aligned}$$

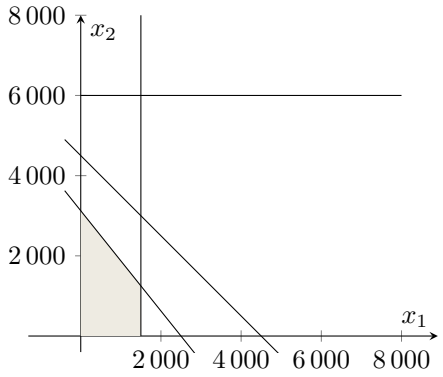
- Restrições de não-negatividade e demanda máxima:



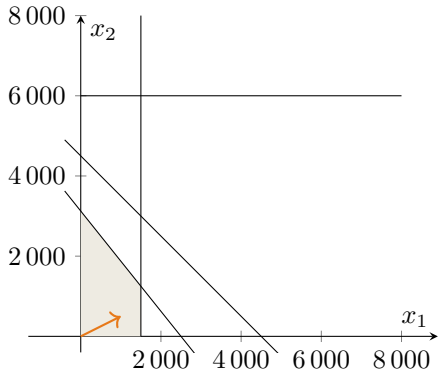
- $x_1 + x_2 \leq 4\,500$ (capacidade da linha de montagem)



- $10x_1 + 8x_2 \leq 25\,000$ (limitação da mão-de-obra)

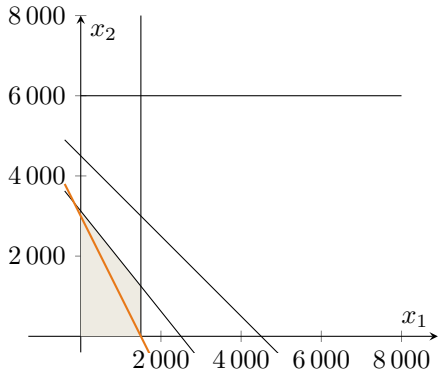


- $\max f(x_1, x_2) = 100x_1 + 50x_2$
  - Sentido de crescimento: $\nabla f = (100, 50)$

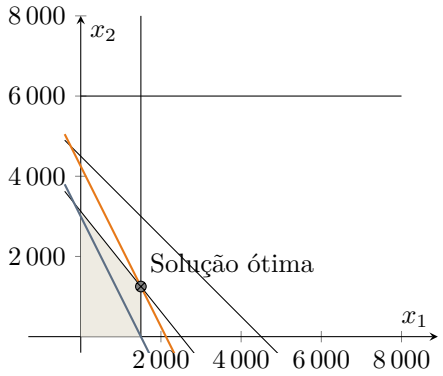


- Candidatos a solução ótima: pontos $(1500, 0)$, $(1500, 1250)$ e $(0, 3125)$ (pontos extremos na direção do crescimento)

- $\max f(x_1, x_2) = 100x_1 + 50x_2$
  - Na *solução básica viável* $(1500, 0)$, temos $f = 150\,000$.



- $\max f(x_1, x_2) = 100x_1 + 50x_2$
  - Na *solução básica viável* $(1500, 1250)$, temos $f = 212\,500$.



- Esta é a *solução ótima*, pois a solução básica viável não testada – $(0, 3125)$ – está no sentido oposto ao de crescimento da função objetivo, em relação à curva de nível.

- Logo, a empresa deve produzir 1500 geladeiras do modelo luxo, e 1250 do modelo básico por mês, maximizando o lucro, que será de \$ 212 500.

Solução do problema da ração

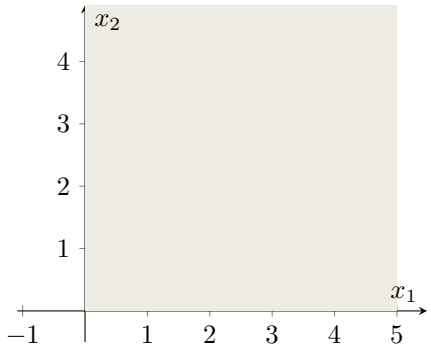
Voltando ao modelo da ração (problema de mistura):

$$\min \quad C = 65x_1 + 30x_2$$

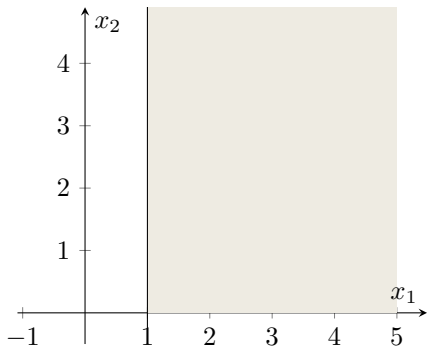
sujeito a:

$$2x_1 + 3x_2 \geq 7$$
$$3x_1 + 2x_2 \geq 9$$
$$1x_1 + 0x_2 \geq 1$$
$$x_1 \geq 0; x_2 \geq 0$$

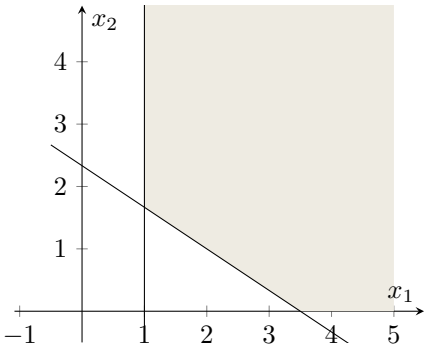
- Não-negatividade



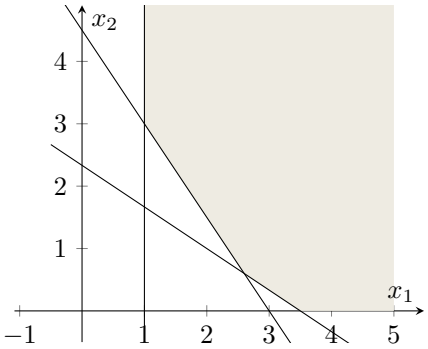
- $1x_1 + 0x_2 \geq 1$.



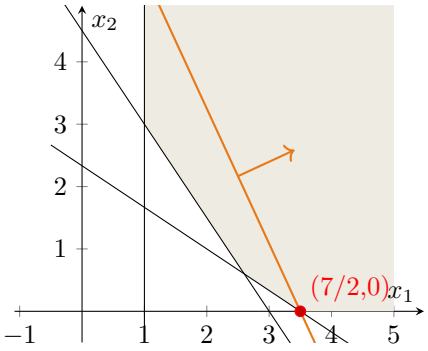
- $2x_1 + 3x_2 \geq 7$.



- $3x_1 + 2x_2 \geq 9$.

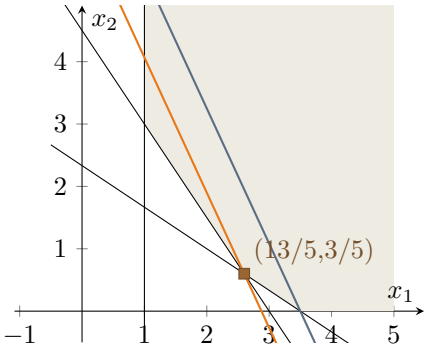


- $\min C = 65x_1 + 30x_2$
  - Na *solução básica viável* $(7/2, 0)$, temos $C = \$227,5$.

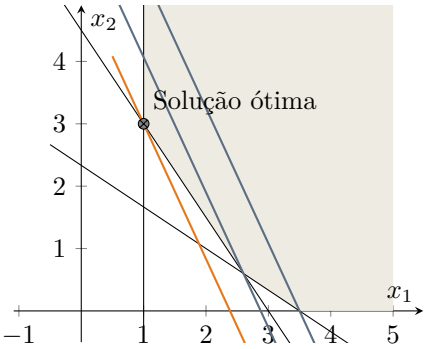


- Problema de *minimização*: caminha-se no sentido *oposto* ao de crescimento de C.

- $\min C = 65x_1 + 30x_2$
  - Na *solução básica viável* $(13/5, 3/5)$, temos $C = \$187$.



- $\min C = 65x_1 + 30x_2$
  - Na *solução básica viável* $(1, 3)$, temos $C = \$155$.



- $(1, 3)$ é a *solução ótima* do problema da ração. Neste ponto, o custo total é o menor possível, \$ 155.

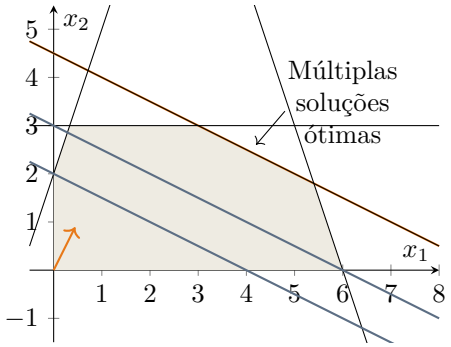
11.3 Casos especiais

Múltiplas soluções ótimas

Exemplo 11.2. *Maximizar* $f(x_1, x_2) = x_1 + 2x_2$ *sujeito a:*

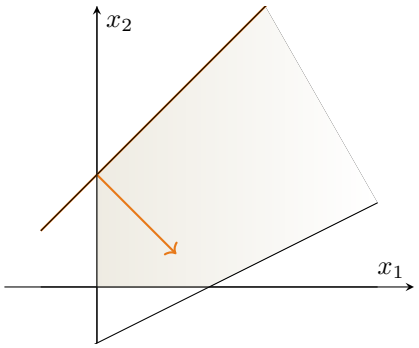
$$
\begin{gathered}
-3x_1 + x_2 \leq 2 \\
x_2 \leq 3 \\
x_1 + 2x_2 \leq 9 \\
3x_1 + x_2 \leq 18 \\
x_1 \geq 0,\ x_2 \geq 0
\end{gathered}
$$

- $\max f(x_1, x_2) = x_1 + 2x_2$

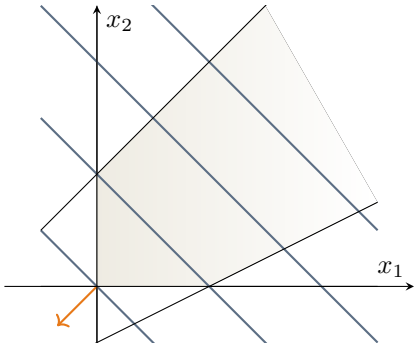


Região viável ilimitada

- Infinitas soluções ótimas (minimização, neste exemplo):

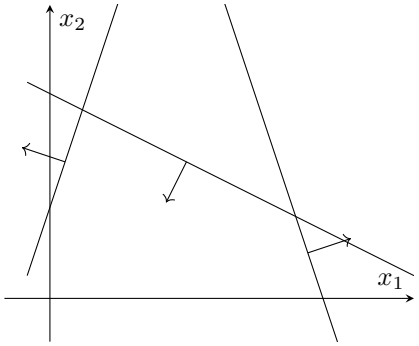


- Não existe solução ótima (minimização, neste exemplo):



Região vazia

- Região viável vazia: não existe solução ótima (restrições conflitantes)



11.4 Exercícios

1. Faça a solução gráfica dos exercícios envolvendo duas variáveis de decisão propostos na Seção anterior (modelagem).

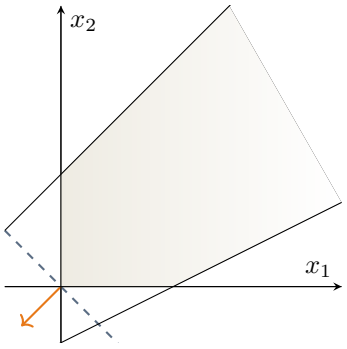
2. Determine a região das soluções viáveis de acordo com as seguintes restrições:

$$\begin{cases} x_1 + x_2 \leq 9 \\ x_1 \leq 3 \\ x_2 \leq 4 \\ x_1,\, x_2 \geq 0 \end{cases}$$

3. Maximize a função objetivo $Z = 5x_1 + 2x_2$ no gráfico do item anterior: Quais os valores (x_1, x_2) e qual o valor máximo de Z?

4. Faça a solução gráfica para o exemplo do investidor das ações Cosmo Fonte e Tele Mundo, visto em aula, e responda: quantas ações comprar de cada empresa, e qual o lucro máximo esperado?

5. Observe a situação abaixo:



Além das restrições de não-negatividade, há um par de retas representando as restrições adicionais, delimitando a região viável entre elas. Esta é ilimitada para $x_1 \to +\infty$ e $x_2 \to +\infty$.

A seta na figura indica a direção do **vetor gradiente** da função objetivo (representada em tracejado na sua curva de nível 0). Considerando-se que este é um problema de **minimização** desta função objetivo, o que se pode dizer sobre sua otimização: existe um ótimo? Se sim, ele é único? Justifique.

Referências

1. ARENALES, M.; ARMENTANO, V.; MORABITO, R.; YANASSE, H. *Pesquisa operacional: para cursos de engenharia.* Rio de Janeiro: Elsevier Brasil, 2006.

2. MARINS, F. A. S. *Introdução à pesquisa operacional.* São Paulo: Cultura Acadêmica, 2011.

Os materiais de parte desta seção foram gentilmente cedidos por Paulo H. R. Gabriel (FACOM/UFU)
Adaptações: Renato Pimentel, FACOM/UFU

12 O método simplex

12.1 Introdução

- O método *simplex* visa a *resolução algébrica* de um problema de PL.
- Problemas agora não se limitam mais a 2 variáveis de decisão (como na solução gráfica)
- *1º passo*: Criação de *Variáveis de folga* ou *excesso*: transformam o modelo num *sistema linear* de *equações* a ser resolvido.

Eliminação das desigualdades

- Inicialmente, é preciso eliminar as *desigualdades* presentes nas restrições do modelo.
  - Criam-se assim novas *equações lineares* no problema, a partir das inequações anteriores.
- Exemplo:
$$2x_1 + x_2 \leq 5$$
- Como o *lado esquerdo* é *menor ou igual* a 5 (a diferença é desconhecida), a adição de uma variável *não-negativa*, chamada, por exemplo, x_3, que represente tal diferença, permite que a inequação seja escrita como uma equação:
$$2x_1 + x_2 + x_3 = 5$$
- $x_3 \geq 0$ é denominada *variável de folga*.
- De modo similar, no caso da inequação
$$x_1 + 3x_2 \geq 7,$$
onde tem-se o lado esquerdo *maior ou igual* ao lado direito, é possível representar a diferença pela *subtração* de uma variável de folga não-negativa:
$$x_1 + 3x_2 - x_4 = 7\,.$$
- Algumas referências chamam neste caso a nova variável de *variável de excesso*.

Observação
Apenas as *restrições técnicas* são reescritas como equações.
As restrições de não-negatividade são mantidas.

12.2 Forma padrão

Um problema de PL está na *forma padrão* quando:

1. É um problema de *maximização*;
2. As restrições são do tipo $\leq$;
3. O lado direito das restrições (termo independente) é sempre não-negativo;
4. As variáveis de decisão são não-negativas.

Observação
Alguns autores – ex.: Marins (2011) – trabalham com definições alternativas para a forma padrão. A adotada no curso foi considerada por questões didáticas.

Exemplo 12.1.

$$\max Z(x_1,\, x_2) = 5x_1 + 2x_2$$

sujeito a

$$\begin{gathered} x_1 \leq 3 \\ x_2 \leq 4 \\ x_1 + 2x_2 \leq 9 \\ x_1 \geq 0,\, x_2 \geq 0 \end{gathered}$$

$$\max Z(x_1,\, x_2,\, x_3,\, x_4,\, x_5) - 5x_1 - 2x_2 = 0$$

sujeito a

$$\begin{gathered} x_1 + x_3 = 3 \\ x_2 + x_4 = 4 \\ x_1 + 2x_2 + x_5 = 9 \\ x_1 \geq 0,\, x_2 \geq 0,\, x_3 \geq 0,\, x_4 \geq 0,\, x_5 \geq 0 \end{gathered}$$

- Como a *função objetivo* é dada como uma equação, não é necessária a introdução de variáveis de folga na mesma.
- Note que a função objetivo foi reescrita, de modo a deixar o lado direito nulo.

12.3 Algoritmo simplex

Quadro inicial

- A tabela ou *quadro* abaixo auxilia na resolução:

		x_1	x_2	x_3	x_4	x_5	**b**
$L_0^{(0)}$	Z	-5	-2	0	0	0	0
$L_1^{(0)}$	x_3	1	0	1	0	0	3
$L_2^{(0)}$	x_4	0	1	0	1	0	4
$L_3^{(0)}$	x_5	1	2	0	0	1	9

- Na linha L_0 encontram-se os coeficientes da função objetivo.
- Nas linhas L_i, $i = 1, \ldots, 3$, encontram-se os coeficientes das restrições.
- O super-índice entre parênteses (k) das linhas indica que as mesmas são as linhas obtidas após a k-ésima iteração do simplex.
  - (0) indica que estas são as linhas do quadro inicial.
- O vetor **b** contém as *constantes* (termos independentes) das restrições, bem como da função objetivo reescrita.

Solução básica viável inicial

$$\begin{aligned} x_3 &= 3 & x_1 &= 0 \\ x_4 &= 4 & x_2 &= 0 \\ x_5 &= 9 & Z &= 0 \end{aligned}$$

Algoritmo

1. A solução já é a ótima? Se sim, o problema encontra-se resolvido, e o algoritmo se encerra nesta etapa.
   - Este é um problema de *maximização*. A solução será ótima se *não houver coeficientes negativos* na linha L_0 da função objetivo.
   - Caso haja – este é o caso do exemplo – é preciso passar à etapa seguinte, *iterativa*.
2. As *variáveis de folga* formam uma *base* do $\mathbb{R}^m$ (m é o número de restrições), pois a matriz $m \times m$ formada pelas linhas L_i, $i = 1, \ldots, m$ e respectivas colunas de tais variáveis é uma *matriz identidade*, portanto com determinante diferente de 0.

- No quadro inicial, portanto, as *variáveis de folga* são chamadas de *básicas* (representadas na coluna à esquerda no mesmo), e as *variáveis de decisão* originais do problema, *não básicas*.
- Esta etapa do algoritmo consiste em *colocar na base* uma variável de decisão, retirando da mesma uma das variáveis básicas (deve ser repetida até que a condição da etapa 1 seja satisfeita)

Etapas do passo 2

1. Identificar quem entrará na base (*condição de otimalidade*):

   Regra de Dantzig: Procura-se, na linha L_0, qual o coeficiente negativo de *maior valor absoluto* (i.é., de menor valor). A variável associada a ele é a que entrará na base.

   - No exemplo, entrará na base x_1, pois $|-5| > |-2|$. A coluna em destaque é a *coluna pivô* da iteração.

		$\downarrow x_1$	x_2	x_3	x_4	x_5	**b**
$L_0^{(0)}$	Z	-5	-2	0	0	0	0
$L_1^{(0)}$	x_3	1	0	1	0	0	3
$L_2^{(0)}$	x_4	0	1	0	1	0	4
$L_3^{(0)}$	x_5	1	2	0	0	1	9

2. A variável básica que *sairá da base* é aquela cuja divisão da constante b_i, $i = 1, \ldots, m$ (a linha L_0 da função objetivo nunca é considerada) pelo coeficiente correspondente c_{ij} da coluna pivô seja o *menor de todos* – apenas *divisões não-negativas* e *finitas* são consideradas. Esta é a *Condição de viabilidade*.

   - No caso, temos $m = 3$, $j = 1$ (selecionou-se x_1 para deixar a base) e as divisões

$$\frac{b_1}{c_{11}} = \frac{3}{1} = 3 \qquad \frac{b_2}{c_{21}} = \frac{4}{0} = \infty \text{ (ignora-se)} \qquad \frac{b_3}{c_{31}} = \frac{9}{1} = 9$$

   - Portanto, x_3 (associada a linha L_1) *deixará a base* e a linha L_1 passa a ser a *linha pivô* desta iteração – razão mínima não-negativa nesta linha.

		$\downarrow x_1$	x_2	x_3	x_4	x_5	**b**
$L_0^{(0)}$	Z	-5	-2	0	0	0	0
$L_1^{(0)}$	$\leftarrow x_3$	*1*	0	1	0	0	3
$L_2^{(0)}$	x_4	0	1	0	1	0	4
$L_3^{(0)}$	x_5	1	2	0	0	1	9

- O elemento $c_{11} = 1$, dado pelo cruzamento das linhas e colunas pivô, é o *número pivô* da iteração.

3. Redefine-se a linha pivô, dividindo-se a mesma pelo número pivô.

   - No caso,

   $$L_1^{(1)} = \frac{L_1^{(0)}}{c_{11}} = \frac{L_1^{(0)}}{1}$$

   - Note que agora x_1 faz parte da base, e x_3 passou a ser não-básica.

		x_1	x_2	x_3	x_4	x_5	**b**
$L_0^{(0)}$	Z	-5	-2	0	0	0	0
$L_1^{(1)}$	x_1	1	0	1	0	0	3
$L_2^{(0)}$	x_4	0	1	0	1	0	4
$L_3^{(0)}$	x_5	1	2	0	0	1	9

   - Detalhamento:

	1	0	1	0	0	3	$L_1^{(0)}$
$\div 1$:	*1*	*0*	*1*	*0*	*0*	*3*	$L_1^{(1)}$

4. As demais linhas (incluindo a da função objetivo) são também redefinidas:

   $$L_k^{(1)} = L_k^{(0)} - c_{kj}\, L_i^{(1)},\ k = 0, \ldots, m,\ k \neq i,$$

   onde i e j são os índices da (nova) linha pivô e coluna pivô, respectivamente.

   - Linha 0 (função objetivo): $L_0^{(1)} = L_0^{(0)} - (-5)\, L_1^{(1)}$

		x_1	x_2	x_3	x_4	x_5	**b**
$L_0^{(1)}$	Z	0	-2	5	0	0	15
$L_1^{(1)}$	x_1	1	0	1	0	0	3
$L_2^{(0)}$	x_4	0	1	0	1	0	4
$L_3^{(0)}$	x_5	1	2	0	0	1	9

   - Detalhamento:

	1	0	1	0	0	3	$L_1^{(1)}$
$\times 5$:	5	0	5	0	0	15	
	-5	-2	0	0	0	0	$L_0^{(0)}$
	0	-2	*5*	*0*	*0*	*15*	$L_0^{(1)}$

- Linha 2: $L_2^{(1)} = L_2^{(0)} - 0\, L_1^{(1)} = L_2^{(0)}$ (inalterada)

		x_1	x_2	x_3	x_4	x_5	**b**
$L_0^{(1)}$	Z	0	−2	5	0	0	15
$L_1^{(1)}$	x_1	1	0	1	0	0	3
$L_2^{(1)}$	x_4	0	1	0	1	0	4
$L_3^{(0)}$	x_5	1	2	0	0	1	9

- Linha 3: $L_3^{(1)} = L_3^{(0)} - 1\, L_1^{(1)}$

		x_1	x_2	x_3	x_4	x_5	**b**
$L_0^{(1)}$	Z	0	−2	5	0	0	15
$L_1^{(1)}$	x_1	1	0	1	0	0	3
$L_2^{(1)}$	x_4	0	1	0	1	0	4
$L_3^{(1)}$	x_5	0	2	−1	0	1	6

- Detalhamento:

	1	0	1	0	0	3	$L_1^{(1)}$
$\times(-1)$:	−1	0	−1	0	0	−3	
	1	2	0	0	1	9	$L_3^{(0)}$
	0	*2*	−1	*0*	*1*	*6*	$L_0^{(1)}$

- A primeira iteração está concluída.

Solução básica viável após iteração 1

$$x_1 = 3 \qquad x_2 = 0$$
$$x_4 = 4 \qquad x_3 = 0$$
$$x_5 = 6 \qquad Z = 15$$

Nova iteração do passo 2

- Como se pode observar na tabela anterior, ainda há um coeficiente negativo na linha L_0.
- Portanto, repete-se o passo 2.
  - Agora x_2 entrará na base, e x_5 sairá. Portanto, o número pivô é $C_{23} = 2$.

		x_1	x_2	x_3	x_4	x_5	**b**
$L_0^{(2)}$	Z	0	0	4	0	1	21
$L_1^{(2)}$	x_1	1	0	1	0	0	3
$L_2^{(2)}$	x_4	0	0	1/2	1	−1/2	1
$L_3^{(2)}$	x_2	0	1	−1/2	0	1/2	3

Solução básica viável após iteração 2 (solução ótima)

$$x_1 = 3 \qquad x_3 = 0$$
$$x_4 = 1 \qquad x_5 = 0$$
$$x_2 = 3 \qquad Z = 21$$

12.4 Situações especiais

1. Empate na entrada da base
Na condição de otimalidade, quando se busca a variável que entrará na base; se houver empate escolhe-se arbitrariamente qual deverá de fato entrar.

Única implicação: pode-se escolher um caminho mais longo ou mais curto – dependendo da escolha – para se chegar à solução ótima

Exemplo: problema envolvendo maximização da função objetivo

$$Z = 4x_1 + 4x_2 + 3x_3$$

Note que o *maior coeficiente* é 4, e está associado a *duas variáveis* (x_1 e x_2). Na 1a. iteração, deve-se escolher qual das duas entrará (aparecerão como -4 no quadro inicial).

2. Empate na saída da base
Na condição de viabilidade, quando se busca a variável que sairá na base, se houver empate em geral *também* se escolhe arbitrariamente qual deverá de fato sair.

Exemplo:
$\max Z = 5x_1 + 2x_2$, sujeito a

$$x_1 \leq 3$$
$$x_2 \leq 4$$
$$4x_1 + 3x_2 \leq 12$$
$$x_1 \geq 0,\ x_2 \geq 0$$

		x_1	x_2	x_3	x_4	x_5	**b**
$L_0^{(0)}$	Z	-5	-2	0	0	0	0
$L_1^{(0)}$	x_3	1	0	1	0	0	3
$L_2^{(0)}$	x_4	0	1	0	1	0	4
$L_3^{(0)}$	x_5	4	3	0	0	1	12

x_1 entrará na base. As candidatas a sair da base (menor razão não-negativa):

$$x_3 : \frac{b_1}{c_{11}} = \frac{3}{1} = 3 \qquad\qquad x_5 : \frac{b_3}{c_{31}} = \frac{12}{4} = 3$$

Escolhe-se, por exemplo, x_3 para deixar a base:

		x_1	$\downarrow x_2$	x_3	x_4	x_5	**b**
$L_0^{(1)}$	Z	0	-2	5	0	0	15
$L_1^{(1)}$	x_1	1	0	1	0	0	3
$L_2^{(1)}$	x_4	0	1	0	1	0	4
$L_3^{(1)}$	$\leftarrow x_5$	0	3	-4	0	1	0

Note que x_5 é nula, mesmo sendo variável básica. Isto ocorre devido à condição de empate e a solução viável encontrada é dita *degenerada*.

		x_1	x_2	x_3	x_4	x_5	**b**
$L_0^{(2)}$	Z	0	0	7/3	0	2/3	15
$L_1^{(2)}$	x_1	1	0	1	0	0	3
$L_2^{(2)}$	x_4	0	0	4/3	1	$-1/3$	4
$L_3^{(2)}$	x_2	0	1	$-4/3$	0	1/3	0

Pode ocorrer a *ciclagem* (ou *retorno cíclico*) – o valor da função objetivo não melhora, sendo possível que o método entre em uma sequência de iterações sem nunca melhorar tal valor e satisfazer a condição de otimalidade. Neste exemplo, esta última foi satisfeita (encontrou-se solução ótima).

Exemplo de caso em que ocorre ciclagem (Taha, 2008):

$$\max Z = \frac{3}{4}x_1 - 20x_2 + \frac{1}{2}x_3 - 6x_4$$

sujeito a

$$\begin{gathered}
\frac{1}{4}x_1 - 8x_2 - x_3 + 9x_4 \leq 0 \\
\frac{1}{2}x_1 - 12x_2 - \frac{1}{2}x_3 + 3x_4 \leq 0 \\
x_3 \leq 1 \\
x_1 \geq 0,\ x_2 \geq 0,\ x_3 \geq 0,\ x_4 \geq 0
\end{gathered}$$

- O sistema encontra-se na forma padrão.

- Na forma de equações:

$$\max Z(x_1,\, x_2,\, x_3,\, x_4,\, x_5,\, x_6,\, x_7) - \frac{3}{4}x_1 + 20x_2 - \frac{1}{2}x_3 + 6x_4 = 0$$

sujeito a

$$\frac{1}{4}x_1 - 8x_2 - x_3 + 9x_4 + x_5 = 0$$
$$\frac{1}{2}x_1 - 12x_2 - \frac{1}{2}x_3 + 3x_4 + x_6 = 0$$
$$x_3 + x_7 = 1$$
$$x_1 \geq 0,\, x_2 \geq 0,\, x_3 \geq 0,\, x_4 \geq 0,\, x_5 \geq 0,\, x_6 \geq 0,\, x_7 \geq 0$$

		$\downarrow x_1$	x_2	x_3	x_4	x_5	x_6	x_7	**b**
$L_0^{(0)}$	Z	$-3/4$	20	$-1/2$	6	0	0	0	0
$L_1^{(0)}$	$\leftarrow x_5$	1/4	-8	-1	9	1	0	0	0
$L_2^{(0)}$	x_6	1/2	-12	$-1/2$	3	0	1	0	0
$L_3^{(0)}$	x_7	0	0	1	0	0	0	1	1

		x_1	$\downarrow x_2$	x_3	x_4	x_5	x_6	x_7	**b**
$L_0^{(1)}$	Z	0	-4	$-7/2$	33	3	0	0	0
$L_1^{(1)}$	x_1	1	-32	-4	36	4	0	0	0
$L_2^{(1)}$	$\leftarrow x_6$	0	4	3/2	-15	-2	1	0	0
$L_3^{(1)}$	x_7	0	0	1	0	0	0	1	1

		x_1	x_2	$\downarrow x_3$	x_4	x_5	x_6	x_7	**b**
$L_0^{(2)}$	Z	0	0	-2	18	1	1	0	0
$L_1^{(2)}$	$\leftarrow x_1$	1	0	8	-84	-12	8	0	0
$L_2^{(2)}$	x_2	0	1	3/8	$-15/4$	$-1/2$	1/4	0	0
$L_3^{(2)}$	x_7	0	0	1	0	0	0	1	1

		x_1	x_2	x_3	$\downarrow x_4$	x_5	x_6	x_7	**b**
$L_0^{(3)}$	Z	1/4	0	0	-3	-2	3	0	0
$L_1^{(3)}$	x_3	1/8	0	1	$-21/2$	$-3/2$	1	0	0
$L_2^{(3)}$	$\leftarrow x_2$	$-3/64$	1	0	3/16	1/16	$-1/8$	0	0
$L_3^{(3)}$	x_7	$-1/8$	0	0	21/2	3/2	-1	1	1

		x_1	x_2	x_3	x_4	$\downarrow x_5$	x_6	x_7	**b**
$L_0^{(4)}$	Z	$-1/2$	16	0	0	-1	1	0	0
$L_1^{(4)}$	$\leftarrow x_3$	$-5/2$	56	1	0	2	-6	0	0
$L_2^{(4)}$	x_4	$-1/4$	16/3	0	1	1/3	$-2/3$	0	0
$L_3^{(4)}$	x_7	5/2	-56	0	0	-2	6	1	1

		x_1	x_2	x_3	x_4	x_5	$\downarrow x_6$	x_7	**b**
$L_0^{(5)}$	Z	$-7/4$	44	$1/2$	0	0	-2	0	0
$L_1^{(5)}$	x_5	$-5/4$	28	$1/2$	0	1	-3	0	0
$L_2^{(5)}$	$\leftarrow x_4$	$1/6$	-4	$-1/6$	1	0	$1/3$	0	0
$L_3^{(5)}$	x_7	0	0	1	0	0	0	1	1

		$\downarrow x_1$	x_2	x_3	x_4	x_5	x_6	x_7	**b**
$L_0^{(6)}$	Z	$-3/4$	20	$-1/2$	6	0	0	0	0
$L_1^{(6)}$	$\leftarrow x_5$	$1/4$	-8	-1	9	1	0	0	0
$L_2^{(6)}$	x_6	$1/2$	-12	$-1/2$	3	0	1	0	0
$L_3^{(6)}$	x_7	0	0	1	0	0	0	1	1

Tal quadro é exatamente igual ao inicial: ao se prosseguir com o algoritmo, a mesma sequência de quadros se repetirá sem melhoria do valor da função objetivo (*laço infinito*).

3. Soluções múltiplas

Modelo de PL apresenta mais de uma solução ótima.

Exemplo:
$\max Z = 2x_1 + 4x_2$, sujeito a

$$x1 + 2x_2 \leq 5$$
$$x_1 + x_2 \leq 4$$
$$x_1 \geq 0,\ x_2 \geq 0$$

		x_1	$\downarrow x_2$	x_3	x_4	**b**
$L_0^{(0)}$	Z	-2	-4	0	0	0
$L_1^{(0)}$	$\leftarrow x_3$	1	2	1	0	5
$L_2^{(0)}$	x_4	1	1	0	1	4

		$\downarrow x_1$	x_2	x_3	x_4	**b**
$L_0^{(1)}$	Z	0	0	2	0	10
$L_1^{(1)}$	x_2	$1/2$	1	$1/2$	0	$5/2$
$L_2^{(1)}$	$\leftarrow x_4$	$1/2$	0	$-1/2$	1	$3/2$

A solução é ótima, e tem-se $x_1 = 0$, $x_2 = 5/2$ e $Z = 10$. O coeficiente de x_1 (não-básica) em L_0 é zero, indicando que a mesma pode entrar na base, de modo que o valor da função objetivo fique inalterado – apenas os valores das variáveis se alteram.

		x_1	x_2	x_3	x_4	**b**
$L_0^{(2)}$	Z	0	0	2	0	10
$L_1^{(2)}$	x_2	0	1	1	-1	1
$L_2^{(2)}$	x_1	1	0	-1	2	3

Forçando-se a saída de x_4 da base, inserindo-se x_1 em seu lugar, tem-se nova solução em $x_1 = 3$, $x_2 = 1$ e $Z = 10$.

Qualquer *combinação convexa* desta solução e da anterior também será uma solução ótima. Graficamente: segmento de reta entre os pontos $(0, 5/2)$ e $(3, 1)$

4. Função objetivo ilimitada

- Outro resultado possível é aquele no qual nenhuma variável se qualifica para ser a variável básica a deixar a base.
- Este resultado ocorre quando a variável que entra na base pode ser aumentada indefinidamente sem dar valores negativos a qualquer das variáveis básicas atuais. Na forma tabular, isso significa que todos os coeficientes da coluna pivô (excluindo-se a linha L_0) são negativos ou zero.
- Neste caso, as restrições não impedem que o valor da função objetivo cresça indefinidamente.
- Isto ocorre, provavelmente, porque o modelo foi mal formulado, seja por omitir restrições relevantes, seja por declará-las de modo incorreto.

Exemplo:
$\max Z = 2x_1 + x_2$ sujeito a

$$x1 - x_2 \leq 10$$
$$2x_1 \leq 40$$
$$x_1 \geq 0,\ x_2 \geq 0$$

		$\downarrow x_1$	x_2	x_3	x_4	**b**
$L_0^{(0)}$	Z	-2	-1	0	0	0
$L_1^{(0)}$	$\leftarrow x_3$	1	-1	1	0	10
$L_2^{(0)}$	x_4	2	0	0	1	40

Todos os coeficientes das restrições sob x_2 são todos negativos ou zero. Note que x_2 pode ser aumentada indefinidamente sem desobedecer nenhuma das restrições. Embora x_1 entre na base pelo critério de otimalidade, note que caso x_2 entrasse na base, nem x_3 nem x_4 poderia sair da mesma pelo critério de viabilidade.

		x_1	$\downarrow x_2$	x_3	x_4	**b**
$L_0^{(1)}$	Z	0	-3	2	0	20
$L_1^{(1)}$	x_1	1	-1	1	0	10
$L_2^{(1)}$	$\leftarrow x_4$	0	2	-2	1	20

		x_1	x_2	$\downarrow x_3$	x_4	**b**
$L_0^{(2)}$	Z	0	0	-1	$3/2$	50
$L_1^{(2)}$	$\leftarrow x_1$	0	0	0	$1/2$	30
$L_2^{(2)}$	x_2	0	1	-1	$1/2$	10

Como consequência do observado para x_2 no quadro inicial, agora x_3 possui as mesmas características, sendo a única variável candidata a entrar na base: nem x_1 nem x_2 podem sair.

Obs.: É suficiente a análise do quadro inicial para concluir que a solução é ilimitada.

5. Problema de minimização

Quando a função objetivo tiver de ser minimizada pode-se fazer duas coisas, a saber:

- *Inverter* o teste de otimização e o critério de entrada na base. Assim, se todos os coeficientes da linha L_0 forem negativos, ou nulos, a solução é ótima. Caso contrário, escolha a variável x_j para entrar que apresente o *maior valor*.

- Transformar o problema de minimização em um problema de maximização. Sabe-se que achar o mínimo de uma função é equivalente a encontrar o máximo do simétrico desta função.

  - *Exemplo:* $\min W = 2x_1 + 3x_2 \Leftrightarrow \max Z = -2x_1 - 3x_2$. Depois, na solução final, fazer $W = -Z$.

- Um aspecto de problemas de minimização é que em geral as restrições contém desigualdades do tipo $\geq$ (maior-ou-igual).

- Os exemplos abordados com o simplex são todos problemas de *maximização*, onde as restrições são do tipo

$$c_{i1}x_1 + c_{i2}x_2 + \cdots + c_{in}x_n \leq b_i,$$

  onde a constante do lado direito b_i é tal que $b_i \geq 0$ (*forma padrão*).

  - Sob esta forma, as variáveis acrescentadas são de folga e o problema pode ser resolvido como visto.
  - Problemas com restrições envolvendo a desigualdade $\geq$ ou mesmo igualdade ($=$) exigem etapas adicionais.

Lado direito negativo

- Para que a resolução vista possa ser empregada, é preciso que o lado direito das restrições seja não-negativo.
- Por exemplo, a restrição

$$-x_1 + x_2 \leq -3$$

  leva ao surgimento da equação

$$-x_1 + x_2 + x_3 = -3,\ x_3 \geq 0\,.$$

- O problema é resolvido fazendo-se a multiplicação de ambos os lados por -1:

$$x_1 - x_2 - x_3 = 3\,.$$

- Neste caso, o coeficiente de x_3 é -1. Logo, esta não pode entrar na base (na equação reescrita é variável *de excesso*). Isto equivale a partirmos da inequação

$$x_1 - x_2 \geq 3\,.$$

  (nada mais do que a inequação original multiplicada por -1 – a desigualdade é invertida).

Solução inicial artificial

- Para se iniciar a resolução de problemas de PL "mal comportados" (com restrições do tipo $\geq$ e $=$) deve se adotar *variáveis artificiais*
- Estas desempenham o papel de folgas na primeira iteração.
- São descartadas em iterações posteriores.
- Dois métodos:
  - Método do M-grande;
  - Método das duas fases.

Considere o seguinte problema:

$$\max Z = 5x_1 + 2x_2 \qquad \text{sujeito a:}$$

$$x_1 \leq 3$$
$$x_2 \leq 4$$
$$x_1 + 2x_2 \geq 9$$
$$x_1 \geq 0,\ x_2 \geq 0$$

$\max Z$ tal que $Z - 5x_1 - 2x_2 = 0$ sujeito a:

$$\begin{aligned} x_1 + x_3 &= 3 \\ x_2 + x_4 &= 4 \\ x_1 + 2x_2 - x_5 &= 9 \\ x_1, \ldots, x_5 &\geq 0 \end{aligned}$$

- Variáveis não-básicas: $x_1 = x_2 = 0$.
- Variáveis básicas: $x_3 = 3$, $x_4 = 4$, $x_5 = -9$.
- *Não é solução viável*, pois x_5 deveria ser não-negativa.

Pode-se acrescentar uma *variável artificial* na equação problemática. Esta variável ocupará o lugar de x_5 na base inicial. Logo:

$\max Z$ tal que $Z - 5x_1 - 2x_2 = 0$ sujeito a:

$$\begin{aligned} x_1 + x_3 &= 3 \\ x_2 + x_4 &= 4 \\ x_1 + 2x_2 - x_5 + t_1 &= 9 \\ x_1, \ldots, x_5, t_1 &\geq 0 \end{aligned}$$

- Variáveis não-básicas: $x_1 = x_2 = x_5 = 0$.
- Variáveis básicas: $x_3 = 3$, $x_4 = 4$, $t_1 = 9$.

- Os sistemas somente se equivalem se a variável artificial t_1 for nula.
- As variáveis artificiais não têm significado no problema real, mas permitem a inicialização do processo de maneira automática.

Método do M-grande

- Como as variáveis artificiais não fazem parte do modelo, estas sofrerão *punições* na função objetivo:
  - As punições visam *zerar* tais variáveis na solução ótima.
  - Isto sempre ocorrerá se houver solução viável.

  Regra de penalização das variáveis artificiais

  Dado $M > 0$, valor suficientemente alto ($M \to \infty$), o coeficiente na função objetivo representa uma punição adequada quando igual a:

  - $-M$, em problemas de maximização;
  - M, em problemas de minimização.

- O valor de M deve ser suficientemente grande *em relação aos demais coeficientes da função objetivo*, de modo a forçar as variáveis a ter valor nulo no ótimo.

Retornando ao exemplo anterior:

$\max Z = 5x_1 + 2x_2 - Mt_1$
sujeito a:

$$\begin{aligned} x_1 + x_3 &= 3 \\ x_2 + x_4 &= 4 \\ x_1 + 2x_2 - x_5 + t_1 &= 9 \\ x_1, \ldots, x_5, t_1 &\geq 0 \end{aligned}$$

$\max Z$ tal que $Z - 5x_1 - 2x_2 + 100t_1 = 0$
sujeito a:

$$\begin{aligned} x_1 + x_3 &= 3 \\ x_2 + x_4 &= 4 \\ x_1 + 2x_2 - x_5 + t_1 &= 9 \\ x_1, \ldots, x_5, t_1 &\geq 0 \end{aligned}$$

- Como os coeficientes na função objetivo são 5 e 2, parece razoável definir $M = 100$.
- Quadro inicial:

		x_1	x_2	x_3	x_4	x_5	t_1	**b**
$L_0^{(0)}$	Z	-5	-2	0	0	0	100	0
$L_1^{(0)}$	x_3	1	0	1	0	0	0	3
$L_2^{(0)}$	x_4	0	1	0	1	0	0	4
$L_3^{(0)}$	t_1	1	2	0	0	-1	1	9

- A linha L_0 é *inconsistente* com o resto da tabela, uma vez que $t_1 = 9$ (t_1 está na base) e portanto $Z = -900$.
- Para empregar a resolução do simplex, é preciso que os coeficientes das variáveis básicas na linha L_0 sejam todos nulos. Este ajuste inicial pode ser feito redefinindo-se esta linha como sendo a soma dela mesma com a linha associada a t_1 multiplicada por $-M$:

$$L_0^{(0)} = L_0^{(0)} - ML_3^{(0)} = L_0^{(0)} - 100L_3^{(0)}$$

- O quadro inicial então se torna

		x_1	$\downarrow x_2$	x_3	x_4	x_5	t_1	**b**
$L_0^{(0)}$	Z	-105	-202	0	0	100	0	-900
$L_1^{(0)}$	x_3	1	0	1	0	0	0	3
$L_2^{(0)}$	$\leftarrow x_4$	0	1	0	1	0	0	4
$L_3^{(0)}$	t_1	1	2	0	0	-1	1	9

- Detalhamento:

	1	2	0	0	-1	1	9	$L_3^{(0)}$
$\times(-100)$:	-100	-200	0	0	100	-100	-900	
	-5	-2	0	0	0	100	0	$L_0^{(0)}$ original
	-105	-202	*0*	*0*	*100*	*0*	-900	$L_0^{(0)}$ ajustada

Solução básica viável inicial

$$\begin{aligned} x_3 &= 3 & x_1 &= 0 \\ x_4 &= 4 & x_2 &= 0 \\ t_1 &= 9 & x_5 &= 0 \\ & & Z &= -900 \end{aligned}$$

		$\downarrow x_1$	x_2	x_3	x_4	x_5	t_1	**b**
$L_0^{(1)}$	Z	-105	0	0	202	100	0	-92
$L_1^{(1)}$	x_3	1	0	1	0	0	0	3
$L_2^{(1)}$	x_2	0	1	0	1	0	0	4
$L_3^{(1)}$	$\leftarrow t_1$	1	0	0	-2	-1	1	1

		x_1	x_2	x_3	$\downarrow x_4$	x_5	t_1	**b**
$L_0^{(2)}$	Z	0	0	0	-8	-5	105	13
$L_1^{(2)}$	$\leftarrow x_3$	0	0	1	2	1	-1	2
$L_2^{(2)}$	x_2	0	1	0	1	0	0	4
$L_3^{(2)}$	x_1	1	0	0	-2	-1	1	1

		x_1	x_2	x_3	x_4	$\downarrow x_5$	t_1	**b**
$L_0^{(3)}$	Z	0	0	4	0	-1	101	21
$L_1^{(3)}$	$\leftarrow x_4$	0	0	1/2	1	1/2	$-1/2$	1
$L_2^{(3)}$	x_2	0	1	$-1/2$	0	$-1/2$	1/2	3
$L_3^{(3)}$	x_1	1	0	1	0	0	0	3

		x_1	x_2	x_3	x_4	x_5	t_1	**b**
$L_0^{(4)}$	Z	0	0	5	2	0	100	23
$L_1^{(4)}$	x_5	0	0	1	2	1	-1	2
$L_2^{(4)}$	x_2	0	1	0	1	0	0	4
$L_3^{(4)}$	x_1	1	0	1	0	0	0	3

O método do M-grande pode resultar em *erros de arredondamento* durante a fase de punição do valor M – definido sempre de forma relativamente arbitrária.

- Na prática, usa-se o *método das duas fases*, desenvolvido posteriormente.
- O método das duas fases está implementado em praticamente todos os pacotes comerciais para resolução de problemas de PL.

Método das duas fases

- Alternativa ao método do M-grande, contornando a dificuldade do mesmo por eliminar o uso da constante M.

- Inicialmente, variáveis artificiais são introduzidas ao modelo, como no método anterior.
- Como o nome sugere, há *duas fases* ou etapas:
  - *Fase I*: consiste em resolver um *problema de minimização* cuja função objetivo é dada pelo *somatório das variáveis artificiais*. Espera-se que o mínimo seja *zero* (requisito para Fase II).

    Observação

    Caso o valor mínimo da soma seja *diferente de zero*, o problema *não tem nenhuma solução viável*, o que *encerra o processo* – variável artificial positiva indica que restrição original não foi satisfeita.
  - *Fase II*: Usa-se a solução da Fase I como solução básica viável inicial para o problema original.

Seja o problema:

$$\max Z = 4x_1 + x_2$$

sujeito a

$$\begin{aligned} 3x_1 + x_2 &= 3 \\ 4x_1 + 3x_2 &\geq 6 \\ x1 + 2x_2 &\leq 4 \\ x_1 \geq 0,\, x_2 &\geq 0 \end{aligned}$$

Variáveis de folga:

$$\max Z = 4x_1 + x_2$$

sujeito a

$$\begin{aligned} 3x_1 + x_2 &= 3 \\ 4x_1 + 3x_2 - x_3 &= 6 \\ x1 + 2x_2 + x_4 &= 4 \\ x_1 \geq 0,\, \ldots,\, x_4 &\geq 0 \end{aligned}$$

Como não há uma solução básica viável são inseridas as variáveis artificiais t_1 e t_2 às restrições envolvendo $\geq$ e $=$:

$$\max Z = 4x_1 + x_2$$

sujeito a

$$\begin{aligned} 3x_1 + x_2 + t_1 &= 3 \\ 4x_1 + 3x_2 - x_3 + t_2 &= 6 \\ x1 + 2x_2 + x_4 &= 4 \\ x_1 \geq 0,\, \ldots,\, x_4 \geq 0,\, t_1 \geq 0,\, t_2 &\geq 0\,. \end{aligned}$$

A função objetivo inicial será portanto

$$W = t_1 + t_2$$

Fase I

$$\min W = t_1 + t_2$$

sujeito a

$$3x_1 + x_2 + t_1 = 3$$
$$4x_1 + 3x_2 - x_3 + t_2 = 6$$
$$x1 + 2x_2 + x_4 = 4$$
$$x_1 \geq 0, \ldots, x_4 \geq 0, t_1 \geq 0, t_2 \geq 0\,.$$

		x_1	x_2	x_3	x_4	t_1	t_2	**b**
$L_0^{(0)}$	$-W$	0	0	0	0	1	1	0
$L_1^{(0)}$	t_1	3	1	0	0	1	0	3
$L_2^{(0)}$	t_2	4	3	-1	0	0	1	6
$L_3^{(0)}$	x_4	1	2	0	1	0	0	4

Como a linha L_0 é *incompatível* com o sistema – possui coeficientes para variáveis t_1 e t_2 da base – faz-se $L_0^{(0)} = L_0^{(0)} - L_1^{(0)} - L_2^{(0)}$:

		$\downarrow x_1$	x_2	x_3	x_4	t_1	t_2	**b**
$L_0^{(0)}$	$-W$	-7	-4	1	0	0	0	-9
$L_1^{(0)}$	$\leftarrow t_1$	3	1	0	0	1	0	3
$L_2^{(0)}$	t_2	4	3	-1	0	0	1	6
$L_3^{(0)}$	x_4	1	2	0	1	0	0	4

Detalhamento:

	3	1	0	0	1	0	3	$L_1^{(0)}$
	4	3	-1	0	0	1	6	$L_2^{(0)}$
$L_1^{(0)} \times (-1)$:	-3	-1	0	0	-1	0	-3	
$L_2^{(0)} \times (-1)$:	-4	-3	1	0	0	-1	-6	
	0	0	0	0	1	1	0	$L_0^{(0)}$ original
	-7	-4	1	*0*	*0*	*0*	-9	$L_0^{(0)}$ redefinido

		x_1	$\downarrow x_2$	x_3	x_4	t_1	t_2	**b**
$L_0^{(1)}$	$-W$	0	$-5/3$	1	0	$7/3$	0	-2
$L_1^{(1)}$	x_1	1	$1/3$	0	0	$1/3$	0	1
$L_2^{(1)}$	$\leftarrow t_2$	0	$5/3$	-1	0	$-4/3$	1	2
$L_3^{(1)}$	x_4	0	$5/3$	0	1	$-1/3$	0	3

		x_1	x_2	x_3	x_4	t_1	t_2	**b**
$L_0^{(2)}$	$-W$	0	0	0	0	1	1	0
$L_1^{(2)}$	x_1	1	0	$1/5$	0	$3/5$	$-1/5$	$3/5$
$L_2^{(2)}$	x_2	0	1	$-3/5$	0	$-4/5$	$3/5$	$6/5$
$L_3^{(2)}$	x_4	0	0	1	1	1	1	1

- No quadro (2), $-W = 0$ (logo, $W = 0$), e não há coeficientes negativos para as variáveis fora da base. Portanto, a fase I está concluída.
- A solução básica viável é dada por:

$$x_1 = 3/5 \qquad x_2 = 6/5 \qquad x_4 = 1$$

  (apenas variáveis básicas). As demais, bem como a função objetivo W são nulas.
- Neste momento, pode-se eliminar totalmente as colunas das variáveis artificiais t_1 e t_2 e passar à fase II.
  - Eliminam-se também as linhas, quando for o caso (variáveis artificiais fora da base).

Fase II

Após eliminar as colunas das variáveis artificiais, reescreve-se o problema original como:

$$\max Z = 4x_1 + x_2$$

sujeito a

$$\begin{aligned} x_1 + 1/5x_3 &= 3/5 \\ x_2 - 3/5x_3 &= 6/5 \\ x_3 + x_4 &= 1 \\ x_1 \geq 0, \ldots, x_4 &\geq 0\,. \end{aligned}$$

Quadro inicial desta fase – note que é preciso adequar a linha L_0 antes de prosseguir para o algoritmo do simplex:

		x_1	x_2	x_3	x_4	**b**
$L_0^{(0)}$	Z	-4	-1	0	0	0
$L_1^{(0)}$	x_1	1	0	1/5	0	3/5
$L_2^{(0)}$	x_2	0	1	$-3/5$	0	6/5
$L_3^{(0)}$	x_4	0	0	1	1	1

12.5 Exercícios

1. Determine a solução ótima a partir do quadro anterior (Fase II).

2. Usando simplex, determine a solução do problema

$$\min f(x_1, x_2) = 65x_1 + 30x_2$$

sujeito a

$$\begin{aligned} 2x_1 + 3x_2 &\geq 7 \\ 3x_1 + 2x_2 &\geq 9 \\ x_1 &\geq 1 \\ x_1 \geq 0,\, x_2 &\geq 0\,. \end{aligned}$$

3. A fabricante Wills produz 2 diferentes modelos de carro elétrico, um SUV e um sedã. A demanda de mercado mensal é de pelo menos 100 unidades do SUV e de 50 do sedã. No caso do sedã, a venda não ultrapassa 200 unidades/mês. O lucro por venda é de \$5000 por unidade para o SUV e \$3000 para cada sedã. A disponibilidade de mão-de-obra é de 8000 homens-hora por mês, sendo que o SUV consome 40 homens-hora em sua produção e o sedã consome 20 homens-hora.

   (a) Faça a modelagem do problema, visando maximizar o lucro através da produção de ambos os modelos.

   (b) Resolva o problema, usando o algoritmo simplex: encontre a solução, ou as soluções do problema (caso exista mais de uma); ou responda se a função objetiva é ilimitada, quando for o caso.

4. Resolva o seguinte problema de programação linear usando o método simplex:

$$\min z = x_1 - 2x_2 + x_3$$

sujeito a

$$\begin{aligned} x_1 + 2x_2 - 2x_3 &\leq 4 \\ 2x_1 - 2x_3 &\leq 6 \\ 2x_1 - x_2 + 2x_3 &\leq 2 \\ x_1,\, x_2,\, x_3 &\geq 0\,. \end{aligned}$$

5. Usando simplex, determine a solução do problema:

$$\max z = 2x_1 + 3x_2$$

sujeito a

$$\begin{aligned} x_1 + 3x_2 &\leq 6 \\ 3x_1 + 2x_2 &\leq 6 \\ x_1, x_2 &\geq 0\,. \end{aligned}$$

6. Maximize $z = 4x_1 + 5x_2 + 9x_3 + 11x_4$ sujeito a:

$$\begin{gathered} x_1 + x_2 + x_3 + x_4 \leq 15 \\ 7x_1 + 5x_2 + 3x_3 + 2x_4 \leq 120 \\ 3x_1 + 5x_2 + 10x_3 + 15x_4 \leq 100 \\ x_1 \geq 0,\, x_2 \geq 0,\, x_3 \geq 0,\, x_4 \geq 0 \end{gathered}$$

7. Determine todas as soluções ótimas do problema

$$\min z = -x_1 - x_2$$

sujeito a

$$\begin{gathered} x_1 + x_2 \leq 6 \\ x_1 - x_2 \leq 4 \\ -x_1 + x_2 \leq 4 \\ x_1,\, x_2 \geq 0\,. \end{gathered}$$

8. Determine, caso haja solução(ões), quais os valores das variáveis x_1 e x_2 que maximizam a função $Z = 2x_1 + 2x_2$ sujeita às restrições:

$$\begin{gathered} x_1 + x_2 \geq 200 \\ -x_1 + 2x_2 \leq 200 \end{gathered}$$

9. Suponha que uma dieta alimentar esteja restrita a leite desnatado, carne magra bovina, carne de peixe e uma salada. A tabela abaixo expressa os requisitos nutricionais em termos das vitaminas A, C e D, dados por suas quantidades mínimas, bem como a quantidade de tais nutrientes presente em uma porção de cada alimento (em peso ou volume).

Vitamina	**A**	**C**	**D**	**Custo**
Leite (L)	2 mg	50 mg	80 mg	R$ 2
Carne (kg)	2 mg	20 mg	70 mg	R$ 4
Peixe (kg)	10 mg	10 mg	10 mg	R$ 1,50
Salada (100g)	20 mg	30 mg	80 mg	R$ 1
Requisito nutricional mínimo	11 mg	70 mg	250 mg	

Tendo em mãos o custo de cada porção dos componentes da dieta, faça a modelagem do problema, visando atender os requisitos nutricionais e gastando-se o mínimo possível.

Em seguida, determine a solução ótima do mesmo, caso exista.

10. Considere o seguinte problema:

$$\max z = 3x_1 + 2x_2$$

sujeito a

$$\begin{aligned} 2x_1 + x_2 &\leq 2 \\ 3x_1 + 4x_2 &\geq 12 \\ x_1,\, x_2 &\geq 0\,. \end{aligned}$$

Usando o método das duas fases, verifique a inviabilidade da solução.

Referências

1. MARINS, F. A. S. *Introdução à pesquisa operacional*. São Paulo: Cultura Acadêmica, 2011.

2. TAHA, H. *Pesquisa operacional*. 8ª. ed. São Paulo: Prentice Hall, 2008.

Os materiais de parte desta seção foram gentilmente cedidos por Paulo H. R. Gabriel (FACOM/UFU)
Adaptações: Renato Pimentel, FACOM/UFU

13 Dual e sua relação com o primal

- *Modelo dual:* definido diretamente a partir do modelo original (ou *primal*) do problema de PL.
- Forte relação com o problema de origem:
  - *Solução ótima* de um problema fornece automaticamente a solução ótima do outro.

Vantagens

- Uma vantagem do uso do modelo dual está na possibilidade de se gerar um problema *menor*, cuja solução seja mais rápida/menos cara que no modelo original.
- Outra vantagem: transformar um problema de minimização num de maximização – o que permite aplicação direta do algoritmo simplex.

Forma de equações do modelo primal

A construção do *modelo dual* será baseada na chamada *forma de equações* (TAHA, 2008) do modelo original, usada para a resolução pelo algoritmo do simplex. Na *forma de equações*:

1. Todas as restrições técnicas – isto é, excluindo-se as de não-negatividade – são dadas como *equações*, com o *lado direito não negativo*.
2. Todas as variáveis são não-negativas.

Construção do modelo dual com base no primal

1. O dual de um problema de maximização (minimização) é um problema de minimização (maximização);
2. Uma *variável* y_i do dual é definida para cada restrição[9] do primal;
3. Uma *restrição* dual é definida para cada variável x_j primal;
4. Os coeficientes associados à variável x_j das restrições do modelo primal definirão os coeficientes da j-ésima restrição primal;
5. Os *coeficientes da função objetivo* do dual são dados pelas constantes (lado direito) das restrições do primal;

[9] Não se consideram as de não-negatividade

No caso de um problema de maximização – somente com restrições do tipo $\leq$ – temos:

- Primal:

$$\max Z = \sum_{j=1}^{n} c_j x_j$$

sujeito a

$$\sum_{j=1}^{n} a_{ij} x_j \leq b_i,\ (i = 1, \ldots, m)$$

$$x_j \geq 0$$

- Dual:

$$\min D = \sum_{i=1}^{m} b_i y_i$$

sujeito a

$$\sum_{i=1}^{m} a_{ji} y_i \geq c_j,\ (j = 1, \ldots, n)$$

$$y_i \geq 0$$

Exemplo

- Primal:

$$\max Z = 25x_1 + 20x_2$$

sujeito a

$$\begin{gathered} x_1 + x_2 \leq 50 \\ 2x_1 + x_2 \leq 80 \\ 2x_1 + 5x_2 \leq 220 \\ x_1 \geq 0,\ x_2 \geq 0\,. \end{gathered}$$

- Dual:

$$\min D = 50y_1 + 80y_2 + 220y_3$$

sujeito a

$$\begin{gathered} y_1 + 2y_2 + 2y_3 \geq 25 \\ y_1 + y_2 + 5y_3 \geq 20 \\ y_1 \geq 0,\ y_2 \geq 0,\ y_3 \geq 0\,. \end{gathered}$$

- Note pelo caso geral e exemplo vistos que o *sinal* de desigualdade das restrições duais está associado ao `tipo de otimização`: se o dual for de *minimização*, todas as restrições serão ($\geq$).
- Outro fato é que as variáveis duais y_i são não negativas, mas nem sempre isto ocorre.
- Casos mais gerais, onde no modelo primal há restrições ($\geq$) e ($=$), ou há *variáveis irrestritas* (podem assumir também valores negativos), levam a outras situações no dual.

13.1 Regras para construção do dual

1. *Restrições de sinal das variáveis duais*: de acordo com os coeficientes das *variáveis de folga/excesso* do primal.

   - Exemplo:

   $$\min Z = 15x_1 + 12x_2$$

   sujeito a

   $$\begin{aligned} x_1 + 2x_2 &\geq 3 \\ 2x_1 - 4x_2 &\leq 5 \\ x_1 \geq 0,\ x_2 &\geq 0\,. \end{aligned}$$

- Na forma de equações:

  $$\min Z = 15x_1 + 12x_2 + 0x_3 + 0x_4$$

  sujeito a

  $$\begin{aligned} x_1 + 2x_2 - x_3 + 0x_4 &= 3 \quad (y_1) \\ 2x_1 - 4x_2 + 0x_3 + x_4 &= 5 \quad (y_2) \\ x_i \geq 0,\ i &= 1, \ldots, 4. \end{aligned}$$

- Dual:

  $$\max D = 3y_1 + 5y_2$$

  sujeito a

  $$\begin{aligned} y_1 + 2y_2 &\leq 15 \\ 2y_1 - 4y_2 &\leq 12 \\ -1y_1 + 0y_2 &\leq 0 \\ 0y_1 + 1y_2 &\leq 0\,. \end{aligned}$$

As 2 últimas restrições duais estão associadas *às variáveis de folga* x_3 e x_4. Note que todas são do tipo ($\leq$) pois o dual é de maximização.

Reescrevendo as duas últimas restrições, temos:

$$\max D = 3y_1 + 5y_2$$

sujeito a

$$\begin{aligned} y_1 + 2y_2 &\leq 15 \\ 2y_1 - 4y_2 &\leq 12 \\ y_1 &\geq 0 \\ y_2 &\leq 0\,. \end{aligned}$$

Exercício

Verifique, para o exemplo de maximização visto anteriormente, que as restrições de não negatividade para y_1, y_2 e y_3 são coerentes com os coeficientes das variáveis de folga do problema.

2. *Restrição do tipo igualdade (=) no primal*: variável *irrestrita* no dual.

   - *Variáveis irrestritas: podem assumir qualquer valor real, mesmo valores negativos.*

   $$\max Z = 5x_1 + 12x_2 + 4x_3$$

   sujeito a

   $$\begin{gathered} x_1 + 2x_2 + x_3 \leq 10 \\ 2x_1 - x_2 + 3x_3 = 8 \\ x_1 \geq 0,\, x_2 \geq 0,\, x_3 \geq 0\,. \end{gathered}$$

- Na forma de equações:

  $$\max Z = 5x_1 + 12x_2 + 4x_3 + 0x_4$$

  sujeito a

  $$\begin{aligned} x_1 + 2x_2 + x_3 + x_4 &= 10 \quad (y_1) \\ 2x_1 - x_2 + 3x_3 + 0x_4 &= 8 \quad (y_2) \\ x_i \geq 0,\, i &= 1, \ldots, 4. \end{aligned}$$

- Dual:

  $$\min D = 10y_1 + 8y_2$$

  sujeito a

  $$\begin{aligned} y_1 + 2y_2 &\geq 5 \\ 2y_1 - y_2 &\geq 12 \\ y_1 + 3y_2 &\geq 4 \\ y_1 + 0y_2 &\geq 0\,. \end{aligned}$$

Da última restrição, obtém-se $y_1 \geq 0$. Não há restrições sobre y_2, portanto esta é irrestrita.

3. Variável irrestrita no primal: restrição associada no dual é de igualdade (=).

$$\max Z = 5x_1 + 6x_2$$

sujeito a

$$\begin{gathered} x_1 + 2x_2 = 5 \\ -x_1 + 5x_2 \geq 3 \\ 4x_1 + 7x_2 \leq 8 \\ x_1 \text{ irrestrita},\, x_2 \geq 0\,. \end{gathered}$$

- Uma situação não apresentada no modelo primal é a de variável irrestrita.
- Nesta situação, se x_i é irrestrita, então definem-se duas variáveis não-negativas, x_i^- e x_i^+, cuja *diferença* entre ambas resulta na irrestrita:

$$x_i = x_i^- - x_i^+$$

- Sendo assim:
  - Se $x_i \geq 0$, então $x_i^- \geq x_i^+ \geq 0$;
  - Se $x_i < 0$, então $x_i^+ > x_i^- \geq 0$.

- Logo, na forma de equações:

$$\max Z = 5x_1^- - 5x_1^+ + 6x_2$$

sujeito a

$$\begin{array}{ll} x_1^- - x_1^+ + 2x_2 = 5 & (y_1) \\ -x_1^- + x_1^+ + 5x_2 - x_3 = 3 & (y_2) \\ 4x_1^- - 4x_1^+ + 7x_2 + x_4 = 8 & (y_3) \\ x_1^- \geq 0,\ x_1^+ \geq 0, & \\ x_2 \geq 0,\ x_3 \geq 0,\ x_4 \geq 0\,. & \end{array}$$

- Dual:

$$\min D = 5y_1 + 3y_2 + 8y_3$$

sujeito a

$$\begin{array}{c} y_1 - y_2 + 4y_3 \geq 5 \\ -y_1 + y_2 - 4y_3 \geq -5 \\ 2y_1 + 5y_2 + 7y_3 \geq 6 \\ -y_2 + 0y_3 \geq 0 \\ 0y_2 + y_3 \geq 0 \end{array}$$

Das 2 primeiras restrições, obtém-se $y_1 - y_2 + 4y_3 = 5$ (basta multiplicar a segunda por -1).

Reescrevendo:

$$\min D = 5y_1 + 3y_2 + 8y_3$$

sujeito a

$$\begin{array}{c} y_1 - y_2 + 4y_3 = 5 \\ 2y_1 + 5y_2 + 7y_3 \geq 6 \\ y_1 \text{ irrestrita},\ y_2 \leq 0,\ y_3 \geq 0\,. \end{array}$$

Teoremas

Teorema I (Dualidade fraca)

Se ambos o primal e o dual possuem soluções viáveis, então $Z \leq D$ para qualquer solução viável do primal de maximização e qualquer solução viável do dual de minimização.

- Se o primal é de minimização, então o dual é de maximização e temos $Z \geq D$.

Teorema II (Dualidade forte)

Se ambos o primal e dual possuírem soluções viáveis tais que $Z = D$, então as mesmas constituem *soluções ótimas*

- Exemplo: primal

$$\max Z = 5x_1 + 2x_2$$

sujeito a

$$\begin{aligned} x_1 &\leq 3 \\ x_2 &\leq 4 \\ x_1 + 2x_2 &\leq 9 \\ x_1 \geq 0,\ x_2 &\geq 0\,. \end{aligned}$$

- Dual:

$$\min D = 3y_1 + 4y_2 + 9y_3$$

sujeito a

$$\begin{aligned} y_1 + y_3 &\geq 5 \\ y_2 + 2y_3 &\geq 2 \\ y_1 \geq 0,\ y_2 \geq 0,\ y_3 &\geq 0\,. \end{aligned}$$

Dadas duas soluções viáveis, $(x_1, x_2) = (2, 3)$ para o primal e $(y_1, y_2, y_3) = (3, 3, 2)$ para o dual, temos

$$\begin{aligned} Z &= 5(2) + 2(3) = 16 \\ D &= 3(3) + 4(3) + 9(2) = 39 \end{aligned}$$

- Temos, portanto $Z \leq D$.
- Considere agora o par de soluções viáveis $(x_1, x_2) = (3, 3)$ para o primal e $(y_1, y_2, y_3) = (4, 0, 1)$ para o dual:

$$\begin{aligned} Z &= 5(3) + 2(3) = 21 \\ D &= 3(4) + 4(0) + 9(1) = 21\,. \end{aligned}$$

- Como $Z = D = 21$, pode-se afirmar que as duas soluções são ótimas para o primal e dual.

Teorema da folga complementar

Seja o problema primal representado pelo quadro inicial:

		x_1	x_2	$\cdots$	x_n	x_{n+1}	x_{n+2}	$\cdots$	x_{n+m}	**b**
$L_0^{(0)}$	Z	$-c_1$	$-c_2$	$\cdots$	$-c_n$	0	0	$\cdots$	0	0
$L_1^{(0)}$	x_{n+1}	a_{11}	a_{12}	$\cdots$	a_{1n}	1	0	$\cdots$	0	b_1
$L_2^{(0)}$	x_{n+2}	a_{21}	a_{22}	$\cdots$	a_{2n}	0	1	$\cdots$	0	b_2
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\ddots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	0	$\vdots$
$L_m^{(0)}$	x_{n+m}	a_{m1}	a_{m2}	$\cdots$	a_{mn}	0	0	$\cdots$	1	b_m

x_j, $j = 1, \ldots, n$: variáveis de decisão primais;
x_{n+i}, $i = 1, \ldots, m$: variáveis de folga do primal.

No caso do dual:
y_i, $i = 1, \ldots, m$: variáveis de decisão duais.
y_{m+j}, $j = 1, \ldots, n$: variáveis de folga do dual.
No quadro ótimo:

		x_1 x_2 $\ldots$ x_n	x_{n+1} x_{n+2} $\ldots$ x_{n+m}	**b**
$L_0^{(p)}$	Z	$\bar{c}_j = p_j - c_j$	$\bar{c}_{n+i} = p_{n+i}$	

- O *valor ótimo* da variável dual y_i corresponde ao coeficiente na linha L_0 ótima associado à variável de folga x_{n+i} do primal:

$$y_i^* = p_{n+i}, \quad i = 1, \ldots, m.$$

- O valor ótimo da variável de folga dual y_{m+j} corresponde ao coeficiente na linha L_0 ótima da variável x_j do primal:

$$y_{m+j}^* = p_j - c_j, \quad j = 1, \ldots, n.$$

Uma vez que o *dual do dual* é o próprio problema primal, pode-se determinar a solução do primal a partir da solução do dual.

13.2 Exercícios

1. Usando dualidade, determine a solução do problema

$$\min f(x_1, x_2) = 65x_1 + 30x_2$$

sujeito a

$$\begin{aligned} 2x_1 + 3x_2 &\geq 7 \\ 3x_1 + 2x_2 &\geq 9 \\ x_1 &\geq 1 \\ x_1 \geq 0,\ x_2 &\geq 0\,. \end{aligned}$$

2. Dado o problema:

$$\min C = 4x_1 + 6x_2 + 5x_3$$

sujeito a

$$
\begin{gathered}
2x_1 + 4x_2 + 3x_3 \geq 7/2 \\
x_1 + 2x_2 + 4x_3 \geq 2 \\
x_1 + x_2 + x_3 = 1 \\
x_1,\, x_2,\, x_3 \geq 0\,.
\end{gathered}
$$

(a) Encontre o seu dual.

(b) Resolva o dual, de forma a se determinar a solução do problema original.

3. Dado o problema:

$$\min C = 35x_a + 30x_b$$

sujeito a

$$
\begin{gathered}
0,3x_a + 0,3x_b \geq 900\,000 \\
0,2x_a + 0,4x_b \geq 800\,000 \\
0,3x_a + 0,2x_b \geq 500\,000 \\
x_a,\, x_b \geq 0\,.
\end{gathered}
$$

(a) Encontre o seu dual.

(b) Resolva o dual, de forma a se determinar a solução do problema original.

4. Refaça os exercícios 4, 7 e 9 da seção anterior, usando o modelo dual.

Referências

1. TAHA, H. *Pesquisa operacional*. 8ª. ed. São Paulo: Prentice Hall, 2008.

Os materiais de parte desta seção foram gentilmente cedidos por Paulo H. R. Gabriel (FACOM/UFU)

Adaptações: Renato Pimentel, FACOM/UFU