Agrupamentos Hierárquicos no R

Esse texto é um guia sobre como utilizar o R na implementação do modelo de Agrupamentos Hierárquicos. Antes da apresentação do código que fornece o dendograma construído a partir do processo de aglomerações, faremos uma breve revisão sobre alguns dos conceitos envolvidos nesse modelo. Todos os conjuntos de dados utilizados nesse texto podem ser acessados na pasta Dados da equipe do grupo no Microsoft Teams.

1 Definindo o modelo

Na primeira parte dessa seção, vamos relembrar alguns conceitos do modelo de agrupamentos hierárquicos; na segunda parte apresentamos sua implementação no R.

O objetivo da análise de agrupamentos é reunir as observações de um conjunto de dados em aglomerados de tal forma que as observações de um aglomerado são mais semelhantes entre si em comparação às outras observações dos outros aglomerados. Adotaremos, como medida de semelhança, a medida Euclidiana (mas lembre-se, não existe apenas essa distância; podemos construir esse modelo levando em consideração outras distâncias; tudo dependerá das variáveis envolvidas). Assim, dois pontos são dissimilares se a distância Euclidiana deles é grande; nesse caso, eles pertecerão a aglomerados distintos.

Nossa análise sempre começará pela normalização dos dados, isto é, transformar os dados para uma mesma escala. Isso é feito para que uma variável não gere um desequilíbro no momento do cálculo das distâncias. Essa normalização é feita da seguinte forma: seja x um vetor de observações (uma coluna do seu conjunto de dados); então subtrai-se de cada entrada desse vetor a média de x e em seguida divide-se o resultado pelo desvio padrão de x. Assim, se `x` é dado por `c(1,3,8,5)`, então, no R, podemos normalizá-lo da seguinte forma:

```
x <- c(1, 3, 8, 5)
x_normalizado <- (x - mean(x))/sd(x).
```

O processo de normalização de um vetor pode ser realizado de maneira bem simples no R a partir da função `scale()`. Assim, no exemplo anterior, o leitor pode verificar que `scale(x)` é igual ao vetor normalizado `x_normalizado` que foi calculado acima. Após a normalização das colunas numéricas do conjunto de dados, calculamos as distâncias entre todas as observações. No R, isso será feito utilizando a função `dist()`. Para um conjunto de dados fictí-

cios, suponha que obtemos a seguinte matriz de distâncias:

$$\begin{bmatrix} 0 & 2 & 6 & 10 & 9 \\ 2 & 0 & 5 & 9 & 8 \\ 6 & 5 & 0 & 4 & 5 \\ 10 & 9 & 4 & 0 & 3 \\ 9 & 8 & 5 & 3 & 0 \end{bmatrix}$$

Dessa matriz, podemos afirmar que a distância (a dissimilaridade) entre a primeira e a terceira observações é 6; já a distância entre a quarta e a segunda observaçãoes é 9. A partir dessa matriz, vamos construir os aglomerados até que, no fim do processo, forme-se um único aglomerado com todas as observações. No início do processo, temos 5 aglomerados, pois cada observação é vista como um único aglomerado. Em seguida, identificamos o menor valor da matriz; em nosso exemplo, a menor entrada é 2; esse valor refere-se a distância entre a primeira e a segunda observações. Logo, no primeiro passo, essas duas observações formarão um aglomerado. Começaremos o passo dois com 4 aglomerados. Agora, consideramos todas as distâncias entre os 4 aglomerados restantes. Nesse momento, precisamos definir qual o critério para calcular a distância, por exemplo, entre um aglomerado com uma observação a e um aglomerado com duas observações c, d. Procederemos da seguinte forma: observamos a distância entre a e c e a distância entre a e d; a maior dessas distâncias será definida como a distância entre os dois aglomerados; esse método é chamado de `complete`. Em geral, dados dois aglomerados A e B, então a distância entre esses dois aglomerados através do método `complete` é calculada da seguinte forma: observa-se todas as distâncias possíveis entre uma observação de A e uma observação B; a maior dessas distâncias será a distância entre A e B. Assim, em nosso exemplo, a distância da terceira observação para o aglomerado formado pelas observações 1 e 2 é 6. Existem outros métodos para estabelecer a distância entre dois aglomerados. O método que, ao invés de oolhar para a maior distância entre as observações de dois aglomerados, olha para a menor distância entre os elementos dos aglomerados será chamada de método `single`.

Agora que sabemos como estabelecer a distância entre dois aglomerados, podemos continuar o processo. No passo 2, a menor distância entre aglomerados se dá entre as observações 4 e 5. Logo, essas duas observações passarão a fazer parte do mesmo aglomerado a partir de agora. Restaram 3 aglomerados: um formado pelas observações 1 e 2, um formado pela observação 3; e um formado pelas observações 4 e 5. A distância entre o aglomerado de 1 e 2 para o aglomerado da observação 3 é 6; já a distância entre o aglomerado de 3 e o aglomerado de 4 e 5 é 5. Portanto, no passo 3, o aglomerado 3 se junta ao aglomerado de 3 e 4. Por fim, como só restaram dois aglomerados, eles necessariamente irão se aglomerar no último passo. A Figura 2

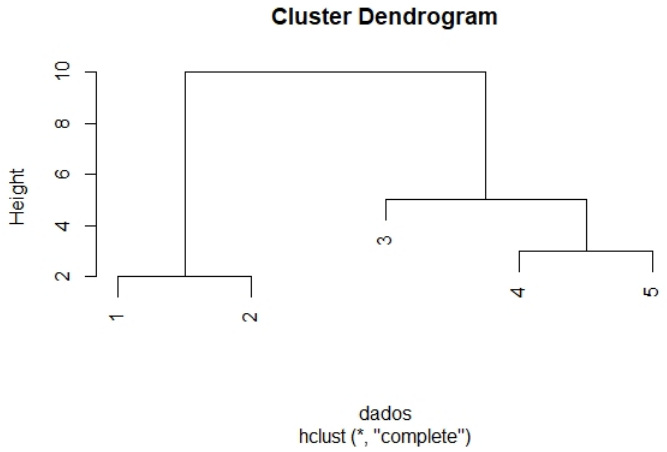


Figura 1: Dendograma obtido através da aglomeração hierárquica pelo método complete de um conjunto de dados fictício que contém 5 observações.

apresenta o dendograma final para esse conjunto de dados utilizando como distância entre aglomerados o método `complete`. Observe que a altura no eixo y refere-se a distância entre dois aglomerados; como exemplo a altura 10 indica que a distância entre o aglomerado 1 e 2 e o aglomerado 3, 4 e 5 é 10. Em resumo, observações que se fundem no começo do processo são bem parecidas, enquanto as observações que se fundem mais próximas do topo da árvore são mais distintas.

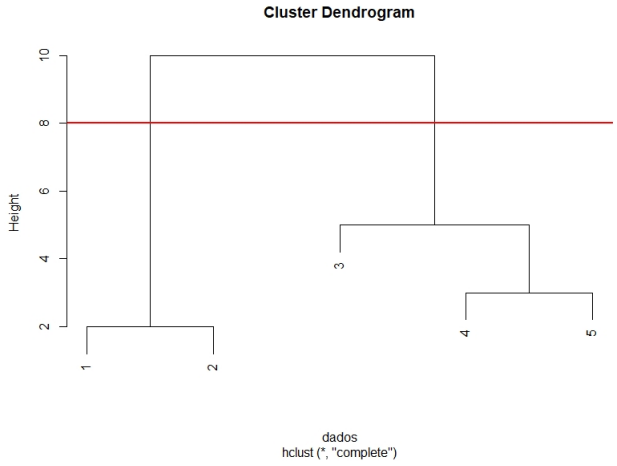


Figura 2: Dendograma com corte na altura $y = 8$.

Um corte na altura $y = 8$, por exemplo, deixaria a árvore separada em dois

ramos, isto é, nos indicaria que, para essa altura, existem dois aglomerados: $\{1, 2\}$ e $\{3, 4, 5\}$.

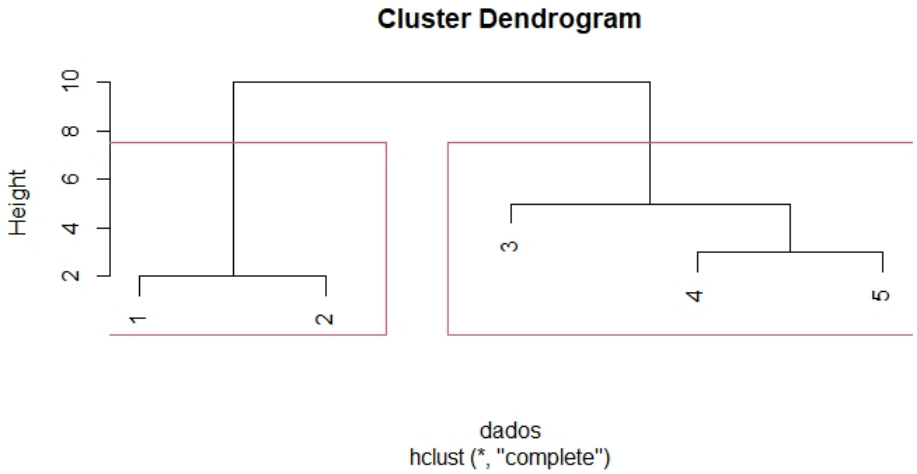


Figura 3: Dois aglomerados. Se o conjunto de dados possui n observações, então pela maneira como o dendograma é construído, é possível obter qualquer número de aglomerados entre 1 e n. Em nossso exemplo, é possível observar, em diferentes alturas, 1, 2, 3, 4 ou 5 aglomerados. A quantidade de aglomerados a ser considerada depende da interpretabilidade do resultado e do problema em estudo.

2 Aglomerados Hierárquicos no R

A seguir, apresentamos o código para impletamentação do algoritmo descrito na Seção 1. Para essa implementação, consideraremos o conjunto de dados do arquivo `protein.txt`. Para construir o agrupamento, usaremos um pequeno conjunto de dados de 1973 sobre o consumo de proteína de nove grupos de alimentos diferentes em 25 países da Europa. O objetivo é agrupar países com base em padrões de consumo de proteínas.

```
#lendo o conjunto de dados
protein <- read.table("protein.txt", sep = "\t", header=TRUE)
summary(protein)

#normalizando o conjunto de dados
matriz_prot <- scale(protein[, 2:10])


#agrupamento hierárquico
matriz_dist <- dist(matriz_prot, method = "euclidean")
```

```
fit1 <- hclust(matriz_dist, method = "ward.D")
plot(fit1, labels = protein$Country)
rect.hclust(fit1, k=5)

#extraindo os aglomerados
aglomerados <- cutree(fit1, k = 5)
protein[aglomerados == 1, c(1,2,6,10)]
protein[aglomerados == 2, c(1,2,6,10)]
protein[aglomerados == 3, c(1,2,6,10)]
protein[aglomerados == 4, c(1,2,6,10)]
protein[aglomerados == 5, c(1,2,6,10)]
```

Decifrando o código: inicialmente lemos o conjunto de dados e o guardamos dentro da variável `protein`. Observe que no argumento `sep` da função `read.table()` utilizamos `"\t"` pois as observações no arquivo .txt estão separadas por um espaço do tipo tabular (tab). A função `scale()` normaliza cada coluna do conjunto, isto é, transforma cada variável para uma mesma escala. Nessa função, consideramos apenas as colunas de 2 até 10; a coluna 1 que apresenta o nome de cada país não é numérica e, portanto, não faz sentido utilizá-la para normalização e posteriormente para o cálculo das distâncias. A função `dist()` calcula a distância entre todas observações. Adotamos como método nessa função a distância Euclidiana. Em nosso curso, sempre adotaremos essse método. As distância obtidas foram salvas dentro da variável `matriz_dist`. Por fim, o dendograma é obtido com a função `hclust()`. O primeiro argumento é dedicado a matriz de distâncias obtidas anteriormente; já o argumento `method` é usado para descrever qual o método de distância entre grupos se está utilizando. Nesse exemplo, estamos adotando o método `ward.D`. No exemplo anterior, adotamos o método do máximo que na função `hclust` seria descrito por `method = "complete"`. Já o método da distância mínima seria descrito por `method = "single"`. Em seguida, plotamos o dendograma a partir da função `plot()`. Cada observação foi *tagueada* pelo nome de seu país. A função `rec.hclust()` exibe no dendograma a quantidade de aglomerados que você deseja dividir a árvore. Em nosso exemplo, queríamos dividir a árvore em 5 aglomerados, por isso utilizamos $k = 5$.

A última parte do código é utilizada para se extrair os aglomerados de `hclust`. Isso é feito com a função `cutree`. Você pode verificar que a saída de `aglomerados será:`

```
> aglomerados
 [1] 1 2 2 1 3 4 3 4 2 5 3 2 5 2 4 3 5 1 5 4 2 2 3 2 1
```

A saída acima informa-nos que o país 1 está no aglomerado 1, que o país 2 está no aglomerado 2, que o país 3 está no aglomerado 3 e assim suces-

sivamente. Caso você queira analisar o consumo de proteínas referente a carne vermelha, ovos e frutas dos países do aglomerado 1, basta utilizar `protein[aglomerados == 1, c(1,2,6,10)]`.

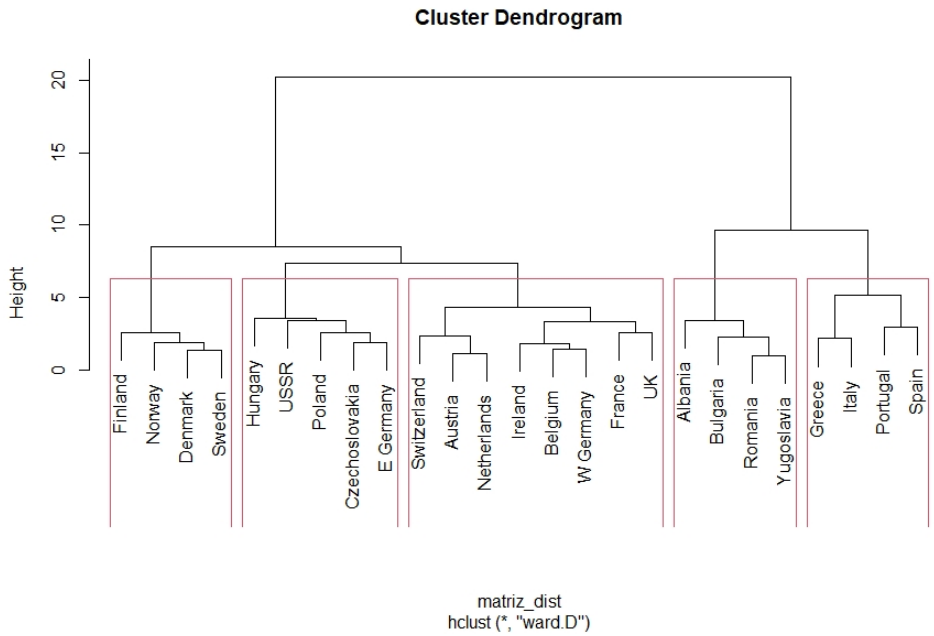


Figura 4: Dendograma dividido em 5 aglomerados.

Considerando ainda a divisão em 5 aglomerados, é possível perceber que há uma certa lógica no agrupamento: os países de cada aglomerado tendem a estar no mesma região geográfica. É plausível admitir que países de uma mesma região possuem hábitos alimentares semelhantes. Você também pode observar que o aglomerado 2 é formado por países com consumo de carne vermelha acima da média; que o aglomerado 4 contém países com consumo de peixe acima da média; e que o aglomerado 5 contém países com alto consumo de peixes e produtos agrícolas.

Exercício 1. Considere o conjunto de dados `USArrests`. Ele já está em sua biblioteca dentro do pacote `datasets`. Visualize esse conjunto de dados e entenda sua estrutura:

```
library(datasets)
USArrests
str(USArrests)
```

Observe que esse conjunto possui 4 variáveis. O nome do estado não é uma variável, apenas o ID de cada observação.

(a) Utilize o método de aglomeração hierárquica com o método `complete` para agrupar os estados.

(b) Corte o dendograma numa altura que resulta em 3 diferentes aglomerados. Quais estados pertencem a cada aglomerado?