Regressão Linear Simples

Esse texto é um guia sobre como utilizar o R na implementação dos modelos de Regressão Linear Simples. As primeiras seções referem-se à Teoria da Regressão Linear Simples. A última seção apresenta as funções do R que podem ser utilizadas para a construção de um modelo de Regressão Linear.

1 Correlação

Suponha que um inspetor de segurança queira determinar se existe relação entre o número de horas de treinamento para um funcionário e o número de acidentes envolvendo este funcionário; ou que um diretor da ONU esteja interessado em investigar se a emissão de CO_2 de um país está relacionado ao seu PIB; ou que um médico pretende determinar se existe uma relação entre idade e pressão sanguínea. Como eles determinariam a existência dessas relações? Nesta aula você estudará como descrever que tipo de relação (ou correlação) existe entre duas variáveis quantitativas e como determinar se a correlação é significativa.

Definição 1. *Uma correlação é uma relação entre duas variáveis. Os dados podem ser representados por pares ordenados* (X, Y)*, sendo* X *a variável independente (ou explanatória) e* Y *a variável dependente (ou resposta).*

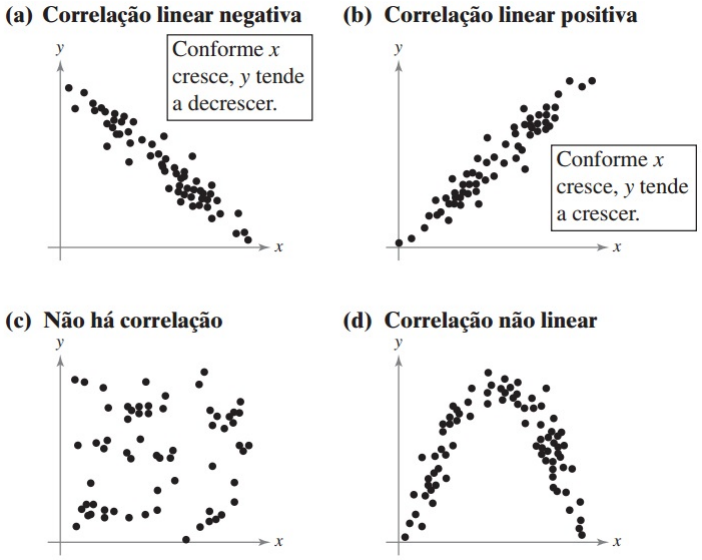


Figura 1: Gráficos indicativos sobre correlação.

O gráfico dos pares ordenados (X, Y) é chamado de diagrama de dispersão. Em um diagrama de dispersão, os pares ordenados (X, Y) são colocados no gráfico como pontos em um plano coordenado. A variável independente

(explanatória) X é indicada no eixo horizontal e a variável dependente (resposta) Y, no eixo vertical. Um diagrama de dispersão pode ser usado para averiguar sobre a existência de uma correlação linear (linha reta) entre duas variáveis. Os diagramas de dispersão da Figura 1 mostram alguns tipos de correlação.

Exemplo 1. Um economista quer determinar se existe relação linear entre o produto interno bruto (PIB) de um país e sua respectiva emissão de dióxido de carbono (CO_2). Os dados encontram-se na Tabela 1. Exiba os dados em um diagrama de dispersão e descreva o tipo de correlação. (*Fonte: World Bank e U.S. Energy Information Administration.*)

PIB (em trilhões de dólares), X	Emissões de CO_2 (em milhões de toneladas métricas), Y
1,7	552,6
1,2	462,3
2,5	475,4
2,8	374,3
3,6	748,5
2,2	400,9
0,8	253,0
1,5	318,6
2,4	496,8
5,9	1.180,6

Tabela 1: Dados do PIB e da quantidade de CO_2 emitida de 10 países.

O diagrama de dispersão é mostrado na Figura 2. A partir deste diagrama, parece que existe uma correlação linear positiva entre as variáveis.

Interpretação: observando o gráfico da esquerda para a direita, verifica-se que, conforme o produto interno bruto cresce, as emissões de dióxido de carbono também tendem a crescer.

Exemplo 2. Um estudante conduz um estudo para determinar se existe uma relação linear entre o número de horas que um aluno faz exercícios a cada semana e o seu coeficiente de rendimento (CR). Os dados são mostrados na Tabela 2. Exiba os pontos em um diagrama de dispersão e descreva o tipo de correlação.

O diagrama de dispersão é mostrado na Figura 3. Nele, parece que não

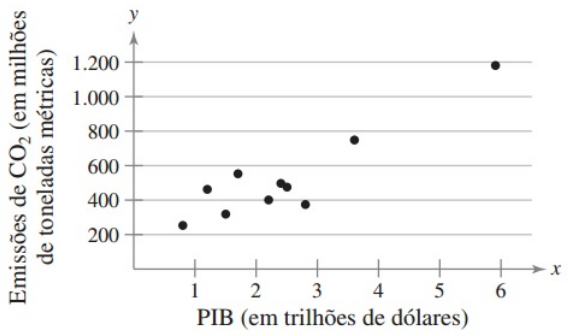


Figura 2: Relação entre PIB e a quantidade de CO_2 emitida para uma amostra com 10 países.

Horas de exercício, X	12	3	0	6	10	2	18	14	15	5
CR, Y	3,6	4,0	3,9	2,5	2,4	2,2	3,7	3,0	1,8	3,1

Tabela 2: Horas semanais de exercícios e os correspondentes coeficientes de rendimento de um aluno.

existe uma correlação linear entre as variáveis.

Interpretação: o número de horas que um estudante faz exercícios a cada semana não parecer estar relacionado ao seu coeficiente de rendimento.

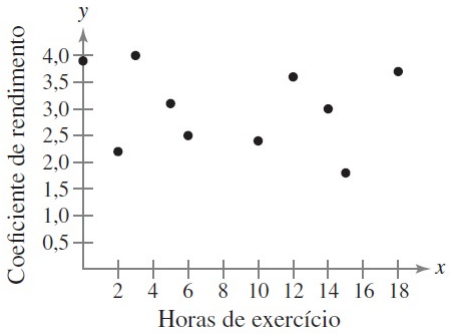


Figura 3: Relação entre o tempo dedicado a exercícios e o rendimento de um aluno

2 Coeficiente de correlação linear

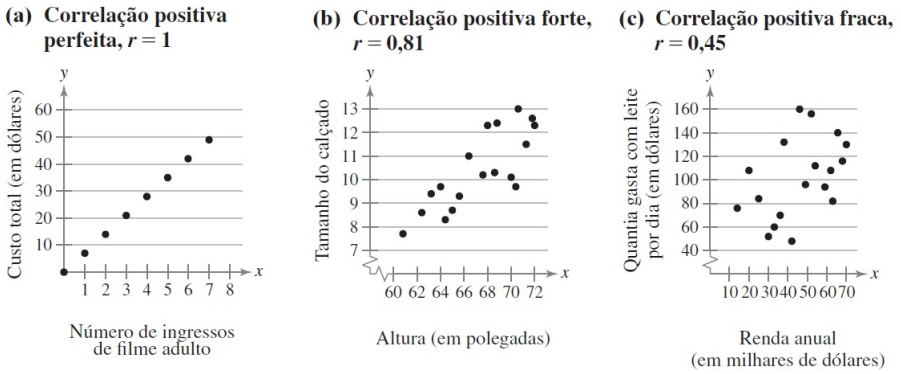
Interpretar a correlação usando um diagrama de dispersão pode ser subjetivo. Uma maneira adequada de obter a direção e medir a força de uma correlação linear entre duas variáveis é calcular o coeficiente de correlação.

Definição 2. *O coeficiente de correlação é uma medida da força e da direção de uma relação linear entre duas variáveis. O símbolo r representa o coeficiente de correlação amostral. Uma fórmula para r é:*

$$r = \frac{\sum XY - n\overline{X}\ \overline{Y}}{\sqrt{(\sum X^2 - n\overline{X}^2)(\sum Y^2 - n\overline{Y}^2)}}.$$

em que n é o número de pares de dados. O coeficiente de correlação populacional é representado pela letra grega ρ.

A variação do coeficiente de correlação é de –1 a 1, inclusive. Quando X e Y têm uma correlação linear positiva forte, r está próximo de 1. Quando X e Y têm uma correlação linear negativa forte, r está próximo de –1. Quando X e Y têm correlação linear positiva perfeita ou correlação linear negativa perfeita, r é igual a 1 ou –1, respectivamente. Quando não há correlação linear, r está próximo a 0. É importante lembrar que quando r está próximo de 0 não significa que não há relação entre X e Y, significa apenas que não há relação linear. Diversos exemplos são mostrados na Figura 4.



Exemplo 3. Calcule o coeficiente de correlação para os dados do produto interno bruto e da emissão de dióxido de carbono que foram apresentados no Exemplo 1. Interprete o resultado no contexto dos dados.

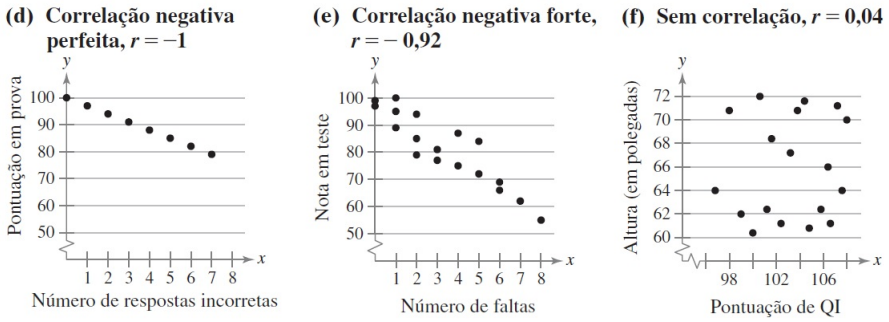


Figura 4: Exemplos de correlações e os respectivos valores do coeficiente r.

Da fórmula do coeficiente de correlação, temos que:

$$\begin{aligned} r &= \frac{\sum XY - n(\overline{X})(\overline{Y})}{\sqrt{(\sum X^2 - n\overline{X}^2)(\sum Y^2 - n\overline{Y}^2)}} \\ &= \frac{16.145,46 - 10 \times 2,46 \times 526,3}{\sqrt{(79,68 - 10(2,46)^2)(3.412.308,32 - 10(526,3)^2)}} \approx 0,912. \end{aligned}$$

O resultado $r \approx 0,912$ sugere uma correlação linear positiva forte. Interpretação Conforme o produto interno bruto do país aumenta, as emissões de dióxido de carbono tendem a aumentar.

3 Correlação e causalidade

O fato de duas variáveis serem fortemente correlacionadas não implica, em si, numa relação de causa e efeito entre elas. Um estudo mais profundo é usualmente necessário para determinar se há uma relação causal entre as variáveis. Quando há uma correlação significativa entre duas variáveis, um pesquisador deve considerar as seguintes possibilidades.

1. Há uma relação direta de causa e efeito entre as variáveis? Ou seja, X causa Y? Por exemplo, considere a relação entre o produto interno bruto e as emissões de dióxido de carbono que foi discutida ao longo desta seção. É razoável concluir que um aumento no produto interno bruto de um país resultará em maiores emissões de dióxido de carbono.

2. Há uma relação reversa de causa e efeito entre as variáveis? Ou seja, Y causa X? Como exemplo, considere o seguinte problema.

O Old Faithful, localizado no Parque Nacional Yellowstone nos Estados Unidos, é o gêiser mais famoso do mundo. A duração (em minutos) de diversas erupções do Old Faithful e os intervalos (em minutos) até que a próxima erupção ocorra são mostrados na Tabela 3.

Duração, X	1,80	1,82	1,90	1,93	1,98	2,05	2,13	2,30	2,37
Intervalos, Y	56	58	62	56	57	57	60	57	61

Duração, X	2,82	3,13	3,27	3,65	3,78	3,83	3,88	4,10	4,27
Intervalos, Y	73	76	77	77	79	85	80	89	90

Duração, X	4,30	4,43	4,47	4,53	4,55	4,60	4,63
Intervalos, Y	89	89	86	89	86	92	91

Tabela 3: Duração de erupções e intervalos entre erupções do Old Faithful.

O gráfico de dispersão entre a duração X e o tempo Y está representado na figura a seguir.

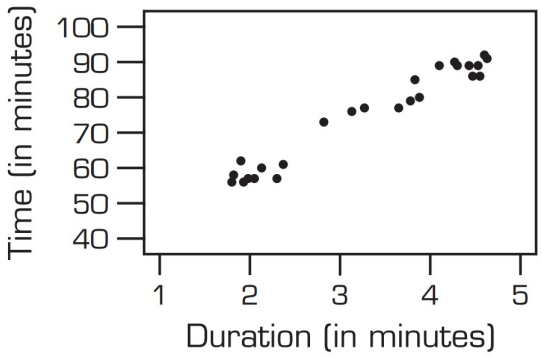


Figura 5: Relação entre os tempos de erupção e os tempos de duração até a próxima erupção.

As variáveis X e Y possuem uma correlação linear positiva e é possível concluir que a duração de uma erupção afeta o tempo antes da próxima erupção. Entretanto, também é possível que o tempo entre as erupções afete a duração da próxima erupção.

3. É possível que a relação entre as variáveis possa ser causada por uma terceira variável ou talvez pela combinação de diversas outras variáveis? Por exemplo, considere os salários e a média de público por jogo em casa para os times na Major League Baseball. Os dados podem ser vistos no gráfico de dispersão da Figura 6. Embora essas variáveis tenham uma correlação linear positiva, podemos duvidar de que só porque o salário de um time decresce, a média de público por jogo em casa também decrescerá. A relação é devida, provavelmente, a outras variáveis, como: a economia, os jogadores no time e se o time está ou não ganhando partidas. Variáveis que têm um efeito nas variáveis em estudo, mas que não estão incluídas no estudo, são chamadas de variáveis omitidas.

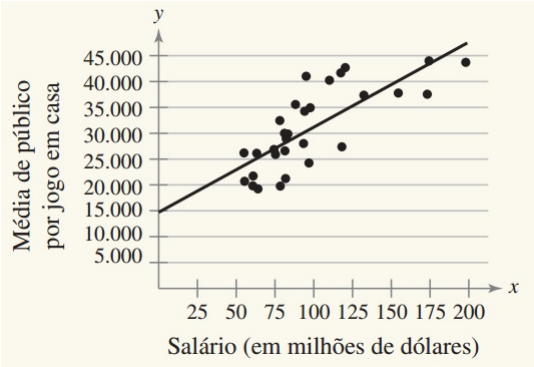


Figura 6: Major League Baseball: média de público por jogo em casa e salário por equipe.

4. É possível que a relação entre duas variáveis seja uma coincidência? Por exemplo, embora seja possível encontrar uma correlação significativa entre o número de espécies de animais que vivem em certas regiões e o número de pessoas que têm mais de dois carros nas mesmas regiões, é altamente improvável que exista entre as variáveis alguma relação de causalidade. A relação provavelmente é uma coincidência, também conhecida por correlação espúria.

Determinar qual dos casos destacados é válido (como uma relação de causa e efeito) para um conjunto de dados pode ser difícil. Por exemplo, considere o seguinte: uma pessoa sofre erupções na pele após comer camarão em um certo restaurante. Isso ocorre toda vez que a pessoa come camarão no restaurante. A conclusão natural é que a pessoa é alérgica a camarão. Entretanto, depois da avaliação de um alergista, descobre-se que essa pessoa não é alérgica a camarão, mas ao tipo de tempero usado no camarão pelo chef.

4 Determinando a melhor reta

Após verificar que a correlação linear entre duas variáveis é significativa, o próximo passo é determinar a equação da reta que melhor modela os dados. Essa reta é chamada de reta de regressão e sua equação pode ser usada para predizer os valores de Y para um dado valor de X. Embora muitas retas possam ser desenhadas por meio de um conjunto de pontos, uma reta de regressão é determinada por critérios específicos. Considere o diagrama de dispersão e a reta mostrados na Figura 7. Para cada ponto, d_i representa a diferença entre o valor observado de Y e o valor previsto de Y para um dado valor de X. Essas diferenças são chamadas de resíduos e podem ser positivas, negativas ou zero. Quando o ponto está acima da reta, d_i é positivo. Quando o ponto está abaixo da reta, d_i é negativo. Quando o valor observado de Y é igual ao valor previsto de Y, $d_i = 0$. De todas as retas possíveis que podem ser desenhadas através de um conjunto de pontos, a reta de regressão é a reta para a qual a soma dos quadrados de todos os resíduos é mínima, isto é, será a reta para o qual a seguinte soma

$$\sum d_i^2 = \text{soma dos quadrados dos resíduos.}$$

possui o menor valor comparado a todos os valores das outras retas.

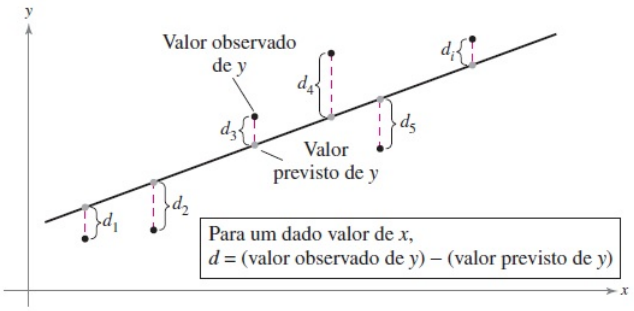


Figura 7: Diagrama de dispersão, reta de regressão e os desvios.

Definição 3. *Uma reta de regressão, também chamada de reta de melhor ajuste, é a reta para a qual a soma dos quadrados dos resíduos é mínima.*

Em álgebra, você aprendeu que é possível escrever a equação de uma reta encontrando sua inclinação m e o intercepto em y, b. A equação tem a forma:

$$y = mx + b.$$

Lembre-se de que a inclinação de uma reta é a razão da variação de y sobre a variação de x e o intercepto no eixo y é o valor de y no ponto em que a

reta cruza esse eixo. Isto é, o valor de y quando $x = 0$. Por exemplo, o gráfico de $y = 2x + 1$ é mostrado na Figura 8. A inclinação da reta é 2 e o intercepto em y é 1.

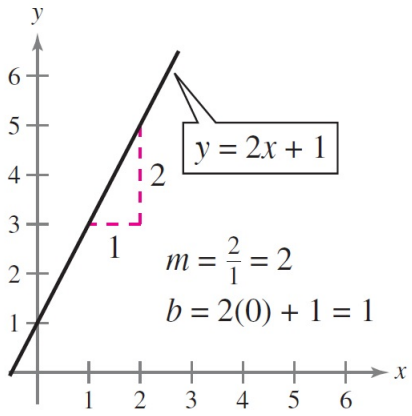


Figura 8: Representação gráfica de uma reta, sua inclinação e interseção com o eixo y.

Em álgebra, você usava dois pontos para determinar a equação de uma reta. Em estatística, você vai usar todos pontos do conjunto de dados para determinar a equação da reta de regressão. A equação de uma reta de regressão permite que você use a variável independente (explanatória) X para fazer previsões para a variável dependente (resposta) Y.

Teorema 4. *A equação de uma reta de regressão para uma variável independente X e uma variável dependente Y é:*

$$\hat{Y} = mX + b$$

em que $\hat{Y}$ é o valor previsto de Y para um dado valor de X. A inclinação m e o intercepto em Y, b, são dados por:

$$\begin{aligned} m &= \frac{n\sum_{i=1}^{n} x_i y_i - \left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right)}{n\sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i\right)^2}. \\ b &= \overline{y} - m\overline{x}, \end{aligned}$$

em que $\overline{y}$ é a média dos valores de Y no conjunto de dados, $\overline{x}$ é a média dos valores de X e n é o número de pares de dados. A reta de regressão sempre passa pelo ponto $(\overline{x}, \overline{y})$.

Exemplo 4. Determinaremos a equação da reta de regressão para os dados do produto interno bruto e emissão de dióxido de carbono apresentados Tabela 1.

Para este conjunto de dados, temos que $n = 10$ e:

$$\sum_{i=1}^{10} x_i = 24,6; \quad \sum_{i=1}^{10} y_i = 5263;$$

$$\sum_{i=1}^{10} x_i y_i = 16145,46; \quad \sum_{i=1}^{10} x_i^2 = 79,68.$$

A partir desses valores, a inclinação m da reta de regressão será:

$$\begin{aligned} m &= \frac{n\sum_{i=1}^{n} x_i y_i - \left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right)}{n\sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i\right)^2} \\ &= \frac{10(16145,46) - (24,6)(5263)}{10(79,68) - (24,6)^2} = 166,900 \end{aligned}$$

e seu intercepto em Y, b, será

$$b = \overline{y} - m\overline{x} = \frac{5263}{10} - (166,900)\left(\frac{24,6}{10}\right) = 115,725.$$

Desse modo, a equação da reta de regressão será

$$\hat{y} = 166,900x + 115,725. \tag{1}$$

A reta de regressão e o diagrama de dispersão dos dados são apresentados na figura a seguir. Note que a reta passa pelo ponto $(\overline{X}, \overline{Y}) = (2,46; 526,3)$.

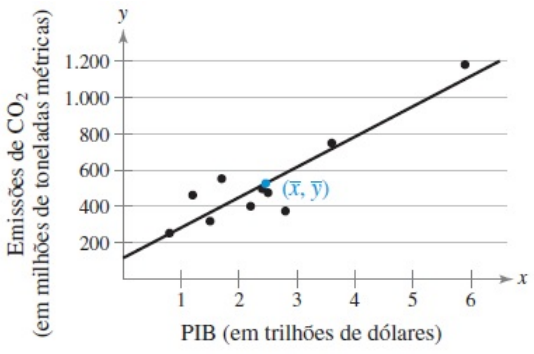


Figura 9: Relação entre PIB e emissões deCO_2: diagrama de dispersão e a reta de regressão.

Para finalizar este exemplo, vamos interpretar o significado das constantes m e b na reta de regressão $\hat{y} = mx + b$. Para este exemplo, da Equação (1), sabemos que $m = 166,900$ e que $b = 115,725$.

Vamos iniciar nossa interpretação pelo valor de b. Observe que para $X = 0$ (o que é um resultado estranho, visto que é razoável considerar que todo país tenha um PIB diferente de zero) temos que $\hat{Y} = 115,725$, isto é, um país que possui PIB igual a zero tem uma emissão de CO_2 de 115,725 milhões de toneladas métricas. Em resumo, para interpretar o valor de b igualamos $X = 0$. Deve-se ressaltar que nem sempre este valor será interpretável a partir de $X = 0$ visto que a taxa de variação da variável explanatória X de alguns dados nem sempre admitirá $X = 0$.

Por outro lado, o valor da inclinação sempre terá uma interpretação que está relacionada a taxa de variação da variável resposta Y. Para isto, neste exemplo, considere que um certo país tenha um PIB igual a x_0. Logo, a partir da Equação (1), esperamos que ele emita $166,90x_0 + 115,725$ milhões de toneladas métricas de dióxido de carbono. Um aumento de uma unidade de trilhão de seu PIB produzirá uma emissão em milhões de toneladas métricas de dióxido de carbono de

$$166,900(x_0 + 1) + 115,725 = (166,900x_0 + 115,725) + 166,900.$$

Portanto a variação desse aumento de uma unidade de trilhão de seu PIB produzirá uma variação na emissão de $C0_2$ de

$$[(166,900x_0 + 115,725) + 166,900] - [166,90x_0 + 115,725] = 166,900,$$

que é justamente o valor da inclinação da reta. Em resumo, a taxa de variação de uma unidade na variável explanatória produz uma variação de 166,900 unidades na variável resposta. Traduzindo para nosso exemplo, um aumento de 1 trilhão de dólares produzirá um aumento de emissão de 166,900 milhões de toneladas métricas de dióxido de carbono.

5 Aplicações das retas de regressão

Quando a correlação linear entre X e Y é significativa, a equação de uma reta de regressão pode ser usada para prever valores de Y para certos valores de X. Os valores previstos têm sentido somente para os valores de X pertencentes ao (ou próximo do) intervalo dos valores observados. Ilustrando, no Exemplo 1, os valores observados de X no conjunto variam de US\$0,8 trilhão a US\$5,9 trilhões. Então, não seria apropriado usar a equação de regressão

encontrada no Exemplo 1 para prever emissões de dióxido de carbono para um produto interno bruto como US$0,2 trilhão ou US$14,5 trilhões.

Para prever valores de Y, substitua um valor de X na equação de regressão e então calcule $\hat{Y}$, o valor previsto de Y. Esse processo é mostrado no próximo exemplo.

Exemplo 5. A equação de regressão para os dados do produto interno bruto (em trilhões de dólares) e as emissões de dióxido de carbono (em milhões de toneladas métricas) é:

$$\hat{y} = 166,900x + 115,725.$$

Use essa equação para prever as emissões de dióxido de carbono esperadas para um produto interno bruto de (a) US$1,2 trilhão e para um produto interno bruto de (b) US$2,0 trilhões.

Solução: Já sabemos que X e Y possuem correlação linear significativa. Então, podemos usar a equação de regressão para prever valores de Y. Note que os valores dados do produto interno bruto estão no intervalo (US$0,8 trilhão a US$5,9 trilhões) de valores observados de X. Para prever as emissões de dióxido de carbono esperadas, substitua cada produto interno bruto por X na equação de regressão. Depois, calcule $\hat{Y}$.

(a) Para um PIB de US$1,2 trilhão:

$$\hat{y} = 166,900x + 115,725 = 166,900 \times 1,2 + 115,725 = 316,005.$$

Interpretação: quando o produto interno bruto é 1,2 trilhão, as emissões de CO_2 previstas são de 316,005 milhões de toneladas métricas.

(b) Para um PIB de US$2,0 trilhões:

$$\hat{y} = 166,900x + 115,725 = 166,900 \times 2,0 + 115,725 = 449,525.$$

Interpretação: quando o produto interno bruto é 2,0 trilhões, as emissões de CO_2 previstas são de 449,525 milhões de toneladas métricas.

6 O coeficiente de determinação

Nesta seção, você vai estudar uma medida usada nos estudos de correlação e regressão. Antes de estudar este conceito, você precisa entender os três tipos de variação em torno de uma reta de regressão.

Para encontrar a variação total, a variação explicada e a variação não explicada em torno de uma reta de regressão, você deve primeiro calcular o desvio total, o desvio explicado e o desvio não explicado para cada par ordenado (x_i, y_i) em um conjunto de dados. Esses desvios são mostrados na Figura 10.

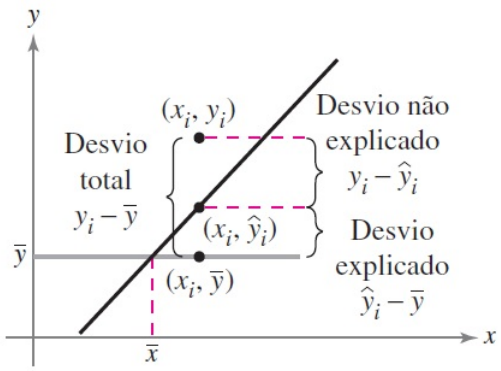


Figura 10: Representação dos tipos de desvios relativos a um ponto genérico.

Definição 5. *A **variação total** em torno de uma reta de regressão é a soma dos quadrados das diferenças entre o valor de Y em cada par ordenado e a média de Y.*

$$Variação\ Total = \sum_{i=1}^{n} (y_i - \overline{y})^2.$$

*A **variação explicada** é a soma dos quadrados das diferenças entre cada valor de Y previsto e a média de Y.*

$$Variação\ Explicada = \sum_{i=1}^{n} (\hat{y}_i - \overline{y})^2.$$

*A **variação não explicada** é a soma dos quadrados das diferenças entre o valor de Y em cada par ordenado e cada valor correspondente de Y previsto.*

$$Variação\ Não\ Explicada = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

A soma das variações explicadas e não explicadas é igual à variação total.

$$Variação\ Total = Variação\ Explicada + Variação\ Não\ Explicada.$$

Como seu nome indica, a variação explicada pode ser explicada pelo modelo linear que relaciona X e Y. A variação não explicada é aquela não explicada por esse modelo, e é devida a outros fatores, tais como erro amostral, coincidência, variáveis omitidas ou outras variáveis.

Você já sabe como calcular o coeficiente de correlação r. O quadrado desse coeficiente é chamado de coeficiente de determinação. Podemos verificar a seguir que o coeficiente de determinação é igual à razão entre a variação explicada e a variação total.

Definição 6. *O coeficiente de determinação r^2 é a razão entre a variação explicada e a variação total. Isto é,*

$$r^2 = \frac{\textit{variação explicada}}{\textit{variação total}}.$$

É importante interpretar o coeficiente de determinação corretamente. Por exemplo, se o coeficiente de correlação é $r = 0,900$, então o coeficiente de determinação é

$$r^2 = (0,900)^2 = 0,810.$$

Isso significa que 81% da variação em Y pode ser explicada pelo modelo que relaciona X e Y. Os restantes 19% da variação não são explicados e são consequência de outros fatores, como erro amostral, ou variáveis não consideradas.

Exemplo 6. O coeficiente de correlação para os dados do produto interno bruto e das emissões de dióxido de carbono é $r = 0,912$. Determine o coeficiente de determinação. O que isso lhe diz sobre a variação explicada dos dados em torno da reta de regressão? E sobre a variação não explicada?

Solução: o coeficiente de determinação é:

$$r^2 = (0,912)^2 = 0,832.$$

Interpretação: cerca de 83,2% da variação nas emissões de dióxido de carbono pode ser explicada pela equação de regressão em função do produto interno bruto. Os restantes 16,8% da variação são a parte não explicada e consequência de outros fatores, tais como erro amostral, e outras variáveis não consideradas.

7 Análise de Regressão Simples no R

Considere os dados presentes no arquivo `grilo.txt`. Os dados mostram a relação entre os chilros por minuto de um grilo e a temperatura do solo correspondente.

```
grilo <- read.table("grilo.txt", sep = ",", header = TRUE)
str(grilo) #conhecendo o conjunto de dados
summary(grilo) #algumas estátisticas sobre os dados
```

A função `read.table()` lê os dados do arquivo `grilo.txt`; esse é o primeiro argumento da função. O argumento `sep` é para identificar qual o elemento separa as observações. Nesse caso, as observações estão separadas por uma vírgula, daí `sep = ","`. Um outro tipo de separador é o espaço tabular dado pela tecla `tab`. Quando esse for o separador, deverá ser `sep = "\t"`.

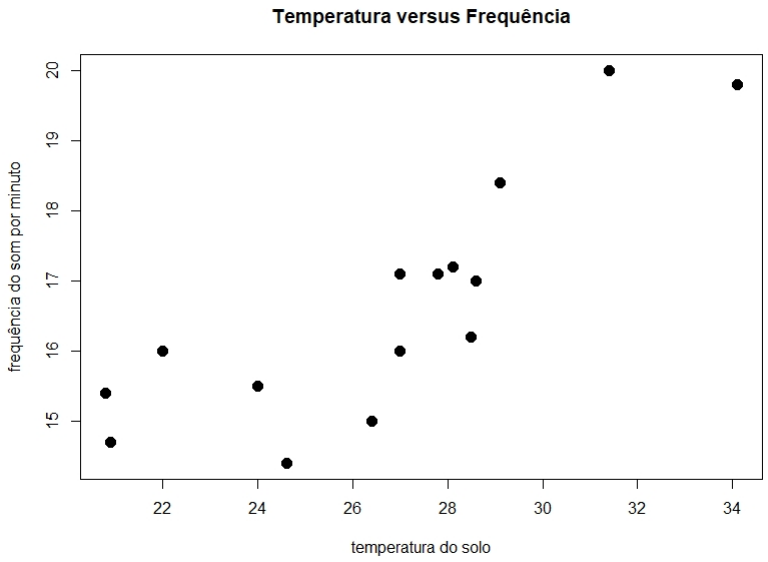


Figura 11: Gráfico de temperatura versus frequência.

A seguir, o comando que fornece o gráfico da temperatura versus frequência e o comando que fornece o coeficiente de correlação entre essas duas variáveis:

```
plot(grilo$temperatura, grilo$frequencia, pch = 16,
     xlab = "temperatura do solo",
     ylab = "frequência do som por minuto",
     main = "Temperatura versus Frequência", cex = 1.5)

cor(grilo$temperatura, grilo$frequencia)
```

O gráfico da Figura 1 conjuntamente com o coeficiente de correlação obtido (aproxidamente 0.836 ou 83,6%) fornecem indícios de que há uma relação linear forte e positiva entre as variáveis envolvidas. A partir desses indícios, vamos estimar a reta de regressão para os dados de temperatura (variável explanatória, x) e frequência (variável resposta, y):

```
> fit <- lm(grilo$frequencia ~ grilo$temperatura)
> fit

Call:
lm(formula = grilo$frequencia ~ grilo$temperatura)

Coefficients:
      (Intercept)  grilo$temperatura
           6.4812             0.3812
```

A partir dos coeficientes de `fit`, temos que a reta de regressão para os dados de temperatura e frequência é dada por:

$$\hat{y} = 0.3812 * x + 6.4812,$$

isto é,

$$frequência = 0.3812 * temperatura + 6.4812.$$

A reta acima nos diz que uma variação de 1 grau Celsius produz uma variação de 0.3812 na frequência emitida pelo grilo! Podemos utilizar a reta de regressão também para fazer previsões (nessa parte é importante conhecer a variação dos valores da variável x; não se pode fazer previsões para valores que estejam fora do domínio de variação de x). Assim, para um temperatura do solo de 25.3 graus Celsius, espera-se que, em média, um grilo emita 16, 13 chilros por minuto (frequência), pois para $x = 25.3$, tem-se que

$$frequência = 0.3812 * temperatura + 6.4812 = 0.3812 * 25.3 + 6.4812 = 16.13.$$

Por fim, vamos analisar o coeficiente de determinação do modelo. Esse coeficiente, denotado por r^2, é exatamente o quadrado do coefieciente de correlação. Logo,

$$r^2 = 0.836^2 = 0.699.$$

Assim, cerca de 70% da variação das frequências emitidas por essa espécie de grilo pode ser explicada pela equação da reta de regressão linear simples em função da temperatura do solo. Os 30% restantes da variação são a parte não explicada pelo modelo.