SEGUNDA PROVA DE ESTATÍSTICA COMPUTACIONAL - 23/03/2022

Questão 1. Uma urna contém: 2 bolas vermelhas, 3 amarelas, 4 verdes, 5 azuis e 7 pretas. Todas as bolas são iguais. Uma bola será retirada da urna. Seja X a variável que registra a cor da bola sorteada. Assim, sabemos que: $P(X = \text{vermelha}) = 2/21$, $P(X = \text{ amarela}) = 3/21$, $P(X = \text{ verde}) = 4/21$, $P(X = \text{azul}) = 5/21$, $P(X = \text{ preta}) = 7/21$.

(a) Vamos sortear n bolas com reposição, isto é, sortea-se a primeira bola, registra-se sua cor e em seguida devolvemos a bola para urna. Depois, sorteamos a segunda bola e repetimos o que foi feito no passo anterior e procedemos assim até o sorteio da n-ésima bola. Crie uma função que tem como entrada o argumento n e que retorne um vetor de tamanho n com as cores das n bolas sorteadas. Para a função, utilize a técnica de simulação de variáveis a partir da distribuição uniforme.

(b) Bolas serão sorteadas até que se obtenha uma vermelha e uma amarela. O número de bolas sorteadas será registrado. Exemplo: se a sequência de sorteios foi preta, preta, amarela, azul, preta, vermelha então o resultado do experimento será 6. Utilize a função criada em (a) e o Método de Monte Carlo para estimar a média do número bolas retiradas até se retirar uma vermelha e uma amarela.

Questão 2. Na Estação Antártica Palmer, pesquisadores fizeram medições em três espécies diferentes de pinguins: Adélie, Chinstrap e Gentoo. Os dados obtidos estão no arquivo **pinguim.csv**. O conjunto possui 7 variáveis: sexo, espécie, ilha onde o pinguim habita, peso em gramas (`body_mass_g`), tamanho da asa em milímetros (`flipper_length_mm`), tamanho da crista dorsal do bico em milímetros (`culmen_length_mm`) e profundidade da crista dorsal do bico em milímetros (`culmen_depth_mm`).

(a) Divida o conjunto de dados em dois outros conjuntos: um contendo apenas os machos e outro contendo apenas as fêmeas.

(b) A partir do conjunto que contém apenas os machos, use o modelo de aglomerados hierárquicos com o método ward.D2 para agrupar os pinguins. Em seguida, plote o dendograma referente ao modelo criado.

(c) A partir da análise do gráfico plotado em (a), em qual altura você cortaria o dendograma? Justifique sua resposta. Quantos aglomerados resultaram do corte? Identifique a proporção de cada espécie dentro de cada aglomerado. Comente os resultados obtidos.

(d) O conjunto referente às fêmeas foi dividido em dois conjuntos: um para treinamento (`treino.csv`) e um para teste (`teste.csv`). Use o conjunto de treinamento para criar uma árvore de decisão para classificar os pinguins de acordo com suas espécies. Em seguida, plote a árvore de decisão.

(e) A partir da árvore de decisão obtida em (d), crie uma função cuja entrada seja um vetor contendo o peso em gramas (`body_mass_g`), tamanho da asa em milímetros (`flipper_length_mm`), tamanho da crista dorsal do bico em milímetros (`culmen_length_mm`) e profundidade da crista dorsal do bico em milímetros (`culmen_depth_mm`) de um pinguim e que retorne a espécie do pinguim. Para esta questão, não utilize a função `predict`; utilize uma estrutura condicional if-else.

(f) Calcule a sua taxa de acerto para o modelo construído em (f) utilizando nesse cálculo o conjunto de teste. Em seguida, construa a matriz de confusão e, por fim, comente os resultados encontrados.