Matrizes e Data Frames

Na primeira seção, veremos como se dá a construção de uma matriz no R. Na segunda seção, estudaremos uma estrutura chamada *data frame*.

1 Matrizes

O exemplo a seguir nos mostra como podemos contruir e manipular uma matriz no R.

Exemplo 1. A função que cria uma matriz em R é `matrix`. Alguns dos argumentos dessa função são: `data` serve para guardar os elementos que serão alocados na matriz; `nrow` indica o número de linhas que a matriz terá; `ncol` indica o número de colunas da matriz; `byrow` indica se a matriz deve ser preenchida a partir das linhas ou das colunas. Vamos criar uma matriz A de dimensão 3×2 (isto é, uma matriz de 3 linhas e 2 colunas) em que as linhas são dadas por $(4, 5), (3, 9)$ e $(7, 2)$:

```
A <- matrix(data = c(4,5,3,9,7,2), ncol = 2, byrow = TRUE)
```

A linha de comando acima gera a seguinte resposta:

```
> A
     [,1] [,2]
[1,]    4    5
[2,]    3    9
[3,]    7    2
```

Observe que não foi preciso utilizar o argumento `nrow`, uma vez que há 2 colunas e o tamanho do vetor em `data` é 6. Logo o número de linhas está definido e só pode ser 3. Observe também que poderíamos criar uma matriz B a partir das colunas (`byrow = FALSE`), isto é:

```
B <- matrix(data = c(4,5,3,9,7,2), ncol = 2, byrow = FALSE)
```

Nesse caso, a matriz B seria diferente de A:

```
> B
     [,1] [,2]
[1,]    4    9
[2,]    5    7
[3,]    3    2
```

O elemento da linha 3 e coluna 1 de A, a primeira linha de A e a segunda coluna de B podem ser acessados, respectivamente, pelos comandos `A[3,1]`, `A[1,]` e `B[,2]`:

```
> A[3,1]
[1] 7
> A[1,]
[1] 4 5
> B[,2]
[1] 9 7 2
```

As funções `cbind` e `rbind` permitem acrescentar, respectivamente, colunas e linhas a uma matriz. Veja:

```
> cbind(A, c(3,1,3))
     [,1] [,2] [,3]
[1,]    4    5    3
[2,]    3    9    1
[3,]    7    2    3
> rbind(B, c(12, 4))
     [,1] [,2]
[1,]    4    9
[2,]    5    7
[3,]    3    2
[4,]   12    4
```

Por fim, deve-se ressaltar que matrizes no R admitem apenas elementos da mesma classe. Assim, por exemplo, se adicionarmos a coluna $c(\text{“}a\text{”}, \text{“}b\text{”}, \text{“}f\text{”})$ à matriz A, então todos os elementos de A serão convertidos para a classe *character*:

```
> cbind(A, c("a", "b", "f"))
     [,1] [,2] [,3]
[1,] "4"  "5"  "a"
[2,] "3"  "9"  "b"
[3,] "7"  "2"  "f"
```

2 Data Frames

Data frames são uma das estruturas mais utilizadas em R para representar um conjunto de dados. As linhas de um *data frame* representam as observações e as colunas representam as variáveis do conjunto de dados. Um *data frame* pode ser visto como uma generalização de uma matriz. Uma matriz em R admite apenas elementos da mesma classe. Por outro lado, um *data frame* admite que suas colunas possam ser constituídas por vetores de diferentes classes.

Exemplo 2. Vamos criar um conjunto de dados a partir da função `data.frame`.

Esse conjunto de dados conterá informações sobre alguns bons filmes, seus diretores e ano de exibição. Veja:

```
dados<- data.frame(filme= c("Blue Valentine","Whiplash",
                            "Baby Driver"),
                   diretor= c("Derek Cianfrance",
                   "Damien Chazelle","Edgar Wright"),
                   ano= c(2011,2015, 2017))
```

O conjunto de dados acima será exibido da seguinte forma:

```
> dados
           filme        diretor  ano
1 Blue Valentine Derek Cianfrance 2011
2        Whiplash   Damien Chazelle 2015
3    Baby Driver     Edgar Wright 2017
```

A maneira de acessar elementos, linhas e colunas de um data.frame se dá da mesma forma de uma matriz. Assim, o elemento (2,3), a linha 3 e a coluna 2 de `dados` podem ser acessados a partir dos seguintes comandos:

```
> dados[2,3]
[1] 2015
> dados[3,]
        filme      diretor  ano
3 Baby Driver Edgar Wright 2017
> dados[,2]
[1] "Derek Cianfrance" "Damien Chazelle"  "Edgar Wright"
```

Também é possível selecionar mais linhas e mais colunas de uma única vez. Como exemplo, as colunas 1 e 3 podem ser acessadas por:

```
dados[,c(1,3)]
```

Uma maneira elegante de selecionar uma coluna é a partir de seu nome. Isto será feito utilizando o símbolo cifrão.

```
> dados$filme
[1] "Blue Valentine" "Whiplash"       "Baby Driver"
```

Exemplo 3. Vamos analisar, nesse exemplo, um conjunto de dados. Para acessá-lo, você precisará instalar o pacote `dslabs`.

```
install.packages("dslabs")
```

Após a instalação, você deve acessar o conjunto de dados `murders` que pertence a esse pacote.

```
library(dslabs)
data(murders)
```

Esse conjunto de dados apresenta 51 observações e 5 variáveis. Cada observação diz respeito a um estado dos EUA. As cinco variáveis são:

- **state**: representa os estados e o distrito federal (Distrito de Columbia) dos Estados Unidos;
- **abb**: sigla dos estados;
- **region**: indica a região do estado, podendo ser Northeast, South, West e North Central;
- **population**: população do estado em 2010;
- **total**: número de mortes provocadas por arma de fogo no estado em 2010.

Uma maneira de verificar a estrutura de um conjunto de dados é utilizando a função `str`. A partir dessa função é possível extrair algumas informações dos dados, como número de observações, número de variáveis e nome das variáveis.

```
> str(murders)
'data.frame':   51 obs. of  5 variables:
 $ state     : chr  "Alabama" "Alaska" "Arizona" ...
 $ abb       : chr  "AL" "AK" "AZ" ...
 $ region    : Factor w/ 4 levels "Northeast","South",...
 $ population: num  4779736 710231 6392017  ...
 $ total     : num  135 19 232 ...
```

Um breve resumo de algumas estatísticas referentes aos dados pode ser obtido através da função `summary`.

```
> summary(murders)
    state               abb
 Length:51          Length:51
 Class :character   Class :character
 Mode  :character   Mode  :character


          region     population
 Northeast     : 9   Min.   :  563626
 South         :17   1st Qu.: 1696962
```

```
North Central:12   Median : 4339367
West          :13   Mean   : 6075769
                    3rd Qu.: 6636084
                    Max.   :37253956
     total
Min.   :   2.0
1st Qu.:  24.5
Median :  97.0
Mean   : 184.4
3rd Qu.: 268.0
Max.   :1257.0
```

Suponha agora que desejamos responder as seguintes perguntas: qual o estado mais violento e qual o estado menos violento em relação a mortes por armas de fogo? Para responder essas perguntas, não podemos apenas olhar para a coluna `total` e extrair dela o maior e menor valor pois a população de cada estado deve ser levada em consideração. Se dois estados A e B tiveram o mesmo número de mortes por armas de fogo mas o estado A possuir uma população maior do que o estado B, então A é mais violento do que B. Portanto, para respondermos a pergunta, iremos criar uma nova variável, chamada `taxa`, que levará em conta o número de mortes por 100 mil habitantes. Dessa forma, todos os estados passam a ser equiparáveis em relação a esta nova variável. Para adicionarmos uma nova variável a um data frame, podemos proceder da seguinte forma:

```
murders$taxa <- murders$total * 100000/murders$population
```

Você pode imprimir as seis primeiras linhas do data frame e verificar, agora, que uma nova coluna foi criada.

```
> head(murders)
       state abb region population total     taxa
1    Alabama  AL  South    4779736   135 2.824424
2     Alaska  AK   West     710231    19 2.675186
3    Arizona  AZ   West    6392017   232 3.629527
4   Arkansas  AR  South    2915918    93 3.189390
5 California  CA   West   37253956  1257 3.374138
6   Colorado  CO   West    5029196    65 1.292453
```

Por fim, basta identificarmos agora as posições do maior e do menor valor do vetor `taxa`. A linha de comando abaixo retornará o estado mais violento.

```
> murders$state[order(taxa)[length(taxa)]]
[1] "District of Columbia"
```

A função `order` aplicada no vetor `taxa` retorna um vetor cuja primeira entrada possui o índice do menor valor do vetor `taxa`, a segunda entrada possui

o índice do segundo menor valor do vetor `taxa` e assim sucessivamente até o índice do maior valor do vetor `taxa`. Assim, `order(taxa)[length(taxa)]` retorna o índice do maior valor de `taxa` e, consequentemente, ao utilizarmos este índice no vetor `murders$state` obteremos o nome do estado mais violento. Para sabermos qual a taxa de mortes por 100 mil habitantes do Distrito de Columbia, podemos proceder assim:

```
> murders$taxa[order(taxa)[length(taxa)]]
[1] 16.45275
```

O estado menos violento e sua taxa de morte podem ser obtidos assim:

```
> murders$state[order(taxa)[1]]
[1] "Vermont"
> murders$taxa[order(taxa)[1]]
[1] 0.3196211
```