GBC053 - Gerenciamento de Bancos de Dados

Aula 7
Indexação

Humberto Razente
humberto.razente@ufu.br

Curso de estruturas de dados

- Vetores, listas, filhas, pilhas
- Análise de algoritmos: empírica, assintótica, notação O, recursão, programação dinâmica
- Vetores: busca linear e busca binária
- Grafos: algoritmos básicos, caminho mínimo
- Árvores binárias, árvores binárias balanceadas
- Hashing
- ...

O que é um índice?

- Conceito básico: chaves e referências
- Permite impor uma ordem em um arquivo sem ter que rearranjar o arquivo
  - com índices, é possível realizar buscas com atributos diferentes em um mesmo arquivo

O que é um índice?

- Considere que se esteja procurando um livro na biblioteca:
  - deseja-se procurar por **autor**, **título** ou **assunto**
  - se houvessem 3 cópias de cada livro, poderia-se ter 1 prateleira ordenada por autor, outra prateleira por título, outra por assunto → 3 arquivos de dados ordenados por atributos diferentes?



Há menos de 3 décadas as buscas em bibliotecas eram assim

Operações requeridas para manter um arquivo de índice

- Criar arquivos de dados e índices
- Carregar o arquivo de índice na memória
- Reescrever o arquivo de índice após usá-lo
- Adicionar registros no arquivo de dados
- Atualizar registros no arquivo de dados
- Remover registros no arquivo de dados
- Atualizar índice para refletir as mudanças nos registros no arquivo de dados

Operações requeridas para manter um arquivo de índice

- Operações devem envolver o uso de buffers
- Deve-se haver um mecanismo para saber se o índice foi alterado
  - para determinar se o índice em disco está desatualizado, e nesse caso, deverá ser reescrito

Índices muito grandes para serem mantidos em memória

- Até agora, assumiu-se que os índices eram pequenos o suficiente para caberem em memória principal
- O acesso a um índice diretamente no disco tem as seguintes desvantagens:
  - uma busca binária envolve vários ***seeks*** no disco
  - um rearranjo no índice por adição ou remoção requer um ***shift*** nos registros do arquivo
- Deve-se considerar:
  - organização ***hash***
  - índice com estrutura em árvore ou multinível

Índices muito grandes para serem mantidos em memória

- Mas antes de descartar o uso de índices simples, deve-se considerar:
  - um índice simples torna possível usar uma busca binária → o índice pode ser uma estrutura com registros de tamanho fixo, mesmo se indexação for de registros de tamanho variável
  - se as entradas do índice forem bem menores que os registros de dados, ordenar e manter o índice pode ser menos caro que ordenar e manter o arquivo de dados

Índexação para prover acessos por múltiplas chaves

- Em geral não se procura na biblioteca pelo livro com número do catálogo QA331T5
  - identificador único é necessário → chave primária
  - procura dá-se por consultas tipo
    - ”procuro um livro sobre estruturas de dados”
    - ”procuro um livro do Donald Knuth”
    - ”procuro um livro de estruturas de dados do Donald Knuth”
  - chaves secundárias: chave que pode levar a nenhuma, uma ou mais chaves primárias

Índexação para prover acessos por múltiplas chaves

Composer index

Secondary key	*Primary key*
BEETHOVEN	ANG3795
BEETHOVEN	DG139201
BEETHOVEN	DG18807
BEETHOVEN	RCA2626
COREA	WAR23699
DVORAK	COL31809
PROKOFIEV	LON2312
RIMSKY-KORSAKOV	MER75016
SPRINGSTEEN	COL38358
SWEET HONEY IN THE R	FF245

- Manutenção de índices secundários deve ser feita
  - inserções de registros no arquivo de dados
  - alterações
  - remoções

Recuperação baseada em combinações de chaves secundárias

- A combinação de duas ou mais chaves secundárias pode ser usada para buscar um subconjunto de registros no arquivo de dados
  - Uso de operadores booleanos AND e OR
    - Intersecções
    - Uniões
  - Possibilita múltiplas perspectivas dos registros

Recuperação baseada em combinações de chaves secundárias

- Exemplo
  - ”encontrar todos os livros de estruturas de dados do Donald Knuth”
    - assunto = ”estruturas de dados”
    - autor = ”Donald Knuth”
    - operador: ”e”
- Envolve o ”casamento” de valores em dois índices

Leitura complementar

- Capítulo ”**Indexing**” do livro
  - Folk et al. ”File Structures: An Object-Oriented Approach with C++”, Editora Pearson, 3ª edição, 1998